

Gram 矩阵

导论

1. 给定向量 $v_1, v_2, \dots, v_n \in \mathbb{R}^d$ ，Gram 矩阵定义为 $G_{ij} = v_i^T v_j$
2. 将这些向量按列排列为 $V = [v_1, v_2, \dots, v_n] \in \mathbb{R}^{d \times n}$ ，则 $G = V^T V$
3. Gram 矩阵一定是对称半正定矩阵 $G^T = G$ ； $a^T G a \geq 0$
4. Gram 矩阵对角线元素是各向量的平方范数 $G_{ii} = \|v_i\|_2^2$
5. 非对角线元素是不同向量之间的内积 $G_{ij} = v_i^T v_j$
6. Gram 矩阵的迹等于特征矩阵的平方能量 $\text{tr}(G) = \|V\|_F^2$
7. Gram 矩阵的秩满足 $\text{rank}(G) = \text{rank}(V)$
8. 若卷积特征为 $F \in \mathbb{R}^{C \times HW}$ ，通道 Gram 矩阵通常写为 $G = FF^T \in \mathbb{R}^{C \times C}$
9. Gram 矩阵不是协方差矩阵，因为它通常没有减去均值。
10. 若先对特征进行中心化，则中心化 Gram 矩阵与协方差矩阵只相差一个归一化系数。
11. 神经风格迁移通常通过匹配生成图像与风格图像的特征 Gram 矩阵来定义风格损失。
12. Gram 矩阵只保留全局二阶统计关系，通常会丢失具体空间排列信息。

给定 n 个 d 维列向量 $v_1, v_2, \dots, v_n \in \mathbb{R}^d$ ，定义 Gram 矩阵 $G \in \mathbb{R}^{n \times n}$ ，其中第 i 行、第 j 列的元素为 $G_{ij} = v_i^T v_j$ ，展开内积 $G_{ij} = \sum_{k=1}^d v_{ki} v_{kj}$

将所有向量按列排列 $V = [v_1, v_2, \dots, v_n]$ ，则 $V \in \mathbb{R}^{d \times n}$ ，矩阵乘积 $V^T V$ 的第 ij 个元素为 $(V^T V)_{ij} = v_i^T v_j$ ，因此 $G = V^T V$

[设有三个二维向量 $v_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$; $v_2 = \begin{bmatrix} 2 \\ 0 \end{bmatrix}$; $v_3 = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$

将它们按列排列 $V = \begin{bmatrix} 1 & 2 & -1 \\ 2 & 0 & 1 \end{bmatrix}$ ，转置为 $V^T = \begin{bmatrix} 1 & 2 \\ 2 & 0 \\ -1 & 1 \end{bmatrix}$

Gram 矩阵为 $G = V^T V$

因此 $G = \begin{bmatrix} 5 & 2 & 1 \\ 2 & 4 & -2 \\ 1 & -2 & 2 \end{bmatrix}$

Gram 矩阵的第 i 个对角线元素为 $G_{ii} = v_i^T v_i$ ，即 $G_{ii} = \sum_{k=1}^d v_{ki}^2$ ，这就是向量平方范数 $G_{ii} = \|v_i\|_2^2$ ，因此，对角线元素描述每个向量的总平方能量。如果 v_i 是一个卷积通道在全部空间位置上的响应，则 G_{ii} 表示该通道在整张特征图上的激活平方和。较大的 G_{ii} 表示该通道在当前输入上的总体激活较强。

对于 $i \neq j$ 有 $G_{ij} = v_i^T v_j$ ，即 $G_{ij} = \sum_{k=1}^d v_{ki} v_{kj}$ ，如果两个向量在相同维度上经常同时具有较大的同号值，则 G_{ij} 往往较大。如果两个向量在相同维度上经常具有相反符号，则 G_{ij} 可能为负。Gram 矩阵中的内积没有对向量进行中心化，因此它同时受到向量均值、长度和共同变化的影响。

由定义 $G = V^T V$ ，取转置 $G^T = (V^T V)^T$

利用矩阵乘积转置公式 $(AB)^T = B^T A^T$ 得到 $G^T = V^T (V^T)^T$

因为 $(V^T)^T = V$ ，所以 $G^T = V^T V$ ，因此 $G^T = G$ ，所以 Gram 矩阵一定是对称矩阵。

任取 $a \in \mathbb{R}^n$ ，考虑二次型 $a^T G a$ ，代入 $G = V^T V$ 得到 $a^T G a = a^T V^T V a$

注意 $a^T V^T = (V a)^T$ ，所以 $a^T G a = (V a)^T (V a)$ ，即 $a^T G a = \|V a\|_2^2$

因为平方范数非负 $\|V a\|_2^2 \geq 0$ ，所以 $a^T G a \geq 0$ ，因此 Gram 矩阵是半正定矩阵。这意味着 Gram 矩阵的所有特征值都大于或等于零。

Gram 矩阵与奇异值

设特征矩阵的奇异值分解为 $V = U \Sigma W^T$ ，则 $G = V^T V$ 代入奇异值分解 $G = W \Sigma^T U^T U \Sigma W^T$ ，由于 $U^T U = I$ ，所以 $G = W \Sigma^T \Sigma W^T$ ，因此 Gram 矩阵的非零特征值等于 V 的非零奇异值的平方。

如果 V 的奇异值为 $\sigma_1, \sigma_2, \dots, \sigma_r$ ，那么 Gram 矩阵的非零特征值为 $\sigma_1^2, \sigma_2^2, \dots, \sigma_r^2$ ，这说明 Gram 矩阵包含特征矩阵在不同主方向上的能量信息。

Gram 矩阵的迹为 $\text{tr}(G) = \sum_{i=1}^n G_{ii}$ ，因为 $G_{ii} = \|v_i\|_2^2$ ，所以 $\text{tr}(G) = \sum_{i=1}^n \|v_i\|_2^2$

而矩阵的 Frobenius 范数定义为 $\|V\|_F^2 = \sum_{i=1}^d \sum_{j=1}^n V_{ij}^2$

因此 $\text{tr}(G) = \|V\|_F^2$ ，也就是说 Gram 矩阵全部特征值之和，等于原特征矩阵全部元素的平方和。

卷积特征图如何构造 Gram 矩阵

设卷积神经网络某一层输出特征为 $\mathcal{F} \in \mathbb{R}^{C \times H \times W}$ ，令 $M = HW$ ，将每个通道展平

为长度为 M 的向量 $f_c \in \mathbb{R}^M$ ，将所有通道按行排列 $F = \begin{bmatrix} f_1^T \\ f_2^T \\ \vdots \\ f_C^T \end{bmatrix} \in \mathbb{R}^{C \times M}$

通道 Gram 矩阵定义为 $G = F F^T$ ，因此 $G \in \mathbb{R}^{C \times C}$ ，其元素为 $G_{ij} = \sum_{p=1}^M F_{ip} F_{jp}$

如果计算 $F^T F$ ，则 $F^T F \in \mathbb{R}^{M \times M}$ ，它描述不同空间位置之间的内积关系。所以 $F F^T$ 为通道—通道关系； $F^T F$ 为位置—位置关系。二者都可以称为 Gram 矩阵，但

表示的对象不同。


卷积特征 Gram 矩阵的含义

通道 Gram 矩阵 $G = FF^T$ ，的第 i, j 个元素为 $G_{ij} = \sum_{p=1}^M F_{ip} F_{jp}$

当 $i=j$ 时， $G_{ii} = \sum_{p=1}^M F_{ip}^2$ ，它表示第 i 个通道的总体激活能量。

当 $i \neq j$ 时， $G_{ij} = \sum_{p=1}^M F_{ip} F_{jp}$ ，它表示第 i 个通道和第 j 个通道在全部空间位置上的未中心化共同响应。

因此，Gram 矩阵可以记录哪些特征通道总体激活较强；哪些特征通道经常共同激活；特征通道之间的全局二阶关系。神经风格迁移的经典方法正是利用多层卷积特征的 Gram 矩阵表示风格统计。（<https://arxiv.org/pdf/1508.06576>）



Gram 矩阵与协方差矩阵的区别

设 $F \in \mathbb{R}^{C \times M}$ 每一列表示一个空间位置的 C 维特征。通道均值向量为 $\mu = \frac{1}{M} F \mathbf{1}$ ，其中 $\mathbf{1} \in \mathbb{R}^M$ ，是元素全为 1 的向量。构造中心化特征 $F_c = F - \mu \mathbf{1}^T$ ，未中心化 Gram 矩阵为 $G = FF^T$ ，中心化 Gram 矩阵为 $G_c = F_c F_c^T$ ，总体形式的经验协方差矩阵为 $\Sigma = \frac{1}{M} F_c F_c^T$ ，所以 $\Sigma = \frac{1}{M} G_c$ ，如果使用无偏样本协方差，则 $S = \frac{1}{M-1} F_c F_c^T$ ，因此协方差矩阵是经过中心化和归一化的 Gram 矩阵。

由 $F = F_c + \mu \mathbf{1}^T$ 得到 $FF^T = (F_c + \mu \mathbf{1}^T)(F_c + \mu \mathbf{1}^T)^T$

展开 $FF^T = F_c F_c^T + F_c \mathbf{1} \mu^T + \mu \mathbf{1}^T F_c^T + M \mu \mu^T$ ，由于中心化后 $F_c \mathbf{1} = 0$ ，所以中间两项为零： $FF^T = F_c F_c^T + M \mu \mu^T$ ，因此 $G = M \Sigma + M \mu \mu^T$ ，这里的 Σ 使用分母 M 。这个公式说明，未中心化 Gram 矩阵同时包含特征的协方差信息；特征均值的外积信息。因此，Gram 矩阵比协方差矩阵多保留了一阶矩信息。

归一化 Gram 矩阵

由于 Gram 矩阵元素是对全部空间位置求和 $G = FF^T$ ，当空间位置数量 M 增大时，其元素通常也会增大。因此实践中常使用归一化形式 $\tilde{G} = \frac{1}{M} FF^T$ ，也可以进一步考虑通道数 $\tilde{G} = \frac{1}{CM} FF^T$ ，不同实现可能使用不同的归一化系数。归一化的主要作用是减少特征图尺寸和通道数量对损失尺度的影响。但需要注意归一化系数不同，会改变损失函数和梯度的数值大小，因此必须与损失权重共同考虑。

Gram 矩阵为什么会丢失空间排列

设 $F \in \mathbb{R}^{C \times M}$ ，并设 $P \in \mathbb{R}^{M \times M}$ 是一个置换矩阵，用于重新排列空间位置。

重新排列后的特征为 $F' = FP$ ，它的 Gram 矩阵为 $G' = F'F'^T$ ，代入 $G' = FPP^T F^T$ ，置换矩阵满足 $PP^T = I$ ，所以 $G' = FF^T$ ，即 $G' = G$ ，因此，只要对所有通道进行相同的空间位置重排，通道 Gram 矩阵保持不变。这说明 Gram 矩阵记录的是全局特征统计，而不是特征出现的具体空间位置。这也是它能够描述纹理和整体风格，却难以精确保留局部语义布局的原因。后续风格迁移工作经常将这一全局统计性质视为 Gram 风格表示的局限。

神经风格迁移中的 Gram 矩阵

设 x_s 是风格图像； x_g 是生成图像； $F^{(l)}(x)$ 是第 l 层网络特征； $G^{(l)}(x)$ 是该层的 Gram 矩阵。

对于第 l 层 $G^{(l)}(x) = F^{(l)}(x)F^{(l)}(x)^T$

风格图像的 Gram 矩阵为 $G_s^{(l)} = G^{(l)}(x_s)$ ；

生成图像的 Gram 矩阵为 $G_g^{(l)} = G^{(l)}(x_g)$

风格损失可以定义为 $\mathcal{L}_{\text{style}}^{(l)} = |G_g^{(l)} - G_s^{(l)}|_F^2$ ；多层风格损失为 $\mathcal{L}_{\text{style}} = \sum_{l \in S} w_l \mathcal{L}_{\text{style}}^{(l)}$ ，

经典神经风格迁移通过同时优化内容特征损失和多层 Gram 风格损失，把内容结构与全局二阶风格统计结合起来。

设当前层特征矩阵为 $F \in \mathbb{R}^{C \times M}$ ，目标 Gram 矩阵为 $A \in \mathbb{R}^{C \times C}$ ，当前 Gram 矩阵为 $G = FF^T$ ，定义损失 $\mathcal{L}(F) = \frac{1}{2} |FF^T - A|_F^2$ ，其中， $|\cdot|_F$ 表示 Frobenius 范数。

[对于矩阵 $B \in \mathbb{R}^{m \times n}$ ，Frobenius 范数定义为 $|B|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n B_{ij}^2}$

因此 $|B|_F^2 = \sum_{i=1}^m \sum_{j=1}^n B_{ij}^2$ ，所以 Gram 损失 $\mathcal{L}(F) = \frac{1}{2}|FF^T - A|_F^2$ 也可以展开为 $\mathcal{L}(F) = \frac{1}{2} \sum_{i=1}^C \sum_{j=1}^C ((FF^T)_{ij} - A_{ij})^2$ ，它衡量当前特征的 Gram 矩阵与目标 Gram 矩阵之间的逐元素平方误差。]

令 $E = FF^T - A$ ，则损失可以写为 $\mathcal{L} = \frac{1}{2}|E|_F^2$ ，利用 Frobenius 范数与矩阵迹的关系 $|E|_F^2 = \text{tr}(E^T E)$ ，所以 $\mathcal{L} = \frac{1}{2}\text{tr}(E^T E)$ ，如果 A 是 Gram 矩阵，那么 A 是对称矩阵。同时 FF^T 也是对称矩阵，因此 $E^T = E$

损失的微分为 $d\mathcal{L} = \text{tr}(E^T dE)$ ，因为 $E = FF^T - A$ ，而 A 是常数矩阵，所以 $dE = d(FF^T)$ ，使用矩阵乘积的微分法则 $d(FF^T) = dF F^T + F dF^T$ ，因此 $dE = dF F^T + F dF^T$ ，代入损失微分 $d\mathcal{L} = \text{tr}(E^T dF F^T) + \text{tr}(E^T F dF^T)$

第一项为 $\text{tr}(E^T dF F^T)$

利用矩阵迹的循环性质 $\text{tr}(ABC) = \text{tr}(BCA) = \text{tr}(CAB)$

得到 $\text{tr}(E^T dF F^T) = \text{tr}(F^T E^T dF)$ ，因为 $F^T E^T = (EF)^T$

所以 $\text{tr}(E^T dF F^T) = \text{tr}((EF)^T dF)$

第二项为 $\text{tr}(E^T F dF^T)$

利用恒等式 $\text{tr}(B dF^T) = \text{tr}(B^T dF)$

得到 $\text{tr}(E^T F dF^T) = \text{tr}((E^T F)^T dF)$

由于 E 是对称矩阵： $E^T = E$

所以 $\text{tr}(E^T F dF^T) = \text{tr}((EF)^T dF)$

两项相加 $d\mathcal{L} = 2\text{tr}((EF)^T dF)$

根据矩阵梯度的定义 $d\mathcal{L} = \text{tr}\left(\left(\frac{\partial \mathcal{L}}{\partial F}\right)^T dF\right)$ ，因此 $\frac{\partial \mathcal{L}}{\partial F} = 2EF$ ，代入 $E = FF^T - A$ ，得到 $\frac{\partial \mathcal{L}}{\partial F} = 2(FF^T - A)F$ ，这就是 Gram 矩阵匹配损失对特征矩阵的梯度。

如果损失定义为 $\mathcal{L}(F) = |FF^T - A|_F^2$ ，即没有前面的 1/2，那么梯度为 $\frac{\partial \mathcal{L}}{\partial F} = 4(FF^T - A)F$ ，因此需要注意损失前有 1/2 时，梯度系数为 2；损失前没有 1/2 时，梯度系数为 4。

如果 Gram 矩阵定义为 $G = \frac{1}{M} FF^T$

损失函数定义为 $\mathcal{L}(F) = \frac{1}{2} \sum_{i=1}^C \sum_{j=1}^C \left(\frac{1}{M} (FF^T)_{ij} - A_{ij}\right)^2$

令 $E = \frac{1}{M} FF^T - A$ ，则梯度为 $\frac{\partial \mathcal{L}}{\partial F} = \frac{2}{M} EF$ ，即 $\frac{\partial \mathcal{L}}{\partial F} = \frac{2}{M} \left(\frac{1}{M} FF^T - A \right) F$ ，如果损失中还包含其他归一化系数，那么这些系数也会乘到梯度中。

[举例：

设卷积特征有两个通道，每个通道有三个空间位置 $F = \begin{bmatrix} 1 & 2 & 0 \\ 2 & 1 & 1 \end{bmatrix}$ ，其中 $C=2$ ；
 $M=3$ 。通道 Gram 矩阵为 $G = FF^T$ ，展开计算 $G = \begin{bmatrix} 1 & 2 & 0 \\ 2 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 2 & 1 \\ 0 & 1 \end{bmatrix}$ ，所以 $G = \begin{bmatrix} 5 & 4 \\ 4 & 6 \end{bmatrix}$ ，
 归一化后的 Gram 矩阵为 $\tilde{G} = \frac{1}{3} FF^T$ ，因此 $\tilde{G} = \frac{1}{3} \begin{bmatrix} 5 & 4 \\ 4 & 6 \end{bmatrix}$ ，即 $\tilde{G} = \begin{bmatrix} \frac{5}{3} & \frac{4}{3} \\ \frac{4}{3} & 2 \end{bmatrix}$

这个矩阵表示第一个通道的平均平方响应为 $5/3$ ；第二个通道的平均平方响应为 2 ；两个通道的平均乘积为 $4/3$ 。]

样本 Gram 矩阵

设一个小批量包含 B 个样本，每个样本的特征向量为： $z_i \in \mathbb{R}^d$

将样本按行排列 $Z = \begin{bmatrix} z_1^T \\ z_2^T \\ \vdots \\ z_B^T \end{bmatrix} \in \mathbb{R}^{B \times d}$ ，样本 Gram 矩阵定义为 $K = ZZ^T$ ，因此

$K \in \mathbb{R}^{B \times B}$ ，第 i,j 个元素为 $K_{ij} = z_i^T z_j$

如果所有特征都经过 L_2 归一化： $|z_i|_2 = 1$

那么余弦相似度为 $\cos(z_i, z_j) = \frac{z_i^T z_j}{|z_i|_2 |z_j|_2}$

由于两个范数都等于 1： $\cos(z_i, z_j) = z_i^T z_j$

因此 $K_{ij} = \cos(z_i, z_j)$ ，此时样本 Gram 矩阵就是样本之间的余弦相似度矩阵。

Gram 矩阵与知识蒸馏

设教师网络和学生网络分别产生特征 $F_t \in \mathbb{R}^{C_t \times M}$ ； $F_s \in \mathbb{R}^{C_s \times M}$

如果教师和学生的通道维度相同 $C_t = C_s = C$ ，可以分别构造通道 Gram 矩阵 $G_t = F_t F_t^T$ ； $G_s = F_s F_s^T$ ，然后定义 Gram 关系蒸馏损失 $\mathcal{L}_{\text{Gram}} = |\tilde{G}_s - \tilde{G}_t|_F^2$ ，其中 $\tilde{G}_t$ 是归一化后的教师 Gram 矩阵； $\tilde{G}_s$ 是归一化后的学生 Gram 矩阵。这种损失不要求学生网络逐元素复制教师网络的特征，而是要求学生网络保持教师特征中的二阶关系。

如果 $C_t \neq C_s$ ，那么 $G_t \in \mathbb{R}^{C_t \times C_t}$ ； $G_s \in \mathbb{R}^{C_s \times C_s}$ ，二者形状不同，不能直接计算 $|G_s - G_t|_F^2$ ，常见处理方法包括使用投影层将教师和学生特征映射到相同通道维度；比较空间 Gram 矩阵；比较样本 Gram 矩阵；对关系矩阵进行低维投影；比较归一化后的奇异值或特征值结构。

Gram 矩阵与自监督表征学习

设两种数据增强视图产生的批量特征为: $Z^{(a)}, Z^{(b)} \in \mathbb{R}^{B \times d}$

可以构造交叉关系矩阵 $C = \frac{1}{B} (Z^{(a)})^T Z^{(b)}$, 其中 B 是批量大小; d 是特征维数;

$C \in \mathbb{R}^{d \times d}$ 。

第 i, j 个元素为 $C_{ij} = \frac{1}{B} \sum_{b=1}^B Z_{bi}^{(a)} Z_{bj}^{(b)}$, 如果特征已经按维度进行中心化和标准化,

那么 C 可以解释为交叉相关矩阵。

对角线元素 C_{ii} 描述两种增强视图中第 i 个特征维度之间的一致性。希望 $C_{ii} \approx 1$ 表示相同特征维度在两种视图下保持稳定。非对角线元素 C_{ij} , $i \neq j$ 描述不同特征维度之间的交叉关系。希望 $C_{ij} \approx 0$ 可以减少不同特征维度之间的冗余。对应损失可以写为 $\mathcal{L} = \sum_i (1 - C_{ii})^2 + \lambda \sum_{i \neq j} C_{ij}^2$, 其中第一项使对角线元素接近 1; 第二项使非对角线元素接近 0; λ 控制冗余抑制项的权重。

需要区分:

$Z^T Z$: 同一组特征的 Gram 矩阵;

$(Z^{(a)})^T Z^{(b)}$: 两组特征的交叉 Gram 矩阵;

对标准化特征计算的交叉矩阵: 交叉相关矩阵。

注意力矩阵是不是 Gram 矩阵

Transformer 中, 查询矩阵和键矩阵分别为 $Q \in \mathbb{R}^{n_q \times d_k}$, $K \in \mathbb{R}^{n_k \times d_k}$

注意力分数矩阵为 $S = \frac{QK^T}{\sqrt{d_k}}$, 其中 $QK^T \in \mathbb{R}^{n_q \times n_k}$

第 i, j 个元素为 $(QK^T)_{ij} = q_i^T k_j$, 它表示第 i 个查询向量与第 j 个键向量之间的内积。因此, QK^T 可以看作查询向量与键向量之间的交叉 Gram 矩阵。

Softmax 后不再是 Gram 矩阵

注意力权重为 $A = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)$, softmax 通常按行计算 $A_{ij} = \frac{\exp(S_{ij})}{\sum_{k=1}^{n_k} \exp(S_{ik})}$,

经过 softmax 后每一行元素之和等于 1; 所有元素都大于 0; 矩阵通常不对称; 它不再是内积矩阵。

因此, softmax 后的注意力权重矩阵 A 不是 Gram 矩阵。

Gram 矩阵与核矩阵

设神经网络编码器产生特征: $z_i = f_\theta(x_i)$, 对样本 $x_1, x_2, \dots, x_B$, 定义线性核 $k(x_i, x_j) = z_i^T z_j$, 构造核矩阵 $K_{ij} = k(x_i, x_j)$, 所以 $K_{ij} = z_i^T z_j$, 矩阵形式为 $K = ZZ^T$, 因此, 线性核矩阵本质上就是特征向量构成的 Gram 矩阵。可以用于表示样本间相似性; 对比学习; 度量学习; 聚类; 关系蒸馏; 特征空间几何结构分析。

对于非线性特征映射 $\phi(x)$, 定义 $k(x_i, x_j) = \phi(x_i)^T \phi(x_j)$, 核矩阵为 $K_{ij} = k(x_i, x_j)$,

虽然可能没有显式计算 $\phi(x)$ ，但只要核函数对应某个内积空间，得到的核矩阵仍然可以看作该空间中的 Gram 矩阵。

Gram 矩阵相等

设两个特征矩阵 $F_1, F_2 \in \mathbb{R}^{C \times M}$ 满足 $F_1 F_1^T = F_2 F_2^T$ ，这表示它们具有相同的通道内积结构，并不能推出 $F_1 = F_2$

正交变换不改变 Gram 矩阵，设 $F_2 = F_1 Q$ ，其中 $Q \in \mathbb{R}^{M \times M}$ 是正交矩阵，即 $Q Q^T = I$ ，则 $F_2 F_2^T = F_1 Q Q^T F_1^T$ ，由于 $Q Q^T = I$ ，所以 $F_2 F_2^T = F_1 F_1^T$ ，因此，对特征空间位置维度进行正交变换不会改变通道 Gram 矩阵。空间位置的置换矩阵也是正交矩阵，所以空间位置重排不会改变通道 Gram 矩阵。

相同 Gram 矩阵不表示相同语义，两个特征矩阵可能具有相同的通道能量；通道间内积；全局二阶统计关系；但它们仍可能具有不同的空间排列；局部结构；物体位置；语义内容。

因此，Gram 矩阵匹配是一种二阶关系约束，而不是完整特征约束。