

常见概率分布

1. 离散型随机变量

随机变量 X 只能取有限个或可数多个值时，称为离散型随机变量。它的概率质量函数写为 $p_X(x) = P(X = x)$

概率质量函数必须满足 $p_X(x) \geq 0$ 以及 $\sum_x p_X(x) = 1$

离散型随机变量的期望定义为 $\mathbb{E}[X] = \sum_x x p_X(x)$

方差定义为 $\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$

展开后可以得到更常用的形式： $\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2$

$$\begin{aligned} \mathbb{E}[(X - \mathbb{E}[X])^2] &= \mathbb{E}[X^2 - 2X\mathbb{E}[X] + \mathbb{E}[X]^2] \\ &= \mathbb{E}[X^2] - 2\mathbb{E}[X]^2 + \mathbb{E}[X]^2 \\ &= \mathbb{E}[X^2] - \mathbb{E}[X]^2 \end{aligned}$$

2. 连续型随机变量

连续型随机变量用概率密度函数表示： $f_X(x)$

必须满足 $f_X(x) \geq 0$ 以及 $\int_{-\infty}^{+\infty} f_X(x) dx = 1$

区间概率为 $P(a \leq X \leq b) = \int_a^b f_X(x) dx$

连续型随机变量在某一个单独点上的概率为零： $P(X = x) = 0$

其期望为 $\mathbb{E}[X] = \int_{-\infty}^{+\infty} x f_X(x) dx$

方差仍然满足 $\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2$

一、伯努利分布

Bernoulli 分布描述一次只有两种结果的随机试验，例如：

3. 成功或失败；
4. 正类或负类
5. 是或否；
6. 神经元是否激活；
7. 样本标签是 1 还是 0。

设 $X \in \{0, 1\}$ ，定义 $P(X = 1) = p$ ； $P(X = 0) = 1 - p$

其中 $0 \leq p \leq 1$ ，记作 $X \sim \text{Bernoulli}(p)$

Bernoulli 分布可以写成：

$$p_X(x) = p^x (1 - p)^{1-x}, \quad x \in \{0, 1\} \quad (1)$$

验证这个表达式：当 $x = 1$ 时， $p_X(1) = p^1 (1 - p)^0 = p$ ；当 $x = 0$ 时，

$p_X(0) = p^0(1-p)^1 = 1-p$ ，归一化条件为 $p_X(0) + p_X(1) = 1-p+p=1$

根据定义， $\mathbb{E}[X] = \sum_{x \in \{0,1\}} x p_X(x)$ ，因此 $\mathbb{E}[X] = 0 \cdot (1-p) + 1 \cdot p = p$ ，所以

$$\mathbb{E}[X] = p \quad (2)$$

因为 X 只能等于 0 或 1，所以 $X^2 = X$ 。因此 $\mathbb{E}[X^2] = \mathbb{E}[X] = p$ ，于是 $\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2 = p - p^2 = p(1-p)$ ，所以

$$\text{Var}(X) = p(1-p) \quad (3)$$

当 $p=0$ 或 $p=1$ 时，结果完全确定，方差为零。当 $p=0.5$ 时，不确定性最大，方差达到最大值 $\frac{1}{4}$

观察一个样本 $x \in \{0,1\}$ 时，其概率为 $P(X=x) = p^x(1-p)^{1-x}$

取负对数 $-\log P(X=x) = -x \log p - (1-x) \log(1-p)$

二元交叉熵损失 $\mathcal{L} = -x \log p - (1-x) \log(1-p)$

因此，二元分类中的交叉熵，本质上是 Bernoulli 分布的负对数似然。

二、二项分布

设进行 n 次相互独立的 Bernoulli 试验： $X_1, X_2, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Bernoulli}(p)$

定义成功总次数 $X = \sum_{i=1}^n X_i$ ，那么 $X \sim \text{Binomial}(n, p)$ 。随机变量 X 的取值为

$X \in \{0, 1, \dots, n\}$ 。

要使总成功次数等于 k ，需要有 k 次成功以及 $n-k$ 次失败。某一种特定排列的概率为 $p^k(1-p)^{n-k}$ ，例如，前三次成功、其余失败，就是其中一种排列。但 k 次成功可以出现在 n 个位置中的任意 k 个位置上，因此排列数量为 $\binom{n}{k} = \frac{n!}{k!(n-k)!}$

所以：

$$P(X=k) = \binom{n}{k} p^k (1-p)^{n-k} \quad (4)$$

其中 $k=0, 1, \dots, n$ 。

需要验证 $\sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} = 1$ ，根据二项式定理 $(a+b)^n = \sum_{k=0}^n \binom{n}{k} a^k b^{n-k}$

令 $a=p$ ， $b=1-p$ ，得到 $\sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} = (p+1-p)^n = 1^n = 1$

由于 $X = \sum_{i=1}^n X_i$

根据期望的线性性质： $\mathbb{E}[X] = \mathbb{E}\left[\sum_{i=1}^n X_i\right] = \sum_{i=1}^n \mathbb{E}[X_i] = \sum_{i=1}^n p = np$

所以：

$$\mathbb{E}[X] = np \quad (5)$$

注意：计算期望时不需要独立性，期望本身始终具有线性性质。

因为各次试验相互独立，即 $\text{Cov}(X_i, X_j) = 0$ ， $i \neq j$

$$\text{因此 } \text{Var}(X) = \text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i) = \sum_{i=1}^n p(1-p) = np(1-p)$$

所以：

$$\text{Var}(X) = np(1-p) \quad (6)$$

三、多项分布

二项分布中的每次试验只有两个类别。多项分布将其推广到 K 个类别。

设每次试验可能落入以下类别之一： $1, 2, \dots, K$

各类别概率分别为 $p_1, p_2, \dots, p_K$

并满足 $p_i \geq 0$ 以及 $\sum_{i=1}^K p_i = 1$ ，独立重复进行 n 次试验。设第 i 类出现次数为 N_i ，

那么 $N_1 + \dots + N_K = n$ ，记作 $(N_1, \dots, N_K) \sim \text{Multinomial}(n, p_1, \dots, p_K)$

假设各类别分别出现 $n_1, n_2, \dots, n_K$ 次，其中 $\sum_{i=1}^K n_i = n$ 。某一种特定排列的概率为

$\prod_{i=1}^K p_i^{n_i}$ ，具有相同类别计数的排列数量为多项式系数 $\frac{n!}{n_1! n_2! \dots n_K!}$ 。因此：

$$P(N_1 = n_1, \dots, N_K = n_K) = \frac{n!}{\prod_{i=1}^K n_i!} \prod_{i=1}^K p_i^{n_i} \quad (7)$$

其中 $\sum_{i=1}^K n_i = n$ 。

根据多项式定理 $(p_1 + \dots + p_K)^n = \sum_{n_1 + \dots + n_K = n} \frac{n!}{n_1! \dots n_K!} p_1^{n_1} \dots p_K^{n_K}$

因为 $p_1 + \dots + p_K = 1$ ，所以所有可能计数组合的概率之和为 $1^n = 1$ 。

定义指示变量 $I_{t,i} = \begin{cases} 1, & \text{第 } t \text{ 次试验属于第 } i \text{ 类} \\ 0, & \text{其他情况} \end{cases}$ ，那么 $N_i = \sum_{t=1}^n I_{t,i}$ 。由于

$I_{t,i} \sim \text{Bernoulli}(p_i)$ ，所以 $\mathbb{E}[I_{t,i}] = p_i$ 。因此：

$$\mathbb{E}[N_i] = np_i \quad (8)$$

类似地

$$\text{Var}(N_i) = np_i(1 - p_i) \quad (9)$$

对于 $i \neq j$ ，同一次试验不可能同时属于两个类别，因此 $I_{t,i}I_{t,j} = 0$ 。于是 $\text{Cov}(I_{t,i}, I_{t,j}) = \mathbb{E}[I_{t,i}I_{t,j}] - \mathbb{E}[I_{t,i}]\mathbb{E}[I_{t,j}] = 0 - p_i p_j = -p_i p_j$ ，不同试验之间相互独立，所以 $\text{Cov}(N_i, N_j) = -np_i p_j$ ， $i \neq j$ ，协方差为负，是因为总次数固定为 n 。某个类别出现得更多，其他类别能够出现的次数就会减少。

忽略与模型参数无关的组合系数

$$\text{多项分布的对数似然为 } \log P = \text{constant} + \sum_{i=1}^K n_i \log p_i$$

$$\text{负对数似然为 } -\log P = \text{constant} - \sum_{i=1}^K n_i \log p_i$$

当单个样本使用 one-hot 标签 y_i 时， $-\sum_{i=1}^K y_i \log p_i$ 就是多分类交叉熵。

四、泊松分布

Poisson 分布描述固定时间或空间范围内，某种事件出现的次数。例如：

1. 一分钟内到达服务器的请求数量；
2. 一段道路上的事故数量；
3. 一张图像中的缺陷数量；
4. 一个文本窗口中的某词出现次数。

设平均发生次数为 $\lambda > 0$ ，则 $X \sim \text{Poisson}(\lambda)$ 。概率质量函数为：

$$P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!} \quad (10)$$

其中 $k = 0, 1, 2, \dots$ 。

考虑 $X_n \sim \text{Binomial}(n, p_n)$ 。假设总平均事件数固定为 λ ，令 $p_n = \frac{\lambda}{n}$ ，于是 $np_n = \lambda$ 。

$$\text{二项分布概率为 } P(X_n = k) = \binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k}$$

$$\text{首先考虑前半部分 } \binom{n}{k} \left(\frac{\lambda}{n}\right)^k = \frac{n(n-1) \cdots (n-k+1)}{k!} \frac{\lambda^k}{n^k} = \frac{\lambda^k}{k!} \prod_{j=0}^{k-1} \left(1 - \frac{j}{n}\right)$$

$$\text{当 } n \rightarrow \infty \text{ 时，} \prod_{j=0}^{k-1} \left(1 - \frac{j}{n}\right) \rightarrow 1, \text{ 所以 } \binom{n}{k} \left(\frac{\lambda}{n}\right)^k \rightarrow \frac{\lambda^k}{k!}$$

$$\text{另一方面 } \left(1 - \frac{\lambda}{n}\right)^{n-k} = \left(1 - \frac{\lambda}{n}\right)^n \left(1 - \frac{\lambda}{n}\right)^{-k}$$

$$\text{当 } n \rightarrow \infty \text{ 时，} \left(1 - \frac{\lambda}{n}\right)^n \rightarrow e^{-\lambda}, \text{ 而 } \left(1 - \frac{\lambda}{n}\right)^{-k} \rightarrow 1。$$

因此 $P(X_n = k) \rightarrow e^{-\lambda} \frac{\lambda^k}{k!}$

Poisson 分布是二项分布在“大量试验、单次概率很小、平均次数固定”条件下的极限。

利用指数函数的幂级数 $e^\lambda = \sum_{k=0}^{\infty} \frac{\lambda^k}{k!}$, 有 $\sum_{k=0}^{\infty} e^{-\lambda} \frac{\lambda^k}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} e^\lambda = 1$

期望 $\mathbb{E}[X] = \sum_{k=0}^{\infty} k e^{-\lambda} \frac{\lambda^k}{k!} = e^{-\lambda} \sum_{k=1}^{\infty} \frac{k \lambda^k}{k!} = e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^k}{(k-1)!} = \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!}$

所以:

$$\mathbb{E}[X] = \lambda \quad (11)$$

先计算 $\mathbb{E}[X(X-1)]$:

$$\mathbb{E}[X(X-1)] = \sum_{k=0}^{\infty} k(k-1) e^{-\lambda} \frac{\lambda^k}{k!} = e^{-\lambda} \sum_{k=2}^{\infty} \frac{\lambda^k}{(k-2)!} = \lambda^2 e^{-\lambda} \sum_{j=0}^{\infty} \frac{\lambda^j}{j!} = \lambda^2$$

又因为 $X^2 = X(X-1) + X$, 所以 $\mathbb{E}[X^2] = \lambda^2 + \lambda$

因此 $\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \lambda^2 + \lambda - \lambda^2 = \lambda$

所以:

$$\text{Var}(X) = \lambda \quad (12)$$

五、均匀分布

设随机变量在区间 $[a, b]$ 上各位置具有相同的概率密度, 记作 $X \sim U(a, b)$ 。由于密度是常数, 设 $f_X(x) = c$, $a \leq x \leq b$ 。

归一化要求 $\int_a^b c \, dx = 1$, 所以 $c(b-a) = 1$, 从而 $c = \frac{1}{b-a}$ 。因此:

$$f_X(x) = \begin{cases} 1/b-a, & a \leq x \leq b \\ 0, & \text{其他} \end{cases}$$

分布函数定义为 $F_X(x) = P(X \leq x)$ 。因此:

$$F_X(x) = \begin{cases} 0, & x < a \\ x-a/b-a, & a \leq x \leq b \\ 1, & x > b \end{cases} \quad (13)$$

期望:

$$\mathbb{E}[X] = \int_a^b x \frac{1}{b-a} \, dx = \frac{1}{b-a} \left[\frac{x^2}{2} \right]_a^b = \frac{b^2-a^2}{2(b-a)} = \frac{(b-a)(a+b)}{2(b-a)} = \frac{a+b}{2}$$

所以:

$$\mathbb{E}[X] = \frac{a+b}{2} \quad (14)$$

$$\text{计算二阶矩 } \mathbb{E}[X^2] = \frac{1}{b-a} \int_a^b x^2 dx = \frac{1}{b-a} \left[\frac{x^3}{3} \right]_a^b = \frac{b^3 - a^3}{3(b-a)} = \frac{a^2 + ab + b^2}{3}$$

$$\text{因此 } \text{Var}(X) = \frac{a^2 + ab + b^2}{3} - \left(\frac{a+b}{2} \right)^2 = \frac{(b-a)^2}{12}$$

所以：

$$\text{Var}(X) = \frac{(b-a)^2}{12} \quad (15)$$

六、高斯分布

Gaussian 分布也称正态分布。

设 $X \sim \mathcal{N}(\mu, \sigma^2)$ ，其中 $\mu \in \mathbb{R}$, $\sigma > 0$ 。

$$\text{其概率密度为 } f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

其中：

1. μ 控制中心位置；
2. σ^2 是方差；
3. σ 是标准差。

为了说明归一化常数为什么是 $\frac{1}{\sqrt{2\pi}\sigma}$ ，首先考虑标准积分 $I = \int_{-\infty}^{+\infty} e^{-\frac{x^2}{2}} dx$

直接计算这个积分较困难。考虑平方形式 $I^2 = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} e^{-\frac{x^2+y^2}{2}} dx dy$

将直角坐标变为极坐标： $x = r \cos \theta$, $y = r \sin \theta$ ，且面积元满足 $dx dy = r dr d\theta$ 。

于是 $I^2 = \int_0^{2\pi} \int_0^\infty e^{-\frac{r^2}{2}} r dr d\theta$ ，内层积分令 $u = \frac{r^2}{2}$, $du = r dr$ ，得到：

$$\int_0^\infty e^{-\frac{r^2}{2}} r dr = \int_0^\infty e^{-u} du = 1$$

因此 $I^2 = 2\pi$ 。由于 $I > 0$ ，所以 $I = \sqrt{2\pi}$ ，这就是正态分布中的 $\sqrt{2\pi}$ 的来源。

令 $z = \frac{x-\mu}{\sigma}$ ，则 $dx = \sigma dz$ 。因此：

$$\int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-\mu)^2/(2\sigma^2)} dx = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} e^{-\frac{z^2}{2}} dz = 1$$

定义标准化变量 $Z = \frac{X-\mu}{\sigma}$ ，则 $X = \mu + \sigma Z$ 。标准正态分布关于零对称，因此

$\mathbb{E}[Z] = 0$ 。所以 $\mathbb{E}[X] = \mu + \sigma \mathbb{E}[Z] = \mu$ ，即：

$$\mathbb{E}[X] = \mu \quad (16)$$

需要先证明 $\mathbb{E}[Z^2] = 1$ 。有 $\mathbb{E}[Z^2] = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} z^2 e^{-z^2/2} dz$

注意 $\frac{d}{dz} e^{-z^2/2} = -ze^{-z^2/2}$ 。

使用分部积分可得 $\int_{-\infty}^{+\infty} z^2 e^{-z^2/2} dz = \int_{-\infty}^{+\infty} e^{-\frac{z^2}{2}} dz = \sqrt{2\pi}$

因此 $\mathbb{E}[Z^2] = 1$ 。于是 $\text{Var}(X) = \text{Var}(\mu + \sigma Z) = \sigma^2 \text{Var}(Z) = \sigma^2$

所以：

$$\text{Var}(X) = \sigma^2 \quad (17)$$

正态分布的负对数密度为 $-\log f_X(x) = \frac{(x-\mu)^2}{2\sigma^2} + \log \sigma + \frac{1}{2} \log(2\pi)$

当 σ 固定时，只有第一项与 μ 有关，因此最大化正态似然等价于最小化 $(x-\mu)^2$

对于向量 $\mathbf{x} \in \mathbb{R}^d$ ，多元 Gaussian 密度为：

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} \sqrt{\det \Sigma}} \exp\left(-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})\right)$$

其中 $\boldsymbol{\mu} \in \mathbb{R}^d$ 是均值向量， $\Sigma \in \mathbb{R}^{d \times d}$ 是协方差矩阵。二次型 $(\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})$ 称为平方 Mahalanobis 距离。

七、拉普拉斯分布

Laplace 分布写为 $X \sim \text{Laplace}(\mu, b)$ ，其中 $b > 0$ 。

其密度为 $f_X(x) = \frac{1}{2b} \exp\left(-\frac{|x-\mu|}{b}\right)$

它关于 μ 对称，但尾部比 Gaussian 分布更厚。

令 $y = x - \mu$ ，则：

$$\int_{-\infty}^{+\infty} \frac{1}{2b} e^{-|x-\mu|/b} dx = \frac{1}{2b} \int_{-\infty}^{+\infty} e^{-|y|/b} dy = \frac{1}{2b} \left(\int_{-\infty}^0 e^{y/b} dy + \int_0^{\infty} e^{-y/b} dy \right) = \frac{1}{2b} (b + b) = 1$$

因为密度关于 μ 对称， $\mathbb{E}[X - \mu] = 0$ 。所以：

$$\mathbb{E}[X] = \mu \quad (18)$$

令 $Y = X - \mu$ ，则 $\mathbb{E}[Y^2] = \int_{-\infty}^{+\infty} y^2 \frac{1}{2b} e^{-|y|/b} dy = \frac{1}{b} \int_0^{\infty} y^2 e^{-y/b} dy$

令 $t = \frac{y}{b}$ ， $y = bt$ ， $dy = b dt$ 。因此 $\mathbb{E}[Y^2] = \frac{1}{b} \int_0^{\infty} b^2 t^2 e^{-t} b dt = b^2 \int_0^{\infty} t^2 e^{-t} dt$

而 $\int_0^{\infty} t^2 e^{-t} dt = 2$ ，所以：

$$\text{Var}(X) = 2b^2 \quad (19)$$

Laplace 分布的负对数密度为： $-\log f_X(x) = \frac{|x-\mu|}{b} + \log(2b)$ ，当 b 固定时，最

大化似然等价于最小化 $|x - \mu|$ 。

Laplace 分布对异常值通常比 Gaussian 分布更稳健。

八、指数分布

指数分布常用于描述 Poisson 事件之间的等待时间。设事件发生速率为 $\lambda > 0$ ，则 $X \sim \text{Exponential}(\lambda)$ 。密度为 $f_X(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$ ，这里使用的是速率参数 λ 。

归一化：
$$\int_0^{\infty} \lambda e^{-\lambda x} dx = [-e^{-\lambda x}]_0^{\infty} = 1$$

对于 $x \geq 0$ ：

$$F_X(x) = \int_0^x \lambda e^{-\lambda t} dt = 1 - e^{-\lambda x} \quad (20)$$

所以生存函数为 $P(X > x) = 1 - F_X(x) = e^{-\lambda x}$

$$\mathbb{E}[X] = \int_0^{\infty} x \lambda e^{-\lambda x} dx$$

使用分部积分 $u = x$, $dv = \lambda e^{-\lambda x} dx$ ，则 $du = dx$, $v = -e^{-\lambda x}$ 。

$$\text{因此 } \mathbb{E}[X] = [-xe^{-\lambda x}]_0^{\infty} + \int_0^{\infty} e^{-\lambda x} dx = \frac{1}{\lambda}$$

所以：

$$\mathbb{E}[X] = \frac{1}{\lambda} \quad (21)$$

可以类似地计算出二阶矩 $\mathbb{E}[X^2] = \frac{2}{\lambda^2}$ 。因此 $\text{Var}(X) = \frac{2}{\lambda^2} - \left(\frac{1}{\lambda}\right)^2 = \frac{1}{\lambda^2}$

所以：

$$\text{Var}(X) = \frac{1}{\lambda^2} \quad (22)$$

指数分布满足 $P(X > s + t | X > s) = P(X > t)$

[证明如下：

$$P(X > s + t | X > s) = \frac{P(X > s + t)}{P(X > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = P(X > t)$$

这意味着：已经等待了多久，不影响接下来还要等待多久的概率分布。]

假设单位时间事件数服从 Poisson 分布，速率为 λ 。设第一次事件发生时间为 T 。那么 $P(T > t)$ 表示时间 t 内一次事件都没有发生。

Poisson 分布给出 $P(N(t) = 0) = e^{-\lambda t}$ ，因此 $P(T > t) = e^{-\lambda t}$

说明 $T \sim \text{Exponential}(\lambda)$ ，Poisson 分布描述事件次数，指数分布描述事件间隔。

九、Gamma 分布

Gamma 分布建立在 Gamma 函数之上。定义 $\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t} dt$, 其中 $\alpha > 0$ 。通过分部积分 (令 $u = t^\alpha$, $dv = e^{-t} dt$), 可以得到 $\Gamma(\alpha+1) = \alpha \Gamma(\alpha)$, 对于正整数 n , $\Gamma(n) = (n-1)!$ 。因此 Gamma 函数可以理解为阶乘向正实数的推广。

采用形状参数 α 和速率参数 β : $X \sim \text{Gamma}(\alpha, \beta)$ 。密度为:

$$f_X(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \quad x > 0 \quad (23)$$

其中 $\alpha > 0$, $\beta > 0$ 。

考虑积分 $\int_0^\infty \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} dx$

令 $t = \beta x$, $x = \frac{t}{\beta}$, $dx = \frac{dt}{\beta}$ 。则:

$$\int_0^\infty f_X(x) dx = \frac{\beta^\alpha}{\Gamma(\alpha)} \int_0^\infty \left(\frac{t}{\beta}\right)^{\alpha-1} e^{-t} \frac{dt}{\beta} = \frac{1}{\Gamma(\alpha)} \int_0^\infty t^{\alpha-1} e^{-t} dt = 1$$

$$\mathbb{E}[X] = \int_0^\infty x \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} dx = \frac{\beta^\alpha}{\Gamma(\alpha)} \int_0^\infty x^\alpha e^{-\beta x} dx$$

令 $t = \beta x$, 得到 $\mathbb{E}[X] = \frac{1}{\beta} \frac{\Gamma(\alpha+1)}{\Gamma(\alpha)}$ 。使用 $\Gamma(\alpha+1) = \alpha \Gamma(\alpha)$, 得到:

$$\mathbb{E}[X] = \frac{\alpha}{\beta} \quad (24)$$

类似地, 可以求出二阶矩 $\mathbb{E}[X^2] = \frac{\Gamma(\alpha+2)}{\beta^2 \Gamma(\alpha)}$

因为 $\Gamma(\alpha+2) = (\alpha+1)\alpha \Gamma(\alpha)$, 所以 $\mathbb{E}[X^2] = \frac{\alpha(\alpha+1)}{\beta^2}$

$$\text{因此 } \text{Var}(X) = \frac{\alpha(\alpha+1)}{\beta^2} - \left(\frac{\alpha}{\beta}\right)^2 = \frac{\alpha}{\beta^2}$$

所以:

$$\text{Var}(X) = \frac{\alpha}{\beta^2} \quad (25)$$

当 $\alpha=1$ 时, $\Gamma(1)=1$, 因此 Gamma 密度变为, $f_X(x) = \beta e^{-\beta x}$ 。这正是指数分布。所以 $\text{Exponential}(\beta) = \text{Gamma}(1, \beta)$

当 α 是正整数时, Gamma 分布可以表示多个独立相同指数等待时间之和。

十、Beta 分布

Beta 函数定义为 $B(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1-x)^{\beta-1} dx$ ，其中 $\alpha > 0, \beta > 0$ 。Beta 函数与 Gamma 函数满足关系 $B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$

从 $\Gamma(\alpha)\Gamma(\beta)$ 开始： $\Gamma(\alpha)\Gamma(\beta) = \int_0^\infty \int_0^\infty s^{\alpha-1} t^{\beta-1} e^{-(s+t)} ds dt$

作变量替换 $u = s + t, x = \frac{s}{s+t}$ 。于是 $s = ux, t = u(1-x)$ 。Jacobian 矩阵的行列式绝对值为 $\left| \frac{\partial(s,t)}{\partial(u,x)} \right| = u$ ，因此 $ds dt = u du dx$ 。代入得到：

$$\begin{aligned} \Gamma(\alpha)\Gamma(\beta) &= \int_0^\infty \int_0^1 (ux)^{\alpha-1} (u(1-x))^{\beta-1} e^{-u} u dx du \\ &= \left(\int_0^\infty u^{\alpha+\beta-1} e^{-u} du \right) \left(\int_0^1 x^{\alpha-1} (1-x)^{\beta-1} dx \right) \\ &= \Gamma(\alpha+\beta) B(\alpha, \beta) \end{aligned}$$

$$\text{所以 } B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$$

Beta 分布定义在区间 $0 < x < 1$ 上，记作 $X \sim \text{Beta}(\alpha, \beta)$ 。

其密度为： $f_X(x) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1}$

它特别适合描述概率、比例和占比，因为随机变量的取值天生限制在 $[0, 1]$ 内。

$$\begin{aligned} \mathbb{E}[X] &= \frac{1}{B(\alpha, \beta)} \int_0^1 x^\alpha (1-x)^{\beta-1} dx = \frac{B(\alpha+1, \beta)}{B(\alpha, \beta)}, \text{ 根据 Gamma 函数表示,} \\ \frac{B(\alpha+1, \beta)}{B(\alpha, \beta)} &= \frac{\Gamma(\alpha+1)\Gamma(\beta)}{\Gamma(\alpha+\beta+1)} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} = \frac{\alpha}{\alpha+\beta}, \text{ 因此:} \end{aligned}$$

$$\mathbb{E}[X] = \frac{\alpha}{\alpha+\beta} \quad (26)$$

通过计算二阶矩 $\mathbb{E}[X^2] = \frac{B(\alpha+2, \beta)}{B(\alpha, \beta)} = \frac{\alpha(\alpha+1)}{(\alpha+\beta)(\alpha+\beta+1)}$ ，可以得到方差为：

$$\text{Var}(X) = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)} \quad (27)$$

均值由比例 $\frac{\alpha}{\alpha+\beta}$ 决定。总量 $\alpha+\beta$ 控制分布的集中程度。

假设 Bernoulli 成功概率为 p ，并对 p 使用 Beta 先验： $p \sim \text{Beta}(\alpha, \beta)$ 。观察到

s 次成功和 f 次失败，似然函数满足 $P(D|p) \propto p^s(1-p)^f$ 。

先验密度为 $p(p) \propto p^{\alpha-1}(1-p)^{\beta-1}$ 。

因此后验分布满足 $p(p|D) \propto P(D|p)p(p) \propto p^{s+\alpha-1}(1-p)^{f+\beta-1}$

所以 $p|D \sim \text{Beta}(\alpha+s, \beta+f)$

因此可以把 α 和 β 看成成功与失败的先验虚计数。

十一、Dirichlet 分布

Beta 分布描述二分类概率中的一个概率值。如果有 K 个类别，其概率向量为 $\mathbf{p} = (p_1, \dots, p_K)^\top$ ，满足 $p_i \geq 0$ 以及 $\sum_{i=1}^K p_i = 1$ 。所有满足这些条件的向量组成一个单纯形。Dirichlet 分布定义在这个单纯形上，记作 $\mathbf{p} \sim \text{Dirichlet}(\alpha_1, \dots, \alpha_K)$ 。定义 $\alpha_0 = \sum_{i=1}^K \alpha_i$ 。

Dirichlet 密度为 $f(\mathbf{p}) = \frac{\Gamma(\alpha_0)}{\prod_{i=1}^K \Gamma(\alpha_i)} \prod_{i=1}^K p_i^{\alpha_i-1}$ ，其中 $p_i \geq 0$ ， $\sum_{i=1}^K p_i = 1$ ， $\alpha_i > 0$

当 $K=2$ 时，令 $p_2 = 1 - p_1$ ，就得到 Beta 分布。因此，就得到 Beta 分布。因此 Beta 是 Dirichlet 的二维特殊情况。

设 $Y_i \sim \text{Gamma}(\alpha_i, 1)$ ， $i = 1, \dots, K$ ，并且这些变量相互独立。定义 $S = \sum_{i=1}^K Y_i$ 以及 $P_i = \frac{Y_i}{S}$ 。显然 $P_i \geq 0$ 并且 $\sum_{i=1}^K P_i = 1$ 。

由 $Y_i = SP_i$ 进行变量变换，其 Jacobian 决定式中会产生因子 S^{K-1} 。独立 Gamma 变量的联合密度为 $\prod_{i=1}^K \frac{1}{\Gamma(\alpha_i)} y_i^{\alpha_i-1} e^{-y_i}$ 。

代入 $y_i = sp_i$ 之后，得到 $\prod_{i=1}^K y_i^{\alpha_i-1} = s^{\alpha_0-K} \prod_{i=1}^K p_i^{\alpha_i-1}$

而 $\prod_{i=1}^K e^{-y_i} = e^{-s}$ 。再乘上 Jacobian 因子 s^{K-1} ，得到 $s^{\alpha_0-1} e^{-s} \prod_{i=1}^K p_i^{\alpha_i-1}$

这个表达式可以分解为 $\frac{1}{\Gamma(\alpha_0)} s^{\alpha_0-1} e^{-s}$ 与 $\frac{\Gamma(\alpha_0)}{\prod_{i=1}^K \Gamma(\alpha_i)} \prod_{i=1}^K p_i^{\alpha_i-1}$

第一部分是 $S \sim \text{Gamma}(\alpha_0, 1)$ 的密度，第二部分正是 Dirichlet 密度。

因此，将独立 Gamma 随机变量归一化 $P_i = \frac{Y_i}{\sum_j Y_j}$ ，就可以得到 Dirichlet 随机

向量。

Dirichlet 分布的第 i 个分量满足：

$$\mathbb{E}[P_i] = \frac{\alpha_i}{\alpha_0} \quad (28)$$

这与 Beta 分布的均值形式一致。可以把参数归一化后的比例 $\frac{\alpha_i}{\alpha_0}$ 看作第 i 类的中心概率。

第 i 个分量的方差为：

$$\text{Var}(P_i) = \frac{\alpha_i(\alpha_0 - \alpha_i)}{\alpha_0^2(\alpha_0 + 1)} \quad (29)$$

当所有比例保持不变，而整体参数规模 α_0 增大时，方差减小，分布会更加集中。

对于 $i \neq j$ ，有：

$$\text{Cov}(P_i, P_j) = -\frac{\alpha_i \alpha_j}{\alpha_0^2(\alpha_0 + 1)} \quad (30)$$

协方差为负，是因为 $\sum_{i=1}^K P_i = 1$ 。某一个概率分量增大时，其他分量必须减小。

设类别概率满足 $\mathbf{p} \sim \text{Dirichlet}(\alpha_1, \dots, \alpha_K)$ 。观察多项分布计数 $n_1, \dots, n_K$ 。似然中与 $\mathbf{p}$ 有关的部分为 $P(D | \mathbf{p}) \propto \prod_{i=1}^K p_i^{n_i}$ 。先验为 $p(\mathbf{p}) \propto \prod_{i=1}^K p_i^{\alpha_i - 1}$

所以 $\mathbf{p} | D \sim \text{Dirichlet}(\alpha_1 + n_1, \dots, \alpha_K + n_K)$ ，因此 Dirichlet 分布是多项分布参数的共轭先验。

十二、总结

12.1 伯努利分布

$$X \sim \text{Bernoulli}(p)$$

$$\mathbb{E}[X] = p, \quad \text{Var}(X) = p(1 - p)$$

12.2 二项分布

$$X \sim \text{Binomial}(n, p)$$

$$\mathbb{E}[X] = np, \quad \text{Var}(X) = np(1 - p)$$

12.3 泊松分布

$$X \sim \text{Poisson}(\lambda)$$

$$\mathbb{E}[X] = \lambda, \quad \text{Var}(X) = \lambda$$

12.4 均匀分布

$$X \sim U(a, b)$$

$$\mathbb{E}[X] = \frac{a+b}{2}, \quad \text{Var}(X) = \frac{(b-a)^2}{12}$$

12.5 高斯分布

$$X \sim \mathcal{N}(\mu, \sigma^2)$$

$$\mathbb{E}[X] = \mu, \quad \text{Var}(X) = \sigma^2$$

12.6 拉普拉斯分布

$$X \sim \text{Laplace}(\mu, b)$$

$$\mathbb{E}[X] = \mu, \quad \text{Var}(X) = 2b^2$$

12.7 指数分布

$$X \sim \text{Exponential}(\lambda)$$

$$\mathbb{E}[X] = \frac{1}{\lambda}, \quad \text{Var}(X) = \frac{1}{\lambda^2}$$

12.8 Gamma 分布

$$X \sim \text{Gamma}(\alpha, \beta)$$

$$\mathbb{E}[X] = \frac{\alpha}{\beta}, \quad \text{Var}(X) = \frac{\alpha}{\beta^2}$$

12.9 Beta 分布

$$X \sim \text{Beta}(\alpha, \beta)$$

$$\mathbb{E}[X] = \frac{\alpha}{\alpha + \beta}, \quad \text{Var}(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$$

12.10 Dirichlet 分布

$$\mathbf{P} \sim \text{Dirichlet}(\alpha_1, \dots, \alpha_K)$$

$$\mathbb{E}[P_i] = \frac{\alpha_i}{\alpha_0}, \quad \text{Var}(P_i) = \frac{\alpha_i(\alpha_0 - \alpha_i)}{\alpha_0^2(\alpha_0 + 1)}$$

$$\text{其中 } \alpha_0 = \sum_{i=1}^K \alpha_i \circ$$