

概率论知识补全

导论

1. 蒙特卡洛方法的思想是将待求量写成数学期望： $I = \mathbb{E}_{X \sim p}[f(X)]$
2. 从分布 p 中独立采样： $X_1, \dots, X_N \stackrel{\text{i.i.d.}}{\sim} p$
使用样本均值估计： $\hat{I}_N = \frac{1}{N} \sum_{i=1}^N f(X_i)$
3. 在期望存在时，基本蒙特卡洛估计量是无偏的： $\mathbb{E}[\hat{I}_N] = I$
4. 若方差有限，则估计量方差为： $\text{Var}(\hat{I}_N) = \frac{\sigma_f^2}{N}$
5. 蒙特卡洛方法的标准误差按 $O(N^{-1/2})$ 的速度下降。若希望误差缩小为原来的 $1/10$ ，通常需要将样本量扩大到原来的 100 倍。
6. 蒙特卡洛积分不是直接“随机计算积分”，而是先把积分改写成期望。
7. 重要性采样通过改变采样分布降低方差： $I = \mathbb{E}_{X \sim q} \left[f(X) \frac{p(X)}{q(X)} \right]$
8. MCMC 用于无法直接从目标分布采样的情况。它产生相关样本，而不是独立样本。
9. Metropolis–Hastings 接受概率为： $\alpha(x, y) = \min \left\{ 1, \frac{\tilde{\pi}(y)q(x|y)}{\tilde{\pi}(x)q(y|x)} \right\}$
10. 对 MCMC，真正有效的样本量通常小于实际迭代次数： $N_{\text{eff}} \approx \frac{N}{\tau_{\text{int}}}$

设随机变量 $X \sim p$ ，其中 p 是概率密度函数或概率质量函数。我们希望计算 $I = \mathbb{E}_{X \sim p}[f(X)]$ ，如果 X 是连续随机变量，则 $I = \int_{\mathcal{X}} f(x)p(x) dx$ ；如果 X 是离散随机变量，则 $I = \sum_{x \in \mathcal{X}} f(x)p(x)$

从目标分布 p 中生成 N 个相互独立且同分布的随机样本 $X_1, X_2, \dots, X_N \stackrel{\text{i.i.d.}}{\sim} p$

计算 $Y_i = f(X_i)$ ，于是 $\mathbb{E}[Y_i] = I$ ，使用样本均值 $\hat{I}_N = \frac{1}{N} \sum_{i=1}^N Y_i$

即 $\hat{I}_N = \frac{1}{N} \sum_{i=1}^N f(X_i)$ ，作为 I 的估计量。

假设 $\mathbb{E}[|f(X)|] < \infty$ ，则 $\mathbb{E}[\hat{I}_N] = \mathbb{E} \left[\frac{1}{N} \sum_{i=1}^N f(X_i) \right]$

利用期望的线性性 $\mathbb{E}[\hat{I}_N] = \frac{1}{N} \sum_{i=1}^N \mathbb{E}[f(X_i)]$

因为每个 X_i 都服从相同分布 p ，所以 $\mathbb{E}[f(X_i)] = I$ ，从而 $\mathbb{E}[\hat{I}_N] = \frac{1}{N} \sum_{i=1}^N I$ ，因此 $\mathbb{E}[\hat{I}_N] = I$ ，所以基本蒙特卡洛估计量是无偏估计量。

[估计量无偏，是指在固定真实参数和固定抽样规则下，对所有可能样本产生的估计结果取期望后，恰好等于被估计的真实参数。

设未知参数为 θ ，使用随机样本构造估计量 $\hat{\theta}$ ，如果满足 $\mathbb{E}[\hat{\theta}] = \theta$ ，那么称 $\hat{\theta}$ 是参数 θ 的无偏估计量。

估计量 $\hat{\theta}$ 对参数 θ 的偏差定义为 $\text{Bias}(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta$

无偏条件可以写成 $\text{Bias}(\hat{\theta}) = 0$

设随机变量 $X_1, X_2, \dots, X_N$ 相互独立且服从相同分布，并且总体均值为 $\mathbb{E}[X_i] = \mu$

样本均值定义为 $\bar{X} = \frac{1}{N} \sum_{i=1}^N X_i$ ，对样本均值求期望 $\mathbb{E}[\bar{X}] = \mathbb{E}\left[\frac{1}{N} \sum_{i=1}^N X_i\right]$

利用期望的线性性质 $\mathbb{E}[\bar{X}] = \frac{1}{N} \sum_{i=1}^N \mathbb{E}[X_i]$ ，因为每个样本的期望都是 μ ，所以

$\mathbb{E}[\bar{X}] = \frac{1}{N} \sum_{i=1}^N \mu$ ，共有 N 项，因此 $\mathbb{E}[\bar{X}] = \frac{N\mu}{N} = \mu$ ，所以 $\mathbb{E}[\bar{X}] = \mu$ ，因此，样

本均值 $\bar{X}$ 是总体均值 μ 的无偏估计量。

设总体均值为 μ ，总体方差为 $\sigma^2 = \mathbb{E}[(X - \mu)^2]$ ，一个看起来直接的样本方差定义是 $\tilde{S}^2 = \frac{1}{N} \sum_{i=1}^N (X_i - \bar{X})^2$ ，但这个估计量是有偏的。可以证明 $\mathbb{E}[\tilde{S}^2] = \frac{N-1}{N} \sigma^2$ ，所以它平均低估总体方差。

为了修正这个偏差，定义 $S^2 = \frac{1}{N-1} \sum_{i=1}^N (X_i - \bar{X})^2$ ，于是 $\mathbb{E}[S^2] = \sigma^2$ ，因此， S^2 是总体方差 σ^2 的无偏估计量。

无偏性要求对任意固定样本量 N ： $\mathbb{E}[\hat{\theta}_N] = \theta$ ；一致性要求当样本量趋于无穷时 $\hat{\theta}_N \xrightarrow{p} \theta$ ，其中 $\xrightarrow{p}$ 表示依概率收敛。

设 $\hat{\theta}_N = \theta + Z$ ，其中 $\mathbb{E}[Z] = 0$ ，且 Z 的方差不随 N 减小。那么 $\mathbb{E}[\hat{\theta}_N] = \theta$ ，所以它无偏。但随着 N 增大，随机误差 Z 并没有消失，因此它不一定收敛到 θ 。

设 $\hat{\theta}_N = \bar{X} + \frac{1}{N}$ ，其中 $\mathbb{E}[\bar{X}] = \mu$ ，则 $\mathbb{E}[\hat{\theta}_N] = \mu + \frac{1}{N}$ ，它对有限 N 有偏，偏差为 $\text{Bias}(\hat{\theta}_N) = \frac{1}{N}$ ，但 $\frac{1}{N} \rightarrow 0$ 并且 $\bar{X} \xrightarrow{p} \mu$ ，所以 $\hat{\theta}_N \xrightarrow{p} \mu$ 因此它有偏但一致。]

记 $\sigma_f^2 = \text{Var}(f(X))$ ，因为 $X_1, \dots, X_N$ 相互独立

$$\text{所以 } \text{Var}(\hat{I}_N) = \text{Var}\left(\frac{1}{N} \sum_{i=1}^N f(X_i)\right)$$

$$\text{提取常数 } \text{Var}(\hat{I}_N) = \frac{1}{N^2} \text{Var}\left(\sum_{i=1}^N f(X_i)\right)$$

$$\text{独立性给出 } \text{Var}\left(\sum_{i=1}^N f(X_i)\right) = \sum_{i=1}^N \text{Var}(f(X_i))$$

$$\text{因此 } \text{Var}(\hat{I}_N) = \frac{1}{N^2} \sum_{i=1}^N \sigma_f^2, \text{ 得到 } \text{Var}(\hat{I}_N) = \frac{\sigma_f^2}{N}$$

标准差为 $\text{SD}(\hat{I}_N) = \frac{\sigma_f}{\sqrt{N}}$ ，这个标准差也称为蒙特卡洛标准误差。

$$\text{估计量的均方误差定义为 } \text{MSE}(\hat{I}_N) = \mathbb{E}[(\hat{I}_N - I)^2]$$

$$\text{它可以分解为 } \text{MSE}(\hat{I}_N) = \text{Var}(\hat{I}_N) + \text{Bias}(\hat{I}_N)^2$$

$$\text{由于基本蒙特卡洛估计量无偏 } \text{Bias}(\hat{I}_N) = 0$$

$$\text{所以 } \text{MSE}(\hat{I}_N) = \frac{\sigma_f^2}{N}, \text{ 均方根误差为 } \text{RMSE}(\hat{I}_N) = \sqrt{\text{MSE}(\hat{I}_N)}$$

$$\text{即 } \text{RMSE}(\hat{I}_N) = \frac{\sigma_f}{\sqrt{N}}$$

若 $\mathbb{E}[|f(X)|] < \infty$ ，根据大数定律 $\frac{1}{N} \sum_{i=1}^N f(X_i) \xrightarrow{\text{a.s.}} \mathbb{E}[f(X)]$ ，因此 $\hat{I}_N \xrightarrow{\text{a.s.}} I$

符号 $\xrightarrow{\text{a.s.}}$ 表示几乎处处收敛。其含义是：随着 N 趋于无穷，样本均值以概率 1 收敛到真实期望。这说明蒙特卡洛估计量具有一致性。但是，大数定律只说明最终会收敛，并没有直接给出有限样本下误差的分布。要研究误差大小，需要中心极限定理。

假设 $\mathbb{E}[f(X)^2] < \infty$ ，并记 $\sigma_f^2 = \text{Var}(f(X))$

$$\text{中心极限定理给出 } \sqrt{N}(\hat{I}_N - I) \xrightarrow{d} \mathcal{N}(0, \sigma_f^2)$$

$$\text{等价地，当 } N \text{ 足够大时 } \hat{I}_N \approx \mathcal{N}\left(I, \frac{\sigma_f^2}{N}\right)$$

$$\text{因此，标准化误差近似满足 } \frac{\hat{I}_N - I}{\sigma_f/\sqrt{N}} \approx \mathcal{N}(0, 1)$$

$$\text{这给出了误差阶 } \hat{I}_N - I = O_p(N^{-1/2})$$

真实方差 σ_f^2 通常未知，可以使用样本方差 $S_N^2 = \frac{1}{N-1} \sum_{i=1}^N (f(X_i) - \hat{I}_N)^2$ 估计 σ_f^2 ，标准误差估计为 $\widehat{\text{SE}}(\hat{I}_N) = \frac{S_N}{\sqrt{N}}$

于是近似的 $100(1-\alpha)\%$ 置信区间为 $\hat{I}_N \pm z_{1-\alpha/2} \frac{S_N}{\sqrt{N}}$

考虑积分 $I = \int_{\mathcal{D}} g(x) dx$ ，选择一个概率密度 $p(x)$ ，要求在 $g(x) \neq 0$ 的区域满足 $p(x) > 0$ ，然后写成 $I = \int_{\mathcal{D}} \frac{g(x)}{p(x)} p(x) dx$ ，因此 $I = \mathbb{E}_{X \sim p} \left[\frac{g(X)}{p(X)} \right]$ ，蒙特卡洛估计量为 $\hat{I}_N = \frac{1}{N} \sum_{i=1}^N \frac{g(X_i)}{p(X_i)}$ ，其中 $X_i \stackrel{\text{i.i.d.}}{\sim} p$

考虑一维积分 $I = \int_a^b g(x) dx$ ，令 $X \sim \text{Uniform}(a, b)$ ，均匀分布密度为 $p(x) = \frac{1}{b-a}$ ，因此 $I = \int_a^b g(x) (b-a) p(x) dx$ 得到 $I = (b-a) \mathbb{E}[g(X)]$ ，估计量为 $\hat{I}_N = \frac{b-a}{N} \sum_{i=1}^N g(X_i)$ ；设 $\mathcal{D} \subseteq \mathbb{R}^d$ ，区域体积为 $|\mathcal{D}|$ ，若 $X \sim \text{Uniform}(\mathcal{D})$ ，则 $p(x) = \frac{1}{|\mathcal{D}|}$ ，因此 $\int_{\mathcal{D}} g(x) dx = |\mathcal{D}| \mathbb{E}[g(X)]$ ，对应估计量 $\hat{I}_N = \frac{|\mathcal{D}|}{N} \sum_{i=1}^N g(X_i)$

基本蒙特卡洛方法的 $N^{-1/2}$ 收敛阶在形式上不直接依赖积分维数，但被积函数方差、采样难度和有效区域大小仍可能随维数急剧恶化。

[举例：

计算 $I = \int_0^1 x^2 dx$ ，解析结果为 $I = \frac{1}{3}$ ，现在使用蒙特卡洛方法。

令 $X \sim \text{Uniform}(0, 1)$ ，则 $I = \mathbb{E}[X^2]$

假设得到四个随机样本 $X_1 = 0.1$ ， $X_2 = 0.4$ ， $X_3 = 0.7$ ， $X_4 = 0.9$

对应函数值 $X_1^2 = 0.01$ ； $X_2^2 = 0.16$ ； $X_3^2 = 0.49$ ； $X_4^2 = 0.81$

蒙特卡洛估计为 $\hat{I}_4 = \frac{0.01 + 0.16 + 0.49 + 0.81}{4}$ ，因此 $\hat{I}_4 = 0.3675$]

设事件为 A ，定义示性函数 $\mathbf{1}_A(x) = \begin{cases} 1, & x \in A, \\ 0, & x \notin A. \end{cases}$

事件概率为 $\mathbb{P}(X \in A) = \mathbb{E}[\mathbf{1}_A(X)]$ ，因此可以使用 $\hat{p}_N = \frac{1}{N} \sum_{i=1}^N \mathbf{1}_A(X_i)$ 估计事件

概率。由于 $\mathbf{1}_A(X) \sim \text{Bernoulli}(p)$ ，所以 $\mathbb{E}[\hat{p}_N] = p$ 并且 $\text{Var}(\hat{p}_N) = \frac{p(1-p)}{N}$ ，标准

$$\text{误差为SE}(\hat{p}_N) = \sqrt{\frac{p(1-p)}{N}}$$

基本蒙特卡洛方法满足 $\text{RMSE} = \frac{\sigma_f}{\sqrt{N}}$ ，设当前样本量为 N ，希望误差缩小到原

来的比例 r ： $\frac{\sigma_f}{\sqrt{N_{\text{new}}}} = r \frac{\sigma_f}{\sqrt{N}}$ ，消去 σ_f 得到 $\frac{1}{\sqrt{N_{\text{new}}}} = \frac{r}{\sqrt{N}}$ ，所以 $N_{\text{new}} = \frac{N}{r^2}$

[例如：

误差减半： $r=1/2$ ，需要 $4N$ 个样本；

误差缩小为原来的 $1/10$ ：需要 $100N$ 个样本；

误差缩小为原来的 $1/100$ ：需要 $10000N$ 个样本。]

因此，降低方差通常比单纯增加样本数量更加重要。

基本估计量是 $\hat{I}_N = \frac{1}{N} \sum_{i=1}^N Y_i$ ，其方差为 $\frac{\text{Var}(Y)}{N}$ ，所以提高蒙特卡洛效率有两条

主要途径：增加 N ；构造方差更小、但期望仍为 I 的随机变量。方差缩减方法主要研究第二种途径。

对偶变量法

设 $U \sim \text{Uniform}(0, 1)$ ，则 $1 - U \sim \text{Uniform}(0, 1)$ ，构造 $Y = \frac{f(U) + f(1 - U)}{2}$ ，

则 $\mathbb{E}[Y] = I$ ，其方差为 $\text{Var}(Y) = \frac{1}{4} \text{Var}(f(U) + f(1 - U))$

展开 $\text{Var}(Y) = \frac{1}{4} [\text{Var}(f(U)) + \text{Var}(f(1 - U)) + 2\text{Cov}(f(U), f(1 - U))]$

由于两个边缘分布相同 $\text{Var}(f(U)) = \text{Var}(f(1 - U)) = \sigma_f^2$

所以 $\text{Var}(Y) = \frac{\sigma_f^2}{2} + \frac{1}{2} \text{Cov}(f(U), f(1 - U))$ ，如果 $\text{Cov}(f(U), f(1 - U)) < 0$ 则

对偶变量估计的方差会下降。如果协方差为正，则这种方法可能反而增加方差，因此不能无条件使用。

控制变量法

设目标为 $I = \mathbb{E}[f(X)]$ ，同时存在另一个函数 $h(X)$ ，其期望已知： $\mathbb{E}[h(X)] = \eta$

构造随机变量 $Y_\beta = f(X) - \beta(h(X) - \eta)$

其期望为 $\mathbb{E}[Y_\beta] = \mathbb{E}[f(X)] - \beta(\mathbb{E}[h(X)] - \eta)$

因此 $\mathbb{E}[Y_\beta] = I$ ，对应估计量为 $\hat{I}_{\text{CV}} = \bar{f} - \beta(\bar{h} - \eta)$ ，其中 $\bar{f} = \frac{1}{N} \sum_{i=1}^N f(X_i)$ ；

$\bar{h} = \frac{1}{N} \sum_{i=1}^N h(X_i)$ ，单个控制变量样本的方差为 $\text{Var}(Y_\beta) = \sigma_f^2 + \beta^2 \sigma_h^2 - 2\beta \text{Cov}(f, h)$

对 β 求导 $\frac{d}{d\beta} \text{Var}(Y_\beta) = 2\beta\sigma_h^2 - 2\text{Cov}(f, h)$

令其等于零： $2\beta\sigma_h^2 - 2\text{Cov}(f, h) = 0$

得到最优系数 $\beta^* = \frac{\text{Cov}(f, h)}{\text{Var}(h)}$ ，代回方差 $\text{Var}(Y_{\beta^*}) = \sigma_f^2 - \frac{\text{Cov}(f, h)^2}{\sigma_h^2}$

定义相关系数 $\rho_{f, h} = \frac{\text{Cov}(f, h)}{\sigma_f \sigma_h}$

则 $\text{Var}(Y_{\beta^*}) = \sigma_f^2(1 - \rho_{f, h}^2)$ ，所以，只要 $f(X)$ 与 $h(X)$ 高度相关，无论是正相关还是负相关，控制变量都可以显著降低方差。

分层采样

将样本空间划分为互不相交的区域 $\mathcal{X} = A_1 \cup A_2 \cup \dots \cup A_J$

并且 $A_j \cap A_k = \emptyset$, $j \neq k$ ，记 $p_j = \mathbb{P}(X \in A_j)$ ，条件期望 $\mu_j = \mathbb{E}[f(X) | X \in A_j]$

根据全期望公式 $I = \sum_{j=1}^J p_j \mu_j$

在第 j 层中采样 n_j 个样本，计算 $\hat{\mu}_j = \frac{1}{n_j} \sum_{i=1}^{n_j} f(X_{j,i})$

分层估计量为 $\hat{I}_{\text{str}} = \sum_{j=1}^J p_j \hat{\mu}_j$ ，如果不同层之间独立，则 $\text{Var}(\hat{I}_{\text{str}}) = \sum_{j=1}^J \frac{p_j^2 \sigma_j^2}{n_j}$ ，

其中 $\sigma_j^2 = \text{Var}(f(X) | X \in A_j)$ ，在总样本数固定 $\sum_{j=1}^J n_j = N$ 的条件下，理论最优分配满足 $n_j \propto p_j \sigma_j$ ，即概率质量大、层内方差大的区域应分配更多样本。

重要性采样

目标积分为 $I = \int f(x) p(x) dx$ ，假设从 p 中直接采样困难，或者从 p 采样会产生很大的方差。选择另一个容易采样的分布 q ，并要求 $q(x) > 0$ ，在所有满足 $f(x)p(x) \neq 0$ 的位置成立。于是 $I = \int f(x) \frac{p(x)}{q(x)} q(x) dx$

因此 $I = \mathbb{E}_{X \sim q} \left[f(X) \frac{p(X)}{q(X)} \right]$ ，定义重要性权重 $w(x) = \frac{p(x)}{q(x)}$ ，估计量为

$\hat{I}_{\text{IS}} = \frac{1}{N} \sum_{i=1}^N f(X_i) w(X_i)$ ，其中 $X_i \stackrel{\text{i.i.d.}}{\sim} q$

有 $\mathbb{E}_q[\hat{I}_{\text{IS}}] = \frac{1}{N} \sum_{i=1}^N \mathbb{E}_q[f(X_i) w(X_i)]$

而 $\mathbb{E}_q[f(X) w(X)] = \int f(x) \frac{p(x)}{q(x)} q(x) dx$ ，因此 $\mathbb{E}_q[f(X) w(X)] = I$

所以 $\mathbb{E}_q[\hat{I}_{\text{IS}}] = I$

重要性采样估计量的方差为 $\text{Var}(\hat{I}_{\text{IS}}) = \frac{1}{N} \text{Var}_q\left(f(X) \frac{p(X)}{q(X)}\right)$

展开 $N \left[\int \frac{f(x)^2 p(x)^2}{q(x)} dx - I^2 \right]$, 因此, q 的选择决定了重要性采样是否有效。

理论最优分布

要最小化 $\int \frac{f(x)^2 p(x)^2}{q(x)} dx$, 可以得到理论最优分布 $q^*(x) = \frac{|f(x)|p(x)}{\int |f(u)|p(u) du}$,

如果 $f(x) \geq 0$, 则 $q^*(x) = \frac{f(x)p(x)}{I}$, 在这种情况下 $f(x) \frac{p(x)}{q^*(x)} = I$ 对所有样本都成立, 所以理论方差为零。但是 q^* 依赖未知的 I , 因此它通常不能直接使用。这个结论的作用是指导我们选择一个接近 $|f(x)|p(x)$ 的提议分布。重要性采样是蒙特卡洛方差缩减中的基本方法, 但错误的提议分布可能导致极端权重和无限方差。

自归一化重要性采样

在贝叶斯推断中, 经常只知道未归一化密度 $\tilde{p}(x)$, 而真实密度为 $p(x) = \frac{\tilde{p}(x)}{Z}$,

其中归一化常数 $Z = \int \tilde{p}(x) dx$ 通常未知。定义未归一化权重 $\tilde{w}_i = \frac{\tilde{p}(X_i)}{q(X_i)}$, 再归一化

$\bar{w}_i = \frac{\tilde{w}_i}{\sum_{j=1}^N \tilde{w}_j}$, 自归一化重要性采样估计量为 $\hat{I}_{\text{SNIS}} = \sum_{i=1}^N \bar{w}_i f(X_i)$, 它也可以写成比

值形式 $\hat{I}_{\text{SNIS}} = \frac{\sum_{i=1}^N \tilde{w}_i f(X_i)}{\sum_{i=1}^N \tilde{w}_i}$, 这个估计量在有限样本下一般不是严格无偏的, 但在适

当条件下是一致的。

基本蒙特卡洛方法要求 $X_i \stackrel{\text{i.i.d.}}{\sim} \pi$, 但在许多问题中目标分布维数很高; 归一化常数未知; 只能计算与密度成比例的函数; 无法直接生成独立样本。

假设目标分布为 $\pi(x) = \frac{\tilde{\pi}(x)}{Z}$, 其中 $Z = \int \tilde{\pi}(x) dx$ 未知。MCMC 不要求直接从 π 中独立采样, 而是构造马尔可夫链: $X_0, X_1, X_2, \dots$, 使其平稳分布为 π 。在适当的不可约性、非周期性和遍历性条件下, 长期样本可以用于估计 $\mathbb{E}_\pi[f(X)]$

马尔可夫链满足 $\mathbb{P}(X_{n+1} \in A | X_0, \dots, X_n) = \mathbb{P}(X_{n+1} \in A | X_n)$, 也就是说, 下一状态的条件分布只依赖当前状态。

设转移核为 $K(x, dy)$, 如果分布 π 满足 $\pi(dy) = \int \pi(dx) K(x, dy)$

则 π 称为该马尔可夫链的平稳分布。若 $X_n \sim \pi$ ，则 $X_{n+1} \sim \pi$ ，MCMC 的目标就是设计一个容易模拟的转移核 K ，使目标分布 π 成为它的平稳分布。

Metropolis–Hastings 算法

假设当前状态是 $X_n = x$

1. 生成候选状态，从提议分布采样 $Y \sim q(y|x)$
2. 计算接受概率 $\alpha(x, y) = \min \left\{ 1, \frac{\tilde{\pi}(y)q(x|y)}{\tilde{\pi}(x)q(y|x)} \right\}$
3. 生成均匀随机数 $U \sim \text{Uniform}(0, 1)$
4. 接受或拒绝，如果 $U \leq \alpha(x, y)$ ，则 $X_{n+1} = Y$ ，否则 $X_{n+1} = X_n$

拒绝候选状态时，链必须保留当前状态。不能简单删除拒绝步骤，否则得到的样本分布通常不再是目标分布。

目标分布为 $\pi(x) = \frac{\tilde{\pi}(x)}{Z}$ ，接受比率中的目标密度比为 $\frac{\pi(y)}{\pi(x)} = \frac{\tilde{\pi}(y)/Z}{\tilde{\pi}(x)/Z}$

归一化常数 Z 消去 $\frac{\pi(y)}{\pi(x)} = \frac{\tilde{\pi}(y)}{\tilde{\pi}(x)}$ ，因此，Metropolis–Hastings 只需要计算未归

一化目标密度 $\tilde{\pi}(x)$ ，这是它适合贝叶斯后验采样的重要原因。

定义从 x 到 y 的有效转移密度： $T(x, y) = q(y|x)\alpha(x, y)$

对 $x \neq y$ ，有 $\pi(x)T(x, y) = \pi(x)q(y|x)\alpha(x, y)$

代入接受概率 $\pi(x)T(x, y) = \pi(x)q(y|x)\min \left\{ 1, \frac{\pi(y)q(x|y)}{\pi(x)q(y|x)} \right\}$

利用恒等式 $a \min \left\{ 1, \frac{b}{a} \right\} = \min \{ a, b \}$

得到 $\pi(x)T(x, y) = \min \{ \pi(x)q(y|x), \pi(y)q(x|y) \}$

同理 $\pi(y)T(y, x) = \min \{ \pi(y)q(x|y), \pi(x)q(y|x) \}$

所以 $\pi(x)T(x, y) = \pi(y)T(y, x)$ ，对所有 x, y 积分后，可以推出 π 是该马尔可夫链的平稳分布。

定义滞后 k 的自相关系数 $\rho_k = \text{Corr}(f(X_i), f(X_{i+k}))$ ，在适当条件下，MCMC 样本均值的渐近方差约为 $\text{Var}(\hat{I}_N^{\text{MCMC}}) \approx \frac{\sigma_f^2}{N} \left(1 + 2 \sum_{k=1}^{\infty} \rho_k \right)$ ，定义积分自相关时间

$\tau_{\text{int}} = 1 + 2 \sum_{k=1}^{\infty} \rho_k$ ，于是 $\text{Var}(\hat{I}_N^{\text{MCMC}}) \approx \frac{\sigma_f^2 \tau_{\text{int}}}{N}$ ，定义有效样本量 $N_{\text{eff}} = \frac{N}{\tau_{\text{int}}}$

如果自相关为正，则 $\tau_{\text{int}} > 1$ ，从而 $N_{\text{eff}} < N$ ，例如运行 10000 次迭代，但 $\tau_{\text{int}} = 50$ ，则有效样本量约为 $N_{\text{eff}} = \frac{10000}{50} = 200$ ，因此，MCMC 不能只报告总迭代次数，还应

分析自相关和有效样本量。

小批量梯度是期望梯度的蒙特卡洛估计

设总体目标为 $\mathcal{L}(\theta) = \mathbb{E}_{Z \sim p_{\text{data}}} [\ell(\theta; Z)]$

在适当的可交换条件下 $\nabla_{\theta} \mathcal{L}(\theta) = \mathbb{E}_{Z \sim p_{\text{data}}} [\nabla_{\theta} \ell(\theta; Z)]$

使用大小为 B 的小批量 $Z_1, \dots, Z_B$

估计梯度 $\hat{g}_B(\theta) = \frac{1}{B} \sum_{i=1}^B \nabla_{\theta} \ell(\theta; Z_i)$

如果样本独立且均匀抽取，则 $\mathbb{E}[\hat{g}_B(\theta)] = \nabla_{\theta} \mathcal{L}(\theta)$

并且 $\text{Var}(\hat{g}_B) = \frac{\text{Var}(\nabla_{\theta} \ell)}{B}$

因此，小批量随机梯度本质上是总体期望梯度的蒙特卡洛估计。

贝叶斯神经网络

贝叶斯预测通常包含后验期望 $p(y^* | x^*, \mathcal{D}) = \int p(y^* | x^*, \theta) p(\theta | \mathcal{D}) d\theta$

如果能够从后验分布中获得样本 $\theta_1, \dots, \theta_N \sim p(\theta | \mathcal{D})$

则可以估计 $p(y^* | x^*, \mathcal{D}) \approx \frac{1}{N} \sum_{i=1}^N p(y^* | x^*, \theta_i)$

后验分布通常无法直接采样，因此可能需要 MCMC 或其他近似推断方法。

随机目标函数

若目标为 $\mathcal{J}(\theta) = \mathbb{E}_{\varepsilon \sim p(\varepsilon)} [F(\theta, \varepsilon)]$

则可用 $\hat{\mathcal{J}}_N(\theta) = \frac{1}{N} \sum_{i=1}^N F(\theta, \varepsilon_i)$ 近似。

这类形式出现在随机优化；变分推断；强化学习；随机正则化；随机生成模型；不确定性估计。