

多维函数

一、多维实值函数

设 $D \subseteq \mathbb{R}^n$ ，一般的多维函数可以从 $\mathbb{R}^n$ 映射到 $\mathbb{R}^m$ 。在最优化中，主要考虑值域为实数的标量函数，即 $f: D \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$

其中， $\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{R}^n$ 称为函数的自变量向量。因此，多维优化中的目标函数通

常可以写成 $f(\mathbf{x}) = f(x_1, x_2, \dots, x_n)$

二、水平集

2.1 定义

对于函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ，给定常数 c ，函数 f 在 c 上的水平集（level set）定义为

$$S = \{\mathbf{x}: f(\mathbf{x}) = c\}$$

对于 $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ ，水平集通常表现为平面中的曲线，也称为等值线。对于 $f: \mathbb{R}^3 \rightarrow \mathbb{R}$ 水平集通常表现为一组曲面。通常情况下，水平集具有以下性质。

2.2 水平集的基本性质

通常情况下，水平集具有以下性质。

2.2.1 不同水平集互不相交

若 $c_1 \neq c_2$ ，则水平集 $S_1 = \{\mathbf{x}: f(\mathbf{x}) = c_1\}$ 与 $S_2 = \{\mathbf{x}: f(\mathbf{x}) = c_2\}$ 不会相交。否则若存在某个点同时属于两个水平集，则将同时满足 $f(\mathbf{x}) = c_1$ 和 $f(\mathbf{x}) = c_2$ ，与 $c_1 \neq c_2$ 矛盾。

2.2.2 水平集的疏密反映函数变化速度

水平集较为稠密的位置，目标函数随位置变化较快；水平集较为稀疏的位置，目标函数变化较慢。

2.2.3 极值点附近的水平集

在许多光滑函数的极值点附近，水平集近似表现为一族同心椭圆。

三、线性函数与仿射函数

3.1 线性函数

设 $\mathbf{a}, \mathbf{x} \in \mathbb{R}^n$ ，形如 $f(\mathbf{x}) = \mathbf{a}^T \mathbf{x}$ ，的函数称为**线性函数**（linear function）。

3.2 仿射函数

形如 $f(\mathbf{x}) = \mathbf{a}^T \mathbf{x} + b$ 的函数称为**仿射函数 (affine function)**。仿射函数可以看作在线性函数基础上增加一个常数项 b ，即在线性函数上进行平移。

四、二次型与二次函数

4.1 二次型

设 $\mathbf{x} \in \mathbb{R}^n, Q \in \mathbb{R}^{n \times n}$ ，形如 $f(\mathbf{x}) = \mathbf{x}^T Q \mathbf{x}$ ，的二次齐次多项式函数称为**二次型 (quadratic form)**。

4.2 二次函数

最高阶项为二次型的多项式实函数称为**二次函数 (quadratic function)**，通常写为

$$f(\mathbf{x}) = \mathbf{x}^T A \mathbf{x} + \mathbf{b}^T \mathbf{x} + c$$

其中 $A \in \mathbb{R}^{n \times n}, \mathbf{b} \in \mathbb{R}^n, c \in \mathbb{R}$

五、二次型矩阵的对称化

对于任意矩阵 $A \in \mathbb{R}^{n \times n}$ ，二次型 $\mathbf{x}^T A \mathbf{x}$ 总可以等价地写成一个对称矩阵对应的二次型。

定义 $Q = \frac{1}{2}(A + A^T)$ ，显然有 $Q = Q^T$ ，同时，对于任意 $\mathbf{x} \in \mathbb{R}^n$ ，均有 $\mathbf{x}^T A \mathbf{x} = \mathbf{x}^T Q \mathbf{x}$ ，因此，研究二次型时可以不失一般性地假定二次型矩阵是对称矩阵。

任意二次函数也可以表示成 $f(\mathbf{x}) = \mathbf{x}^T Q \mathbf{x} + \mathbf{b}^T \mathbf{x} + c$ ，其中 $Q = Q^T$

六、正定矩阵与半正定矩阵

6.1 正定矩阵

设 $Q \in \mathbb{R}^{n \times n}$ 为对称矩阵。如果对于任意非零向量 $\mathbf{x} \in \mathbb{R}^n, \mathbf{x} \neq \mathbf{0}$ ，均有 $\mathbf{x}^T Q \mathbf{x} > 0$ ，则称 Q 为**正定矩阵**，记为 $Q > 0$

6.2 半正定矩阵

如果对于任意 $\mathbf{x} \in \mathbb{R}^n$ 均有 $\mathbf{x}^T Q \mathbf{x} \geq 0$ ，则称 Q 为**半正定矩阵**，记为 $Q \geq 0$

6.3 负定矩阵与半负定矩阵

类似地，若对于所有非零向量 $\mathbf{x}$ 均有 $\mathbf{x}^T Q \mathbf{x} < 0$ ，则称 Q 为**负定矩阵**。若 $\mathbf{x}^T Q \mathbf{x} \leq 0$ ，则称 Q 为**半负定矩阵**。

6.4 特征值判定

对于对称矩阵 Q ：

Q 正定，当且仅当其所有特征值均为正数；
 Q 半正定，当且仅当其所有特征值均为非负数。

6.4.1 顺序主子式判定

对称矩阵 Q 正定，当且仅当 Q 的所有顺序主子式均为正。

需要注意，顺序主子式方法不能仅通过“所有顺序主子式非负”来充分判定矩阵半正定。矩阵半正定可以推出所有顺序主子式非负，但反向关系一般不成立。

七、向量范数

7.1 范数的定义

范数是赋予向量“长度”概念的实值函数，记为 $|\mathbf{x}|$ ，范数满足以下三个基本条件。

7.1.1 正定性

对于任意 $\mathbf{x} \in \mathbb{R}^n$ ，有 $|\mathbf{x}| \geq 0$ ，当且仅当 $\mathbf{x} = \mathbf{0}$

7.1.2 齐次性

对于任意实数 a ， $|a\mathbf{x}| = |a||\mathbf{x}|$

7.1.3 三角不等式

对于任意 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ ，有 $|\mathbf{x} + \mathbf{y}| \leq |\mathbf{x}| + |\mathbf{y}|$

7.1.4 常见向量范数

1-范数： $|\mathbf{x}|_1 = \sum_{i=1}^n |x_i|$

2-范数： $|\mathbf{x}|_2 = \sqrt{\mathbf{x}^T \mathbf{x}} = \sqrt{\sum_{i=1}^n x_i^2}$

p -范数：对于 $p \geq 1$ ，定义 $|\mathbf{x}|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}$

无穷范数： $|\mathbf{x}|_\infty = \max_{1 \leq i \leq n} |x_i|$

八、优化问题及最优解

考虑优化问题 $\min f(\mathbf{x})$ ，满足 $\mathbf{x} \in \Omega$ ，其中 Ω 表示可行域。

九、全局最优解

9.1 定义

若存在 $\mathbf{x}^* \in \Omega$ ，使得对于所有 $\mathbf{x} \in \Omega$ ，均有 $f(\mathbf{x}) \geq f(\mathbf{x}^*)$ ，则称 $\mathbf{x}^*$ 为该优化问题

的全局最优解 (global minimizer)。对应的函数值 $f(\mathbf{x}^*)$ 称为最优目标值。全局最优解不一定唯一，但最优目标值是唯一的。

十、局部最优解

10.1 邻域

对于 $\mathbf{x}^* \in \Omega$ 和 $\varepsilon > 0$ ，定义其 ε 邻域为 $N(\mathbf{x}^*, \varepsilon) = \{\mathbf{x} \in \Omega: |\mathbf{x} - \mathbf{x}^*|_2 < \varepsilon\}$

10.1.1 局部最优解的定义

如果存在 $\varepsilon > 0$ ，使得对于所有 $\mathbf{x} \in N(\mathbf{x}^*, \varepsilon)$ ，都有 $f(\mathbf{x}) \geq f(\mathbf{x}^*)$ ，则称 $\mathbf{x}^*$ 为 f 在 Ω 中的一个局部最优解 (local minimizer)。

十一、严格最优解

若在全局或局部最优解的定义中，对于所有满足 $\mathbf{x} \neq \mathbf{x}^*$ 的点均有严格不等式 $f(\mathbf{x}) > f(\mathbf{x}^*)$ ，则称 $\mathbf{x}^*$ 为相应的严格全局最优解或严格局部最优解。

十二、全局最优与局部最优的关系

全局最优解一定是局部最优解，但局部最优解不一定是全局最优解。

对于形状复杂、具有多个局部低谷的目标函数，仅从局部信息通常难以判断某一部局最优点是否同时为全局最优点。

如果优化算法进入一个局部最优点，而算法本身无法跳出该局部区域，就可能无法进一步寻找全局最优解。

因此，在实际建模中通常有两类处理思路：

1. 尽可能将问题建立为容易获得全局最优解的模型，如线性优化或凸优化模型；
2. 当模型本身十分复杂时，可以将目标转变为寻找一个合适的局部最优解，而非强求全局最优解。

十三、梯度

13.1 梯度的定义

设函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 一阶可微。

$$\text{函数在点 } \mathbf{x} \text{ 处的梯度定义为 } \nabla f(\mathbf{x}) = \begin{bmatrix} \partial f(\mathbf{x})/\partial x_1 \\ \partial f(\mathbf{x})/\partial x_2 \\ \vdots \\ \partial f(\mathbf{x})/\partial x_n \end{bmatrix}$$

梯度是由函数对于各个变量的偏导数组成的列向量。符号 ∇ 在优化教材中，梯度也经常简记为 $\mathbf{g}$

十四、常见函数的梯度

设 $\mathbf{x}, \mathbf{c} \in \mathbb{R}^n$.

14.1 常数函数

若 f 为常数, 则 $\nabla f(\mathbf{x}) = \mathbf{0}$, 若 $f(\mathbf{x}) = \mathbf{c}^T \mathbf{x}$ 则 $\nabla f(\mathbf{x}) = \mathbf{c}$

14.2 向量平方

$f(\mathbf{x}) = \mathbf{x}^T \mathbf{x}$, 则 $\nabla f(\mathbf{x}) = 2\mathbf{x}$

14.3 对称二次型

若 $A = A^T$, 且 $f(\mathbf{x}) = \mathbf{x}^T A \mathbf{x}$, 则 $\nabla f(\mathbf{x}) = 2A\mathbf{x}$

14.4 一般对称二次函数

若 $A = A^T$, 且 $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T A \mathbf{x} + \mathbf{b}^T \mathbf{x} + c$, 则 $\nabla f(\mathbf{x}) = A\mathbf{x} + \mathbf{b}$

十五、Jacobian 矩阵

15.1 定义

设向量值函数 $\mathbf{f}: \mathbb{R}^n \rightarrow \mathbb{R}^m$, 写成 $\mathbf{f}(\mathbf{x}) = \begin{bmatrix} f_1(\mathbf{x}) \\ f_2(\mathbf{x}) \\ \vdots \\ f_m(\mathbf{x}) \end{bmatrix}$, 若各分量函数 $f_1, \dots, f_m$, 均可

微, 则 $\mathbf{f}$ 在 $\mathbf{x}$ 处的导数称为 **Jacobian 矩阵**

定义为 $D\mathbf{f}(\mathbf{x}) = \begin{bmatrix} \partial f_1/\partial x_1 & \partial f_1/\partial x_2 & \cdots & \partial f_1/\partial x_n \\ \partial f_2/\partial x_1 & \partial f_2/\partial x_2 & \cdots & \partial f_2/\partial x_n \\ \vdots & \vdots & \ddots & \vdots \\ \partial f_m/\partial x_1 & \partial f_m/\partial x_2 & \cdots & \partial f_m/\partial x_n \end{bmatrix}$, Jacobian 矩阵一般记为

$D\mathbf{f}(\mathbf{x})$ 或者 $J(\mathbf{x})$

15.2 梯度与 Jacobian 的关系

梯度实际上是标量值多维函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 的导数。

由于梯度采用列向量表示, 而 Jacobian 在 $m=1$ 时为行向量, 因此

$$Df(\mathbf{x}) = \nabla f(\mathbf{x})^T$$

十六、多维函数的链式法则

16.1 一般形式

设复合函数 $h(\mathbf{t}) = g(\mathbf{x}(\mathbf{t}))$ ，其中 $g: \mathbb{R}^n \rightarrow \mathbb{R}$ ，而 $\mathbf{x}(\mathbf{t}) = \begin{bmatrix} x_1(\mathbf{t}) \\ \vdots \\ x_n(\mathbf{t}) \end{bmatrix}$ ， $\mathbf{t} \in \mathbb{R}^m$ ，则复合函数的梯度满足 $\nabla h(\mathbf{t}) = D\mathbf{x}(\mathbf{t})^T \nabla g(\mathbf{x}(\mathbf{t}))$ ，其中 $D\mathbf{x}(\mathbf{t})$ ，表示 $\mathbf{x}(\mathbf{t})$ 关于 $\mathbf{t}$ 的 Jacobian 矩阵。

16.2 函数复合形式

若 $f(\mathbf{x}) = h(g(\mathbf{x}))$ ，则相应的梯度可以写成

$$\nabla f(\mathbf{x}) = Dg(\mathbf{x})^T \nabla h(g(\mathbf{x}))$$

在多维复合函数求导过程中，需要特别注意矩阵相乘的顺序以及各向量、矩阵的维度。

十七、乘积法则

设 $f(\mathbf{x}) = g(\mathbf{x})h(\mathbf{x})$ ，其中 g 和 h 均为标量函数。则梯度满足

$$\nabla f(\mathbf{x}) = \nabla g(\mathbf{x})h(\mathbf{x}) + \nabla h(\mathbf{x})g(\mathbf{x})$$

十八、可行方向

考虑约束优化问题的可行域 $\Omega \subseteq \mathbb{R}^n$ ，设 $\mathbf{x} \in \Omega, \mathbf{d} \in \mathbb{R}^n, \mathbf{d} \neq \mathbf{0}$

如果存在 $\alpha_0 > 0$ ，使得对于所有 $\alpha \in (0, \alpha_0)$ ，均满足 $\mathbf{x} + \alpha \mathbf{d} \in \Omega$ ，则称 $\mathbf{d}$ 为点 $\mathbf{x}$ 处的可行方向。对于约束集的内点 $\mathbf{x}$ ，任意方向 $\mathbf{d} \in \mathbb{R}^n$ ，均为可行方向。

十九、方向导数

19.1 定义

设 $f: \Omega \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ ，并给定方向 $\mathbf{d} \in \mathbb{R}^n$ ，函数 f 在点 $\mathbf{x}$ 沿方向 $\mathbf{d}$ 的方向导数定义为

$$\frac{\partial f(\mathbf{x})}{\partial \mathbf{d}} = \left. \frac{d}{d\alpha} f(\mathbf{x} + \alpha \mathbf{d}) \right|_{\alpha=0^+}$$

等价地，
$$\frac{\partial f(\mathbf{x})}{\partial \mathbf{d}} = \lim_{\alpha \rightarrow 0^+} \frac{f(\mathbf{x} + \alpha \mathbf{d}) - f(\mathbf{x})}{\alpha}$$

若 f 可微，则
$$\frac{\partial f(\mathbf{x})}{\partial \mathbf{d}} = \nabla f(\mathbf{x})^T \mathbf{d}$$

方向导数是一个标量。

二十、函数沿方向的增长率

如果方向 $\mathbf{d}$ 是单位向量，即 $|\mathbf{d}| = 1$

则函数沿 $\mathbf{d}$ 的增长率就是该方向上的方向导数： $\nabla f(\mathbf{x})^T \mathbf{d}$

设 θ 为梯度 $\nabla f(\mathbf{x})$ 与方向 $\mathbf{d}$ 之间的夹角，则 $\nabla f(\mathbf{x})^T \mathbf{d} = |\nabla f(\mathbf{x})| |\mathbf{d}| \cos \theta$

当 $|\mathbf{d}| = 1$ 时， $\nabla f(\mathbf{x})^T \mathbf{d} = |\nabla f(\mathbf{x})| \cos \theta$

二十一、梯度的基本性质

21.1 最大增长方向

在可行域内点处，对于所有单位方向 $|\mathbf{d}| = 1$

方向导数为 $\nabla f(\mathbf{x})^T \mathbf{d}$ ，当 $\mathbf{d}$ 与梯度方向一致时，夹角 $\theta = 0$ ，从而 $\cos \theta = 1$

因此函数沿梯度方向具有最大的增长率。

最大增长方向为 $\mathbf{d} = \frac{\nabla f(\mathbf{x})}{|\nabla f(\mathbf{x})|}$ ，相应地，梯度的反方向是局部意义下函数值下降最

快的方向。

梯度方向具有最大增长率。

21.2 梯度与水平集正交

设 $f(\mathbf{x}) = f(\mathbf{x}_0)$ ，为经过点 $\mathbf{x}_0$ 的水平集。水平集在 $\mathbf{x}_0$ 处的任意切向量都与梯度 $\nabla f(\mathbf{x}_0)$ 正交。

因此，梯度方向是水平集在该点的法向方向。换言之， $\nabla f(\mathbf{x}_0)$ 与经过 $\mathbf{x}_0$ 的水平集垂直。

二十二、Hessian 矩阵

梯度可以视为标量函数的一阶导数，而 Hessian 矩阵描述函数的二阶导数信息。

22.1 定义

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 二阶可微。函数在点 $\mathbf{x}$ 处的 Hessian 矩阵定义为

$$\nabla^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_2 \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_n \partial x_1} \\ \frac{\partial^2 f}{\partial x_1 \partial x_2} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_n \partial x_2} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_1 \partial x_n} & \frac{\partial^2 f}{\partial x_2 \partial x_n} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

Hessian 矩阵也常记作 $F(\mathbf{x})$ 或 $D^2 f(\mathbf{x})$

22.2 Hessian 矩阵的对称性

如果函数的二阶偏导数连续，则混合偏导满足交换关系，因此 Hessian 矩阵为对称矩阵： $\nabla^2 f(\mathbf{x}) = \nabla^2 f(\mathbf{x})^T$

22.3 Taylor 展开

Taylor 展开可以用函数在某一点处的函数值以及各阶导数，对该点附近的函数进

行多项式近似。

二十三、一维函数的二阶 Taylor 展开

设 $f: D \subseteq \mathbb{R} \rightarrow \mathbb{R}$ ，在 x^0 的某个邻域内二阶连续可微，则在 x^0 附近有

$$f(x) = f(x^0) + f'(x^0)(x - x^0) + \frac{1}{2}f''(x^0)(x - x^0)^2 + o((x - x^0)^2)$$

其中 $o((x - x^0)^2)$ 表示相对于 $(x - x^0)^2$ 的高阶无穷小量。

二十四、多维函数的一阶 Taylor 展开

设 $f: D \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ ，且 f 在点 $\mathbf{x}^0$ 的某邻域内一阶连续可微。

对于邻域内任意 $\mathbf{x}$ ，有 $f(\mathbf{x}) = f(\mathbf{x}^0) + \nabla f(\mathbf{x}^0)^T(\mathbf{x} - \mathbf{x}^0) + o(|\mathbf{x} - \mathbf{x}^0|)$

令 $\mathbf{x} = \mathbf{x}^0 + \mathbf{p}$ ，则可以写成 $f(\mathbf{x}^0 + \mathbf{p}) = f(\mathbf{x}^0) + \mathbf{p}^T \nabla f(\mathbf{x}^0) + o(|\mathbf{p}|)$

其中 $o(|\mathbf{p}|)$ 表示关于 $|\mathbf{p}|$ 的高阶无穷小量。

忽略高阶项后，可以得到函数在 $\mathbf{x}^0$ 附近的一阶近似：

$$f(\mathbf{x}^0 + \mathbf{p}) \approx f(\mathbf{x}^0) + \mathbf{p}^T \nabla f(\mathbf{x}^0)$$

二十五、多维函数的二阶 Taylor 展开

设 $f: D \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ ，在 $\mathbf{x}^0$ 的某邻域内二阶连续可微。则对于邻域内任意 $\mathbf{x}$ ，有

$$f(\mathbf{x}) = f(\mathbf{x}^0) + \nabla f(\mathbf{x}^0)^T(\mathbf{x} - \mathbf{x}^0) + \frac{1}{2}(\mathbf{x} - \mathbf{x}^0)^T \nabla^2 f(\mathbf{x}^0)(\mathbf{x} - \mathbf{x}^0) + o(|\mathbf{x} - \mathbf{x}^0|^2)$$

令 $\mathbf{x} = \mathbf{x}^0 + \mathbf{p}$

$$f(\mathbf{x}^0 + \mathbf{p}) = f(\mathbf{x}^0) + \mathbf{p}^T \nabla f(\mathbf{x}^0) + \frac{1}{2}\mathbf{p}^T \nabla^2 f(\mathbf{x}^0)\mathbf{p} + o(|\mathbf{p}|^2)$$

表示关于 $|\mathbf{p}|^2$ 的高阶无穷小量。

这是多维优化中非常重要的局部二次近似公式。

二十六、沿给定方向的一维函数

在优化算法中，经常固定当前位置 $\mathbf{x}$ 和搜索方向 $\mathbf{p}$ ，定义一维函数

$$\phi(\alpha) = f(\mathbf{x} + \alpha \mathbf{p})$$

由多元复合函数的求导法则，有

$$\phi'(\alpha) = \nabla f(\mathbf{x} + \alpha \mathbf{p})^T \mathbf{p}$$

因此，在 $\alpha = 0$ 附近进行二阶 Taylor 展开：

$$\phi(\alpha) = \phi(0) + \phi'(0)\alpha + \frac{1}{2}\phi''(0)\alpha^2 + o(\alpha^2)$$

代入相应表达式，有

$$\phi(\alpha) = f(\mathbf{x}) + \alpha \mathbf{p}^T \nabla f(\mathbf{x}) + \frac{1}{2}\alpha^2 \mathbf{p}^T \nabla^2 f(\mathbf{x})\mathbf{p} + o(\alpha^2)$$

二十七、总结

多维实值函数写为 $f: D \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$

函数的水平集定义为 $S = \{\mathbf{x}: f(\mathbf{x}) = c\}$

常见的多维函数包括线性函数 $f(\mathbf{x}) = \mathbf{a}^T \mathbf{x}$

仿射函数 $f(\mathbf{x}) = \mathbf{a}^T \mathbf{x} + b$

以及二次函数 $f(\mathbf{x}) = \mathbf{x}^T Q \mathbf{x} + \mathbf{b}^T \mathbf{x} + c$

任意二次型矩阵均可以通过 $Q = \frac{1}{2}(A + A^T)$ 对称化。

对称矩阵的正定性可以通过二次型、特征值以及顺序主子式进行判断。

优化问题 $\min_{\mathbf{x} \in \Omega} f(\mathbf{x})$ 中的最优解可分为全局最优解和局部最优解。

对于一阶可微函数，梯度为 $\nabla f(\mathbf{x}) = \begin{bmatrix} \partial f / \partial x_1 \\ \vdots \\ \partial f / \partial x_n \end{bmatrix}$

方向导数满足 $\frac{\partial f(\mathbf{x})}{\partial \mathbf{d}} = \nabla f(\mathbf{x})^T \mathbf{d}$

梯度方向是函数局部最大增长方向，并与水平集正交。

对于二阶可微函数，Hessian 矩阵为 $\nabla^2 f(\mathbf{x}) = \left[\frac{\partial^2 f}{\partial x_i \partial x_j} \right]$

多维函数的二阶 Taylor 展开为

$$f(\mathbf{x} + \mathbf{p}) = f(\mathbf{x}) + \mathbf{p}^T \nabla f(\mathbf{x}) + \frac{1}{2} \mathbf{p}^T \nabla^2 f(\mathbf{x}) \mathbf{p} + o(|\mathbf{p}|^2)$$