

凸集、凸函数与凸优化

一、凸集

设集合 $\Omega \subseteq \mathbb{R}^n$ ，如果对于任意 $\mathbf{x}^{(1)}, \mathbf{x}^{(2)} \in \Omega$ 以及任意 $\alpha \in [0, 1]$ ，都有

$$\alpha \mathbf{x}^{(1)} + (1 - \alpha) \mathbf{x}^{(2)} \in \Omega$$

则称集合 Ω 为**凸集 (convex set)**。

从几何角度来看，若集合中任意两个点之间的整条线段都包含在该集合内，则该集合是凸集。

凸集的概念可以推广到多个点。设 $\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(m)} \in \mathbb{R}^n$ ，以及非负实数 $\alpha_1, \alpha_2, \dots, \alpha_m$ 满足 $\alpha_i \geq 0, \sum_{i=1}^m \alpha_i = 1$ ，则 $\sum_{i=1}^m \alpha_i \mathbf{x}^{(i)}$ 称为这些点的**凸组合**。

集合 Ω 为凸集的充要条件是： Ω 中任意有限个点的凸组合仍属于 Ω 。在优化问题中，经常出现一些具有凸性的基本集合。对于非零向量 $\mathbf{a}$ ，集合

$$\{\mathbf{x} : \mathbf{a}^T \mathbf{x} = b\}$$

称为**超平面**；集合

$$\{\mathbf{x} : \mathbf{a}^T \mathbf{x} \leq b\}$$

称为**半空间**。其中 $\mathbf{a}$ 是相应超平面或半空间边界的法向量，一个超平面将 $\mathbb{R}^n$ 分成两个半空间。

以欧氏距离定义的球可以写为

$$B(\mathbf{x}_c, r) = \{\mathbf{x} : |\mathbf{x} - \mathbf{x}_c|_2 \leq r\}$$

其中 $\mathbf{x}_c$ 为球心， r 为半径。若采用其他范数定义距离，可以得到相应的范数球。椭球可以表示为

$$\{\mathbf{x} : (\mathbf{x} - \mathbf{x}_c)^T P^{-1} (\mathbf{x} - \mathbf{x}_c) \leq 1\}$$

其中 $P = P^T > 0$

多面体是满足有限组线性等式和线性不等式的点的集合，一般写为

$$\{\mathbf{x} : A\mathbf{x} \leq \mathbf{b}, C\mathbf{x} = \mathbf{d}\}$$

因此，多面体可以看作有限个半空间与超平面的交集。

在矩阵空间中，记 $\mathbf{S}^n$ 为 $n \times n$ 对称矩阵的集合，并定义

$$\mathbf{S}_+^n = \{X \in \mathbf{S}^n : X \succeq 0\}$$

$$\mathbf{S}_{++}^n = \{X \in \mathbf{S}^n : X \succ 0\}$$

其中 $\mathbf{S}_+^n$ 称为半正定锥， $\mathbf{S}_{++}^n$ 称为正定锥，它们均为凸集。

凸集还具有一些重要的保凸运算性质。任意多个凸集的交仍然是凸集。对于仿射映射 $f(\mathbf{x}) = A\mathbf{x} + \mathbf{b}$ ，若 $S \subseteq \mathbb{R}^n$ 为凸集，则其仿射像 $\{f(\mathbf{x}) : \mathbf{x} \in S\}$ 仍是凸集；若 $C \subseteq \mathbb{R}^m$ 为凸集，则其逆像 $\{\mathbf{x} : f(\mathbf{x}) \in C\}$ 也是凸集。

因此，缩放、平移和投影等仿射变换均保持凸性。

二、凸函数

设 $f: D \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$, 其中定义域 D 是凸集。如果对于任意 $\mathbf{x}^{(1)}, \mathbf{x}^{(2)} \in D$ 和 $\alpha \in (0, 1)$ 都有 $f(\alpha \mathbf{x}^{(1)} + (1-\alpha)\mathbf{x}^{(2)}) \leq \alpha f(\mathbf{x}^{(1)}) + (1-\alpha)f(\mathbf{x}^{(2)})$, 则称 f 为定义在 D 上的**凸函数 (convex function)**。

如果对于不同的两点, 上式中的不等号可以严格写成 $<$, 则称 f 为**严格凸函数**。

凸函数的定义同样可以推广到有限个点。对于任意正整数 $m \geq 2$, 若 $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)} \in D$ 且 $\alpha_i \geq 0, \sum_{i=1}^m \alpha_i = 1$, 则凸函数满足 $f\left(\sum_{i=1}^m \alpha_i \mathbf{x}^{(i)}\right) \leq \sum_{i=1}^m \alpha_i f(\mathbf{x}^{(i)})$

此外, 如果 f 是凸函数, 则 $-f$ 是凹函数。

对于可微函数, 可以通过一阶条件判断其凸性。设 $f: D \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ 在凸集 D 上可微, 则 f 在 D 上为凸函数的充要条件是: 对于任意 $\mathbf{x}, \mathbf{y} \in D$ 均有

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x})$$

这一条件表明, 可微凸函数的图像始终位于其任意一点处切平面的上方。

这一结论的必要性可以由凸函数定义与一阶 Taylor 展开得到。由凸性,

$$f(\mathbf{x} + \alpha(\mathbf{y} - \mathbf{x})) \leq (1-\alpha)f(\mathbf{x}) + \alpha f(\mathbf{y})$$

整理得 $f(\mathbf{y}) - f(\mathbf{x}) \geq \frac{f(\mathbf{x} + \alpha(\mathbf{y} - \mathbf{x})) - f(\mathbf{x})}{\alpha}$, 当 $\alpha \rightarrow 0$ 时, 右端趋于 $\nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x})$, 从而得到 $f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x})$

反过来, 若上述一阶条件成立, 对于 $\mathbf{z} = \alpha \mathbf{x} + (1-\alpha)\mathbf{y}$, 分别对 $\mathbf{x}$ 和 $\mathbf{y}$ 应用一阶条件, 再按权重 α 和 $1-\alpha$ 相加, 即可得到 $f(\mathbf{z}) \leq \alpha f(\mathbf{x}) + (1-\alpha)f(\mathbf{y})$, 因此 f 是凸函数。

对于二阶连续可微函数, 通常可以利用 Hessian 矩阵更加方便地判断凸性。设 D 是凸集, 函数 $f: D \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ 在 D 上二阶连续可微, 则 f 在 D 上为凸函数的充要条件是 $\nabla^2 f(\mathbf{x}) \geq 0, \forall \mathbf{x} \in D$, 即函数在整个定义域上的 Hessian 矩阵均为半正定矩阵。

对于二次函数 $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T Q \mathbf{x} - \mathbf{b}^T \mathbf{x}$, 若 $Q = Q^T \geq 0$, 则该函数为凸函数。

最小二乘函数 $f(\mathbf{x}) = \frac{1}{2} \|A\mathbf{x} - \mathbf{b}\|_2^2$ 的 Hessian 矩阵为 $\nabla^2 f(\mathbf{x}) = A^T A$, 而 $A^T A$ 为半正定矩阵, 因此最小二乘目标函数属于凸函数。

常见凸函数还包括仿射函数 $f(\mathbf{x}) = \mathbf{a}^T \mathbf{x} + b$;

指数函数 $f(x) = e^{ax}$;

幂函数 $f(x) = x^\alpha, x > 0$, 其中当 $\alpha \geq 1$ 或 $\alpha \leq 0$ 时该函数为凸函数;

负熵函数 $f(x) = x \ln x, x > 0$ 也是凸函数。

此外, 所有范数函数均为凸函数。

三、凸优化问题

设优化问题为 $p^* = \min_{\mathbf{x} \in \Omega} f(\mathbf{x})$ ，如果可行域 Ω 是凸集，并且目标函数 $f(\mathbf{x})$ 在其定义域上是凸函数，则该问题称为**凸优化问题（convex optimization problem）**。

凸优化问题通常写成

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^n} \quad & f(\mathbf{x}) \\ \text{s.t.} \quad & g_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, q, \quad h_j(\mathbf{x}) = 0, \quad j = 1, \dots, m \end{aligned}$$

为了使上述问题成为凸优化问题，需要满足： $f(\mathbf{x})$ 是凸函数， $g_i(\mathbf{x}), i = 1, \dots, q$ 均为凸函数，而等式约束函数 $h_j(\mathbf{x})$ 均为仿射函数。

由于 g_i 是凸函数，其次水平集 $\Omega_i = \{\mathbf{x}: g_i(\mathbf{x}) \leq 0\}$ 是凸集；仿射等式约束 $h_j(\mathbf{x}) = 0$ ，所对应的集合也是凸集。又由于凸集的交仍然是凸集，因此整个可行域是凸集。

由于等式约束必须为仿射形式，因此凸优化问题也经常统一写成

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^n} \quad & f(\mathbf{x}) \\ \text{s.t.} \quad & g_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, q, \quad A\mathbf{x} = \mathbf{b} \end{aligned}$$

其中 f 和所有 g_i 均为凸函数。

如果没有约束，则问题退化为 $\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x})$

只要 f 为凸函数，该问题就是无约束凸优化问题。

凸优化问题最重要的性质是：凸优化问题的任意局部最优解都是全局最优解。

设 $\mathbf{x}^{(1)}$ 是局部最优解。若其不是全局最优解，则存在另一个可行点，使得 $f(\mathbf{x}^{(2)}) < f(\mathbf{x}^{(1)})$ ，由于可行域为凸集，对于任意 $\alpha \in (0, 1)$ ，点 $\alpha\mathbf{x}^{(1)} + (1-\alpha)\mathbf{x}^{(2)}$ 仍属于可行域。又因为 f 是凸函数， $f(\alpha\mathbf{x}^{(1)} + (1-\alpha)\mathbf{x}^{(2)}) \leq \alpha f(\mathbf{x}^{(1)}) + (1-\alpha)f(\mathbf{x}^{(2)})$ ，由于 $f(\mathbf{x}^{(2)}) < f(\mathbf{x}^{(1)})$ ， $f(\alpha\mathbf{x}^{(1)} + (1-\alpha)\mathbf{x}^{(2)}) < f(\mathbf{x}^{(1)})$ ，当 α 足够接近 1 时，上述点可以任意接近 $\mathbf{x}^{(1)}$ ，这与 $\mathbf{x}^{(1)}$ 是局部最优解相矛盾。

因此，局部最优解必然是全局最优解。正是由于这一性质，在实际建模中通常优先考虑将问题建立为凸优化模型，因为一旦找到局部最优解，就可以保证已经获得全局最优解。

四、常见凸优化问题

凸优化包含若干重要的标准模型。

线性优化（Linear Program）的目标函数和约束均为线性或仿射形式，可以写为

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^n} \quad & \mathbf{c}^T \mathbf{x} \\ \text{s.t.} \quad & \mathbf{a}_i^T \mathbf{x} - b_i \leq 0, \quad i = 1, \dots, m, \quad \mathbf{d}_j^T \mathbf{x} - e_j = 0, \quad j = 1, \dots, p \end{aligned}$$

二次优化（Quadratic Program）具有二次目标函数和线性约束，其基本形式为

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^n} \quad & \frac{1}{2} \mathbf{x}^T Q \mathbf{x} + \mathbf{c}^T \mathbf{x} \\ \text{s.t.} \quad & \mathbf{a}_i^T \mathbf{x} - b_i \leq 0, \quad i = 1, \dots, m, \quad \mathbf{d}_j^T \mathbf{x} - e_j = 0, \quad j = 1, \dots, p \end{aligned}$$

其中 $Q = Q^T \succeq 0$

二阶锥优化（Second-Order Cone Program）可以包含形如

$$\|A_i \mathbf{x} + \mathbf{b}_i\|_2 \leq \mathbf{c}_i^T \mathbf{x} + d$$

的二阶锥约束。其一般形式可表示为

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^n} \quad & \mathbf{c}^T \mathbf{x} \\ \text{s.t.} \quad & \|A_i \mathbf{x} + \mathbf{b}_i\|_2 \leq \mathbf{c}_i^T \mathbf{x} + d_i, \quad i = 1, \dots, m, \quad \mathbf{d}_j^T \mathbf{x} - e_j = 0, \quad j = 1, \dots, p \end{aligned}$$

半正定优化（Semidefinite Program）则包含矩阵半正定约束，其基本形式为

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^n} \quad & \mathbf{c}^T \mathbf{x} \\ \text{s.t.} \quad & F_0 + \sum_{i=1}^n x_i F_i \succeq 0 \end{aligned}$$

其中 $F_0, F_1, \dots, F_n$ 均为对称矩阵。

从结构上看，线性优化、凸二次优化、二阶锥优化以及半正定优化都属于凸优化的重要类别。

五、总结

凸集要求集合中任意两点之间的线段仍然位于集合内，即 $\mathbf{x}^{(1)}, \mathbf{x}^{(2)} \in D, \alpha \in [0, 1]$ 时， $\alpha \mathbf{x}^{(1)} + (1 - \alpha) \mathbf{x}^{(2)} \in D$ ，常见的凸集包括超平面、半空间、球、椭圆、多面体以及半正定锥。

凸函数定义在凸集上，并满足

$$f(\alpha \mathbf{x}^{(1)} + (1 - \alpha) \mathbf{x}^{(2)}) \leq \alpha f(\mathbf{x}^{(1)}) + (1 - \alpha) f(\mathbf{x}^{(2)})$$

对于可微函数，可以利用一阶条件

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x})$$

判断凸性；对于二阶连续可微函数，可以利用

$$\nabla^2 f(\mathbf{x}) \succeq 0$$

判断凸性。

凸优化问题是可行域为凸集、目标函数为凸函数的最小化问题。对于带约束问题，通常要求不等式约束函数为凸函数，而等式约束必须为仿射函数。

凸优化最重要的性质是局部最优解 $\implies$ 全局最优解