

多维无约束优化：模型与最优性条件

多维无约束优化问题的一般形式为 $\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x})$

无约束优化是多维优化的基础。一方面，大量实际模型可以直接表示为无约束优化问题；另一方面，多维无约束优化算法往往需要调用前面介绍的一维搜索方法，同时也是进一步研究约束优化问题的重要基础。

一、无约束优化及回归模型

在机器学习中，许多模型训练问题本质上都可以表示为目标函数的无约束最小化。其中，回归分析是一类典型问题。回归分析通过建立变量之间的数学关系，根据输入变量预测目标变量。课件中主要涉及线性回归，并指出线性回归用于监督学习中的预测，而逻辑回归主要用于分类。

设训练数据为 $\{(\mathbf{x}^{(i)}, y_i)\}_{i=1}^m$ ，其中 $\mathbf{x}^{(i)} \in \mathbb{R}^l$ ，表示第 i 个样本的 l 个特征， y_i 表示相应的观测值或标签。线性回归希望建立线性模型 $h_{\mathbf{w}, b}(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$ ，使得对于每一个样本， $h_{\mathbf{w}, b}(\mathbf{x}^{(i)}) \approx y_i$ ，因此，模型训练的本质就是确定参数 $\mathbf{w} = (w_1, \dots, w_l)^T$ 和截距 b 。衡量预测值与真实值之间差异的一种常用方式是均方误差

$$MSE(\mathbf{w}, b) = \frac{1}{m} \sum_{i=1}^m (\mathbf{w}^T \mathbf{x}^{(i)} + b - y_i)^2$$

因此，线性回归可以表示为无约束优化问题 $\min_{\mathbf{w}, b} \sum_{i=1}^m (\mathbf{w}^T \mathbf{x}^{(i)} + b - y_i)^2$

这种通过最小化误差平方和求取参数的方法称为**最小二乘法 (least squares method)**。从几何角度看，其目标是寻找一条直线或一个超平面，使所有样本点到该模型的残差平方和尽可能小。

为了写成更紧凑的矩阵形式，将 $\mathbf{w}$ 与 b 合并为 $\hat{\mathbf{w}} = \begin{bmatrix} \mathbf{w} \\ b \end{bmatrix} \in \mathbb{R}^{l+1}$

并令 $\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix}$ ，定义数据矩阵 $X = \begin{bmatrix} (\mathbf{x}^{(1)})^T & 1 \\ (\mathbf{x}^{(2)})^T & 1 \\ \vdots & \vdots \\ (\mathbf{x}^{(m)})^T & 1 \end{bmatrix} \in \mathbb{R}^{m \times (l+1)}$ ，则最小二乘问题可

以写为 $\min_{\hat{\mathbf{w}} \in \mathbb{R}^{l+1}} \|X\hat{\mathbf{w}} - \mathbf{y}\|_2^2$

除平方误差之外，还可以采用其他误差度量。例如，可以最小化误差绝对值之和：

$$\min_{\mathbf{w}, b} \sum_{i=1}^m |\mathbf{w}^T \mathbf{x}^{(i)} + b - y_i|$$

也可以最小化所有样本中的最大绝对偏差： $\min_{\mathbf{w}, b} \max_i |\mathbf{w}^T \mathbf{x}^{(i)} + b - y_i|$

这些模型同样都属于无约束优化问题。

实际建模中还经常在拟合误差基础上增加正则项。最小二乘问题的最优解不一定唯一；当 X 列满秩时最优解唯一，否则可能存在多个最优解。为了获得具有特定性质

的参数，可以采用正则化方法。

采用 l_1 范数作为正则项，可得到 $\min_{\hat{\mathbf{w}}} \|X\hat{\mathbf{w}} - \mathbf{y}\|_2^2 + \mu \|\hat{\mathbf{w}}\|_1, \mu \geq 0$ ，其中 $\mu \|\hat{\mathbf{w}}\|_1$ ，为正则项。该模型称为 LASSO， l_1 正则项通常用于促进参数解的稀疏性。

另一种常见方法是使用 l_2 正则项： $\min_{\hat{\mathbf{w}}} \|X\hat{\mathbf{w}} - \mathbf{y}\|_2^2 + \mu \|\hat{\mathbf{w}}\|_2^2, \mu \geq 0$

这就是岭回归 (Ridge Regression)。参数 μ 用于在模型拟合误差与参数大小之间进行权衡。当 $\mu > 0$ 时，该目标函数具有唯一的全局最优解。

二、无约束优化的最优性条件

对于一般无约束优化问题 $\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x})$ ，一个基本问题是：如何判断某一点是否可能为局部极小点？

为此，需要利用函数的一阶和二阶导数建立最优性条件。

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 一阶连续可微。如果 $\mathbf{x}^*$ 是局部极小点，则必须有 $\nabla f(\mathbf{x}^*) = \mathbf{0}$ ，这一条件称为一阶必要条件 (First-Order Necessary Condition, FONC)。

其证明可以利用下降方向与 Taylor 展开。假设 $\nabla f(\mathbf{x}^*) \neq \mathbf{0}$ ，取方向 $\mathbf{d} = -\nabla f(\mathbf{x}^*)$ ，定义 $\phi(\alpha) = f(\mathbf{x}^* + \alpha \mathbf{d})$ ，对于充分小的 $\alpha > 0$ ，由一阶 Taylor 展开

$$f(\mathbf{x}^* + \alpha \mathbf{d}) = f(\mathbf{x}^*) + \alpha \mathbf{d}^T \nabla f(\mathbf{x}^*) + o(\alpha)$$

由于 $\mathbf{d} = -\nabla f(\mathbf{x}^*)$ ，因此 $\mathbf{d}^T \nabla f(\mathbf{x}^*) = -\|\nabla f(\mathbf{x}^*)\|_2^2 < 0$ ，于是，对于充分小的 $\alpha > 0$ ， $f(\mathbf{x}^* + \alpha \mathbf{d}) < f(\mathbf{x}^*)$ ，这与 $\mathbf{x}^*$ 为局部极小点矛盾，所以必须有 $\nabla f(\mathbf{x}^*) = \mathbf{0}$ 。

满足 $\nabla f(\mathbf{x}) = \mathbf{0}$ 的点称为驻点或平稳点。需要特别注意，驻点并不一定是局部极小点，它也可能是局部极大点或鞍点。

若进一步假设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 二阶连续可微，则局部极小点还必须满足二阶条件。若 $\mathbf{x}^*$ 是局部极小点，则 $\nabla f(\mathbf{x}^*) = \mathbf{0}$ ，且 $\nabla^2 f(\mathbf{x}^*) \geq 0$ ，这称为二阶必要条件 (Second-Order Necessary Condition, SONC)。

证明的核心仍然是二阶 Taylor 展开。由一阶必要条件已有 $\nabla f(\mathbf{x}^*) = \mathbf{0}$

若 Hessian 矩阵不是半正定的，则存在非零方向 $\mathbf{d}$ ，使 $\mathbf{d}^T \nabla^2 f(\mathbf{x}^*) \mathbf{d} < 0$

对于充分小的 $\alpha > 0$

$$f(\mathbf{x}^* + \alpha \mathbf{d}) = f(\mathbf{x}^*) + \alpha \mathbf{d}^T \nabla f(\mathbf{x}^*) + \frac{1}{2} \alpha^2 \mathbf{d}^T \nabla^2 f(\mathbf{x}^*) \mathbf{d} + o(\alpha^2)$$

由于 $\nabla f(\mathbf{x}^*) = \mathbf{0}$ ，且 $\mathbf{d}^T \nabla^2 f(\mathbf{x}^*) \mathbf{d} < 0$

因此对于充分小的 α ， $f(\mathbf{x}^* + \alpha \mathbf{d}) < f(\mathbf{x}^*)$ 从而与局部极小性矛盾。

因此 Hessian 必须半正定。

需要强调，一阶必要条件和二阶必要条件都只是必要条件，而不是充分条件。也就是说，满足 $\nabla f(\mathbf{x}^*) = \mathbf{0}$ 甚至同时满足 $\nabla^2 f(\mathbf{x}^*) \geq 0$ 仍然不能保证 $\mathbf{x}^*$ 一定是局部极小点。为了得到能够保证局部极小的条件，可以使用二阶充分条件。

设 f 二阶连续可微，如果某点 $\mathbf{x}^*$ 满足 $\nabla f(\mathbf{x}^*) = \mathbf{0}$ ，且 $\nabla^2 f(\mathbf{x}^*) \succ 0$ ，则 $\mathbf{x}^*$ 是一个严格局部极小点。这一结论称为二阶充分条件 (Second-Order Sufficient Condition,

SOSC)。

证明同样利用二阶 Taylor 展开。令 $\mathbf{x} = \mathbf{x}^* + \alpha \mathbf{d}, \mathbf{d} \neq 0$ ，则

$$f(\mathbf{x}^* + \alpha \mathbf{d}) = f(\mathbf{x}^*) + \alpha \mathbf{d}^T \nabla f(\mathbf{x}^*) + \frac{1}{2} \alpha^2 \mathbf{d}^T \nabla^2 f(\mathbf{x}^*) \mathbf{d} + o(\alpha^2)$$

因为 $\nabla f(\mathbf{x}^*) = \mathbf{0}$ ，而 $\nabla^2 f(\mathbf{x}^*) \succ 0$ ，所以对于任意非零 $\mathbf{d}$ ， $\mathbf{d}^T \nabla^2 f(\mathbf{x}^*) \mathbf{d} > 0$ ，因此 $\mathbf{x}^*$ 的充分小邻域内， $f(\mathbf{x}) > f(\mathbf{x}^*)$ ， $\mathbf{x} \neq \mathbf{x}^*$ ，故 $\mathbf{x}^*$ 是严格局部极小点。

需要注意，二阶充分条件同样不是局部极小点的必要条件。也就是说，一个点即使是局部极小点，其 Hessian 也未必正定。实际优化计算中，经常首先寻找满足 $\nabla f(\mathbf{x}) = \mathbf{0}$ 的驻点，而这些驻点是否进一步满足二阶充分条件，则需要继续检查。

因此，对于二阶连续可微函数，可以将驻点处 Hessian 的性质概括为：

$$\nabla f(\mathbf{x}^*) = \mathbf{0}, \nabla^2 f(\mathbf{x}^*) \succ 0$$

说明 $\mathbf{x}^*$ 是严格局部极小点；

$\nabla f(\mathbf{x}^*) = \mathbf{0}, \nabla^2 f(\mathbf{x}^*) \prec 0$ 对应局部极大点；而 Hessian 为不定矩阵时，该驻点不能是局部极小点或局部极大点，通常表现为鞍点。如果 Hessian 仅为半正定或半负定，则仅凭二阶信息通常无法确定该驻点的具体类型。

三、凸函数的无约束最优性条件

对于一般非凸函数， $\nabla f(\mathbf{x}^*) = \mathbf{0}$ ，只能说明 $\mathbf{x}^*$ 是驻点，并不能保证它是局部极小点，更不能保证它是全局最优解。

对于凸函数，情况则明显不同。设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 为连续可微凸函数，则对于任意 $\mathbf{x}^* \in \mathbb{R}^n$ ，有 $\nabla f(\mathbf{x}^*) = \mathbf{0} \iff \mathbf{x}^*$ 是 $\min_{\mathbf{x}} f(\mathbf{x})$ 的全局最优解。

因此，对于连续可微凸函数，FONC 不再只是必要条件，而成为全局最优的充要条件。

证明可以直接利用凸函数的一阶性质。若 $\nabla f(\mathbf{x}^*) = \mathbf{0}$ ，则对于任意 $\mathbf{x} \in \mathbb{R}^n$ ，由凸函数的一阶条件， $f(\mathbf{x}) \geq f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^T (\mathbf{x} - \mathbf{x}^*)$ ，代入 $\nabla f(\mathbf{x}^*) = \mathbf{0}$ 得到 $f(\mathbf{x}) \geq f(\mathbf{x}^*)$ ，因此 $\mathbf{x}^*$ 是全局最优解。

反过来，如果 $\mathbf{x}^*$ 是全局最优解，那么它必然也是局部最优解。由一般无约束优化的一阶必要条件可得 $\nabla f(\mathbf{x}^*) = \mathbf{0}$ ，需要注意，这一条件是对一个给定点是否最优进行判定，并不能保证一个具体凸函数一定存在最优解。

也就是说， $\nabla f(\mathbf{x}^*) = \mathbf{0} \iff \mathbf{x}^*$ 为全局最优解的前提是存在这样的 $\mathbf{x}^*$ ，特别指出，即使一个函数是严格凸函数，也可能在整个 $\mathbb{R}^n$ 上不存在能够达到的最小值。

这一区别在无约束优化中十分重要。对于一般函数，通常需要先解方程 $\nabla f(\mathbf{x}) = \mathbf{0}$ ，得到所有驻点，再利用 Hessian 判断其局部性质；而对于可微凸函数，只要找到满足 $\nabla f(\mathbf{x}) = \mathbf{0}$ 的点，就已经找到了全局最优解。

四、最优性条件之间的关系

无约束优化中的一阶和二阶条件可以集中整理如下。

对于一阶连续可微函数，若 $\mathbf{x}^*$ 是局部极小点，则 $\nabla f(\mathbf{x}^*) = \mathbf{0}$ ，这是一阶必要条件

FONC。

对于二阶连续可微函数，若 $\mathbf{x}^*$ 是局部极小点，则进一步有 $\nabla f(\mathbf{x}^*) = 0, \nabla^2 f(\mathbf{x}^*) \succeq 0$ ，这是二阶必要条件 SONC。

反过来，如果 $\nabla f(\mathbf{x}^*) = 0, \nabla^2 f(\mathbf{x}^*) \succ 0$ ，则 $\mathbf{x}^*$ 一定是严格局部极小点。这是二阶充分条件 SOSC。

五、总结

多维无约束优化研究的问题为 $\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x})$ ，线性回归、最小二乘模型以及带正则项的回归模型都可以表示为这一基本形式。

普通最小二乘问题可以写成 $\min_{\mathbf{w}} \|\mathbf{X}\hat{\mathbf{w}} - \mathbf{y}\|_2^2$

LASSO 模型为 $\min_{\mathbf{w}} \|\mathbf{X}\hat{\mathbf{w}} - \mathbf{y}\|_2^2 + \mu \|\hat{\mathbf{w}}\|_1$

岭回归为 $\min_{\mathbf{w}} \|\mathbf{X}\hat{\mathbf{w}} - \mathbf{y}\|_2^2 + \mu \|\hat{\mathbf{w}}\|_2^2$

对于一般连续可微函数，局部极小点必须满足一阶必要条件 $\nabla f(\mathbf{x}^*) = 0$

对于二阶连续可微函数，局部极小点还必须满足 $\nabla^2 f(\mathbf{x}^*) \succeq 0$

若进一步满足 $\nabla^2 f(\mathbf{x}^*) \succ 0$ ，则该驻点是严格局部极小点。

因此，在一般无约束优化中，求解过程通常首先寻找满足 $\nabla f(\mathbf{x}) = 0$ 的驻点，然后利用 Hessian 矩阵进一步分析驻点性质。

而对于连续可微凸函数， $\nabla f(\mathbf{x}^*) = 0$ ，已经成为全局最优解的充要条件：

$$\nabla f(\mathbf{x}^*) = 0 \iff \mathbf{x}^* \text{ 是全局最优解}$$

这也是凸优化相比一般非凸优化具有良好求解性质的重要原因。