

多维无约束优化：下降法

对于无约束优化问题 $\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x})$ ，理论上可以通过求解一阶最优性条件 $\nabla f(\mathbf{x}) = 0$ ，来寻找驻点。但在实际问题中，直接求解这一方程往往比较困难。一方面，数据规模和变量维度可能很大；另一方面，一阶最优性条件本身可能构成复杂的非线性方程组。因此，在实际求解多维无约束优化问题时，更常采用迭代式的下降方法。

一、下降法的基本框架

下降法的基本思想是从一个初始点出发，不断寻找能够使目标函数值减小的方向，并沿该方向移动一定距离，从而得到新的迭代点。

设当前迭代点为 $\mathbf{x}^{(k)}$ ，选择一个方向 $\mathbf{d}^{(k)}$ ，并确定步长 $\alpha_k > 0$ ，则下一次迭代点为 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}$ ，希望新的迭代点满足 $f(\mathbf{x}^{(k+1)}) < f(\mathbf{x}^{(k)})$

因此，一个典型的下降算法可以概括为：首先给定初始点，然后在每一步构造下降方向，再确定适当步长并完成更新，直到满足停机条件。

在机器学习中，步长因子 α_k 也经常称为学习率。按照这一过程可以得到迭代序列

$$\{\mathbf{x}^{(k)}\}_{k=0}^{\infty}$$

若存在极小点 $\mathbf{x}^*$ 使得 $\lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \mathbf{x}^*$ ，则称该算法收敛到 $\mathbf{x}^*$ 。

从算法设计角度看，下降法主要包含三个核心问题：如何选择下降方向，如何选择步长，以及如何定义停机规则。不同下降算法之间的主要差别通常体现在下降方向和步长策略上。

二、下降方向

设函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ，在当前点 $\mathbf{x}^{(k)}$ 处一阶可微。若某个非零方向 $\mathbf{d}$ 满足 $\nabla f(\mathbf{x}^{(k)})^T \mathbf{d} < 0$ ，则称 $\mathbf{d}$ 为 f 在 $\mathbf{x}^{(k)}$ 处的下降方向。

由一阶 Taylor 展开

$$f(\mathbf{x}^{(k)} + \alpha \mathbf{d}) = f(\mathbf{x}^{(k)}) + \alpha \nabla f(\mathbf{x}^{(k)})^T \mathbf{d} + o(\alpha)$$

如果 $\nabla f(\mathbf{x}^{(k)})^T \mathbf{d} < 0$ ，则对于充分小的正数 α ，有 $f(\mathbf{x}^{(k)} + \alpha \mathbf{d}) < f(\mathbf{x}^{(k)})$ ，因此，只要选择了下降方向，就一定能够找到一个足够小的正步长，使目标函数值下降。

最常见的下降方向是负梯度方向 $\mathbf{d}^{(k)} = -\nabla f(\mathbf{x}^{(k)})$ ，因为此时 $\nabla f(\mathbf{x}^{(k)})^T \mathbf{d}^{(k)} = -\|\nabla f(\mathbf{x}^{(k)})\|_2^2$

只要当前点不是驻点，上式严格小于零，因此负梯度必然是下降方向。

不同算法通常采用不同方式构造下降方向。后续常见方法包括梯度下降法、共轭梯度法、Newton 法以及拟 Newton 法。其中梯度下降法和共轭梯度法主要使用一阶信息，Newton 法使用二阶信息，而拟 Newton 法通过一阶信息近似构造二阶信息。

三、步长选择与线搜索

确定下降方向后，还需要决定沿该方向移动多远，即确定步长 α_k 。最简单的方法是采用固定步长，即在所有迭代中使用同一个 α_k 。这种方法实现简单，但步长过小时

可能导致收敛很慢，步长过大时又可能导致迭代发生较大振荡。

也可以采用衰减步长，例如 $\alpha_k = \alpha_0 \gamma^{k-1}$ ，其中 $0 < \gamma < 1$ ，这种方法在带有噪声的目标函数中比较常见。

更系统的方法是线搜索。对于给定的当前点和搜索方向，定义一维函数

$$\phi_k(\alpha) = f(\mathbf{x}^{(k)} + \alpha \mathbf{d}^{(k)})$$

于是多维优化中的步长选择问题转化为一维优化问题。

3.1 精确线搜索

精确线搜索要求选择使该方向上目标函数取得最小值的步长

$$\alpha_k = \arg \min_{\alpha \geq 0} \phi_k(\alpha)$$

等价地， $\alpha_k = \arg \min_{\alpha \geq 0} f(\mathbf{x}^{(k)} + \alpha \mathbf{d}^{(k)})$ ，因此，精确线搜索本质上是在当前射线上求解一个一维最优化问题，可以调用前面介绍的一维搜索方法。

若 f 一阶连续可微，并且 α_k 是精确线搜索得到的步长，则新的迭代点满足

$$\nabla f(\mathbf{x}^{(k+1)})^T \mathbf{d}^{(k)} = 0$$

证明可由一维函数 $\phi_k(\alpha) = f(\mathbf{x}^{(k)} + \alpha \mathbf{d}^{(k)})$ 得到 $\phi_k'(\alpha) = \nabla f(\mathbf{x}^{(k)} + \alpha \mathbf{d}^{(k)})^T \mathbf{d}^{(k)}$ ，由于 α_k 是 ϕ_k 的极小点，根据一维一阶必要条件 $\phi_k'(\alpha_k) = 0$ ，因此 $\nabla f(\mathbf{x}^{(k+1)})^T \mathbf{d}^{(k)} = 0$ ，也就是说，在精确线搜索下，新迭代点处的梯度与上一轮搜索方向正交。

若搜索方向取为负梯度方向 $\mathbf{d}^{(k)} = -\nabla f(\mathbf{x}^{(k)})$ ，并配合精确线搜索，则该方法称为最速下降法。

3.2 近似线搜索

精确线搜索需要在每一步中求解一个完整的一维优化问题，计算代价可能较高，而且沿搜索方向得到的一维函数也不一定具有简单结构。因此，实际计算中更常采用近似线搜索。

近似线搜索并不要求找到最优步长，而是寻找一个满足一定条件的可接受步长。其中最基本的是 Armijo 充分下降条件。设 $0 < \beta < 1$

若步长 α 满足

$$f(\mathbf{x}^{(k+1)}) \leq f(\mathbf{x}^{(k)}) + \alpha \beta \nabla f(\mathbf{x}^{(k)})^T \mathbf{d}^{(k)}$$

则称该步长满足 Armijo 条件。

由于 $\mathbf{d}^{(k)}$ 是下降方向，因此 $\nabla f(\mathbf{x}^{(k)})^T \mathbf{d}^{(k)} < 0$ ，所以 Armijo 条件要求新点的函数值不仅要下降，而且下降量还需要达到一定程度。

一个常用的实现方式是回溯线搜索。算法从一个较大的初始步长开始，如果当前步长满足 Armijo 条件，则接受该步长；否则乘以缩减因子并继续测试。设缩减因子为 $0 < \rho < 1$ ，则步长不断按照 $\alpha \leftarrow \rho \alpha$ 减小，直到满足充分下降条件。

仅满足充分下降条件仍可能出现步长过小的问题。步长虽然可以使目标函数下降，但如果下降幅度太小，算法可能推进缓慢。因此，还可以进一步引入曲率条件。

曲率条件要求 $\nabla f(\mathbf{x}^{(k+1)})^T \mathbf{d}^{(k)} \geq \sigma \nabla f(\mathbf{x}^{(k)})^T \mathbf{d}^{(k)}$

其中通常有 $\beta < \sigma < 1$ ，该条件用于避免选择过小的步长，并要求新的方向导数发

生足够变化。

更严格的强曲率条件为 $|\nabla f(\mathbf{x}^{(k+1)})^T \mathbf{d}^{(k)}| \leq -\sigma \nabla f(\mathbf{x}^{(k)})^T \mathbf{d}^{(k)}$

Armijo 条件与曲率条件组合后称为 Wolfe 条件, Armijo 条件与强曲率条件组合后称为强 Wolfe 条件。实际线搜索算法常通过先确定适当区间, 再在该区间内寻找满足 Wolfe 或强 Wolfe 条件的步长。

从理论上讲, 若算法到达满足 $\nabla f(\mathbf{x}^{(k)}) = 0$ 的点, 则满足无约束优化的一阶必要条件, 可以考虑停止迭代。

但在数值计算中, 由于舍入误差和计算误差, 梯度通常很难精确等于零, 因此实际算法一般采用近似停机条件。

一种常见方法是判断梯度范数是否足够小 $\|\nabla f(\mathbf{x}^{(k)})\| < \varepsilon$, 也可以设置最大迭代次数 $k > k_{\max}$, 此外, 还可以根据连续两次迭代的目标函数值变化判断是否停止。例如绝对变化满足

$$|f(\mathbf{x}^{(k+1)}) - f(\mathbf{x}^{(k)})| < \varepsilon$$

或者相对变化满足

$$\frac{|f(\mathbf{x}^{(k+1)}) - f(\mathbf{x}^{(k)})|}{\max\{1, |f(\mathbf{x}^{(k)})|\}} < \varepsilon$$

实际算法中往往会综合使用多个条件, 以避免由于某一个单独条件过早停止。

如果目标函数存在多个局部最优解, 还可以使用随机重启策略, 即在一次下降算法结束后重新随机生成初始点, 再运行下降法, 以增加搜索到更优局部解的可能性。

四、总结

下降法是求解多维无约束优化问题的一类基本迭代方法, 其统一迭代形式为

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}$$

算法设计的核心在于选择下降方向、确定步长以及设置停机条件。

下降方向需要满足

$$\nabla f(\mathbf{x}^{(k)})^T \mathbf{d}^{(k)} < 0$$

负梯度是最基本的下降方向

$$\mathbf{d}^{(k)} = -\nabla f(\mathbf{x}^{(k)})$$

步长可以采用固定步长、衰减步长或线搜索方法。精确线搜索求解

$$\alpha_k = \arg \min_{\alpha \geq 0} f(\mathbf{x}^{(k)} + \alpha \mathbf{d}^{(k)})$$

并具有正交性质

$$\nabla f(\mathbf{x}^{(k+1)})^T \mathbf{d}^{(k)} = 0$$

近似线搜索通常采用 Armijo 条件、Wolfe 条件或强 Wolfe 条件, 在保证充分下降的同时避免步长过小。

实际计算中的停机规则通常结合梯度大小、函数值变化和最大迭代次数共同判断。

因此, 下降法的基本逻辑可以概括为: 在当前点构造一个能够降低目标函数值的方向, 在该方向上选择合适步长, 并不断重复这一过程, 直到满足给定的收敛标准。