

多维无约束优化：一阶方法

对于无约束优化问题 $\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x})$

一阶方法是指在迭代过程中主要利用目标函数的一阶导数信息构造搜索方向的方法。虽然某些优化问题可以直接通过求解一阶最优性条件获得解析解 $\nabla f(\mathbf{x}) = 0$ ，但对于高维问题，直接求解方程组可能具有较高的计算代价。因此，在大规模优化中，利用梯度信息逐步产生迭代点的一阶方法具有重要作用。

本章主要讨论梯度法和共轭梯度法。

一、梯度法

梯度法在当前迭代点处选择负梯度作为下降方向。设当前点为 $\mathbf{x}^{(k)}$ ，则搜索方向取为 $\mathbf{d}^{(k)} = -\nabla f(\mathbf{x}^{(k)})$ ，因此迭代公式为 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha_k \nabla f(\mathbf{x}^{(k)})$ ，其中 α_k 为第 k 次迭代的步长。

由于负梯度方向是函数在当前点处局部下降最快的方向，因此梯度法是最基本的一类下降算法。根据步长的选择方式，可以形成不同形式的梯度方法。

固定步长梯度法在整个迭代过程中采用固定步长

$$\alpha_k = \alpha_0$$

衰减步长梯度法则使步长随着迭代逐渐减小，例如

$$\alpha_k = \alpha_0 \gamma^{k-1}$$

其中 $0 < \gamma < 1$

如果每次都沿负梯度方向进行精确线搜索，则得到最速梯度法。此时步长满足

$$\alpha_k = \arg \min_{\alpha \geq 0} f(\mathbf{x}^{(k)} - \alpha \nabla f(\mathbf{x}^{(k)}))$$

因此最速梯度法同时满足

$$\mathbf{d}^{(k)} = -\nabla f(\mathbf{x}^{(k)})$$

以及精确线搜索条件。

由精确线搜索的正交性质可知 $\nabla f(\mathbf{x}^{(k+1)})^T \mathbf{d}^{(k)} = 0$ ，而 $\mathbf{d}^{(k+1)} = -\nabla f(\mathbf{x}^{(k+1)})$ ，因此相邻两次最速梯度法的搜索方向相互正交。这也是最速梯度法搜索轨迹经常呈现折线或锯齿形状的原因之一。

对于对称正定二次函数 $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T Q \mathbf{x} + \mathbf{b}^T \mathbf{x} + c$ ，其中 $Q = Q^T > 0$ ，梯度为 $\nabla f(\mathbf{x}) = Q \mathbf{x} + \mathbf{b}$ ，记 $\mathbf{g}^{(k)} = \nabla f(\mathbf{x}^{(k)})$ ，则最速梯度法的迭代形式为 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha_k \mathbf{g}^{(k)}$ ，通过精确线搜索可以得到步长

$$\alpha_k = \frac{\mathbf{g}^{(k)T} \mathbf{g}^{(k)}}{\mathbf{g}^{(k)T} Q \mathbf{g}^{(k)}}$$

这一公式给出了正定二次函数下最速梯度法的精确步长。

梯度法结构简单，每一步只需要计算梯度，因此特别适合高维问题。但是其收敛速度与目标函数水平集的几何形状密切相关。

对于水平集接近圆形的问题，梯度方向通常能较直接地指向极小点附近，因此收

敛较快。当水平集呈狭长椭圆形时，相邻梯度方向容易在狭长区域两侧反复改变方向，从而出现明显的锯齿现象。

因此，梯度法通常在迭代初期能够较快降低目标函数值，而接近极小点后可能明显变慢。水平集越扁平，这种现象通常越明显。

二、共轭方向法

为了改善梯度法在二次函数上的锯齿状收敛问题，可以使用共轭方向

设 $Q \in \mathbb{R}^{n \times n}$ ，且 $Q = Q^T$ ，给定一组非零方向 $\mathbf{d}^{(0)}, \mathbf{d}^{(1)}, \dots, \mathbf{d}^{(m)}$ ，若任意两个不同方向满足 $\mathbf{d}^{(i)T} Q \mathbf{d}^{(j)} = 0$ ，则称这些方向关于 Q 共轭。

需要注意，共轭与普通的欧氏正交并不是同一个概念。两个方向关于 Q 共轭并不意味着它们一定满足普通内积意义下的正交关系

若进一步有 $Q = Q^T > 0$ ，则一组关于 Q 共轭的非零向量一定线性无关。设 $\sum_{i=0}^k \alpha_i \mathbf{d}^{(i)} = 0$ ，对于其中任意一个方向 $\mathbf{d}^{(j)}$ ，在等式左侧乘以 $\mathbf{d}^{(j)T} Q$ ，利用共轭性质可以消去所有满足 $i \neq j$ 的项，得到 $\alpha_j \mathbf{d}^{(j)T} Q \mathbf{d}^{(j)} = 0$ ，由于 Q 正定且 $\mathbf{d}^{(j)}$ 非零，因此 $\mathbf{d}^{(j)T} Q \mathbf{d}^{(j)} > 0$ ，从而 $\alpha_j = 0$ 对所有 j 均成立，因此这些方向线性无关。

由此可知，在 n 维空间中，关于正定矩阵 Q 两两共轭的非零方向最多有 n 个。

考虑正定二次优化问题 $\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x})$ ，其中 $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T Q \mathbf{x} - \mathbf{x}^T \mathbf{b}$ ，以及 $Q = Q^T > 0$ ，如果已经获得 n 个关于 Q 共轭的非零搜索方向，则可以依次沿这些方向进行精确线搜索。

基本迭代公式为 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}$

梯度记为 $\mathbf{g}^{(k)} = Q \mathbf{x}^{(k)} - \mathbf{b}$

对该一维问题使用一阶最优性条件，可以得到 $\alpha_k = - \frac{\mathbf{g}^{(k)T} \mathbf{d}^{(k)}}{\mathbf{d}^{(k)T} Q \mathbf{d}^{(k)}}$

共轭方向法具有一个非常重要的有限步收敛性质。对于正定二次函数，如果采用 n 个关于 Q 共轭的非零方向并进行精确线搜索，则算法能够在不超过 n 次迭代后到达唯一全局极小点。

其本质原因在于这些共轭方向线性无关，因此可以构成整个 $\mathbb{R}^n$ 维空间中的一组基。最优点与初始点之差可以表示为这些方向的线性组合，而精确线搜索能够逐步确定对应的系数。

此外，在精确线搜索的共轭方向法中，还具有梯度与历史搜索方向正交的性质 $\mathbf{g}^{(k+1)T} \mathbf{d}^{(i)} = 0$ ，其中 $0 \leq i \leq k$ ，也就是说，第 k 次迭代完成后，新点处的梯度不仅与当前搜索方向正交，而且与前面已经使用过的搜索方向均正交。

三、共轭梯度法

共轭方向法的关键问题在于如何获得一组彼此共轭的搜索方向。共轭梯度法不需要预先给出这些方向，而是利用当前梯度和前一次搜索方向递推构造新的搜索方向。

对于正定二次函数，首先定义 $\mathbf{g}^{(k)} = \nabla f(\mathbf{x}^{(k)})$

初始方向取负梯度方向 $\mathbf{d}^{(0)} = -\mathbf{g}^{(0)}$

从第二个搜索方向开始，采用递推形式 $\mathbf{d}^{(k)} = -\mathbf{g}^{(k)} + \beta_{k-1}\mathbf{d}^{(k-1)}$

系数 β_{k-1} 的作用是保证新方向与前一方向关于 Q 共轭。

要求 $\mathbf{d}^{(k)T} Q \mathbf{d}^{(k-1)} = 0$

代入方向递推式后得到 $-\mathbf{g}^{(k)T} Q \mathbf{d}^{(k-1)} + \beta_{k-1} \mathbf{d}^{(k-1)T} Q \mathbf{d}^{(k-1)} = 0$

因此 $\beta_{k-1} = \frac{\mathbf{g}^{(k)T} Q \mathbf{d}^{(k-1)}}{\mathbf{d}^{(k-1)T} Q \mathbf{d}^{(k-1)}}$

通过这种递推方式构造出的搜索方向彼此关于 Q 共轭。

对于正定二次优化问题，共轭梯度法可以整理为以下迭代过程。

首先给定初始点 $\mathbf{x}^{(0)}$

计算初始梯度 $\mathbf{g}^{(0)} = \nabla f(\mathbf{x}^{(0)})$ ，并取 $\mathbf{d}^{(0)} = -\mathbf{g}^{(0)}$

在第 k 次迭代中计算精确步长 $\alpha_k = -\frac{\mathbf{g}^{(k)T} \mathbf{d}^{(k)}}{\mathbf{d}^{(k)T} Q \mathbf{d}^{(k)}}$

更新迭代点 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}$ ，再计算新的梯度 $\mathbf{g}^{(k+1)} = \nabla f(\mathbf{x}^{(k+1)})$

然后计算 $\beta_k = \frac{\mathbf{g}^{(k+1)T} Q \mathbf{d}^{(k)}}{\mathbf{d}^{(k)T} Q \mathbf{d}^{(k)}}$ ，并构造下一搜索方向 $\mathbf{d}^{(k+1)} = -\mathbf{g}^{(k+1)} + \beta_k \mathbf{d}^{(k)}$

重复这一过程直到满足停机条件。

由于这些方向关于 Q 共轭，所以对于 n 维正定二次优化问题，在精确计算条件下，共轭梯度法最多经过 n 次迭代即可得到极小点。这使得它在二次优化和大规模线性方程组求解中具有比最速梯度法更好的理论性质。

四、一般非二次函数的共轭梯度法

前面的共轭梯度法直接依赖二次函数中的矩阵 Q 。对于一般非二次函数，不再存在固定的二次型矩阵 Q 。

一种直观方法是用 Hessian 矩阵替代 Q ，但这样每次迭代都必须计算二阶导数，算法也就失去了一阶方法的优势。

因此，对于一般函数，非线性共轭梯度法通常采用两个处理方式：步长通过一维线搜索获得，而 β_k 则使用不含 Hessian 矩阵的计算公式。

定义梯度差 $\mathbf{y}^{(k)} = \mathbf{g}^{(k+1)} - \mathbf{g}^{(k)}$ ，常见的 β_k 计算方法包括 Hestenes–Stiefel 公式

$$\beta_k^{HS} = \frac{\mathbf{g}^{(k+1)T} (\mathbf{g}^{(k+1)} - \mathbf{g}^{(k)})}{\mathbf{d}^{(k)T} (\mathbf{g}^{(k+1)} - \mathbf{g}^{(k)})}$$

Polak–Ribière 公式

$$\beta_k^{PR} = \frac{\mathbf{g}^{(k+1)T} (\mathbf{g}^{(k+1)} - \mathbf{g}^{(k)})}{\mathbf{g}^{(k)T} \mathbf{g}^{(k)}}$$

以及 Fletcher–Reeves 公式

$$\beta_k^{FR} = \frac{\mathbf{g}^{(k+1)T} \mathbf{g}^{(k+1)}}{\mathbf{g}^{(k)T} \mathbf{g}^{(k)}}$$

对于正定二次问题并采用精确线搜索时，这三种公式得到的共轭梯度方法是等价

的。其中 Hestenes–Stiefel 公式可以由二次函数下的 Q 共轭公式得到。

对于二次函数，有 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}$ ，因此梯度满足 $\mathbf{g}^{(k+1)} = \mathbf{g}^{(k)} + \alpha_k Q \mathbf{d}^{(k)}$ ，从而 $Q \mathbf{d}^{(k)} = \frac{\mathbf{g}^{(k+1)} - \mathbf{g}^{(k)}}{\alpha_k}$ ，将这一关系代入二次型共轭方向公式后，即可得到 Hestenes–Stiefel 形式。

对于一般函数，共轭梯度法的基本迭代仍然保持 $\mathbf{d}^{(k+1)} = -\mathbf{g}^{(k+1)} + \beta_k \mathbf{d}^{(k)}$

其计算过程可以概括如下。

给定初始点后首先计算 $\mathbf{g}^{(0)} = \nabla f(\mathbf{x}^{(0)})$

并取 $\mathbf{d}^{(0)} = -\mathbf{g}^{(0)}$

然后利用精确或近似线搜索确定步长 α_k ，更新 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}$

再计算 $\mathbf{g}^{(k+1)} = \nabla f(\mathbf{x}^{(k+1)})$

选择一种共轭参数公式得到 β_k ，最后构造 $\mathbf{d}^{(k+1)} = -\mathbf{g}^{(k+1)} + \beta_k \mathbf{d}^{(k)}$

在一般非线性问题中，由于数值误差以及函数本身不再是严格二次型，递推产生的方向可能失去良好的下降性质。

因此，如果新的搜索方向不满足下降要求，需要重新取负梯度方向。下降方向要求 $\mathbf{d}^{(k+1)T} \mathbf{g}^{(k+1)} < 0$ ，若不满足这一条件，则重置为 $\mathbf{d}^{(k+1)} = -\mathbf{g}^{(k+1)}$

此外，课件指出还可以每隔 n 步进行一次强制重置，以减弱数值计算过程中共轭性逐渐丢失所带来的影响。

五、总结

无约束优化的一阶方法只使用函数的一阶导数信息，其中最基本的是梯度法。

梯度法采用负梯度作为搜索方向 $\mathbf{d}^{(k)} = -\nabla f(\mathbf{x}^{(k)})$

其迭代形式为 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}$

当步长采用精确线搜索时，得到最速梯度法。对于正定二次函数，其精确步长为

$$\alpha_k = \frac{\mathbf{g}^{(k)T} \mathbf{g}^{(k)}}{\mathbf{g}^{(k)T} Q \mathbf{g}^{(k)}}$$

最速梯度法结构简单，但对于狭长水平集可能产生明显的锯齿状迭代轨迹，接近最优点时收敛速度可能较慢。

共轭方向法利用满足 $\mathbf{d}^{(i)T} Q \mathbf{d}^{(j)} = 0$ 的搜索方向避免重复修正已经优化过的方向。

对于正定二次函数，精确线搜索下的共轭方向法能够在不超过 n 次迭代中到达全局最优点。

共轭梯度法进一步利用梯度和前一次搜索方向自动构造共轭方向 $\mathbf{d}^{(k+1)} = -\mathbf{g}^{(k+1)} + \beta_k \mathbf{d}^{(k)}$

对于一般非二次函数，可以利用一维线搜索确定 α_k ，并使用 Hestenes–Stiefel、Polak–Ribière 或 Fletcher–Reeves 公式计算 β_k 。