

多维无约束优化：Newton 法与拟 Newton 法

对于无约束优化问题 $\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x})$

如果目标函数二阶可微，就可以利用 Hessian 矩阵提供的曲率信息构造比一阶方法更精确的局部模型。

梯度法只利用一阶导数信息，而 Newton 法同时利用梯度和 Hessian 矩阵。其基本思想是在当前点附近使用二次函数近似原目标函数，再求这一局部二次模型的极小点作为新的迭代点。

一、Newton 法

设目标函数二阶连续可微。在当前迭代点 $\mathbf{x}^{(k)}$ 附近进行二阶 Taylor 展开，有

$$f(\mathbf{x}) = f(\mathbf{x}^{(k)}) + (\mathbf{x} - \mathbf{x}^{(k)})^T \nabla f(\mathbf{x}^{(k)}) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(k)})^T \nabla^2 f(\mathbf{x}^{(k)}) (\mathbf{x} - \mathbf{x}^{(k)}) + o|\mathbf{x} - \mathbf{x}^{(k)}|^2$$

忽略高阶项，定义局部二次近似模型

$$q_k(\mathbf{x}) = f(\mathbf{x}^{(k)}) + (\mathbf{x} - \mathbf{x}^{(k)})^T \nabla f(\mathbf{x}^{(k)}) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(k)})^T \nabla^2 f(\mathbf{x}^{(k)}) (\mathbf{x} - \mathbf{x}^{(k)})$$

为简化记号，令 $\mathbf{g}^{(k)} = \nabla f(\mathbf{x}^{(k)})$ ，以及 $F_k = \nabla^2 f(\mathbf{x}^{(k)})$ ，则二次模型的一阶条件为

$$\nabla q_k(\mathbf{x}) = \mathbf{g}^{(k)} + F_k(\mathbf{x} - \mathbf{x}^{(k)}) = 0$$

若 Hessian 矩阵正定，则该二次模型存在唯一极小点，于是得到

$$\mathbf{x} = \mathbf{x}^{(k)} - F_k^{-1} \mathbf{g}^{(k)}$$

由此得到多维 Newton 法的基本迭代公式

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - F_k^{-1} \mathbf{g}^{(k)}$$

也可以定义 Newton 方向

$$\mathbf{d}^{(k)} = -F_k^{-1} \mathbf{g}^{(k)}$$

从而写成 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \mathbf{d}^{(k)}$ ，实际计算时通常并不直接计算 Hessian 矩阵的逆，而是通过求解线性方程组得到 Newton 方向：

$$F_k \mathbf{d}^{(k)} = -\mathbf{g}^{(k)}$$

这是 Newton 法实际实现中的基本形式。

Newton 法可以看作每一步利用当前点附近的二次模型预测下一点。原函数与局部二次近似模型在当前点附近相互接近，而算法取二次模型的预测极小点作为下一次迭代点。

对于正定二次函数 $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T Q \mathbf{x} - \mathbf{x}^T \mathbf{b}$ ，其中 $Q = Q^T > 0$

有 $\nabla f(\mathbf{x}) = Q \mathbf{x} - \mathbf{b}$ ，以及 $\nabla^2 f(\mathbf{x}) = Q$

因此从任意初始点出发，Newton 迭代得到 $\mathbf{x}^{(1)} = \mathbf{x}^{(0)} - Q^{-1}(Q \mathbf{x}^{(0)} - \mathbf{b}) = Q^{-1} \mathbf{b}$

而正定二次函数的唯一极小点正是 $\mathbf{x}^* = Q^{-1} \mathbf{b}$ ，因此 Newton 法对正定二次函数可以一步到达最优点。

当初始点充分接近局部极小点并满足适当条件时，Newton 法具有很快的局部收敛速度。课件将其描述为二次收敛，即在最优点附近，误差大致以平方速度减小。但 Newton 法对初始点具有一定敏感性，初始点选择不当时也可能失败。

二、Newton 法的局限与修正

基本 Newton 法虽然局部收敛速度很快，但其直接迭代并不总是可靠。

首先，即使当前 Hessian 矩阵正定，Newton 方向是下降方向，直接采用单位步长仍不能保证新点的目标函数值一定下降。

其次，如果 Hessian 矩阵不正定，则 Newton 方向可能不是下降方向。

此外，如果 Hessian 矩阵奇异，则线性方程组 $F_k \mathbf{d}^{(k)} = -\mathbf{g}^{(k)}$ ，可能没有唯一解，甚至可能没有解。

当 Hessian 矩阵正定时，Newton 方向确实是下降方向。因为 $\mathbf{d}^{(k)} = -F_k^{-1} \mathbf{g}^{(k)}$ ，所以 $\mathbf{g}^{(k)T} \mathbf{d}^{(k)} = -\mathbf{g}^{(k)T} F_k^{-1} \mathbf{g}^{(k)}$ ，若 $F_k > 0$ ，则 $F_k^{-1} > 0$ ，于是只要 $\mathbf{g}^{(k)} \neq 0$ ，就有 $\mathbf{g}^{(k)T} \mathbf{d}^{(k)} < 0$ ，因此 Newton 方向为下降方向。

普通 Newton 法本质上相当于一个采用单位步长的下降方法，其问题可能出在步长固定为 1。

为了避免单位步长过大，可以给 Newton 方向增加步长因子，得到阻尼 Newton 法 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha_k F_k^{-1} \mathbf{g}^{(k)}$ ，步长可以通过线搜索确定

$$\alpha_k = \arg \min_{\alpha > 0} f(\mathbf{x}^{(k)} - \alpha F_k^{-1} \mathbf{g}^{(k)})$$

这样可以利用前面介绍的精确线搜索或近似线搜索控制每次移动距离。

当 Hessian 矩阵不正定时，可以采用 Levenberg-Marquardt 型修正，在 Hessian 上增加单位矩阵的正倍数 $F_k + \mu_k I$

对应的迭代公式为 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - (F_k + \mu_k I)^{-1} \mathbf{g}^{(k)}$

其中 $\mu_k \geq 0$ ，设 F_k 的特征值为 λ_i 。加入修正项以后，相应特征值变为 $\lambda_i + \mu_k$

因此只要 μ_k 充分大，使所有特征值均为正数，就可以使修正后的矩阵正定 $F_k + \mu_k I > 0$ ，于是修正方向 $-(F_k + \mu_k I)^{-1} \mathbf{g}^{(k)}$ 成为下降方向。

还可以同时加入步长 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha_k (F_k + \mu_k I)^{-1} \mathbf{g}^{(k)}$

当 $\mu_k \rightarrow 0$ ，这种方法逐渐接近普通 Newton 法。

当 $\mu_k \rightarrow \infty$ ，方向逐渐表现出小步长梯度下降方法的特征。

实际计算中可以从较小的 μ_k 开始，根据下降情况逐步调整。

如果 Hessian 矩阵奇异而导致 Newton 方程无法求解，简单处理方式是在当前迭代中暂时改用最速梯度下降法。

除了这些稳定性问题，Newton 法还有一个重要的计算问题：对于高维优化，每一步都需要形成 Hessian 矩阵并求解一个高维线性方程组，计算和存储代价较大。这也是引入拟 Newton 法的主要原因。

三、拟 Newton 法与拟 Newton 条件

拟 Newton 法的基本思想是不直接计算真正的 Hessian 矩阵，而是利用迭代过程中已经获得的梯度信息逐步构造 Hessian 逆矩阵的近似。

设 $H_k \approx F_k^{-1}$ ，则搜索方向定义为 $\mathbf{d}^{(k)} = -H_k \mathbf{g}^{(k)}$ ，迭代形式为 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}$ ，

其中步长可以通过精确或近似线搜索获得 $\alpha_k = \arg \min_{\alpha \geq 0} f(\mathbf{x}^{(k)} + \alpha \mathbf{d}^{(k)})$ ，为了保证

$-\mathbf{H}_k \mathbf{g}^{(k)}$ 是下降方向，希望 H_k 保持正定。

若 $H_k > 0$ 且梯度非零，则 $-\mathbf{g}^{(k)T} H_k \mathbf{g}^{(k)} < 0$ ，因此该方向为下降方向。

另一方面， H_k 需要尽可能逼近真正的 Hessian 逆矩阵。

定义相邻迭代点差 $\Delta \mathbf{x}^{(k)} = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}$ ，以及梯度差 $\Delta \mathbf{g}^{(k)} = \mathbf{g}^{(k+1)} - \mathbf{g}^{(k)}$ ，根据梯度的一阶近似关系，希望新的近似矩阵满足 $H_{k+1} \Delta \mathbf{g}^{(k)} = \Delta \mathbf{x}^{(k)}$

这一关系称为**拟 Newton 条件**或割线条件。它使矩阵 H_{k+1} 在当前梯度变化方向上表现得像真实 Hessian 的逆矩阵。

拟 Newton 法的核心问题因此转化为：如何根据 H_k 、当前位移以及梯度变化，构造新的 H_{k+1} ，同时尽量保持对称性、正定性并满足拟 Newton 条件。

四、拟 Newton 矩阵的更新方法

一种最直接的构造是秩 1 修正。设 $H_{k+1} = H_k + a_k \mathbf{z}^{(k)} \mathbf{z}^{(k)T}$

因为外积矩阵的秩为 1，所以这种更新称为秩 1 修正。若 H_k 为对称矩阵，则 H_{k+1} 也保持对称。令 $\mathbf{r}^{(k)} = \Delta \mathbf{x}^{(k)} - H_k \Delta \mathbf{g}^{(k)}$ ，根据拟 Newton 条件 $H_{k+1} \Delta \mathbf{g}^{(k)} = \Delta \mathbf{x}^{(k)}$ ，可以推导出秩 1 更新公式 $H_{k+1} = H_k + \frac{\mathbf{r}^{(k)} \mathbf{r}^{(k)T}}{\Delta \mathbf{g}^{(k)T} \mathbf{r}^{(k)}}$ ，也就是

$$H_{k+1} = H_k + \frac{(\Delta \mathbf{x}^{(k)} - H_k \Delta \mathbf{g}^{(k)}) (\Delta \mathbf{x}^{(k)} - H_k \Delta \mathbf{g}^{(k)})^T}{\Delta \mathbf{g}^{(k)T} (\Delta \mathbf{x}^{(k)} - H_k \Delta \mathbf{g}^{(k)})}$$

当分母不能用于更新时，可以保持原矩阵不变。秩 1 算法正是按照这一原则构造 H_{k+1} 。

对于正定二次优化问题，这种拟 Newton 更新构造的搜索方向与二次型矩阵共轭。因此，在理想精确计算条件下，它具有与共轭方向方法相联系的有限步性质，经过 n 步后可以得到最优解，同时有 $H_n = Q^{-1}$

秩 1 修正并不能始终保证近似矩阵保持正定，因此还可以采用 DFP 更新。

$$\text{DFP 公式为 } H_{k+1} = H_k + \frac{\Delta \mathbf{x}^{(k)} \Delta \mathbf{x}^{(k)T}}{\Delta \mathbf{x}^{(k)T} \Delta \mathbf{g}^{(k)}} - \frac{H_k \Delta \mathbf{g}^{(k)} \Delta \mathbf{g}^{(k)T} H_k}{\Delta \mathbf{g}^{(k)T} H_k \Delta \mathbf{g}^{(k)}}$$

DFP 更新同时满足拟 Newton 条件，并且在适当条件下能够保持矩阵正定。

但是对于某些非二次问题，DFP 构造出的近似矩阵可能逐渐变得病态，因此进一步介绍 BFGS 更新。

BFGS 对 Hessian 逆矩阵近似的更新公式为

$$H_{k+1} = H_k + \left(1 + \frac{\Delta \mathbf{g}^{(k)T} H_k \Delta \mathbf{g}^{(k)}}{\Delta \mathbf{x}^{(k)T} \Delta \mathbf{g}^{(k)}}\right) \frac{\Delta \mathbf{x}^{(k)} \Delta \mathbf{x}^{(k)T}}{\Delta \mathbf{x}^{(k)T} \Delta \mathbf{g}^{(k)}} - \frac{\Delta \mathbf{x}^{(k)} \Delta \mathbf{g}^{(k)T} H_k + H_k \Delta \mathbf{g}^{(k)} \Delta \mathbf{x}^{(k)T}}{\Delta \mathbf{x}^{(k)T} \Delta \mathbf{g}^{(k)}}$$

BFGS 是实际中常用的拟 Newton 方法。使用非精确线搜索时，通常需要配合适当的曲率条件，以维持更新矩阵的良好性质。

不过，标准 BFGS 仍然需要保存一个 $n \times n$ 的稠密矩阵，因此当变量维数非常大时，存储开销依然较高。对此可以采用有限内存 BFGS，也就是 L-BFGS。

五、总结

Newton 法利用目标函数在当前点附近的二次 Taylor 模型构造搜索方向。

定义 $\mathbf{g}^{(k)} = \nabla f(\mathbf{x}^{(k)})$ 以及 $F_k = \nabla^2 f(\mathbf{x}^{(k)})$

Newton 方向由线性方程组确定 $F_k \mathbf{d}^{(k)} = -\mathbf{g}^{(k)}$

基本迭代为 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \mathbf{d}^{(k)}$

当 Hessian 正定但单位步长不合适时，可以引入阻尼系数

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha_k F_k^{-1} \mathbf{g}^{(k)}$$

当 Hessian 不正定时，可以采用 Levenberg-Marquardt 修正

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha_k (F_k + \mu_k I)^{-1} \mathbf{g}^{(k)}$$

当 Hessian 奇异时，可以暂时采用最速梯度方向代替 Newton 方向。课件也将这三种情况作为 Newton 法主要失效情形及其修正方式进行总结。

拟 Newton 法的主要目的，是避免每一步直接计算 Hessian 矩阵及其相关线性系统，而用矩阵 H_k 逐步近似 Hessian 的逆矩阵。

其基本方向为 $\mathbf{d}^{(k)} = -H_k \mathbf{g}^{(k)}$

拟 Newton 条件为 $H_{k+1} \Delta \mathbf{g}^{(k)} = \Delta \mathbf{x}^{(k)}$

常见更新方法包括秩 1 修正、DFP 和 BFGS。

秩 1 更新结构简单，但不一定保持正定性；DFP 能够在适当条件下保持正定；BFGS 是实际中更常使用的拟 Newton 更新之一；对于高维问题，则可以进一步采用 L-BFGS 以减少矩阵存储需求。