

万有逼近定理

在深度学习还没有像今天这样普及之前，人们首先要回答一个最基本的问题：**神经网络到底有没有足够强的表达能力？**也就是说，给定一个连续函数，只要我们允许网络中有足够多的神经元，神经网络能不能把这个函数逼近到任意精度？

这个问题在 1980 年代得到了经典回答。1989 年，George Cybenko 证明了带有 Sigmoid 激活函数的单隐层神经网络，可以一致逼近单位超立方体上的任意连续函数；同年，Hornik、Stinchcombe 和 White 也给出了多层前馈网络作为通用逼近器的重要结果。后来，Leshno 等人进一步刻画了激活函数满足什么条件时神经网络具有这种逼近能力，其中一个重要结论是：非多项式激活函数在通用逼近性质中扮演关键角色。

这个定理给神经网络的“表达能力”提供了数学保证，告诉我们：神经网络不是只能表示少数几类简单函数，而是理论上可以逼近非常广泛的连续函数。图像分类、语音识别、函数拟合、控制系统、科学计算中的很多问题，本质上都可以看成是在学习一个复杂函数。万有逼近定理就说明，只要网络结构足够大，神经网络在表达能力上是有希望完成这些任务的。

我会用尽量通俗的方式带大家理解这个定理的证明过程，不直接从抽象的泛函分析开始，而是先从大家熟悉的微积分知识出发。

设有一个连续函数：

$$f: [a, b] \rightarrow \mathbb{R}$$

其中 $[a, b]$ 是一个闭区间。

我们要证明：

对于任意小的误差： $\varepsilon > 0$ ，都存在一个单隐层 ReLU 神经网络：

$$F(x) = c + s_0 x + \sum_{j=1}^{n-1} A_j \text{ReLU}(x - x_j)$$

对所有 $x \in [a, b]$ 都有 $|f(x) - F(x)| < \varepsilon$

这就是一维情况下的万有逼近定理。

我们只需要证明两件事：

第一：任意分段直线都可以写成 ReLU 神经网络

第二：任意连续函数都可以被一条分段直线逼近。

先证明第一：任意分段直线都可以写成 ReLU 神经网络

[来简单讲讲为什么单隐层 ReLU 神经网络是这个公式，首先我们要知道，对于任意一个函数，例如简单的 $y = x^2$ ，神经网络本质是用一个连续分段线性函数（也就是拥有无数“折点”的折线）去近似拟合这个连续的抛物线，因此这个证明可以表述为任意给定的连续分段线性函数，都可以被唯一地拆解为上述公式的形式。

假设我们要逼近的目标是一个连续分段线性函数 $f(x)$ 。

假设它有 $n - 1$ 个“折点”，将 x 轴划分成了 n 个区间。

设这些折点的横坐标依次为： $x_1 < x_2 < x_3 < \dots < x_{n-1}$ 。

在每个区间内， $f(x)$ 都是一条直线。我们定义这些直线的斜率依次为：

第 0 个区间 $(-\infty, x_1]$ 的斜率为 s_0

第 1 个区间 $[x_1, x_2]$ 的斜率为 s_1

第 j 个区间 $[x_j, x_{j+1}]$ 的斜率为 s_j

我们从最左侧的区间 $(-\infty, x_1]$ 开始构造。在这个区间内， $f(x)$ 是一条纯粹的直线，其斜率为 s_0 。显然，我们可以用一个标准的线性方程来精确表示它：

$$F_0(x) = c + s_0 x$$

这里的 c 是该直线延长到 y 轴上的截距。此时，在区间 $(-\infty, x_1]$ 上， $F_0(x) \equiv f(x)$ 。

当 x 跨过第一个折点 x_1 进入区间 $[x_1, x_2]$ 时，函数的斜率需要从 s_0 突变为 s_1 。

斜率的变化量为： $\Delta s_1 = s_1 - s_0$ 。

为了让函数在 x_1 处发生转折，同时**不破坏** x_1 左侧已经构造好的部分，我们引入一个在 x_1 处激活的 ReLU 项：

$$F_1(x) = F_0(x) + \Delta s_1 \text{ReLU}(x - x_1)$$

当 $x \leq x_1$ 时： $x - x_1 \leq 0$ ， $\text{ReLU}(x - x_1) = 0$ 。此时 $F_1(x) = F_0(x) + 0 = c + s_0 x$ ，完美保持了左侧直线的原状。

当 $x > x_1$ 时： $x - x_1 > 0$ ， $\text{ReLU}(x - x_1) = x - x_1$ 。此时

$$F_1(x) = c + s_0 x + \Delta s_1 (x - x_1)。$$

求导计算此时的斜率： $\frac{d}{dx} F_1(x) = s_0 + \Delta s_1 = s_0 + (s_1 - s_0) = s_1$ 。在 $x = x_1$ 处，

新加的项刚好为 0，没有引起函数值的跳跃，保证了连续性。

由此可见，引入 $\Delta s_1 \text{ReLU}(x - x_1)$ ，就像在 x_1 处给直线“掰”了一下，精确调整了斜率。

我们继续向右推进。当到达第 j 个折点 x_j 时，此时的斜率需要从 s_{j-1} 变为 s_j 。

斜率的变化量为： $A_j = s_j - s_{j-1}$ 。

我们将这个“斜率修正项”累加到函数中：

$$F_j(x) = F_{j-1}(x) + A_j \text{ReLU}(x - x_j)$$

依此类推，遍历完所有的 $n - 1$ 个折点，我们将所有局部的 ReLU 修正项全部加起来，就得到了覆盖整个实数域的最终表达式：

$$F(x) = c + s_0 x + \sum_{j=1}^{n-1} A_j \text{ReLU}(x - x_j)$$

至此，我们证明了：任意一个拥有 $n - 1$ 个折点的连续分段线性函数，都可以被唯一地写成上述公式的形式，其中 A_j 严格等于第 j 个折点处的斜率突变值。]

证明第二：连续函数可以被分段直线逼近

[因为 f 在闭区间 $[a, b]$ 上连续。根据微积分中的结论，闭区间上的连续函数一定是一致连续的。一致连续的意思是：对于任意 $\varepsilon > 0$ 都存在 $\delta > 0$ 使得只要 $|x - y| < \delta$ 就有 $|f(x) - f(y)| < \varepsilon$

这句话的意思是：只要两个输入（也就是横坐标 x ）足够接近，那么它们对应的函数值一定足够接近。

现在我们把区间 $[a, b]$ 切成很多小段 $a = x_0 < x_1 < x_2 < \cdots < x_n = b$ ，并且让每一小段的长度都小于 δ ，也就是 $x_{i+1} - x_i < \delta$ 。

然后在每个点 x_i 上取函数值 $f(x_i)$ ，接着，我们用直线连接相邻两点： $(x_i, f(x_i))$ 和 $(x_{i+1}, f(x_{i+1}))$ 。这样得到一个分段直线函数，记为： $F(x)$ 。

现在取任意一个 $x \in [a, b]$ ，那么它一定落在某个小区间里面： $x \in [x_i, x_{i+1}]$ 。

因为这一小段长度小于 δ ，所以 $|x - x_i| < \delta$ ，并且 $|x - x_{i+1}| < \delta$ 。

根据一致连续性： $|f(x) - f(x_i)| < \varepsilon$ ，并且 $|f(x) - f(x_{i+1})| < \varepsilon$ 。也就是说，在这个小区间里，函数值 $f(x)$ 和左右端点的函数值 $f(x_i)$ ， $f(x_{i+1})$ 都很接近。

分段直线函数 $p(x)$ 在这个小区间上的值，是由 $f(x_i)$ 和 $f(x_{i+1})$ 线性插值得到的。

具体来说： $F(x) = \frac{x_{i+1} - x}{x_{i+1} - x_i} f(x_i) + \frac{x - x_i}{x_{i+1} - x_i} f(x_{i+1})$ 。

$\frac{x_{i+1} - x}{x_{i+1} - x_i}$ 和 $\frac{x - x_i}{x_{i+1} - x_i}$ 都是非负数，而且它们相加等于1，所以 $p(x)$ 是 $f(x_i)$ 和 $f(x_{i+1})$ 的加权平均。既然 $f(x_i)$ 和 $f(x_{i+1})$ 都离 $f(x)$ 很近，那么它们的加权平均 $p(x)$ 也离 $f(x)$ 很近。

严格写就是：

$$|F(x) - f(x)| = \left| \frac{x_{i+1} - x}{x_{i+1} - x_i} (f(x_i) - f(x)) + \frac{x - x_i}{x_{i+1} - x_i} (f(x_{i+1}) - f(x)) \right|$$

由三角不等式：

$$|F(x) - f(x)| \leq \frac{x_{i+1} - x}{x_{i+1} - x_i} |f(x_i) - f(x)| + \frac{x - x_i}{x_{i+1} - x_i} |f(x_{i+1}) - f(x)|$$

因为 $|f(x_i) - f(x)| < \varepsilon$ 且 $|f(x_{i+1}) - f(x)| < \varepsilon$ ，所以：

$$|F(x) - f(x)| < \frac{x_{i+1} - x}{x_{i+1} - x_i} \varepsilon + \frac{x - x_i}{x_{i+1} - x_i} \varepsilon$$

提取 ε 得到 $|F(x) - f(x)| < \varepsilon \left(\frac{x_{i+1} - x}{x_{i+1} - x_i} + \frac{x - x_i}{x_{i+1} - x_i} \right)$ ，括号里面等于1，所以 $|F(x) - f(x)| < \varepsilon$ 。

因为这个结论对任意 $x \in [a, b]$ 都成立，所以 $\sup_{x \in [a, b]} |F(x) - f(x)| < \varepsilon$ ，这就证明了：连续函数可以被分段直线函数任意逼近，证毕！

（ $\sup$ 意为上确界，例如，对于开区间集合 $S = \{x | x < 1\}$ ，它的上确界是 $\sup(S) = 1$ ）]

[大家肯定有疑问，为何神经网络可以用 $F(x) = c + s_0x + \sum_{j=1}^{n-1} A_j \text{ReLU}(x - x_j)$

表示？我们可以这么来看：

c 是输出层的全局偏置

s_0 是从输入层直接连接到输出层的权重

$\text{ReLU}(x - x_j)$ 代表隐藏层中的第 j 个神经元。

在标准的神经网络中，神经元的计算是 $\text{ReLU}(w_jx + b_j)$ 。

通过提取权重，我们可以将其改写为 $w_j \text{ReLU}\left(x - \left(-\frac{b_j}{w_j}\right)\right)$ （假设 $w_j > 0$ ）。

令 $x_j = -\frac{b_j}{w_j}$ ，这个 x_j 就是该神经元的激活阈值。当输入 $x > x_j$ 时，该神经元被激活并开始对输出产生影响。

A_j 代表第 j 个神经元到输出层的权重。

在数学几何上， A_j 严格等于函数在 x_j 这一点的一阶导数（梯度）的变化量。即 $A_j = F'(x_j^+) - F'(x_j^-)$ 。]

因此，只要隐层神经元数量足够多，ReLU 神经网络就可以逼近任意连续函数。

刚才证明的是一维版本： $f: [a, b] \rightarrow \mathbb{R}$ ，更一般的万有逼近定理研究的是多维函数： $f: K \subset \mathbb{R}^d \rightarrow \mathbb{R}$ ，也就是输入可以是 $x = (x_1, x_2, \dots, x_d)$ 。

接下来证明**多维情况下 ReLU 神经网络依旧具有万有逼近能力**。

设 $f: [0, 1]^d \rightarrow \mathbb{R}$ 是一个连续函数。我们要证明对于任意 $\varepsilon > 0$ 都存在一个 ReLU 神经网络 P 使得 $\sup_{x \in [0, 1]^d} |f(x) - P(x)| < \varepsilon$ 。其中 $x = (x_1, x_2, \dots, x_d)$ 。

我们证明三件事：

多维连续函数可以被多维多项式逼近。

多维多项式可以被 ReLU 神经网络逼近。

把两步合起来，就得到 ReLU 神经网络可以逼近多维连续函数。

也就是：连续函数 $\approx$ 多项式 $\approx$ ReLU 神经网络。这里的 $\approx$ 表示误差可以任意小。

证明第一：多维连续函数可以被多维多项式逼近。

[我们使用多维 Bernstein 多项式。

设 $f: [0, 1]^d \rightarrow \mathbb{R}$ 连续。对任意正整数 m ，定义：

$$B_m(f)(x) = \sum_{k_1=0}^m \sum_{k_2=0}^m \cdots \sum_{k_d=0}^m f\left(\frac{k_1}{m}, \frac{k_2}{m}, \dots, \frac{k_d}{m}\right) \prod_{r=1}^d \binom{m}{k_r} x_r^{k_r} (1-x_r)^{m-k_r}$$

这就是多维 Bernstein 多项式。因为里面只有 $x_1, x_2, \dots, x_d$ 的有限次幂相乘和相加，所以 $B_m(f)$ 确实是一个多项式。

因为 $[0, 1]^d$ 是闭且有界的区域，而 f 在这个区域上连续，所以 f 一致连续。也就是说，对于任意 $\eta > 0$ ，都存在 $\delta > 0$ 使得只要 $|x - y|_\infty < \delta$ ，就有 $|f(x) - f(y)| < \eta$ 。这里 $|x - y|_\infty = \max_{1 \leq r \leq d} |x_r - y_r|$ 。

因为 f 在闭区域上连续，所以它有界。因此存在 $M > 0$ 使得 $|f(x)| \leq M$ 对所有 $x \in [0, 1]^d$ 成立。

现在固定任意一个点 $x = (x_1, x_2, \dots, x_d) \in [0, 1]^d$ ，我们研究 $|B_m(f)(x) - f(x)|$ 。由定义：

$$B_m(f)(x) - f(x) = \sum_{k_1=0}^m \cdots \sum_{k_d=0}^m \left[f\left(\frac{k_1}{m}, \dots, \frac{k_d}{m}\right) - f(x) \right] \prod_{r=1}^d \binom{m}{k_r} x_r^{k_r} (1-x_r)^{m-k_r}$$

记：

$$y_k = \left(\frac{k_1}{m}, \dots, \frac{k_d}{m}\right)$$

再记权重：

$$W_k(x) = \prod_{r=1}^d \binom{m}{k_r} x_r^{k_r} (1-x_r)^{m-k_r}$$

这些权重满足 $W_k(x) \geq 0$ 并且 $\sum_{k_1=0}^m \cdots \sum_{k_d=0}^m W_k(x) = 1$ ，原因是：

$$\sum_{k_r=0}^m \binom{m}{k_r} x_r^{k_r} (1-x_r)^{m-k_r} = (x_r + (1-x_r))^m = 1$$

每个维度都是 1，所以所有维度相乘后仍然是 1。因此：

$$|B_m(f)(x) - f(x)| \leq \sum_{k_1=0}^m \cdots \sum_{k_d=0}^m |f(y_k) - f(x)| W_k(x)$$

现在把求和分成两类。第一类是 $|y_k - x|_\infty < \delta$ ，第二类是 $|y_k - x|_\infty \geq \delta$ 。对于第一类，由一致连续性 $|f(y_k) - f(x)| < \eta$ ，所以第一类总贡献小于 η 。对于第二类，因为 $|f(y_k)| \leq M$ 且 $|f(x)| \leq M$ ，所以 $|f(y_k) - f(x)| \leq 2M$ 。第二类总贡献不超过：

$$2M \sum_{|y_k - x|_\infty \geq \delta} W_k(x)$$

因此：

$$|B_m(f)(x) - f(x)| \leq \eta + 2M \sum_{|y_k - x|_\infty \geq \delta} W_k(x)$$

现在需要证明 $\sum_{|y_k - x|_\infty \geq \delta} W_k(x)$ 当 $m \rightarrow \infty$ 时会趋向于 0。可以用一个简单估计。如果 $|y_k - x|_\infty \geq \delta$ ，那么至少存在某个维度 r ，使得 $\left|\frac{k_r}{m} - x_r\right| \geq \delta$ 。因此：

$$\sum_{|y_k - x|_\infty \geq \delta} W_k(x) \leq \sum_{r=1}^d \sum_{\left|\frac{k_r}{m} - x_r\right| \geq \delta} \binom{m}{k_r} x_r^{k_r} (1-x_r)^{m-k_r}$$

对一维二项式权重，有估计：

$$\sum_{\left|\frac{k}{m} - x\right| \geq \delta} \binom{m}{k} x^k (1-x)^{m-k} \leq \frac{1}{4m\delta^2}$$

这个估计来自：

$$\sum_{k=0}^m \left(\frac{k}{m} - x\right)^2 \binom{m}{k} x^k (1-x)^{m-k} = \frac{x(1-x)}{m} \leq \frac{1}{4m}$$

因为当 $\left|\frac{k}{m} - x\right| \geq \delta$ 时有 $\left(\frac{k}{m} - x\right)^2 \geq \delta^2$ ，所以：

$$\delta^2 \sum_{\left|\frac{k}{m} - x\right| \geq \delta} \binom{m}{k} x^k (1-x)^{m-k} \leq \frac{1}{4m}$$

也就是 $\sum_{\left|\frac{k}{m} - x\right| \geq \delta} \binom{m}{k} x^k (1-x)^{m-k} \leq \frac{1}{4m\delta^2}$ ，于是多维情况下：

$$\sum_{|y_k - x|_\infty \geq \delta} W_k(x) \leq \frac{d}{4m\delta^2}$$

所以 $|B_m(f)(x) - f(x)| \leq \eta + 2M \cdot \frac{d}{4m\delta^2}$ ，即 $|B_m(f)(x) - f(x)| \leq \eta + \frac{Md}{2m\delta^2}$ ，

这个估计对所有 $x \in [0, 1]^d$ 都成立。

因此只要 m 足够大，就有 $\sup_{x \in [0, 1]^d} |B_m(f)(x) - f(x)| < 2\eta$ ，令 $2\eta = \frac{\varepsilon}{2}$ ，也就是取

$\eta = \frac{\varepsilon}{4}$ 就得到 $\sup_{x \in [0, 1]^d} |B_m(f)(x) - f(x)| < \frac{\varepsilon}{2}$ 。

所以，多维连续函数可以被多维多项式一致逼近。]

证明第二：多维多项式可以被 ReLU 神经网络逼近。

[多维多项式的一般形式是： $F(x) = \sum_{\alpha} c_{\alpha} x^{\alpha}$ ，其中 $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_d)$ ，并且

$x^{\alpha} = x_1^{\alpha_1} x_2^{\alpha_2} \dots x_d^{\alpha_d}$ 。所以只要证明 ReLU 网络可以逼近每一个单项式 x^{α} ，再把这些单项式线性相加，就能逼近整个多项式。

先证明 ReLU 网络可以逼近 t^2 在任意闭区间 $[-R, R]$ 上的值。

因为 t^2 是连续函数。根据一维情况下已经证明过的结论，任意连续函数都可以被一维分段直线函数逼近。所以对于任意 $\rho > 0$ ，都存在一个分段直线函数 $S(t)$ ，使得

$\sup_{t \in [-R, R]} |t^2 - S(t)| < \rho$ ，而一维分段直线函数可以写成 ReLU 网络：

$$S(t) = c + s_0 t + \sum_{j=1}^N A_j \text{ReLU}(t - t_j)$$

所以 ReLU 网络可以逼近平方函数。

接下来证明 ReLU 网络可以逼近 uv 。

使用恒等式 $uv = \frac{(u+v)^2 - (u-v)^2}{4}$ ，设 $u, v \in [-R, R]$ ，那么 $u+v \in [-2R, 2R]$ ，

并且 $u-v \in [-2R, 2R]$ 。上文已经证明 ReLU 网络可以在 $[-2R, 2R]$ 上逼近平方函数。也就是说，对于任意 $\rho > 0$ ，存在 ReLU 网络 S 使得 $\sup_{t \in [-2R, 2R]} |t^2 - S(t)| < \rho$ 。定义

$M_\rho(u, v) = \frac{S(u+v) - S(u-v)}{4}$ ，那么：

$$|M_\rho(u, v) - uv| = \left| \frac{S(u+v) - S(u-v)}{4} - \frac{(u+v)^2 - (u-v)^2}{4} \right|$$

整理得到 $|M_\rho(u, v) - uv| \leq \frac{|S(u+v) - (u+v)^2|}{4} + \frac{|S(u-v) - (u-v)^2|}{4}$ 。因

为每一项都小于 ρ ，所以 $|M_\rho(u, v) - uv| < \frac{\rho}{4} + \frac{\rho}{4} = \frac{\rho}{2}$ ，因此 ReLU 网络可以逼近乘法 uv 。

现在考虑单项式 $x^\alpha = x_1^{\alpha_1} x_2^{\alpha_2} \cdots x_d^{\alpha_d}$ ，这个单项式本质上是有限多个变量的乘积。例如 $x_1^2 x_2^3 x_4$ 可以写成 $x_1 \cdot x_1 \cdot x_2 \cdot x_2 \cdot x_2 \cdot x_4$ 。因为 ReLU 网络可以逼近两个数的乘法，所以可以反复使用乘法网络，逼近有限多个数的乘积。

更严格地说，设 $q(x)$ 和 $r(x)$ 已经可以被 ReLU 网络逼近。也就是说存在 ReLU 网络 $Q(x)$ 和 $R(x)$ 使得 $|Q(x) - q(x)| < \theta$ 并且 $|R(x) - r(x)| < \theta$ ，又因为 q 和 r 在 $[0, 1]^d$ 上连续，所以它们有界。

存在 $L > 0$ 使得 $|q(x)| \leq L$ 且 $|r(x)| \leq L$ ，当 $\theta < 1$ 时，有 $|Q(x)| \leq L+1$ 且 $|R(x)| \leq L+1$ 。

现在使用乘法逼近网络： $M_\rho(Q(x), R(x))$ 逼近 $Q(x)R(x)$ ，于是：

$$|M_\rho(Q(x), R(x)) - q(x)r(x)|$$

不超过 $|M_\rho(Q(x), R(x)) - Q(x)R(x)| + |Q(x)R(x) - q(x)r(x)|$ ，第一项可以通过选择乘法网络精度，使它小于 ρ ；第二项展开：

$$Q(x)R(x) - q(x)r(x) = Q(x)(R(x) - r(x)) + r(x)(Q(x) - q(x))$$

因此 $|Q(x)R(x) - q(x)r(x)| \leq |Q(x)||R(x) - r(x)| + |r(x)||Q(x) - q(x)|$ ，代入界 $|Q(x)R(x) - q(x)r(x)| \leq (L+1)\theta + L\theta = (2L+1)\theta$ ，只要选择 ρ 和 θ 足够小，就可以让误差任意小。

因此，如果 $q(x)$ 和 $r(x)$ 都能被 ReLU 网络逼近，那么 $q(x)r(x)$ 也能被 ReLU 网络逼近。

由此可以归纳推出：

任意有限乘积 $x_1^{\alpha_1} x_2^{\alpha_2} \cdots x_d^{\alpha_d}$ 都可以被 ReLU 网络逼近。也就是说，任意单项式 x^α 都可以被 ReLU 网络逼近。

设多项式为 $P(x) = \sum_{\alpha} c_{\alpha} x^{\alpha}$ ，因为这个求和是有限求和。对于每个单项式 x^{α} ，我们都可以构造一个 ReLU 网络 $G_{\alpha}(x)$ ，使得 $|G_{\alpha}(x) - x^{\alpha}|$ 足够小。然后令：

$$G(x) = \sum_{\alpha} c_{\alpha} G_{\alpha}(x)$$

神经网络最后一层允许线性组合，所以 G 仍然是一个 ReLU 神经网络。误差为 $|G(x) - P(x)| = \left| \sum_{\alpha} c_{\alpha} (G_{\alpha}(x) - x^{\alpha}) \right|$ ，由三角不等式：

$$|G(x) - P(x)| \leq \sum_{\alpha} |c_{\alpha}| |G_{\alpha}(x) - x^{\alpha}|$$

因为求和项有限，所以只要让每个 $|G_{\alpha}(x) - x^{\alpha}|$ 都足够小，就可以保证：

$$\sup_{x \in [0,1]^d} |G(x) - P(x)| < \frac{\varepsilon}{2}$$

因此，任意多维多项式都可以被 ReLU 神经网络一致逼近，证毕！]

证明第三：合并两部分证明。

[现在回到原函数 $f: [0,1]^d \rightarrow \mathbb{R}$ ，给定任意 $\varepsilon > 0$ ，根据第一步，存在一个多维多项式 P ，使得 $\sup_{x \in [0,1]^d} |f(x) - P(x)| < \frac{\varepsilon}{2}$ ，于是：

$$|f(x) - F(x)| \leq |f(x) - P(x)| + |P(x) - F(x)|$$

所以 $\sup_{x \in [0,1]^d} |f(x) - F(x)| \leq \sup_{x \in [0,1]^d} |f(x) - P(x)| + \sup_{x \in [0,1]^d} |P(x) - F(x)|$ ，代入

上面的两个不等式： $\sup_{x \in [0,1]^d} |f(x) - F(x)| < \frac{\varepsilon}{2} + \frac{\varepsilon}{2} = \varepsilon$ ，因此：

$$\sup_{x \in [0,1]^d} |f(x) - F(x)| < \varepsilon$$

这就证明了多维 ReLU 神经网络的万有逼近定理。]

综上。对于任意连续函数 $f: [0,1]^d \rightarrow \mathbb{R}$ ，任意误差 $\varepsilon > 0$ ，都存在一个 ReLU 神经网络 F ，使得 $\sup_{x \in [0,1]^d} |f(x) - F(x)| < \varepsilon$ 。

也就是说，多维 ReLU 神经网络可以在闭有界区域上一致逼近任意连续函数。
证毕!!!