

没有免费午餐定理

在机器学习刚开始被广泛讨论的时候，人们心里其实有一个很自然的愿望：**能不能找到一种“最强算法”？**

也就是说，不管面对什么问题，不管是图像分类、语音识别、股票预测、疾病诊断，还是路径搜索、参数优化，我们都希望有一个算法永远比其他算法更聪明、更稳定、更可靠。这个想法非常诱人。因为如果真的存在这样的算法，那么机器学习研究就会变得很简单：我们只需要不断寻找那个“万能算法”，一旦找到了，所有问题都可以交给它。

但是，20 世纪 90 年代，David Wolpert 和 William Macready 对这个想法提出了一个非常深刻的反驳。他们在优化问题中系统提出了 No Free Lunch Theorems，也就是“没有免费午餐定理”；而 Wolpert 更早也讨论过监督学习中的类似结论。这个定理的大意是：如果我们把所有可能的问题都平等地考虑进去，那么任何两个算法的平均表现都是一样的。这听起来很反直觉。因为在现实中，我们明明看到有些算法确实更强。例如，卷积神经网络在图像任务上很强，Transformer 在语言任务上很强，决策树在某些结构化表格数据上也很有优势。那为什么没有免费午餐定理还说“所有算法平均起来一样”呢？

原因是它不是说所有算法在现实任务中都一样，而是说：如果你不对任务做任何假设，那么就不存在一个对所有任务都最优的算法。

[举例：

假设我们只看到了几个训练样本，然后想预测没见过数据。如果我们完全不相信“相似的输入有相似的输出”，也不相信“图像有局部结构”，不相信“语言有语法规律”，不相信“真实世界的数据通常不是随机乱码”，那么训练样本其实无法告诉我们未知样本应该是什么。因为未知区域的标签完全可以任意变化。

一个算法之所以能泛化，因为它偷偷带着某种假设进入了问题。这个假设，在机器学习中叫作**归纳偏置**，也就是 inductive bias。所以，没有免费午餐定理真正想告诉我们的机器学习之所以有用，恰恰是因为现实世界不是任意混乱的。现实世界有结构，有规律，有分布，有偏好。]

接下来，我要用一个非常简单的数学推导来说明：如果所有可能的规律都被平均考虑，那么任何算法在未知样本上的平均表现都不会比随机猜测更有优势。

假设输入空间是有限的： $\mathcal{X} = \{x_1, x_2, \dots, x_n\}$

输出空间是分类标签集合： $\mathcal{Y} = \{1, 2, \dots, k\}$

一个真实规律，也就是目标函数，可以写成： $f: \mathcal{X} \rightarrow \mathcal{Y}$

也就是说，每个输入 x 都有一个真实标签 $f(x)$

所有可能的目标函数数量是 $|\mathcal{Y}|^{|\mathcal{X}|} = k^n$

给定训练集 $D = \{(x_1, f(x_1)), (x_2, f(x_2)), \dots, (x_m, f(x_m))\}$ ，其中训练输入集合记为 $S = \{x_1, x_2, \dots, x_m\}$ ，剩下没有见过的测试输入集合记为 $T = \mathcal{X} \setminus S$

学习算法 A 根据训练集 D ，输出一个预测函数 $h_A = A(D)$ ，然后在测试点 $x \in T$ 上进行预测： $h_A(x)$ ，我们考虑它与真实标签 $f(x)$ 是否一致。

使用 0-1 损失 $\ell(h_A(x), f(x)) = \begin{cases} 0, & h_A(x) = f(x) \\ 1, & h_A(x) \neq f(x) \end{cases}$ ，算法 A 在测试集 T 上的平均

误差为 $L_A(f) = \frac{1}{|T|} \sum_{x \in T} \ell(h_A(x), f(x))$

我们比较两个算法: A_1, A_2

没有免费午餐定理说, 如果对所有可能的目标函数 f 求平均, 那么:

$$\frac{1}{|\mathcal{Y}|^{|\mathcal{X}|}} \sum_{f: \mathcal{X} \rightarrow \mathcal{Y}} L_{A_1}(f) = \frac{1}{|\mathcal{Y}|^{|\mathcal{X}|}} \sum_{f: \mathcal{X} \rightarrow \mathcal{Y}} L_{A_2}(f)$$

对任意算法 A , 这个平均误差都一样。

我们要求 $\mathbb{E}_f[L_A(f)]$, 也就是 $\mathbb{E}_f[L_A(f)] = \frac{1}{k^n} \sum_{f: \mathcal{X} \rightarrow \mathcal{Y}} \frac{1}{|T|} \sum_{x \in T} \ell(h_A(x), f(x))$, 交换求和顺序 $\mathbb{E}_f[L_A(f)] = \frac{1}{|T|} \sum_{x \in T} \frac{1}{k^n} \sum_{f: \mathcal{X} \rightarrow \mathcal{Y}} \ell(h_A(x), f(x))$, 由于 $h_A = A(D)$, 而训练集 D 只包含 S 上的信息, 也就是 $D = \{(x, f(x)): x \in S\}$, 所以算法 A 的输出只依赖于 f 在训练点 S 上的取值, 不依赖于 f 在测试点 T 上的取值。

一个完整的函数 f 可以拆成 $f = (f_S, f_T)$, 其中 $f_S: S \rightarrow \mathcal{Y}$ 表示训练点上的标签; $f_T: T \rightarrow \mathcal{Y}$ 表示测试点上的标签。

训练算法只能看到 f_S 看不到 f_T , 因此, 对于固定的 f_S , 算法输出是固定的, 即 $h_A = A(D_{f_S})$, 但是测试标签 $f_T(x)$ 仍然可以是任意标签。对于某个测试点 $x \in T$, 在所有可能函数中, $f(x)$ 会均匀地取遍 $1, 2, \dots, k$

所以对于固定预测 $h_A(x)$, 平均损失是 $\frac{1}{k} \sum_{y \in \mathcal{Y}} \ell(h_A(x), y)$, 由于是 0-1 损失, 只有当 $y = h_A(x)$ 时损失为 0, 其他 $k-1$ 个标签都会产生损失 1。

所以 $\sum_{y \in \mathcal{Y}} \ell(h_A(x), y) = k-1$, 因此 $\frac{1}{k} \sum_{y \in \mathcal{Y}} \ell(h_A(x), y) = \frac{k-1}{k}$, 这个结果和算法 A 无关。因此每个测试点上的平均错误率都是 $\frac{k-1}{k}$, 所以整个测试集上的平均错误率也是 $\mathbb{E}_f[L_A(f)] = \frac{k-1}{k}$, 也就是说, 对任意算法 A , 都有 $\mathbb{E}_f[L_A(f)] = \frac{k-1}{k}$ 。

[举例:

假设输入空间只有 3 个样本 $\mathcal{X} = \{x_1, x_2, x_3\}$

标签只有两类 $\mathcal{Y} = \{0, 1\}$

现在训练集只告诉我们 $D = \{(x_1, 0)\}$, 也就是说, 算法只知道 $f(x_1) = 0$, 但是它完全不知道 $f(x_2), f(x_3)$

剩下的 x_2, x_3 可以任意取 0 或 1。因此一共有 4 种可能的真实规律：

真实函数	$f(x_1)$	$f(x_2)$	$f(x_3)$
f_1	0	0	0
f_2	0	0	1
f_3	0	1	0
f_4	0	1	1

现在假设有三个算法。算法 A 很保守，它认为所有未知样本都是 0：

$$A(x_2) = 0, A(x_3) = 0$$

算法 B 很激进，它认为所有未知样本都是 1：

$$B(x_2) = 1, B(x_3) = 1$$

算法 C 混合预测：

$$C(x_2) = 0, C(x_3) = 1$$

算法 A 的预测是 $(x_2, x_3) = (0, 0)$

真实函数	真实标签 $(f(x_2), f(x_3))$	算法 A 预测	错误数
f_1	(0,0)	(0,0)	0
f_2	(0,1)	(0,0)	1
f_3	(1,0)	(0,0)	1
f_4	(1,1)	(0,0)	2

算法 A 的平均错误数是 $\frac{0+1+1+2}{4} = 1$ ，因为测试样本一共有 4 个，所以平均错误率是 $\frac{1}{2}$

算法 B 的预测是 $(x_2, x_3) = (1, 1)$

真实函数	真实标签 $(f(x_2), f(x_3))$	算法 B 预测	错误数
f_1	(0,0)	(1,1)	2
f_2	(0,1)	(1,1)	1
f_3	(1,0)	(1,1)	1
f_4	(1,1)	(1,1)	0

算法 B 的平均错误数是 $\frac{2+1+1+0}{4} = 1$ ，平均错误率是 $\frac{1}{2}$

算法 C 的预测是 $(x_2, x_3) = (0, 1)$

真实函数	真实标签($f(x_2), f(x_3)$)	算法 C 预测	错误数
f_1	(0,0)	(0,1)	1
f_2	(0,1)	(0,1)	0
f_3	(1,0)	(0,1)	2
f_4	(1,1)	(0,1)	1

所以算法 C 的平均错误数是 $\frac{1+0+2+1}{4} = 1$ ，平均错误率仍然是 $\frac{1}{2}$

三个算法的平均错误率都是 $\frac{1}{2}$ ，也就是说 A, B, C 在所有可能真实规律上的平均表现一样，虽然它们的预测策略完全不同。]

综上，没有免费午餐定理可以概括为“一个算法在某些任务上表现更好，必然意味着它在另一些任务上表现更差”，数学表述为“在所有可能目标函数上取平均，所有学习算法的泛化误差相同”。