

流形假设 Manifold Hypothesis

导论

流形假设是理解深度学习为什么能够处理高维数据时经常使用的一种观点。图像、语音和文本经过数字化以后，通常都会变成非常高维的向量。例如一张 224×224 的 RGB 图片，一共有 $224 \times 224 \times 3 = 150528$ 个数，所以一张图片可以写成 $x \in \mathbb{R}^{150528}$ 。从数学上看，所有可能的图片都位于这个 150528 维空间里，但真实世界中的自然图片只会出现在其中很小的一部分区域。随机生成 150528 个像素值，通常只会得到噪声，很难自然形成一张完整的人脸、汽车或者街景。这说明真实数据虽然使用高维向量表示，但这些维度之间并不能完全独立变化，数据受到大量结构约束。

流形假设描述的就是这种现象：真实高维数据通常集中在一个维度远低于原始输入空间的结构附近。设原始数据属于 $x \in \mathbb{R}^D$ ，真正控制数据变化的有效变量只有 d 个，而且 $d \ll D$ ，那么可以引入低维变量 $z \in \mathbb{R}^d$ ，再通过一个映射 $x = f(z)$ 生成高维数据。所有能够由 $f(z)$ 得到的数据点构成集合 $\mathcal{M} = \{f(z) \mid z \in \mathbb{R}^d\}$ ，这个集合就可以看成嵌入 $\mathbb{R}^D$ 中的一个 d 维结构。

一、从高维空间到低维流形

1.1 为什么高维数据可能只有较低的有效维度

先看一个简单例子。假设一个数据点由三个数表示，即 $x = (x_1, x_2, x_3) \in \mathbb{R}^3$ 。如果这三个数可以完全独立变化，那么数据确实有三个自由度。现在加入约束 $x_1^2 + x_2^2 + x_3^2 = 1$ ，那么所有数据点都会落在单位球面上。虽然每一个点仍然需要三个数来表示，但三个变量之间已经存在关系，所以真正能独立变化的变量只剩两个。

球面上的点可以用两个参数 θ 和 ϕ 表示：

$$x_1 = \sin \theta \cos \phi, \quad x_2 = \sin \theta \sin \phi, \quad x_3 = \cos \theta.$$

因此整个球面可以写成 $x = f(\theta, \phi)$ 。这里输出空间是三维的，但输入只需要两个变量，所以球面的环境空间维度为 $D = 3$ ，内在维度为 $d = 2$ 。深度学习中的情况可以理解成这个例子的高维版本：图片可能有几十万个像素，但这些像素之间存在大量关系，因此真正能够自由变化的方向远少于像素数量。

如果希望进一步从约束数量理解维度下降，可以设 $x \in \mathbb{R}^D$ 受到 m 个彼此独立的约束 $g_1(x) = 0, \dots, g_m(x) = 0$ 。把这些约束写成向量 $g(x)$ ，其 Jacobian 为 $J_g(x) \in \mathbb{R}^{m \times D}$ 。当数据点发生一个很小的变化 δx 时，有 $g(x + \delta x) \approx g(x) + J_g(x)\delta x$ 。因为原来 $g(x) = 0$ ，所以变化后的点要继续满足约束，就需要 $J_g(x)\delta x = 0$ 。这表示真正允许的数据变化方向位于 $J_g(x)$ 的零空间中。如果这些约束独立，即 $\text{rank}(J_g) = m$ ，

根据秩-零化度定理，零空间维度为 $D - m$ 。因此，约束越多，真正能够自由变化的方向就越少。

1.2 流形、局部坐标和切空间

如果一个集合 $\mathcal{M} \subset \mathbb{R}^D$ 在每一个局部区域都可以用 d 个连续变量描述，就可以把它看成一个 d 维流形。形式上可以写成 $x = f(z)$ ，其中 $z \in \mathbb{R}^d$ ，而 $x \in \mathbb{R}^D$ 。这里的重点在于“局部”。一个流形整体可以非常弯曲，但在足够小的区域里，它通常可以近似成一个线性空间。

假设潜变量从 z 变化到 $z + \Delta z$ ，利用一阶 Taylor 展开有

$$f(z + \Delta z) \approx f(z) + J_f(z)\Delta z.$$

其中 $J_f(z) = \partial f / \partial z \in \mathbb{R}^{D \times d}$ 是 Jacobian。把 $J_f(z)$ 展开以后，可以看到 Δx 实际上由 $\partial f / \partial z_1, \dots, \partial f / \partial z_d$ 这些方向共同决定，因此这些向量张成的空间

$$T_x \mathcal{M} = \text{span} \left\{ \frac{\partial f}{\partial z_1}, \dots, \frac{\partial f}{\partial z_d} \right\}$$

就是流形在点 x 附近的切空间。它描述当前数据点附近主要能够发生哪些局部变化。

1.3 人脸图片中的低维变化

假设同一个人的图片大小为 $224 \times 224 \times 3$ ，所以每张图片都是 $\mathbb{R}^{150528}$ 中的一个点。现在只改变头部左右旋转角度，记角度为 θ ，那么每一张图片都可以写成 $x = f(\theta)$ 。虽然图片有 150528 个像素维度，但这一组图片的主要变化只由一个变量控制，所以它们在高维空间中形成一条一维轨迹。

如果再加入上下旋转角度 ϕ ，可以写成 $x = f(\theta, \phi)$ ；再加入光照强度 l ，则变成 $x = f(\theta, \phi, l)$ 。这时潜变量 $z = (\theta, \phi, l) \in \mathbb{R}^3$ ，而图片依然处在 $\mathbb{R}^{150528}$ 中。真实的人脸还会受到身份、表情、距离、背景、相机参数等很多因素影响，所以实际内在维度远大于 3，但仍然可以远低于原始像素维度。原始像素维度描述的是数据怎样被存储，内在维度描述的是数据真正有多少种独立变化方向。

二、为什么流形假设对深度学习有用

2.1 维度灾难与有效自由度

高维空间最大的困难之一是维度灾难。假设每个维度只取 m 个离散位置，那么一个 D 维空间需要 m^D 个采样点才能保持同样的网格密度。例如每个维度只取 10 个位置，当 $D = 2$ 时只有 $10^2 = 100$ 个点；当 $D = 10$ 时已经需要 10^{10} 个点；当 $D = 100$ 时则需要 10^{100} 个点。维度增加以后，完整覆盖空间几乎不可能。

如果真实数据主要集中在一个 d 维流形附近，而且 $d \ll D$ ，那么模型真正需要学习的变化主要发生在 d 个有效方向上。采样复杂度更接近 m^d ，而不是 m^D 。这并不表示训练严格只需要 m^d 个样本，但它说明真实数据的有效复杂度可以远低于原

始输入空间的维度。深度学习能够在高维输入上工作，一个重要原因就是模型主要学习真实数据经常出现的那些结构化区域。

2.2 从概率分布看数据结构

从概率角度看，训练数据来自真实分布 $x \sim p_{\text{data}}(x)$ 。流形假设认为，大部分概率质量集中在低维结构附近。理想情况下，可以写成 $\text{supp}(p_{\text{data}}) \approx \mathcal{M}$ ，其中 $\text{supp}(p)$ 表示概率分布主要有质量的区域。

现实数据还会受到传感器噪声、压缩误差和环境扰动，因此更合理的写法是 $x = f(z) + \epsilon$ ，其中 $z \in \mathbb{R}^d$ 表示低维因素， ϵ 表示噪声。如果假设 $\epsilon \sim \mathcal{N}(0, \sigma^2 I)$ ，那么条件概率可以写成

$$p(x|z) = \mathcal{N}(f(z), \sigma^2 I).$$

再给潜变量一个分布 $p(z)$ ，数据分布可以写成

$$p(x) = \int p(x|z)p(z) dz.$$

这个形式说明，高维观测可以由较低维的潜变量经过非线性映射生成，同时允许数据围绕理想结构产生一定噪声。

三、流形与经典降维方法

3.1 PCA：线性低维结构

PCA 可以看成最简单的低维结构学习。假设数据经过中心化后为 $\tilde{x}_i = x_i - \mu$ ，协方差矩阵为

$$C = \frac{1}{N} \sum_{i=1}^N \tilde{x}_i \tilde{x}_i^\top.$$

对 C 做特征值分解 $C = U\Lambda U^\top$ ，取最大的前 d 个特征向量组成 U_d ，那么低维表示为 $z = U_d^\top(x - \mu)$ ，重建为 $\hat{x} = \mu + U_d z$ 。

这相当于假设数据主要位于一个 d 维线性子空间中，即 $x \approx \mu + U_d z$ 。因此 PCA 对应的映射 $f(z) = \mu + U_d z$ 是线性的。流形假设允许 f 是非线性的，所以可以描述弯曲得多的数据结构。PCA 适合学习一个整体平直的低维结构，而流形学习允许这种低维结构在高维空间中发生弯曲。

3.2 局部 PCA、内在维度与流形学习

虽然整个流形可能是非线性的，但在非常小的局部区域中，它可以近似成切平面。因此可以在某个样本附近取 k 个邻居 $x_1, \dots, x_k$ ，计算局部协方差矩阵

$$C_{\text{local}} = \frac{1}{k} \sum_{i=1}^k (x_i - \mu)(x_i - \mu)^\top.$$

如果局部流形维度大约是 d ，那么最大的前 d 个特征值通常会比较明显，后面的特征值较小，也就是可能出现 $\lambda_1 \geq \dots \geq \lambda_d \gg \lambda_{d+1}$ 。这说明数据主要沿前 d 个方向变化，因此局部 PCA 可以用来近似流形的切空间。

如果只想估计整体的线性内在维度，可以观察 PCA 的累计方差比例。设协方差矩阵特征值满足 $\lambda_1 \geq \dots \geq \lambda_D$ ，定义

$$R(d) = \frac{\sum_{i=1}^d \lambda_i}{\sum_{i=1}^D \lambda_i}.$$

如果一个相对较小的 d 已经使 $R(d)$ 达到 0.95 或 0.99，说明数据的大部分线性变化都集中在前几个方向。

经典流形学习会进一步要求低维表示保留原始空间中的局部关系。给定 $x_i \in \mathbb{R}^D$ ，希望找到 $z_i \in \mathbb{R}^d$ ，可以构造邻接权重 w_{ij} ：样本越接近， w_{ij} 越大。一个常见目标形式为

$$\min_{\{z_i\}} \sum_{i,j} w_{ij} \|z_i - z_j\|_2^2.$$

这个目标要求原空间中的邻居在低维空间中仍然保持接近。LLE、Laplacian Eigenmaps、Isomap 等方法虽然具体形式不同，但都在尝试保留某种局部几何关系。

四、流形与深度表示学习

4.1 Autoencoder：从高维输入到低维潜变量

Autoencoder 很容易和流形假设联系起来。设输入为 $x \in \mathbb{R}^D$ ，Encoder 把它压缩成潜变量 $z = E_\theta(x) \in \mathbb{R}^d$ ，Decoder 再从 z 重建输入 $\hat{x} = D_\phi(z)$ 。训练常用重建损失

$$\mathcal{L}_{\text{rec}} = \|x - D_\phi(E_\theta(x))\|_2^2.$$

如果 $d \ll D$ ，Encoder 无法把所有原始像素都独立保存在潜变量里，它需要保留那些更能决定数据结构的信息。训练完成后，可以把 Decoder 看成映射 $f(z) = D_\phi(z)$ ，于是有 $x \approx f(z)$ ，这和流形假设中的表达形式很接近。

普通 Autoencoder 仍然可能得到不够平滑的潜空间。假设两个训练样本对应 z_1 和 z_2 ，取它们之间的插值 $z_\lambda = (1 - \lambda)z_1 + \lambda z_2$ ，Decoder 输出 $D(z_\lambda)$ 不一定对应合理数据。这说明降低潜变量维度只能提供压缩约束，还不能保证潜空间中的所有区域都具有连续而规则的数据结构。

4.2 VAE：给潜空间加入概率结构

VAE 会进一步给潜变量加入概率约束。Encoder 输出的是条件分布

$$q_\phi(z|x) = \mathcal{N}(\mu_\phi(x), \text{diag}(\sigma_\phi^2(x))),$$

再通过 $z = \mu_\phi(x) + \sigma_\phi(x) \odot \epsilon$ ，其中 $\epsilon \sim \mathcal{N}(0, I)$ ，完成采样。VAE 还会让后验分布接近先验 $p(z) = \mathcal{N}(0, I)$ ，因此训练目标通常写成

$$\mathcal{L}_{\text{VAE}} = \mathcal{L}_{\text{rec}} + \beta D_{\text{KL}}(q_\phi(z|x) \| p(z)).$$

重建项保证潜变量保存足够的数据内容，KL 项让不同样本的潜变量分布保持较规则的整体结构。这样潜空间中的邻近位置更容易对应相似数据，也更适合连续采样和生成。

4.3 深度网络如何改变表示空间

一个深度网络可以写成 $h^{(0)} = x$ ，然后不断计算 $h^{(1)} = f_1(h^{(0)})$ 、 $h^{(2)} = f_2(h^{(1)})$ ，直到 $h^{(L)} = f_L(h^{(L-1)})$ 。因此原始数据结构会经过多层映射逐渐变成新的表示结构。

对于分类任务，输入空间中的不同类别可能交错得非常复杂，最后一个线性分类器很难直接在原始像素上完成分类。前面的深层网络会不断调整表示，使与类别有关的方向更加明显。最终分类器只需要计算 $z = Wh + b$ ，再通过 $\text{softmax}(z)$ 得到类别概率。最后一层虽然是线性的，前面的多层网络已经完成了大量非线性表示变换。

五、局部几何、OOD 与生成模型

5.1 神经网络的局部线性化

设网络表示为 $h = F(x)$ 。如果输入发生一个很小的变化 δ ，可以利用一阶 Taylor 展开得到

$$F(x + \delta) \approx F(x) + J_F(x)\delta.$$

其中 $J_F(x)$ 是网络对输入的 Jacobian。这个式子说明，在非常小的局部区域中，网络对输入变化的响应主要由 Jacobian 决定。

如果数据流形在 x 附近的切空间为 $T_x\mathcal{M}$ ，那么可以把输入扰动分成沿流形的部分 $\delta_{\parallel}$ 和偏离流形的部分 $\delta_{\perp}$ ，满足 $\delta = \delta_{\parallel} + \delta_{\perp}$ 。如果切空间有正交基 $U \in \mathbb{R}^{D \times d}$ ，那么沿流形方向的投影为 $\delta_{\parallel} = UU^T\delta$ ，剩余部分为 $\delta_{\perp} = \delta - UU^T\delta$ 。这样就可以分别分析模型对数据结构内部变化和偏离数据结构变化的响应。

5.2 流形与 OOD

训练模型时，监督主要来自训练样本 $x_1, \dots, x_N$ ，经验风险通常写成

$$\min_{\theta} \frac{1}{N} \sum_{i=1}^N \mathcal{L}(F_{\theta}(x_i), y_i).$$

这意味着模型真正受到约束的区域主要是训练数据附近。如果一个输入远离训练数据所在的高概率区域，模型仍然会给出输出，但这些位置缺少足够训练样本进行约束，所以预测可靠性通常会下降。

从流形角度看，OOD 检测可以理解成判断输入距离数据结构有多远。理想情况下，可以定义 $d(x, \mathcal{M}) = \inf_{x' \in \mathcal{M}} \|x - x'\|$ 。实际中真实流形未知，所以通常会使用特征距离、重建误差、密度估计等方法近似判断输入是否偏离训练数据分布。

5.3 生成模型、扩散模型与 Score

生成模型希望学习真实数据分布 $p_{\text{data}}(x)$ 。如果假设数据由潜变量 $z \sim p(z)$ 生成，并通过 $x = f_{\theta}(z)$ 得到高维数据，那么生成模型要学习的就是这个从潜变量到数据的映射。GAN 直接学习 $x = G_{\theta}(z)$ ；VAE 学习条件分布 $p_{\theta}(x|z)$ ；Normalizing Flow 学习可逆变换 $x = f_{\theta}(z)$ 。这些方法形式不同，但都在尝试描述真实高维数据所处的结构。

扩散模型采用逐步加噪和逐步去噪的方式学习数据分布。前向过程常写成

$$x_t = \sqrt{\alpha_t}x_0 + \sqrt{1 - \alpha_t}\epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$

随着 t 增大，数据逐渐离开原始高概率区域并趋近高斯噪声；反向过程再学习如何一步一步恢复真实数据。

扩散模型中经常出现 Score，定义为 $s(x) = \nabla_x \log p(x)$ ，它表示概率密度增长最快的方向。如果真实数据集中在某个低维结构附近，那么离开这个结构以后，概率密度通常会迅速下降，因此 Score 会包含指向更高概率数据区域的方向信息。Score-based 模型通过学习 $s_{\theta}(x, t) \approx \nabla_x \log p_t(x)$ 来完成反向生成。

六、流形假设的限制与理解方式

真实数据通常不会严格落在一个完美、光滑、固定维度的流形上。不同类别可能具有不同的内在维度，不同局部区域的复杂度也可能不同；类别、文字内容等变量还包含明显的离散变化，无法全部由连续坐标平滑连接。数据中还存在噪声、遮挡和压缩误差，所以实际样本更适合看成集中在某些低维结构附近，而不是精确位于一个数学上完美的流形上。

现代深度网络的隐藏维度也不一定越来越小。有些网络中间层的维度甚至比输入更高，因此“低维”更适理解解为有效自由度、局部变化方向和数据结构复杂度较低，而不是简单比较张量最后一维的大小。

从数学上看，流形假设可以概括为：原始数据属于高维空间 $x \in \mathbb{R}^D$ ，真正控制数据变化的有效因素可以表示成 $z \in \mathbb{R}^d$ ，其中 $d \ll D$ ，高维观测由 $x = f(z) + \epsilon$ 产生。局部上利用一阶 Taylor 展开有 $f(z + \Delta z) \approx f(z) + J_f(z)\Delta z$ ，所以 Jacobian 的列空间描述了数据附近主要的变化方向，也就是流形的局部切空间。

这一观点可以连接很多深度学习方法：PCA 学习线性低维结构，Autoencoder 学习压缩表示，VAE 学习带概率约束的潜空间，生成模型学习从潜变量到真实数据的映射，分类网络不断重组数据表示，OOD 检测研究输入是否偏离训练数据高概率区

域，扩散模型学习如何从噪声状态逐渐回到真实数据分布附近。输入虽然处在很高维的空间中，真正有意义的变化受到大量结构约束，深度学习模型通过多层非线性变换学习这些结构，再把它们用于分类、重建、生成、检索和推理。