

交叉熵损失函数

假设我们有一个分类问题，并且收集到了一个包含 N 个样本的数据集：

$$\mathcal{D} = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$$

x_i 是第 i 个样本的特征（输入）； y_i 是第 i 个样本的真实标签（输出）；模型有一组参数，记作 θ 。模型的任务是输出一个概率分布，即给定输入 x_i 和参数 θ 时，预测类别为 y_i 的概率，我们记作 $P(y_i|x_i; \theta)$ 。

“似然”（Likelihood）的意思是：在已知当前模型参数 θ 的情况下，我们能够观测到这组已有数据集 $\mathcal{D}$ 的概率有多大？

在机器学习中，我们通常假设所有样本都是**独立同分布**的。因为是独立的，所以同时观测到所有样本的概率，等于观测到每个样本概率的乘积。这就是**似然函数** $L(\theta)$ ：

$$L(\theta) = \prod_{i=1}^N P(y_i|x_i; \theta)$$

连乘操作在数学和计算机中很难处理（容易造成浮点数下溢，因为多个小于 1 的概率相乘会极速趋近于 0）。为了方便计算，我们对似然函数取自然对数（log）。因为对数函数是单调递增的，所以使 $L(\theta)$ 最大的参数 θ ，同样也会使 $\log L(\theta)$ 最大。

利用对数的性质 $\log(A \times B) = \log A + \log B$ ，我们将连乘变成了连加，得到**对数似然函数**：

$$\log L(\theta) = \sum_{i=1}^N \log P(y_i|x_i; \theta)$$

最大似然估计（MLE）的目标就是找到一组完美的参数 θ^* ，使得上述对数似然函数最大化：

$$\theta^* = \arg \max_{\theta} \sum_{i=1}^N \log P(y_i|x_i; \theta)$$

[大家在这里会有一个疑问，为什么要最大化似然函数？我举一个通俗的例子，假设有一个纸箱，里面有 1000 张标记着“1”的卡牌，也有 1000 张标记为“0”的卡牌，总计 2000 张卡牌，假设我摸了 4 张，其中有两张“1”卡牌和两张“0”卡牌，这个是最优可能发生的情况，因此摸出两张“1”卡牌和两张“0”卡牌的情况是最大的（这个自己简单想想就知道为啥这个情况概率最大）；

好的，现在吧情况反过来，假设我现在不知纸箱里面 2000 张的卡牌中有多少张“1”卡牌和“0”卡牌，我现在直接抽取 4 张，得到了两张“1”卡牌和两张“0”卡牌，那么我问你纸箱中“1”卡牌和“0”卡牌的数量分别为多少？

显然，对于这个情况我只能假设我抽出来的两张“1”卡牌和两张“0”卡牌是所有抽出来的情况中概率最大的，因为我只有这个样本。因此可以反推出只有当纸箱中的“0”和“1”对半开的时候我抽取出两张“1”卡牌和两张“0”卡牌的概率是最大的。（举一个极端的例子就是纸箱子中有 2 张“1”和 1998 张“0”，我能抽取出两张“1”卡牌和两张“0”卡牌几乎是不可能的），因此我们要求的就是似然函数的最大值。

用数学的语言表述就是我不知道原始“1”和“0”的概率，因此我假设“1”的概率为 p ，“0”的概率为 $1-p$ ，而我抽取的两张“1”卡牌和两张“0”卡牌的概率为 $p^2(1-p)^2$ ，这个概率就是似然函数，其中的自变量为 p ，而现在我们需要求

$p^2(1-p)^2$ 的最大值，很明显，结果为 $p = \frac{1}{2}$ 时概率最大，这与我先前所说的 1000 张“1”卡牌和 1000 张“0”卡牌的结果对应。]

交叉熵衡量的是**两个概率分布之间的差异**。对于任何一个样本 i ，都有两个分布：

真实分布 P_{data} ：在分类任务中，这通常用 One-hot 编码表示。也就是说，对于真实类别，概率为 1；对于其他类别，概率为 0。

模型预测分布 P_{model} ：模型输出的各个类别的概率，即 $P(y|x_i; \theta)$ 。

对于单个样本的某个类别 c ，交叉熵的定义为：

$$H(P_{data}, P_{model}) = - \sum_c P_{data}(c) \log P_{model}(c)$$

因为真实分布 P_{data} 是 One-hot 的（只有正确的那个类别 y_i 概率为 1，其余全为 0），所以上面那个连加公式中，绝大多数项乘以 0 都消失了。唯一留下来的，就是真实类别 y_i 对应的那一项：

$$H(P_{data}, P_{model}) = -1 \cdot \log P(y_i|x_i; \theta)$$

所以，对于单个样本，它的交叉熵损失就是 $-\log P(y_i|x_i; \theta)$ 。

为了衡量模型在整个数据集上的表现，我们将所有样本的交叉熵加起来求平均，得到**交叉熵损失函数 $J(\theta)$** ：

$$J(\theta) = -\frac{1}{N} \sum_{i=1}^N \log P(y_i|x_i; \theta)$$

机器学习的目标是让模型的预测尽可能接近真实情况，也就是最小化这个交叉熵损失：

$$\theta^* = \arg \min_{\theta} \left(-\frac{1}{N} \sum_{i=1}^N \log P(y_i|x_i; \theta) \right)$$

[补充一下交叉熵的由来：

香农认为，一个事件的信息量大小，应该与它发生的概率成反比。概率越小，信息量越大；概率为 1（必定发生），信息量为 0。（比如说奶龙是奶龙，这就是概率为 1 的事情，你说了一句废话，所以信息量为 0）

为了满足这个数学性质，香农将**信息量**定义为概率的负对数。假设事件 x 发生的概率是 $P(x)$ ，那么它的信息量 $I(x)$ 为：

$$I(x) = -\log P(x)$$

（一般来说对数的底数为 2，那么信息量的单位为“比特”，举一个例子，假设一件事件有 8 种可能情况，比如说某一个变量 x 可以取 0,1,2,3,4,5,6,7 这几个值，因此至少要用 $\log_2 8 = 3$ 比特，也就是 000,001,010,011,100,101,110,111 来表示；如果一个事件只有 2 种情况，用 $\log_2 2 = 1$ 比特即可表示，即 0 与 1）

信息量只描述了**单一事件**。但现实中，一个概率分布往往包含多个可能发生的事件。我们将所有可能事件的信息量，乘以它们发生的概率，然后全部加起来。这就是**熵**：

$$H(P) = \mathbb{E}_{x \sim P} [I(x)] = - \sum_x P(x) \log P(x)$$

P 是真实概率分布。熵 $H(P)$ 衡量的是系统的内在不确定性。一个系统越混乱、

越不可预测，它的熵就越大。

在现实中，我们面对一个数据集，它背后有一个未知的真实分布，我们记作 P 。由于不知道真实的 P 长什么样，我们构建了一个模型，模型的输出是一个预测分布，我们记作 Q 。那么对于事件 x ，得到的是 $I_Q(x) = -\log Q(x)$ 。

但是，数据在客观实际上是服从真实分布 P 的。因此，我们计算期望时，**必须在真实分布 P 上进行求期望**。这就是交叉熵 $H(P, Q)$ 的数学定义：

$$H(P, Q) = \mathbb{E}_{x \sim P}[-\log Q(x)] = - \sum_x P(x) \log Q(x)$$

在数学上，KL 散度 $D_{KL}(P||Q)$ 定义为：当我们用分布 Q 来近似真实分布 P 时，交叉熵与真实分布自身的熵之间的差值。

也就是说，它衡量的是 $\mathbb{E}_{x \sim P}[-\log Q(x)]$ 相比于基线 $\mathbb{E}_{x \sim P}[-\log P(x)]$ 多出来的部分。将上述定义转化为等式并展开：

$$D_{KL}(P||Q) = H(P, Q) - H(P)$$

$$D_{KL}(P||Q) = \left(- \sum_x P(x) \log Q(x) \right) - \left(- \sum_x P(x) \log P(x) \right)$$

提取公因式 $\sum_x P(x)$ ：

$$D_{KL}(P||Q) = \sum_x P(x) (-\log Q(x) + \log P(x))$$

$$D_{KL}(P||Q) = \sum_x P(x) (\log P(x) - \log Q(x))$$

根据对数函数的减法运算法则 $\log A - \log B = \log \frac{A}{B}$ ，将括号内部合并，最终得到 KL 散度的标准公式：

$$D_{KL}(P||Q) = \sum_x P(x) \log \frac{P(x)}{Q(x)}$$

现在我们将两个视角的最终目标放在一起对比：

最大化对数似然： $\max \sum_{i=1}^N \log P(y_i|x_i; \theta)$

最小化交叉熵： $\min \left(-\frac{1}{N} \sum_{i=1}^N \log P(y_i|x_i; \theta) \right)$

在数学最优化中，常数系数 $\frac{1}{N}$ 不会改变极值点的位置（它只起到缩放作用），因此：**最大化 $\sum \log P$ 等价于最小化 $-\sum \log P$ 。**