

Adam 优化器

神经网络训练的目标是让损失函数尽可能小，假设神经网络的所有参数记为 θ ，损失函数记为 $L(\theta)$ ，那么训练目标就是 $\min_{\theta} L(\theta)$ ，也就是找到一组参数 θ^* ，使得 $L(\theta^*)$ 尽可能小。

如果是一元函数，例如 $f(x) = x^2$ ，我们想找到它的最小值。它的导数是 $f'(x) = 2x$ ，如果当前在 $x = 3$ ，那么 $f'(3) = 6$ ，导数为正，说明函数在这个点附近往右增加，往左减少。所以我们应该让 x 往导数的反方向走，即 $x \leftarrow x - \eta f'(x)$ ，其中 η 叫学习率，控制每一步走多远。

例如 $x = 3$ ， $\eta = 0.1$ ，那么 $x_{\text{new}} = 3 - 0.1 \times 6 = 2.4$ ，

于是 $f(3) = 9$ ， $f(2.4) = 5.76$ ，损失下降了。

神经网络有很多参数，不只是一个。

假设 $\theta = \begin{bmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_n \end{bmatrix}$ ，损失函数是 $L(\theta_1, \theta_2, \dots, \theta_n)$ ，那么梯度是所有偏导数组成的向量

$$\nabla_{\theta} L(\theta) = \begin{bmatrix} \frac{\partial L}{\partial \theta_1} \\ \frac{\partial L}{\partial \theta_2} \\ \vdots \\ \frac{\partial L}{\partial \theta_n} \end{bmatrix}$$

，梯度下降更新公式是 $\theta \leftarrow \theta - \eta \nabla_{\theta} L(\theta)$ ，这就是最基础的优化算法。

法。

普通梯度下降有一个问题，每次更新只看当前梯度： $\theta_{t+1} = \theta_t - \eta g_t$

其中 $g_t = \nabla_{\theta} L(\theta_t)$ ，表示第 t 步的梯度。但是神经网络训练中，梯度可能会出现两个问题：

问题一：梯度方向变化很剧烈

有时候当前梯度是 $g_1 = 10$ ，下一步可能变成 $g_2 = -8$ ，再下一步又变成 $g_3 = 9$ ，这样参数更新方向会来回震荡。

问题二：不同参数的梯度大小差异很大

比如两个参数 θ_1, θ_2 ，它们的梯度可能是 $\frac{\partial L}{\partial \theta_1} = 100$ ， $\frac{\partial L}{\partial \theta_2} = 0.01$ ，如果使用同一个学习率 η ，那么 θ_1 可能更新太猛， θ_2 可能更新太慢。所以我们希望每个参数都有适合自己的更新步长。

先看第一个改进：**Momentum**

普通梯度下降只看当前梯度 g_t ，Momentum 不仅看当前梯度，还看过去梯度的累积趋势。定义：

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

其中 m_t 表示当前的“梯度平均趋势”。

β_1 通常取 $\beta_1 = 0.9$ ，那么 $m_t = 0.9m_{t-1} + 0.1g_t$ ，意思是当前的方向主要保留过去的方向，同时加入一点当前梯度。然后参数更新为 $\theta_{t+1} = \theta_t - \eta m_t$ ，这可以减少梯度方向的剧烈震荡。

第一个改进：**RMSProp**

RMSProp 会记录梯度平方的平均值：

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$$

注意这里是 g_t^2 ，如果参数是向量，那么平方是逐元素平方： $g_t^2 = \begin{bmatrix} g_{t,1}^2 \\ g_{t,2}^2 \\ \vdots \\ g_{t,n}^2 \end{bmatrix}$

如果某个参数的梯度一直很大，那么它对应的 v_t 就会很大。

RMSProp 更新公式是：

$$\theta_{t+1} = \theta_t - \eta \frac{g_t}{\sqrt{v_t} + \epsilon}$$

其中 ϵ 是一个很小的数，防止分母为零。通常 $\epsilon = 10^{-8}$

重点可以关注 $\frac{g_t}{\sqrt{v_t} + \epsilon}$ ，如果某个参数梯度一直很大， v_t 就大，分母大，更新会被压小。如果某个参数梯度一直很小 v_t 就小，分母小，更新不会被过度压制。

所以 RMSProp 实现了不同参数使用不同的自适应更新幅度。

现在可以理解 Adam 了。Adam 同时做两件事：

第一，像 Momentum 一样，记录梯度的平均趋势： $m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$

第二，像 RMSProp 一样，记录梯度平方的平均趋势： $v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$

然后更新参数： $\theta_{t+1} = \theta_t - \eta \frac{m_t}{\sqrt{v_t} + \epsilon}$

但是 Adam 还有一个步骤：偏差修正。

Adam 初始化时： $m_0 = 0, v_0 = 0$ ，第一步时 $m_1 = \beta_1 m_0 + (1 - \beta_1) g_1$ ，因为 $m_0 = 0$ ，所以 $m_1 = (1 - \beta_1) g_1$ ，如果 $\beta_1 = 0.9$ ，那么 $m_1 = 0.1g_1$ 这明显比真实梯度小很多。

同理： $v_1 = (1 - \beta_2) g_1^2$ ，如果 $\beta_2 = 0.999$ ，那么 $v_1 = 0.001g_1^2$ 也明显偏小。

所以在训练初期， m_t 和 v_t 都会因为初始值为 0 而偏小。

Adam 为了解决这个问题，引入偏差修正：

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}$$

$$\hat{v}_t = \frac{v_t}{1 - \beta_2^t}$$

最后 Adam 更新公式为 $\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$

因此 Adam 算法为：

给定初始参数： θ_0

初始化： $m_0 = 0, v_0 = 0$

常用超参数： $\eta = 0.001, \beta_1 = 0.9, \beta_2 = 0.999, \epsilon = 10^{-8}$

第 t 步：

1. 计算当前梯度

$$g_t = \nabla_{\theta} L(\theta_t)$$

2. 更新一阶矩估计

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

3. 更新二阶矩估计

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$$

4. 修正一阶矩偏差

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}$$

5. 修正二阶矩偏差

$$\hat{v}_t = \frac{v_t}{1 - \beta_2^t}$$

6. 更新参数

$$\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$

什么是一阶矩和二阶矩？这个名字听起来很复杂，其实可以先这样理解。

对于一个随机变量 X ，它的一阶矩通常和均值 $E[X]$ 有关，它的二阶矩通常和平方的均值 $E[X^2]$ 有关。

在 Adam 里面，梯度 g_t 每一步都会变化，所以我们可以把它看成一个不断变化的数据序列。Adam 估计的是梯度的平均值和梯度平方的平均值。也就是：

$$m_t \approx E[g_t], v_t \approx E[g_t^2]$$

[举例：

假设损失函数是 $f(x) = x^2$ ，当前 $x_0 = 3$ ，学习率 $\eta = 0.1$ ，为了方便计算，设 $\beta_1 = 0.9$ ， $\beta_2 = 0.999$ ， $\epsilon \approx 0$ 。初始 $m_0 = 0$ ， $v_0 = 0$

因为 $f'(x) = 2x$ ，所以 $g_1 = f'(3) = 6$ ，更新一阶矩 $m_1 = 0.9 \times 0 + 0.1 \times 6 = 0.6$ ；更新二阶矩 $v_1 = 0.999 \times 0 + 0.001 \times 6^2 = 0.036$

偏差修正: $\hat{m}_1 = \frac{0.6}{1-0.9^1} = \frac{0.6}{0.1} = 6, \hat{v}_1 = \frac{0.036}{1-0.999^1} = \frac{0.036}{0.001} = 36$

参数更新 $x_1 = 3 - 0.1 \times \frac{6}{\sqrt{36}}$

所以 $x_1 = 3 - 0.1 = 2.9$, 那么 $x_1 = 3 - 0.1 \times 6 = 2.4$, Adam 第一步只走了 0.1, 而普通梯度下降走了 0.6, 因为 Adam 会用二阶矩控制更新幅度。]