

参数凝聚

导论

1. 凝聚现象的基本定义

神经网络训练过程中，大量原本随机分布的神经元逐渐聚集到少数几个相近的参数方向或功能方向，使宽网络表现出较低的有效复杂度。

设第 j 个神经元的权重为 $w_j = r_j u_j$ ，其中 $r_j = \|w_j\|_2$ 表示权重大小， $u_j = \frac{w_j}{\|w_j\|_2}$ 表示权重方向。当大量神经元满足 $u_j \approx v_k$ ，即多个神经元集中到同一方向 v_k 附近，就认为发生了凝聚。

2. 凝聚会降低网络的有效宽度

对于双层 ReLU 网络： $f(x) = \sum_{j=1}^m a_j \text{ReLU}(w_j^T x)$ ，若同一簇内 $w_j = r_j v$ ，利用 ReLU 的正齐次性质 $\text{ReLU}(cz) = c\text{ReLU}(z)$ ， $c \geq 0$

可得 $\sum_{j \in C} a_j \text{ReLU}(w_j^T x) = \left(\sum_{j \in C} a_j r_j \right) \text{ReLU}(v^T x)$ ，因此，同一方向上的多个神经元可以合并成一个等效神经元

需要掌握 m 个实际神经元 $\neq m$ 个有效神经元；若网络有 m 个神经元，但只形成 K 个凝聚簇，则 $K \ll m$ ，网络的有效宽度可能更接近 $m_{\text{eff}} \approx K$

凝聚现象描述的是在神经网络的非线性训练过程中，同一层中原本随机分布的大量神经元，会逐渐聚集成若干组；同一组神经元具有相近的参数方向或产生相似的输出，因此一个很宽的网络可能只表现出一个较窄网络的有效复杂度。

近年来的研究发现，小尺度初始化通常会明显促进这一现象；在训练早期，神经元可能先凝聚到极少数方向，随后随着网络逐渐学习更复杂的模式，凝聚簇数量可能增加。需要注意，“簇数量随训练增加”主要是经验规律，并不是所有网络上的普适数学定理。

(<https://arxiv.org/pdf/2504.09484v2>)

考虑一个宽度为 m 的双层神经网络： $f_\theta(x) = \sum_{j=1}^m a_j \sigma(w_j^T x)$

其中：

$x \in \mathbb{R}^d$ 是输入；

$w_j \in \mathbb{R}^d$ 是第 j 个隐藏神经元的输入权重；

$a_j \in \mathbb{R}$ 是隐藏神经元连接到输出层的权重；

$\sigma(\cdot)$ 是激活函数。

为了把偏置统一写入权重，可以令 $\tilde{x} = \begin{bmatrix} x \\ 1 \end{bmatrix}$, $\tilde{w}_j = \begin{bmatrix} w_j \\ b_j \end{bmatrix}$

于是 $w_j^T x + b_j = \tilde{w}_j^T \tilde{x}$ 。

后面仍然用 (x, w_j) 表示扩展后的向量。

在初始化时，各神经元权重通常是随机的： $w_j(0) \sim \mathcal{N}(0, \epsilon^2 I)$ 。

因此它们的方向 $u_j(0) = \frac{w_j(0)}{|w_j(0)|_2}$

大致随机分布在单位球面 $\mathbb{S}^{d-1} = \{u: |u|_2 = 1\}$ 。

$$u_1, u_2, \dots, u_{100} \longrightarrow v_1,$$

训练以后，可能出现 $u_{101}, u_{102}, \dots, u_{180} \longrightarrow v_2,$

$$u_{181}, \dots, u_m \longrightarrow v_3.$$

原本有 m 个随机方向，最后只剩 v_1, v_2, v_3 三个主要方向，这就是参数方向上的凝聚。

可以将权重方向的经验分布写成 $\rho_t = \frac{1}{m} \sum_{j=1}^m \delta_{u_j(t)}$

其中：

δ_u 表示位于方向 u 上的狄拉克质量。

初始化时 ρ_0 可能近似连续分布；凝聚后 $\rho_t \approx \sum_{k=1}^K \pi_k \delta_{v_k}$,

其中 $K \ll m$ 并且 $\sum_{k=1}^K \pi_k = 1$ ，也就是说，大量连续分布的神经元方向逐渐集中到有限个离散方向上。

考虑 ReLU 激活函数： $\sigma(z) = \text{ReLU}(z) = \max(0, z)$

ReLU 满足一阶正齐次性 $\text{ReLU}(cz) = c\text{ReLU}(z)$, $c \geq 0$ 。

假设有三个神经元发生完全凝 $w_1 = r_1 v, w_2 = r_2 v, w_3 = r_3 v$

其中 $|v|_2 = 1$, $r_1, r_2, r_3 \geq 0$ 。

假设有三个神经元，则总输出为：

$$f_C(x) = a_1 \text{ReLU}(r_1 v^T x) + a_2 \text{ReLU}(r_2 v^T x) + a_3 \text{ReLU}(r_3 v^T x).$$

利用齐次性 $\text{ReLU}(r_j v^T x) = r_j \text{ReLU}(v^T x)$

因此 $f_C(x) = (a_1 r_1 + a_2 r_2 + a_3 r_3) \text{ReLU}(v^T x)$

定义 $A = a_1 r_1 + a_2 r_2 + a_3 r_3$ ，得到 $f_C(x) = A \text{ReLU}(v^T x)$ ，原来的三个神经元，可以严格替换成一个神经元，推广到一个凝聚簇 $C = \{j_1, j_2, \dots, j_q\}$ ，若 $w_j = r_j v$, $j \in C$,

$$\text{则} \sum_{j \in C} a_j \text{ReLU}(w_j^T x) = \left(\sum_{j \in C} a_j r_j \right) \text{ReLU}(v^T x)$$

所以即使网络表面宽度是 $m = 1000$ ，若神经元最终只凝聚成 $K = 20$ 组，那么它的有效宽度可能更接近 $m_{\text{eff}} \approx 20$ ，这也是凝聚现象被认为可能与隐式复杂度控制、网络压缩和泛化有关的原因。

现在推导训练动力学。

给定训练集 $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$ ；采用均方误差 $R(\theta) = \frac{1}{2n} \sum_{i=1}^n [f_\theta(x_i) - y_i]^2$

定义第 i 个样本的残差 $e_i = f_\theta(x_i) - y_i$ ，于是 $R(\theta) = \frac{1}{2n} \sum_{i=1}^n e_i^2$

输出权重的梯度：

网络为 $f_\theta(x_i) = \sum_{j=1}^m a_j \sigma(w_j^\top x_i)$ ，因此 $\frac{\partial f_\theta(x_i)}{\partial a_j} = \sigma(w_j^\top x_i)$

利用链式法则 $\frac{\partial R}{\partial a_j} = \frac{1}{n} \sum_{i=1}^n e_i \frac{\partial f_\theta(x_i)}{\partial a_j} = \frac{1}{n} \sum_{i=1}^n e_i \sigma(w_j^\top x_i)$

梯度流为 $\dot{a}_j = \frac{1}{n} \sum_{i=1}^n e_i \sigma(w_j^\top x_i)$

其中 $\dot{a}_j = \frac{da_j}{dt}$

输入权重的梯度：

对 w_j 求导得到 $\frac{\partial f_\theta(x_i)}{\partial w_j} = a_j \sigma'(w_j^\top x_i) x_i$

因此 $\frac{\partial R}{\partial w_j} = \frac{1}{n} \sum_{i=1}^n e_i a_j \sigma'(w_j^\top x_i) x_i$

梯度流为 $\dot{w}_j = \frac{a_j}{n} \sum_{i=1}^n e_i \sigma'(w_j^\top x_i) x_i$

这是凝聚理论的基本动力学方程，相关理论工作正是从这一梯度流出发研究初始化阶段的方向演化。

令 $w_j = r_j u_j$ ，其中 $r_j = |w_j|_2, u_j = \frac{w_j}{|w_j|_2}$ 并满足 $|u_j|_2 = 1$ ，这里 r_j 表示权重大小； u_j 表示权重方向。对 $w_j = r_j u_j$ 关于时间求导 $\dot{w}_j = \dot{r}_j u_j + r_j \dot{u}_j$ ，由于 $u_j^\top u_j = 1$ ，两边求导 $2u_j^\top \dot{u}_j = 0$ ，所以 $u_j^\top \dot{u}_j = 0$ ，即方向变化 $\dot{u}_j$ 一定位于单位球面的切空间中。

左乘 $u_j^\top$ 得到 $u_j^\top \dot{w}_j = \dot{r}_j$ ，因此 $\dot{r}_j = u_j^\top \dot{w}_j$ ，再由 $r_j \dot{u}_j = \dot{w}_j - \dot{r}_j u_j$ 代入 $\dot{r}_j = u_j^\top \dot{w}_j$ 得到 $\dot{u}_j = \frac{1}{r_j} [\dot{w}_j - u_j (u_j^\top \dot{w}_j)] = \frac{1}{r_j} (I - u_j u_j^\top) \dot{w}_j$ ，最终 $\dot{u}_j = \frac{(I - u_j u_j^\top) \dot{w}_j}{r_j}$ ，定义投影

矩阵 $P_{u_j}^\perp = I - u_j u_j^\top$ ，于是 $\dot{u}_j = \frac{1}{r_j} P_{u_j}^\perp \dot{w}_j$ ，矩阵 $P_{u_j}^\perp$ 会删除 $\dot{w}_j$ 中沿着 u_j 的部分，只保留改变权重方向的分量。因此，方向停止变化需要 $\dot{u}_j = 0$ ，也就是 $(I - u_j u_j^\top) \dot{w}_j = 0$ ，等价于 $\dot{w}_j \parallel u_j$ ，也就是说，当梯度速度与当前权重方向平行时，梯度只改变权重长度，不再改变权重方向。凝聚方向就是方向动力系统稳定方向或固定方

假设初始化 $w_j(0) = O(\epsilon)$ ，其中 $0 < \epsilon \ll 1$ ，于是 $r_j = |w_j| = O(\epsilon)$ ，回顾方向动力学 $\dot{u}_j = \frac{1}{r_j} P_{u_j}^\perp \dot{w}_j$ ，其中存在 $\frac{1}{r_j} = O\left(\frac{1}{\epsilon}\right)$ ，因此，小初始化会放大方向变化。

而权重长度动力学 $\dot{r}_j = u_j^\top \dot{w}_j$ 没有 $\frac{1}{r_j}$ 这一放大因子。粗略地说 $|\dot{r}_j| = O(|\dot{w}_j|)$ ，而 $|\dot{u}_j| = O\left(\frac{|\dot{w}_j|}{\epsilon}\right)$ ，因此 $\frac{|\dot{u}_j|}{|\dot{r}_j|} = O\left(\frac{1}{\epsilon}\right)$ ，当 $\epsilon \rightarrow 0$ 时 $\frac{1}{\epsilon} \rightarrow \infty$ ，所以训练早期表现为方向变化

速度远大于权重长度变化速度，神经元会先快速重新排列方向，再明显增长幅值。

定义激活函数在原点附近的重数，若 $\sigma'(0) = \sigma''(0) = \dots = \sigma^{(p-1)}(0) = 0$ ，但 $\sigma^{(p)}(0) \neq 0$ ，则称激活函数的重数为 p ，即 $p = \min\{s \geq 1 : \sigma^{(s)} \neq 0\}$

例如 $\sigma(x) = \tanh(x)$ ，因为 $\tanh'(0) = 1 \neq 0$ ，所以 $p = 1$ ；对于 $\sigma(x) = x \tanh(x)$ 在零点附近 $\tanh(x) = x - \frac{x^3}{3} + O(x^5)$ ，因此 $x \tanh(x) = x^2 - \frac{x^4}{3} + O(x^6)$ ，最低非零项是 x^2 ，所以 $p = 2$ 对于 $\sigma(x) = x^2 \tanh(x)$ 有 $x^2 \tanh(x) = x^3 - \frac{x^5}{3} + O(x^7)$ ，所以 $p = 3$ 。

常见的 Tanh、Sigmoid、Softplus、GELU 等平滑激活在该定义下通常属于 $p = 1$ ；ReLU 在原点不可微，需要利用分段线性或齐次动力学单独分析。

若 $w_j^T x_i \approx 0$ ，则在小初始化阶段 $\sigma'(w_j^T x_i)$ 可以进行泰勒展开：
 $\sigma'(z) = \sigma'(0) + \sigma''(0)z + \frac{\sigma'''(0)}{2!}z^2 + \dots$ ，若激活函数重数为 p ，低阶项全部为零，
 因此 $\sigma'(z) \approx \frac{\sigma^{(p)}(0)}{(p-1)!}z^{p-1}$ ，令 $c_p = \frac{\sigma^{(p)}(0)}{(p-1)!}$ 则 $\sigma'(w_j^T x_i) \approx c_p (w_j^T x_i)^{p-1}$ ，因为 $w_j = r_j u_j$ ，所以 $w_j^T x_i = r_j u_j^T x_i$ ，进而 $\sigma'(w_j^T x_i) \approx c_p r_j^{p-1} (u_j^T x_i)^{p-1}$

代入权重动力学 $\dot{w}_j = \frac{a_j}{n} \sum_i e_i \sigma'(w_j^T x_i) x_i$ 得到 $\dot{w}_j \approx a_j c_p r_j^{p-1} G_p(u_j)$ ，其中定义
 $G_p(u) = \frac{1}{n} \sum_{i=1}^n e_i x_i (u^T x_i)^{p-1}$ ，因此 $\dot{w}_j \approx a_j c_p r_j^{p-1} G_p(u_j)$

方向动力学为 $\dot{u}_j = \frac{1}{r_j} (I - u_j u_j^T) \dot{w}_j \approx a_j c_p r_j^{p-2} (I - u_j u_j^T) G_p(u_j)$ ，方向固定需要 $P_u^\perp G_p(u) = 0$ ，即 $G_p(u) = \lambda u$ 。这里 $\lambda \in \mathbb{R}$ ，这类似一个非线性特征向量方程。稳定凝聚方向，就是方程 $G_p(u) = \lambda u$ 的解。

当 $p = 1$ 时， $\sigma'(0) \neq 0$ ，此时 $(u^T x_i)^{p-1} = (u^T x_i)^0 = 1$ ，因此 $G_1(u) = \frac{1}{n} \sum_{i=1}^n e_i x_i$ ，它与 u 无关。

定义 $g = \frac{1}{n} \sum_{i=1}^n e_i x_i$ 则 $\dot{w}_j \approx a_j \sigma'(0) g$ ，所有隐藏神经元都受到同一个数据方向 g 的控制。区别只存在于标量 $a_j \sigma'(0)$

方向动力学： $\dot{u}_j \approx \frac{a_j \sigma'(0)}{r_j} (I - u_j u_j^T) g$ ，方向达到稳定，需要 $(I - u u^T) g = 0$ ，
 展开 $g - u(u^T g) = 0$ ，因此 $g = (u^T g) u$ ，这说明 $g \parallel u$ ，所以 $u = \frac{g}{\|g\|_2}$ 或者 $u = -\frac{g}{\|g\|_2}$ ，
 最终只有两个相反方向 $u^* = \pm \frac{g}{\|g\|_2}$

如果把 u 和 $-u$ 看成同一条直线,那么只有1条凝聚直线,这就是为什么很多 $p=1$ 激活函数在小初始化阶段会出现“两端凝聚”,即 $+v;-v$,理论研究将其表述为最多出现两个有向凝聚方向。

进一步研究收敛过程。定义 $\hat{g} = \frac{g}{\|g\|_2}$, 令 $z_j = u_j^T \hat{g}$, 由于 $\|u_j\| = \|\hat{g}\| = 1$, 所以 $z_j = \cos \theta_j$, 其中 θ_j 是神经元方向与目标方向之间的夹角。

将方向动力学写成 $\dot{u}_j = \kappa_j (I - u_j u_j^T) g$, 其中 $\kappa_j = \frac{a_j \sigma'(0)}{r_j}$ 。假设在一个很短的局部时间段中 g 变化较慢, 则 $\dot{z}_j = \dot{u}_j^T \hat{g} = \kappa_j g^T (I - u_j u_j^T) \hat{g} = \kappa_j \|g\| [1 - (u_j^T \hat{g})^2]$, 于是 $\dot{z}_j = \kappa_j \|g\| (1 - z_j^2)$ 。若 $\kappa_j > 0$, 则对于 $-1 < z_j < 1$ 有 $\dot{z}_j > 0$, 所以 $z_j \rightarrow 1$, 也就是 $u_j \rightarrow \hat{g}$, 若 $\kappa_j < 0$, 则 $z_j \rightarrow -1$, 即 $u_j \rightarrow -\hat{g}$, 这直接说明, 大量神经元会聚集到 $+\hat{g}$ 和 $-\hat{g}$ 两个方向。

考虑一维输入 $z_i \in \mathbb{R}$ 加入偏置维度 $x_i = \begin{bmatrix} z_i \\ 1 \end{bmatrix}$, 方向 $u = \frac{1}{\sqrt{s^2 + 1}} \begin{bmatrix} s \\ 1 \end{bmatrix}$, 其中 $s = \frac{u_1}{u_2}$ 表示方向斜率。有 $u^T x_i = \frac{sz_i + 1}{\sqrt{s^2 + 1}}$, 忽略与方向无关的公共尺度因子

$$G_p(u) \propto \sum_{i=1}^n e_i \begin{bmatrix} z_i \\ 1 \end{bmatrix} (sz_i + 1)^{p-1}, \text{ 其两个分量为 } G_{p,1} = \sum_i e_i z_i (sz_i + 1)^{p-1} \text{ 以及 } G_{p,2} = \sum_i e_i (sz_i + 1)^{p-1}$$

稳定要求 $G_p(u) \parallel u$, 因为 $\frac{u_1}{u_2} = s$, 所以 $\frac{G_{p,1}}{G_{p,2}} = s$, 即 $G_{p,1} = s G_{p,2}$, 代入 $\sum_{i=1}^n e_i (z_i - s) (sz_i + 1)^{p-1} = 0$ 。

观察最高次数。

第一部分 $z_i - s$ 关于 s 是一次多项式; 第二部分 $(sz_i + 1)^{p-1}$ 关于 s 是 $p-1$ 次多项式。两者相乘最高为 $1 + (p-1) = p$, 因此稳定方向满足一个最高 p 次的方程: $P_p(s) = 0$, 非退化情况下, 最多有 p 个实斜率。每个斜率对应一条直线, 而每条直线存在两个相反的有向单位向量 $u; -u$, 所以有向方向最多为 $2p$, 即最大初始凝聚方向数=两倍激活函数的重数。

[例如

激活函数	重数(p)	最多凝聚直线	最多有向方向
$\tanh(x)$	1	1	2
$x \tanh(x)$	2	2	4
$x^2 \tanh(x)$	3	3	6

这一结论在现有理论中针对 $p=1$ 的高维情形, 或者一维输入下的一般 p 情形得到了分析; 一般高维、高重数情形会转化为高阶多元多项式根的计数问题, 目前更困难。

在小初始化下 $w_j^T x \approx 0$ ，激活函数展开为 $\sigma(z) = \sigma(0) + \frac{\sigma^{(p)}(0)}{p!} z^p + O(z^{p+1})$ ，

因此 $f_\theta(x) = \sum_j a_j \sigma(w_j^T x) \approx \sigma(0) \sum_j a_j + \frac{\sigma^{(p)}(0)}{p!} \sum_j a_j (w_j^T x)^p$ ，得到 $f_\theta(x) \approx C + \sum_j \beta_j (w_j^T x)^p$ ，训练早期，即使神经元数量 m 很大，网络输出仍接近一个低阶多项式。因此，网络虽然表面高度过参数化，但训练早期的有效函数空间可能相当简单。

因此可以形成一种训练过程：少量凝聚方向到简单函数到更多方向到复杂函数。已有实验观察到，训练初期神经元先形成少数凝聚簇，之后簇数量或有效秩可能呈逐步增长趋势。但这里需要严谨地区分“簇数量逐渐增加”是常见经验现象，不是无条件普适定理。（<https://arxiv.org/pdf/2504.09484v2>）

神经网络训练通常可以粗略区分为：线性/惰性训练区域和非线性/特征学习区域。在 NTK 或懒惰训练区域中 $\theta(t) \approx \theta(0)$ ，网络可以在初始化附近进行一阶展开： $f_{\theta(t)}(x) \approx f_{\theta(0)}(x) + \nabla_\theta f_{\theta(0)}(x)^T [\theta(t) - \theta(0)]$ ，由于 $|\theta(t) - \theta(0)|$ 很小，所以隐藏特征变化较小。神经元方向 $u_j(t) = \frac{w_j(t)}{|w_j(t)|}$ 也不会发生大幅重排，因此不容易形成明显凝聚，而在非线性训练区域 $\frac{|w_j(t) - w_j(0)|}{|w_j(0)|}$ 较大，神经元会主动学习特征，方向发生显著变化，从而可能聚集到少量数据相关方向。

所以凝聚是特征学习和非线性训练的重要表现之一，而不是固定特征核方法的典型现象。现有研究观察到，凝聚在非线性训练区域更明显，而在典型 NTK 区域中较弱或不明显。

定义 $C_{jk} = \frac{w_j^T w_k}{|w_j|_2 |w_k|_2}$ ，若 $C_{jk} \approx 1$ ，则 w_j 与 w_k 方向接近；若 $C_{jk} \approx -1$ ，则两者方向相反；若 $C_{jk} \approx 0$ ，则两者近似正交。

训练前，相似度矩阵可能比较随机： $C \approx \begin{bmatrix} 1 & 0.1 & -0.2 & \dots \\ 0.1 & 1 & 0.05 & \dots \\ -0.2 & 0.05 & 1 & \dots \\ \vdots & \vdots & \vdots & \ddots \end{bmatrix}$

凝聚后可能出现块结构： $C \approx \begin{bmatrix} \mathbf{1} & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{1} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \mathbf{1} \end{bmatrix}$

每个高相似度块表示一个凝聚簇。CNN 中也可以将卷积核展平为向量，再计算不同通道之间的余弦相似度。已有实验在卷积网络和残差网络的部分层中观察到这种块状相似度结构。（

权重相似不一定意味着输出完全相同，因此还可以定义神经元在数据集上的输出

向量: $h_j = \begin{bmatrix} \sigma(w_j^T x_1) \\ \sigma(w_j^T x_2) \\ \vdots \\ \sigma(w_j^T x_n) \end{bmatrix}$, 计算 $S_{jk} = \frac{h_j^T h_k}{|h_j|_2 |h_k|_2}$, 若 $S_{jk} \approx 1$, 说明两个神经元在观测数据上的功能接近, 这比只看参数方向更加直接。

构造隐藏表示矩阵 $H = [h_1 \ h_2 \ \cdots \ h_m] \in \mathbb{R}^{n \times m}$, 对其进行奇异值分解 $H = U \Sigma V^T$, 设奇异值为 $s_1, s_2, \dots, s_r$, 归一化 $p_k = \frac{s_k}{\sum_l s_l}$

定义有效秩 $erank(H) = \exp\left(-\sum_k p_k \log p_k\right)$, 若大量神经元输出相似, 则矩阵列之间高度相关: $rank(H) \ll m$, 因此 $erank(H)$ 会降低, 不过训练过程中簇数量增加时, 有效秩也可能逐步增加。已有研究将这种现象与凝聚簇逐渐分化联系起来。

实际网络中通常不会满足 $w_j = r_j v$ 这种完全相等。

假设 $w_j = r_j v + \delta_j$, 其中 $|\delta_j|$ 较小。原始簇输出 $f_C(x) = \sum_{j \in C} a_j ReLU(w_j^T x)$, 合并后的输出为 $\tilde{f}_C(x) = \left(\sum_{j \in C} a_j r_j\right) ReLU(v^T x)$, 由于 $ReLU$ 是 1-Lipschitz 函数: $|ReLU(a) - ReLU(b)| \leq |a - b|$, 所以:

$$\begin{aligned} |f_C(x) - \tilde{f}_C(x)| &\leq \sum_{j \in C} |a_j| |ReLU(w_j^T x) - ReLU(r_j v^T x)| \\ &\leq \sum_{j \in C} |a_j| |(w_j - r_j v)^T x| \leq |x|_2 \sum_{j \in C} |a_j| |\delta_j|_2 \end{aligned}$$

得到误差上界 $|f_C(x) - \tilde{f}_C(x)| \leq |x|_2 \sum_{j \in C} |a_j| |\delta_j|_2$

若 $|x|_2 \leq B$, 则 $|f_C(x) - \tilde{f}_C(x)| \leq B \sum_{j \in C} |a_j| |\delta_j|_2$, 因此 $\delta_j \rightarrow 0$ 时, 合并误差趋近于零, 这给出了利用凝聚进行神经元合并或网络宽度压缩的数学依据。不过, 当凝聚不够充分时, 直接合并可能造成性能下降。

凝聚提供了一种解释过参数化网络的方法。表面上 $m = 10000$, 但若只有 $K = 50$ 个有效方向, 则函数可以近似写成 $f(x) \approx \sum_{k=1}^{50} A_k \sigma(v_k^T x)$, 网络的有效复杂度可能更

接近 K 而不是 m , 因此参数量很大并不一定能够得到实际学习函数一定非常复杂。训练算法可能通过凝聚产生一种隐式正则化, 即宽网络到少量有效神经元进一步推出较简单函数, 但不能直接推出: 凝聚越强可以得到泛化一定越好。原因包括: 第一, 过度凝聚可能降低表达能力; 第二, 训练初期过强的方向对齐可能限制后续优化; 第三, 真实深层网络中的凝聚通常是近似的, 并且不同层的程度不同; 第四, 目前凝聚理论对简单双层网络更成熟, 对大规模深层网络仍不完整。

因此, 更严谨的表述是凝聚提供了一种解释隐式低复杂度和泛化能力的候选机制,

而不是已经被证明适用于所有网络的泛化定理。

当前综述也强调，凝聚是一种可以被初始化、网络结构和优化策略增强或抑制的倾向，而不是所有模型都必然达到的极端状态。

设神经元输出 $h_j(x) = \sigma(w_j^T x)$ ，加入 Dropout: $\xi_j = \frac{z_j}{q}$ ，其中 $z_j \sim \text{Bernoulli}(q)$ ，Dropout 网络输出 $\tilde{f}(x) = \sum_j a_j \xi_j h_j(x)$ ，因为 $\mathbb{E}[\xi_j] = 1$ ，所以 $\mathbb{E}[\tilde{f}(x)] = f(x)$ ，对于平方损失 $\mathbb{E}[(\tilde{f} - y)^2] = (\mathbb{E}[\tilde{f}] - y)^2 + \text{Var}(\tilde{f})$ ，由于各 Dropout 掩码独立：
 $\text{Var}(\tilde{f}) = \frac{1-q}{q} \sum_j a_j^2 h_j^2$ ，因此 $\mathbb{E}[(\tilde{f} - y)^2] = (f - y)^2 + \frac{1-q}{q} \sum_j a_j^2 h_j^2$

Dropout 会增加一个隐式正则项，使网络不能过度依赖某一个神经元。

从功能冗余角度看，当某些神经元随机失活时，其余神经元需要保持类似功能，可能促进神经元形成可替代的功能群。已有实验报告 Dropout 可以在不采用极小初始化的情况下增强凝聚，但这一解释更多是动力学直觉，上面的期望损失公式本身并不能单独证明神经元一定发生方向对齐。

凝聚现象目前仍是一个发展中的深度学习理论方向。对双层网络和训练初期已经有较清晰的数学分析，但对深层 CNN、Transformer 和大规模模型中的完整动力学，仍有大量问题没有得到统一解决。