

解的平坦性

导论

神经网络训练不仅要关注最终损失是否足够低，还需要研究最优参数附近的损失变化情况。若参数受到小幅扰动后，损失仍保持较低，则称该解较为平坦；若微小扰动就会导致损失快速增加，则称该解较为尖锐。解的平坦性主要用于分析模型的局部损失几何、参数稳定性以及泛化能力。

本章重点理解以下知识点：

1. 平坦解与尖锐解

平坦解对参数扰动不敏感，邻域内损失变化较小；
尖锐解对参数扰动敏感，微小扰动可能导致损失快速增加。

2. Hessian 决定局部曲率

在局部极小值附近，损失变化可以近似表示为 $\Delta L \approx \frac{1}{2} \epsilon^T H \epsilon$

Hessian 特征值越大，对应方向越尖锐；

Hessian 特征值越小，对应方向越平坦。

3. 常见平坦性指标

最大 Hessian 特征值衡量最尖锐方向 $\lambda_{\max}$ ；

Hessian 的迹衡量整体曲率 $Tr(H)$ ；

邻域最大损失衡量参数附近的最坏损失增长：

$$S_{\rho}(\theta) = \max_{\|\epsilon\|_2 \leq \rho} [L_S(\theta + \epsilon) - L_S(\theta)]$$

4. 平坦性与泛化

平坦解通常具有更强的参数扰动稳定性，并经常与较好的泛化能力相关；
但平坦并不一定意味着泛化更好，因为平坦性会受到参数尺度和网络重参数化影响。

5. SAM

SAM 不仅最小化当前参数位置的损失，还最小化邻域中的最大损失：

$$\min_{\theta} \max_{\|\epsilon\|_2 \leq \rho} L_S(\theta + \epsilon)$$

其目标是寻找对参数扰动更加稳定的低损失区域。

解的平坦性主要研究神经网络优化结束后，损失函数在最终参数附近的变化速度。

假设神经网络训练得到参数 $\theta^* \in \mathbb{R}^d$ ，如果参数受到较小扰动后，损失函数仍然保持较低，则称该解较为平坦；如果参数发生很小变化就导致损失快速增加，则称该解较为尖锐。平坦解通常对应损失空间中较宽的低损失区域，而尖锐解通常对应狭窄的低损失区域。

早期研究提出，平坦极小值可能对应较低的模型复杂度以及较好的泛化能力。后续研究发现，未经归一化的参数空间平坦性会受到网络重参数化影响，因此不能简单认为所有平坦解一定优于尖锐解。

一、神经网络的损失空间

假设训练数据集为 $S = \{(x_i, y_i)\}_{i=1}^n$ ，神经网络为 $f_\theta(x)$ ，其中参数向量为

$$\theta = \begin{bmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_d \end{bmatrix} \in \mathbb{R}^d, \text{ 定义单个样本的损失函数 } \ell(f_\theta(x_i), y_i), \text{ 训练集上的经验损失为}$$

$$L_S(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(f_\theta(x_i), y_i), \text{ 训练过程希望求解 } \theta^* = \operatorname{argmin}_\theta L_S(\theta)$$

深度神经网络通常包含数百万甚至数十亿个参数，因此损失函数实际上定义在高维参数空间中： $L_S: \mathbb{R}^d \rightarrow \mathbb{R}$

每一个参数向量对应参数空间中的一个点 $\theta \longleftrightarrow L_S(\theta)$ ，训练结束后得到的参数为 θ^* ，但仅知道 $L_S(\theta^*)$ 很小是不够的，还需要研究附近参数的损失 $L_S(\theta^* + \epsilon)$ ，其中 $\epsilon \in \mathbb{R}^d$ 表示参数扰动。

二、什么是平坦解

假设存在一个扰动半径 $\rho > 0$ ，定义参数邻域 $\mathcal{B}_\rho(\theta^*) = \{\theta^* + \epsilon: |\epsilon|_2 \leq \rho\}$ ，如果邻域中的参数损失变化较小： $L_S(\theta^* + \epsilon) \approx L_S(\theta^*)$ ，则认为 θ^* 位于平坦区域；如果存在很小的参数扰动 $|\epsilon|_2 \ll 1$ 却产生较大的损失增长： $L_S(\theta^* + \epsilon) - L_S(\theta^*) \gg 0$ ，则认为 θ^* 位于尖锐区域。因此平坦性关注的不是最低点本身有多低，而是最低点周围的损失变化速度，平坦解 $L_S(\theta^* + \epsilon) - L_S(\theta^*) \approx 0$ 参数发生一定变化后损失仍然较低；尖锐解 $L_S(\theta^* + \epsilon) - L_S(\theta^*) \gg 0$ ，参数发生较小变化后损失迅速增加。

需要注意，平坦与尖锐是局部几何性质，两个模型可能具有相同训练损失 $L_S(\theta_A) = L_S(\theta_B)$ ，但附近的损失变化完全不同 $L_S(\theta_A + \epsilon) \ll L_S(\theta_B + \epsilon)$ ，此时可以认为 θ_A 比 θ_B 更加平坦。

三、使用泰勒展开分析局部损失

为了研究参数附近的损失变化，对损失函数进行二阶泰勒展开，令 $\theta = \theta^* + \epsilon$ ，则

$$L_S(\theta^* + \epsilon) = L_S(\theta^*) + \nabla L_S(\theta^*)^T \epsilon + \frac{1}{2} \epsilon^T H(\theta^*) \epsilon + O(|\epsilon|_2^3), \text{ 其中梯度向量为}$$

$$\nabla L_S(\theta^*) = \begin{bmatrix} \partial L_S / \partial \theta_1 \\ \partial L_S / \partial \theta_2 \\ \vdots \\ \partial L_S / \partial \theta_d \end{bmatrix}, \text{ Hessian 矩阵为 } H(\theta^*) = \nabla^2 L_S(\theta^*), \text{ 展开以后得到}$$

$$H = \begin{bmatrix} \partial^2 L_S / \partial \theta_1^2 & \partial^2 L_S / \partial \theta_1 \partial \theta_2 & \cdots \\ \partial^2 L_S / \partial \theta_2 \partial \theta_1 & \partial^2 L_S / \partial \theta_2^2 & \cdots \\ \vdots & \vdots & \ddots \end{bmatrix}$$

如果 θ^* 是一个可微局部极小值，则一阶梯度通常满足 $\nabla L_S(\theta^*) = 0$ ，忽略三阶及以上误差后 $L_S(\theta^* + \epsilon) - L_S(\theta^*) \approx \frac{1}{2} \epsilon^T H \epsilon$ ，因此解附近的损失变化主要由 Hessian 矩阵决定。

四、Hessian 矩阵为什么可以描述平坦性

Hessian 矩阵描述损失函数在不同参数方向上的二阶曲率，假设 Hessian 为实对称矩阵 $H = H^T$ ，根据谱分解 $H = Q \Lambda Q^T$ ，其中 $Q = [q_1 \ q_2 \ \cdots \ q_d]$ ，矩阵中的列向量满足 $q_i^T q_j = \begin{cases} 1 & i=j \\ 0 & i \neq j \end{cases}$ ，特征值矩阵为 $\Lambda = \begin{bmatrix} \lambda_1 & & \\ & \lambda_2 & \\ & & \ddots \end{bmatrix}$ ，将参数扰动分解到 Hessian

的特征向量方向 $\epsilon = \sum_{k=1}^d z_k q_k$ ，也可以写成 $\epsilon = Qz$ ，代入二阶损失变化 $\Delta L = \frac{1}{2} \epsilon^T H \epsilon$ ，

得到 $\Delta L = \frac{1}{2} z^T Q^T Q \Lambda Q^T Q z$ ，由于 $Q^T Q = I$ ，因此 $\Delta L = \frac{1}{2} z^T \Lambda z$ ，展开得到 $\Delta L = \frac{1}{2} \sum_{k=1}^d \lambda_k z_k^2$ 。

每个 Hessian 特征向量 q_k 代表参数空间中的一个方向，对应的 Hessian 特征值 λ_k 表示损失函数沿该方向的局部曲率。

特征值较大，即 $\lambda_k \gg 0$ 则 $\Delta L \approx \frac{1}{2} \lambda_k z_k^2$ ，即使扰动 z_k 很小，损失也可能快速增加。

该方向较尖锐；

特征值较小，即 $\lambda_k \approx 0$ 则 $\Delta L \approx 0$ ，参数沿该方向发生较大变化，损失仍然变化较小，该方向较平坦。

因此可以得到，特征值越大，方向越尖锐；特征值越小，方向越平坦。

五、定义最大 Hessian 特征值

定义最大 Hessian 特征值： $\lambda_{\max} = \max_k \lambda_k$ ，它描述损失空间中最尖锐方向的曲率，

考虑固定长度的参数扰动 $\|\epsilon\|_2 = \rho$ ，需要求最大局部损失增长 $\max_{\|\epsilon\|_2 \leq \rho} \frac{1}{2} \epsilon^T H \epsilon$ ，将扰动

写成 $\epsilon = \sum_{k=1}^d z_k q_k$ ，扰动长度满足 $\sum_{k=1}^d z_k^2 \leq \rho^2$ ，损失变化为 $\Delta L = \frac{1}{2} \sum_{k=1}^d \lambda_k z_k^2$ ，由于

$\lambda_k \leq \lambda_{\max}$ ，因此 $\Delta L \leq \frac{1}{2} \lambda_{\max} \sum_{k=1}^d z_k^2$ ，继续得到 $\Delta L \leq \frac{1}{2} \rho^2 \lambda_{\max}$ ，当所有扰动都沿最大

特征向量方向时取得最大值 $\epsilon^* = \rho q_{\max}$ ，因此 $\max_{\|\epsilon\|_2 \leq \rho} \Delta L \approx \frac{1}{2} \rho^2 \lambda_{\max}$ ，由此可以得到：

最大 Hessian 特征值越大，最坏方向越尖锐；

最大 Hessian 特征值越小，局部最坏方向越平坦。

六、Hessian 的迹

只使用最大特征值只能测量最尖锐方向，为了描述所有方向的总曲率，可以计算 Hessian 的迹： $Tr(H) = \sum_{k=1}^d H_{kk}$ ，由于矩阵的迹等于特征值之和 $Tr(H) = \sum_{k=1}^d \lambda_k$ ，如果只有一个特征值很大，其余特征值很小，则最大特征值可能很大，但总曲率不一定特别大

[例如 $\Lambda_A = \begin{bmatrix} 100 & 0 \\ 0 & 0.01 \end{bmatrix}$ ，对应 $\lambda_{\max} = 100$ ，对应 $Tr(H) = 100.01$ ；另一个解满足 $\Lambda_B = \begin{bmatrix} 60 & 0 \\ 0 & 60 \end{bmatrix}$ ，对应 $\lambda_{\max} = 60$ ，对应 $Tr(H) = 120$

第一个解存在一个非常尖锐的方向和一个非常平坦的方向；
第二个解在两个方向上的曲率都较大；
因此最大特征值和 Hessian 的迹反映不同的几何性质。]

七、利用随机参数扰动推导平均平坦性

假设训练参数受到随机扰动 $\epsilon \sim \mathcal{N}(0, \Sigma)$ ，在局部极小值附近 $\Delta L \approx \frac{1}{2} \epsilon^T H \epsilon$ ，对参数扰动求期望 $\mathbb{E}[\Delta L] = \frac{1}{2} \mathbb{E}[\epsilon^T H \epsilon]$ ，利用二次型期望 $\mathbb{E}[\epsilon^T H \epsilon] = Tr(H \Sigma)$ ，得到 $\mathbb{E}[\Delta L] \approx \frac{1}{2} Tr(H \Sigma)$ ，假设参数扰动是各向同性高斯噪声 $\Sigma = \sigma^2 I$ ，则 $\mathbb{E}[\Delta L] \approx \frac{\sigma^2}{2} Tr(H)$ 。

因此 Hessian 的迹描述模型对各向同性随机参数噪声的平均敏感程度，如果 $Tr(H)$ 较小，则随机参数扰动带来的平均损失增长较小；如果 $Tr(H)$ 较大，则随机参数扰动带来的平均损失增长较大。

八、平坦区域的几何形状

在局部极小值附近固定允许的损失增长 $\Delta L \leq c$ ，根据二阶近似 $\frac{1}{2} \epsilon^T H \epsilon \leq c$ ，在 Hessian 特征坐标中 $\frac{1}{2} \sum_{k=1}^d \lambda_k z_k^2 \leq c$ ，整理得到 $\sum_{k=1}^d \frac{z_k^2}{2c/\lambda_k} \leq 1$ ，这是一个高维椭球。

第 k 个方向上的半轴长度为 $r_k = \sqrt{\frac{2c}{\lambda_k}}$ ，当特征值较大 $\lambda_k \uparrow$ ，对应半轴长度减小 $r_k \downarrow$ ，损失区域在该方向更加狭窄；当特征值较小 $\lambda_k \downarrow$ ，对应半轴长度增大 $r_k \uparrow$ 损失区域在该方向更加宽阔。

因此平坦性不仅表示曲率较小，也表示低损失区域具有较大的局部体积。

九、平坦区域体积的推导

假设 Hessian 所有特征值均为正 $\lambda_k > 0$ ，低损失椭球为 $\sum_{k=1}^d \lambda_k z_k^2 \leq 2c$ ，定义新的坐标 $u_k = \sqrt{\frac{\lambda_k}{2c}} z_k$ 得到 $\sum_{k=1}^d u_k^2 \leq 1$ ，坐标变换为 $z_k = \sqrt{\frac{2c}{\lambda_k}} u_k$ ，Jacobian 行列式为 $J = \prod_{k=1}^d \sqrt{\frac{2c}{\lambda_k}}$ ，整理得到 $J = \frac{(2c)^{d/2}}{\sqrt{\prod_{k=1}^d \lambda_k}}$ ，设单位球体积为 V_d ，局部低损失区域的体积近似为 $V \approx V_d \frac{(2c)^{d/2}}{\sqrt{\prod_{k=1}^d \lambda_k}}$ ，利用 $\det(H) = \prod_{k=1}^d \lambda_k$ ，得到 $V \approx V_d \frac{(2c)^{d/2}}{\sqrt{\det(H)}}$ ，由此可以得

到 $\det(H) \downarrow$ ，对应低损失区域体积增大 $V \uparrow$ ，因此 Hessian 行列式可以反映局部低损失区域的体积，不过深度神经网络中通常存在大量接近零的 Hessian 特征值，因此直接计算 Hessian 行列式往往比较困难。

十、零特征值代表什么

假设 Hessian 存在零特征值 $\lambda_k = 0$ ，沿对应方向进行扰动 $\epsilon = z_k q_k$ ，二阶损失变化为 $\Delta L \approx \frac{1}{2} \lambda_k z_k^2$ ，因此 $\Delta L \approx 0$ 。

这说明沿该方向移动时，二阶近似下损失不发生变化，这种方向称为平坦方向。深度网络出现大量平坦方向可能有多种原因：

第一种原因是参数冗余，多个参数组合可能实现相同函数；

第二种原因是神经元置换对称性，交换同一隐藏层中两个神经元的位置可能不改变网络输出；

第三种原因是尺度对称性，某一层参数增大，同时下一层参数减小，网络输出可能保持不变；

第四种原因是过参数化，模型参数数量远大于约束数量，因此可能存在高维等价解集合；

需要注意 Hessian 出现零特征值不一定表示模型具有更好的泛化能力，零特征值也可能只是网络参数化方式产生的冗余方向。

十一、解可能不是一个点而是一条流形

传统优化通常将极小值理解为单个参数点 θ^* ，但是在过参数化神经网络中，可能存在大量等价参数 $\mathcal{M} = \{\theta: L_S(\theta) = L_{\min}\}$ ，集合 $\mathcal{M}$ 可能形成高维流形。

假设沿流形切向方向移动 $\epsilon_{\parallel}$ ，损失保持不变 $L_S(\theta^* + \epsilon_{\parallel}) = L_S(\theta^*)$ ；沿垂直于流形的方向移动 $\epsilon_{\perp}$ 损失增加 $L_S(\theta^* + \epsilon_{\perp}) > L_S(\theta^*)$ 。

因此平坦性通常具有方向性：一个解可能沿某些方向非常平坦，同时沿另一些方

向非常尖锐，不能仅用一张二维损失曲线完整表示高维损失空间。


十二、为什么平坦解可能具有更好的泛化能力

训练损失为 $L_S(\theta)$ ，真实数据分布上的期望风险为 $L_D(\theta) = \mathbb{E}_{(x,y)}[\ell(f_\theta(x), y)]$ ，泛化误差可以表示为 $G(\theta) = L_D(\theta) - L_S(\theta)$ ，平坦性理论通常认为如果模型只有在非常精确的参数位置才能保持较低训练损失，那么模型可能对训练数据中的细节较敏感。如果较大的参数区域都具有较低损失，则模型可能学习到了更加稳定的模式。平坦极小值与泛化之间的关系最早被系统地联系到参数精度、模型描述长度以及低复杂度模型。

可以从参数扰动角度理解，平坦解满足 $L_S(\theta^* + \epsilon) \approx L_S(\theta^*)$ ，因此模型能够容忍一定参数误差，参数不需要非常高的存储精度，尖锐解可能满足 $L_S(\theta^* + \epsilon) \gg L_S(\theta^*)$ ，参数必须保存得非常精确。

从最小描述长度的角度看，能够容忍更大参数误差的模型可能只需要较少的信息描述参数，但是必须强调平坦解与良好泛化之间不是无条件等价关系，传统平坦性可能受到参数尺度和重参数化影响，相同网络函数可以对应不同的 Hessian 曲率。

(<https://arxiv.org/pdf/1703.04933>)



十三、使用 PAC-Bayes 理解平坦性

PAC-Bayes 理论不只研究单个参数 θ^* ，而是研究参数分布 $Q(\theta)$ ，假设以训练参数为均值构造高斯分布 $Q = \mathcal{N}(\theta^*, \sigma^2 I)$ ，从分布中随机采样模型参数 $\theta = \theta^* + \epsilon$ ，其中 $\epsilon \sim \mathcal{N}(0, \sigma^2 I)$ ，随机模型的平均训练损失为 $\mathbb{E}_Q[L_S(\theta)]$ ，根据前面的二阶推导

$\mathbb{E}_Q[L_S(\theta)] \approx L_S(\theta^*) + \frac{\sigma^2}{2} \text{Tr}(H)$, 对于平坦解, $\text{Tr}(H)$ 较小, 因此可以选择较大的参数方差 σ^2 同时保持较低的平均训练损失; 对于尖锐解, $\text{Tr}(H)$ 较大, 较小的参数噪声就可能导致训练损失明显增加。

PAC-Bayes 理论通过参数扰动分布将平坦性与泛化界联系起来, 并已经被用于构造深度随机神经网络的非空泛化界。

(<https://arxiv.org/pdf/1703.11008>)

十四、平坦性的重要问题：尺度依赖

传统 Hessian 平坦性存在一个重要问题, 相同神经网络函数可能具有不同的参数尺度。

考虑一个简单的 ReLU 神经元 $f(x) = a\text{ReLU}(wx)$, 取任意正常数 $c > 0$, 定义新参数 $a' = \frac{a}{c}$, 以及 $w' = cw$, 因为 ReLU 满足正齐次性质 $\text{ReLU}(cz) = c\text{ReLU}(z)$, 因此: $a'\text{ReLU}(w'x) = \frac{a}{c} \text{ReLU}(cw x) = a\text{ReLU}(wx)$, 网络函数完全相同: $f_{a',w'} = f_{a,w}$, 预测结果不发生变化, 但是参数空间中的 Hessian 可能发生显著变化。

十五、相同函数为什么可以具有不同尖锐度

考虑简单损失 $L(a, w) = \frac{1}{2} (aw - y)^2$, 定义 $r = aw - y$, 损失为 $L = \frac{1}{2} r^2$, 对参数求梯度 $\frac{\partial L}{\partial a} = rw$, 以及 $\frac{\partial L}{\partial w} = ra$, 继续计算二阶偏导 $\frac{\partial^2 L}{\partial a^2} = w^2$, 以及 $\frac{\partial^2 L}{\partial w^2} = a^2$, 混合偏导为 $\frac{\partial^2 L}{\partial a \partial w} = 2aw - y$, Hessian 为 $H = \begin{bmatrix} w^2 & 2aw - y \\ 2aw - y & a^2 \end{bmatrix}$, 在全局最小值处 $aw = y$, 因此 $H = \begin{bmatrix} w^2 & y \\ y & a^2 \end{bmatrix}$, Hessian 行列式为 $\det(H) = a^2 w^2 - y^2$, 由于 $aw = y$, 因此 $\det(H) = 0$, 两个特征值分别为 $\lambda_1 = 0$ 以及 $\lambda_2 = a^2 + w^2$, 进行尺度变换 $a' = \frac{a}{c}$ 以及 $w' = cw$, 新的最大 Hessian 特征值为 $\lambda'_{\max} = \frac{a^2}{c^2} + c^2 w^2$

当 $c \rightarrow \infty$, 得到 $\lambda'_{\max} \rightarrow \infty$, 网络函数完全不变, 但 Hessian 最大特征值可以任意增大, 因此 $f_{\theta'} = f_{\theta}$ 并不能推出 $\lambda_{\max}(H_{\theta'}) = \lambda_{\max}(H_{\theta})$, 这说明原始 Hessian 尖锐度不是重参数化不变的, Dinh 等人的研究正是利用深度网络的尺度对称性说明, 能够构造函数完全相同但传统尖锐度任意大的参数解。

(<https://arxiv.org/pdf/1703.04933>)

十六、归一化平坦性

为了解决参数尺度问题，可以根据参数大小对扰动进行归一化，传统参数扰动满足 $\|\epsilon\|_2 \leq \rho$ ，归一化扰动可以根据每个参数的大小调整允许的变化范围 $|\epsilon_i| \leq \rho|\theta_i|$ ，

也可以定义相对扰动 $r_i = \frac{\epsilon_i}{|\theta_i| + \eta}$ ，其中 $\eta > 0$ 用于避免分母为零。

此时使用 $\|r\|_2 \leq \rho$ ，参数较大的位置允许较大的绝对扰动；参数较小的位置允许较小的绝对扰动。

归一化平坦性和尺度不变平坦性被提出用于减轻传统平坦性对参数缩放的敏感问题。

十七、邻域最大损失定义

除了 Hessian 以外，还可以直接测量参数邻域内最大的损失增加；

定义局部尖锐度 $S_\rho(\theta) = \max_{|\epsilon|_2 \leq \rho} [L_S(\theta + \epsilon) - L_S(\theta)]$ ，如果 $S_\rho(\theta)$ 较小，则参数邻

域中的最坏损失增长较小，对应较平坦的解；如果 $S_\rho(\theta)$ 较大，则存在某个扰动方向使损失快速增加，对应较尖锐的解。

在局部极小值附近 $\nabla L_S(\theta^*) = 0$ ，根据二阶近似 $S_\rho(\theta^*) \approx \max_{|\epsilon|_2 \leq \rho} \frac{1}{2} \epsilon^T H \epsilon$ ，根据前面的推导 $S_\rho(\theta^*) \approx \frac{\rho^2}{2} \lambda_{\max}$ ，因此邻域最大损失和最大 Hessian 特征值具有直接联系。

十八、Sharpness-Aware Minimization

Sharpness-Aware Minimization 简称 SAM，其目标是降低参数邻域中的最大损失。

传统优化目标为 $\min_{\theta} L_S(\theta)$ ，SAM 的优化目标为 $\min_{\theta} \max_{|\epsilon|_2 \leq \rho} L_S(\theta + \epsilon)$

内部最大化寻找使损失增加最大的参数扰动；外部最小化降低最坏扰动下的损失。SAM 通过同时考虑当前损失和邻域损失，试图寻找对参数扰动更加稳定的解。

十九、SAM 内部扰动的推导

定义当前位置梯度 $g = \nabla_{\theta} L_S(\theta)$ ，对扰动后的损失进行一阶展开 $L_S(\theta + \epsilon) \approx L_S(\theta) + g^T \epsilon$ ，内部优化变为 $\max_{|\epsilon|_2 \leq \rho} g^T \epsilon$

根据柯西施瓦茨不等式 $g^T \epsilon \leq |g|_2 |\epsilon|_2$ ，进一步得到 $g^T \epsilon \leq \rho |g|_2$ ，当扰动方向和梯度方向相同时取得最大值 $\epsilon^* = \rho \frac{g}{|g|_2}$ ，因此 SAM 首先将参数移动到损失上升最快的

位置 $\theta_{\text{adv}} = \theta + \rho \frac{\nabla L_S(\theta)}{|\nabla L_S(\theta)|_2}$ ，然后计算扰动位置的梯度 $g_{\text{SAM}} = \nabla L_S(\theta_{\text{adv}})$ ，最后更新原

参数 $\theta_{t+1} = \theta_t - \eta g_{\text{SAM}}$ 。

因此 SAM 的训练过程可以概括为：先寻找附近最坏参数；再降低最坏参数位置的损失。

二十、SAM 为什么与 Hessian 有关

对梯度进行一阶展开 $\nabla L_S(\theta + \epsilon) \approx \nabla L_S(\theta) + H\epsilon$ ，代入 SAM 扰动 $\epsilon^* = \rho \frac{g}{\|g\|_2}$ ，得到 $g_{\text{SAM}} \approx g + \rho H \frac{g}{\|g\|_2}$ ，相比普通梯度下降 g ，SAM 增加了曲率相关项 $\rho H \frac{g}{\|g\|_2}$ ，因此高曲率方向会产生更明显的修正。

需要注意，SAM 的实际作用机制仍然是持续研究的问题，虽然寻找平坦区域是其核心动机，但后续理论研究指出，仅使用传统平坦性或简单 PAC-Bayes 解释不能完整说明 SAM 的全部优化行为。

二十一、小批量 SGD 为什么可能偏向较宽的解


小批量随机梯度为 $g_B(\theta) = \frac{1}{|B|} \sum_{i \in B} \nabla \ell_i(\theta)$ ，可以将随机梯度写成

$g_B(\theta) = \nabla L_S(\theta) + \xi$ ，其中 ξ 表示梯度噪声

SGD 更新为 $\theta_{t+1} = \theta_t - \eta \nabla L_S(\theta_t) - \eta \xi_t$

设当前参数位于极小值附近 $\theta_t = \theta^* + \delta_t$ ，利用局部线性近似 $\nabla L_S(\theta^* + \delta_t) \approx H\delta_t$ 得到 $\delta_{t+1} = (I - \eta H)\delta_t - \eta \xi_t$ ，投影到第 k 个 Hessian 特征方向 $z_{k,t} = q_k^T \delta_t$ 得到 $z_{k,t+1} = (1 - \eta \lambda_k) z_{k,t} - \eta \xi_{k,t}$ 。

曲率会影响噪声扰动在不同方向上的运动，较小批次通常具有更大的随机梯度噪声，早期实验观察到，大批量训练更容易到达较尖锐的极小值，而小批量训练更容易到达较平坦的区域。（<https://arxiv.org/pdf/1609.04836>）



但不能将其理解为无条件规律，学习率、训练轮数、归一化方式以及优化器设置都会影响大批量训练的泛化表现。

二十二、平坦解不等于泛化一定好

1. 传统参数空间平坦性存在以下问题：
2. 平坦性依赖参数坐标，相同函数可以通过尺度变换获得完全不同的 Hessian 特征值；
3. 神经网络存在大量参数对称性，某些平坦方向可能只是参数冗余；
4. 局部 Hessian 只能描述很小邻域内的二阶几何，当参数扰动较大时，高阶项

不能忽略；

5. 不同平坦性指标关注不同性质，最大特征值测量最坏方向 **Hessian** 的迹测量总曲率，参数扰动测量邻域稳定性，低损失区域体积测量可容忍参数区域大小；
6. 参数空间平坦不一定等价于函数空间稳定，参数变化很大时，网络输出可能几乎不变，参数变化很小时，网络输出也可能明显变化。

因此更加严谨的结论是：

在合理的参数归一化、扰动尺度和模型比较条件下，较低的局部尖锐度经常与较好的泛化表现相关，但原始参数空间平坦性不能被视为泛化能力的充分条件

现代研究仍在探索能够处理重参数化问题并更稳定反映泛化能力的平坦性指标。

二十三、常见平坦性指标总结

1. 最大特征值 $F_1 = \lambda_{\max}(H)$ 衡量最尖锐方向，数值越小通常表示最坏方向越平坦；
2. **Hessian** 的迹 $F_2 = \text{Tr}(H)$ 衡量所有方向的总曲率，也与各向同性高斯参数扰动下的平均损失增长有关；
3. **Hessian** 行列式 $F_3 = \det(H)$ 与局部低损失椭球体积相关，深度网络存在大量零特征值时较难直接使用；
4. 邻域最大损失 $F_4 = \max_{|\epsilon|_2 \leq \rho} [L_S(\theta + \epsilon) - L_S(\theta)]$ 衡量邻域中的最坏损失增长；
5. 随机扰动平均损失 $F_5 = \mathbb{E}_{\epsilon} [L_S(\theta + \epsilon) - L_S(\theta)]$ 衡量模型对随机参数噪声的平均敏感性

