

AttnRes: 注意力残差

导论

残差连接是深层神经网络实现稳定训练和信息传递的重要基础。现代 Transformer 通常通过逐层累加残差输出,使浅层信息能够沿网络深度持续传播。然而,这种固定累加方式对所有历史层一视同仁。随着网络不断加深,隐藏状态中累积的信息越来越多,新层产生的表示在整体残差流中的相对影响可能逐渐减弱,进而出现深层信息被稀释的问题。

Attention Residuals, 简称 AttnRes, 是 Kimi 团队提出的一种新型残差连接方法。它不再简单地将所有历史层输出直接相加,而是在网络深度方向引入注意力机制,使当前层能够根据输入内容动态选择和组合不同历史层的表示。与传统自注意力在 Token 之间建立联系不同,AttnRes 的注意力作用于不同网络层之间,因此可以理解作为一种“深度注意力”机制。

通过这种设计,模型可以在处理不同输入时选择不同的跨层信息路径。例如,某些任务可能更依赖浅层保留的局部特征,而另一些任务则更需要深层形成的抽象语义。AttnRes 使这些选择不再由固定残差结构预先决定,而是由模型动态学习。

为了降低保存全部历史层表示所产生的存储和通信开销,AttnRes 还提供了分块形式 Block AttnRes。该方法将网络划分为多个层块,并主要在块级表示之间执行深度注意力,在保留跨层选择能力的同时减少额外计算和存储成本。总体而言,AttnRes 将传统的固定残差累加转变为输入相关的动态跨层聚合,为缓解深层 Transformer 中的信息稀释问题提供了一种新的残差连接方案。

设第 l 层状态为 x_l , 非线性变换为 F_l , 其 Jacobian 为: $J_l = \frac{\partial F_l(x_l)}{\partial x_l}$

普通深层网络满足 $x_{l+1} = F_l(x_l)$, 因此 $\frac{\partial x_L}{\partial x_l} = J_{L-1}J_{L-2}\cdots J_l$, 连续矩阵乘积可能导致梯度指数放大或衰减,残差连接的主要目标是建立更加稳定的信号与梯度传播路径。

1. Highway Network: 门控残差

Highway Network 使用输入相关的变换门:

$$x_{l+1} = T_l(x_l) \odot H_l(x_l) + (1 - T_l(x_l)) \odot x_l$$

等价地 $x_{l+1} = x_l + T_l(x_l) \odot (H_l(x_l) - x_l)$, 则 $y = x + T \odot (H - x)$

求微分 $dy = dx + D_T(dH - dx) + D_{H-x}dT$, 代入 $dH = J_H dx$, $dT = J_T dx$

得到 $\frac{\partial y}{\partial x} = I + D_T(J_H - I) + D_{H-x}J_T$

当 $T \approx 0$ 时, 网络接近恒等映射; 当 $T \approx 1$ 时, 网络主要采用变换 $H(x)$

设 $x = 2$, $H(x) = 5$, $T(x) = 0.3$

则 $y = 0.3 \times 5 + (1 - 0.3) \times 2$, $y = 1.5 + 1.4 = 2.9$

因此, 输出由原始输入 2 和变换结果 5 按门控比例混合。

论文链接: <https://arxiv.org/pdf/1505.00387>

更完整的后续版本: <https://arxiv.org/pdf/1507.06228>

2. ResNet: 标准加法残差

ResNet 使用 $x_{l+1} = x_l + F_l(x_l)$ ，连续展开得到 $x_L = x_l + \sum_{k=l}^{L-1} F_k(x_k)$ ，因此，深层网络可以理解为在初始表示上不断叠加修正量。

单层 Jacobian 为 $\frac{\partial x_{l+1}}{\partial x_l} = I + J_l$ ，跨越多层 $\frac{\partial x_L}{\partial x_l} = (I + J_{L-1}) \cdots (I + J_l)$

例如两层 $(I + J_2)(I + J_1) = I + J_1 + J_2 + J_2 J_1$ ，展开式中始终存在恒等项 I ，从而形成不经过复杂非线性变换的梯度通路。

若输入与输出维度不同，可以使用投影残差 $x_{l+1} = P_l x_l + F_l(x_l)$

此时 $\frac{\partial x_{l+1}}{\partial x_l} = P_l + J_l$ ，只有当 $P_l = I$ 时，捷径才是严格的恒等映射。

设 $x_l = 2$, $F_l(x_l) = 0.5x_l$


则 $F_l(2) = 1$


所以 $x_{l+1} = 2 + 1 = 3$

因为 $J_l = 0.5$ ，所以单层梯度为 $\frac{\partial x_{l+1}}{\partial x_l} = 1 + 0.5 = 1.5$

若没有残差连接，梯度只有 0.5；加入残差连接后，还保留了恒等梯度 1。

论文链接: <https://arxiv.org/pdf/1512.03385>





3. Pre-activation ResNet

后激活残差为 $x_{l+1} = \sigma(x_l + F_l(x_l))$

其 Jacobian 为 $\frac{\partial x_{l+1}}{\partial x_l} = J_\sigma(I + J_l)$, 梯度仍必须经过外部激活函数。

预激活残差改为 $x_{l+1} = x_l + F_l(\sigma(\text{Norm}(x_l)))$

因此 $\frac{\partial x_{l+1}}{\partial x_l} = I + J_{F_l} J_{\sigma} J_{\text{Norm}}$

恒等项位于最外层，不会被激活函数或归一化直接截断。


设 $x_l = 2$ ，并假设经过归一化和激活后： $\sigma(\text{Norm}(x_l)) = 1.5$


再设 $F_l(1.5) = 0.4$

则 $x_{l+1} = 2 + 0.4 = 2.4$

即使残差支路经过归一化和激活，原始输入 2 仍可直接传递到下一层。

论文链接：<https://arxiv.org/pdf/1603.05027>





4. DenseNet: 密集拼接

DenseNet 不使用加法，而是让第 1 层读取所有历史表示 $z_l = H_l([z_0, z_1, \dots, z_{l-1}])$

任意历史表示 z_i 都可能直接影响多个后续层，因此 $\frac{\partial \mathcal{L}}{\partial z_i} = \sum_{j=i+1}^L \left(\frac{\partial z_j}{\partial z_i} \right)^T \frac{\partial \mathcal{L}}{\partial z_j}$

梯度可以从多个后续层直接返回。

若每层新增 k 个通道，则第 1 层输入宽度为 $d_l = d_0 + lk$ ，因此其代价是通道宽度随深度增长。

设初始表示为 $z_0 = [1, 2]$

第一层产生一个新特征 $z_1 = [0.5]$


那么第二层接收的输入为 $[z_0, z_1] = [1, 2, 0.5]$

如果第二层又产生 $z_2 = [3]$

那么第三层的输入为 $[z_0, z_1, z_2] = [1, 2, 0.5, 3]$

历史特征不会被相加覆盖，而是被完整保留下来。

论文链接: <https://arxiv.org/pdf/1608.06993>



5. Stochastic Depth 与 DropPath

训练时随机关闭残差支路 $m_l \sim \text{Bernoulli}(p_l)$; $x_{l+1} = x_l + \frac{m_l}{p_l} F_l(x_l)$

因为 $\mathbb{E}\left[\frac{m_l}{p_l}\right] = 1$, 所以 $\mathbb{E}[x_{l+1} | x_l] = x_l + F_l(x_l)$

其 Jacobian 为 $\frac{\partial x_{l+1}}{\partial x_l} = I + \frac{m_l}{p_l} J_l$

当 $m_l = 0$ 时, $x_{l+1} = x_l$, 该层严格退化为恒等映射。


设 $x_l = 3$, $F_l(x_l) = 2$, $p_l = 0.8$


当残差支路被保留, 即 $m_l = 1$ 时: $x_{l+1} = 3 + \frac{1}{0.8} \times 2 = 5.5$

当残差支路被关闭, 即 $m_l = 0$ 时: $x_{l+1} = 3$

其期望为 $0.8 \times 5.5 + 0.2 \times 3 = 5$, 正好等于完整残差块的输出 $3+2=5$

论文链接: <https://arxiv.org/pdf/1603.09382>





6. Fixup: 用初始化控制残差规模

假设网络有 L 个残差块，每个残差支路包含 m 个权重层。

若前 $m-1$ 个权重统一缩放为 s ，则支路输出规模近似乘以 s^{m-1}

为了使 L 个近似独立残差的总方差保持 $O(1)$ ，每个支路的输出规模应约为 $O(L^{-1/2})$ ，因此要求 $s^{m-1} = L^{-1/2}$ ，解得 $s = L^{-\frac{1}{2m-2}}$

Fixup 还将残差支路最后一层初始化为零，使初始状态满足 $F_l(x_l) \approx 0$ ； $x_{l+1} \approx x_l$ 因此网络在初始化时接近恒等映射。


设 $L = 16$ ， $m = 2$


则 $s = 16^{-\frac{1}{2}} = \frac{1}{4}$ ，因此残差支路前面的权重需要乘以 0.25。

若未缩放时支路输出规模约为 4，缩放后约为 $0.25 \times 4 = 1$

同时，最后一层初始化为零，因此网络真正初始化时仍满足 $F_l(x_l) \approx 0$

论文链接: <https://arxiv.org/pdf/1901.09321>





7. ReZero

ReZero 为每层加入可学习标量 $x_{l+1} = x_l + \alpha_l F_l(x_l)$ ，初始化 $\alpha_l = 0$

单层 Jacobian 为 $\frac{\partial x_{l+1}}{\partial x_l} = I + \alpha_l J_l$

初始化时 $\left. \frac{\partial x_{l+1}}{\partial x_l} \right|_{\alpha_l=0} = I$

虽然残差支路参数的梯度暂时受到 $\alpha_l = 0$ ，抑制，但残差系数仍可更新：

$$\frac{\partial \mathcal{L}}{\partial \alpha_l} = \left(\frac{\partial \mathcal{L}}{\partial x_{l+1}} \right)^T F_l(x_l)$$


训练会先改变 α_l ，再逐渐打开残差支路。

设 $x_l = 3$ ， $F_l(x_l) = 2$

初始化时 $\alpha_l = 0$ ，所以 $x_{l+1} = 3 + 0 \times 2 = 3$

训练后若 $\alpha_l = 0.1$ ，则 $x_{l+1} = 3 + 0.1 \times 2 = 3.2$ ，残差支路由完全关闭逐渐变为部分开启。

论文链接：<https://arxiv.org/pdf/2003.04887>



8. LayerScale

LayerScale 将 ReZero 的单个标量扩展为逐通道参数: $x_{l+1} = x_l + \Lambda_l F_l(x_l)$

其中 $\Lambda_l = \text{Diag}(\lambda_{l,1}, \dots, \lambda_{l,d})$

对应 Jacobian $\frac{\partial x_{l+1}}{\partial x_l} = I + \Lambda_l J_l$, 不同通道可以学习不同的残差强度。


设 $x_l = (1, 2)$; $F_l(x_l) = (4, -2)$, 并设 $\Lambda_l = \text{Diag}(0.1, 0.01)$

则 $\Lambda_l F_l(x_l) = (0.4, -0.02)$

所以 $x_{l+1} = (1, 2) + (0.4, -0.02) = (1.4, 1.98)$

第一个通道使用较大的残差强度, 第二个通道使用较小的残差强度。

论文链接: <https://arxiv.org/pdf/2103.17239>



9. Post-LN Transformer

Post-LN 的结构为 $x_{l+1} = \text{LN}(x_l + F_l(x_l))$

令 $u_l = x_l + F_l(x_l)$, 则 $\frac{\partial x_{l+1}}{\partial x_l} = J_{\text{LN}}(u_l)(I + J_l)$

虽然残差内部存在恒等项, 但跨越多层时, 梯度仍必须反复经过 LayerNorm 的 Jacobian。

设 $x_l = (1, 3)$; $F_l(x_l) = (1, 1)$

残差相加后 $u_l = (2, 4)$, 其均值为 $\mu = \frac{2+4}{2} = 3$; 标准差为 $\sigma = 1$

忽略可学习缩放和平移参数时 $\text{LN}(u_l) = (-1, 1)$, 因此 $x_{l+1} = (-1, 1)$

可以看到, 恒等输入先与残差相加, 然后整体经过归一化。

论文链接: <https://arxiv.org/pdf/1706.03762>

10. Pre-LN Transformer

Pre-LN 将归一化移入残差支路: $x_{l+1} = x_l + F_l(\text{LN}(x_l))$

其 Jacobian 为 $\frac{\partial x_{l+1}}{\partial x_l} = I + J_{F_l} J_{\text{LN}}$

恒等项位于最外层, 因此梯度可以沿残差流直接传播。

前向展开: $x_L = x_0 + \sum_{l=0}^{L-1} F_l(\text{LN}(x_l))$

令 $v_l = F_l(\text{LN}(x_l))$, 在各残差近似零均值、独立且等方差的假设下:

$$\text{Var}(x_L) \approx \text{Var}(x_0) + \sum_{l=0}^{L-1} \text{Var}(v_l)$$

若 $\text{Var}(v_l) = \sigma_v^2$, 则 $\text{Var}(x_L) \approx \text{Var}(x_0) + L\sigma_v^2$, 因此 $|x_L| \sim O(\sqrt{L})$

若新残差 v_l 的规模保持 $O(1)$, 其相对于已有残差流的贡献约为 $\frac{|v_l|}{|x_l|} \sim O(l^{-1/2})$

这解释了 Pre-LN 易于优化, 但极深网络中的新增层可能被不断增长的残差流稀释。


设 $x_l = (1, 3)$, 则忽略可学习参数时 $\text{LN}(x_l) = (-1, 1)$

假设残差模块为 $F_l(z) = 0.5z$, 则 $F_l(\text{LN}(x_l)) = (-0.5, 0.5)$

最终 $x_{l+1} = (1, 3) + (-0.5, 0.5) = (0.5, 3.5)$

原始输入不会经过输出端的 LayerNorm。

论文链接: <https://arxiv.org/pdf/2002.04745>



11. DeepNorm

DeepNorm 使用 $x_{l+1} = \text{LN}(\alpha x_l + F_l(x_l))$

令 $u_l = \alpha x_l + F_l(x_l)$, 则 $\frac{\partial x_{l+1}}{\partial x_l} = J_{\text{LN}}(u_l)(\alpha I + J_l)$, 其中 α 增强主残差路径, 而残差支路权重通过系数 β 缩小初始化。

对于包含 N 层的 encoder-only Transformer, 可以取 $\alpha = (2N)^{1/4}$, $\beta = (8N)^{-1/4}$ 其目标是同时控制主路径和变换支路的尺度。

设 $N=16$, 则 $\alpha = (32)^{1/4} \approx 2.38$; $\beta = (128)^{-1/4} \approx 0.30$

如果某个位置上的简化标量输入为 $x_l = 1$, $F_l(x_l) = 0.2$

那么归一化前的主残差和变换结果为 $u_l = 2.38 \times 1 + 0.2 = 2.58$

主路径的贡献明显大于残差支路, 从而强化深层网络中的主要传播路径。

论文链接: <https://arxiv.org/pdf/2203.00555>

12. DenseFormer: 静态跨层加权

DenseFormer 对历史层进行可学习线性组合 $Y_l = \sum_{i=0}^l \alpha_{l,i} X_i$

通常初始化为 $\alpha_{l,l} = 1$, $\alpha_{l,i} = 0$, $i < l$

因此初始网络等价于普通 Transformer。

历史层到当前层的直接梯度为: $\frac{\partial Y_l}{\partial X_i} = \alpha_{l,i} I$

这些权重不依赖当前 Token 内容, 也不要求为非负数或和为 1, 因此属于静态线性组合。


设三个历史层表示为 $X_0 = 1$, $X_1 = 2$, $X_2 = 4$

对应权重为 $\alpha_{2,0} = 0.2$, $\alpha_{2,1} = 0.3$, $\alpha_{2,2} = 0.5$

则 $Y_2 = 0.2 \times 1 + 0.3 \times 2 + 0.5 \times 4$, $Y_2 = 0.2 + 0.6 + 2 = 2.8$

三个历史层都直接参与当前表示的计算。

论文链接: <https://arxiv.org/pdf/2402.02622>



13. Hyper-Connections

Hyper-Connections 将单条残差流扩展为 n 条流: $X_l = \begin{bmatrix} x_{l,1} \\ \vdots \\ x_{l,n} \end{bmatrix} \in \mathbb{R}^{n \times d}$

首先读取模块输入 $u_l = H_l^{\text{pre}} X_l$, 随后计算 $z_l = F_l(u_l)$

最后执行残差流混合和写回 $X_{l+1} = H_l^{\text{res}} X_l + (H_l^{\text{post}})^T z_l$

其中 H_l^{pre} 控制从多条残差流中读取什么; H_l^{res} 控制旧残差流之间的路由; H_l^{post} 控制模块输出如何写入各条流。

忽略非线性支路时 $X_L \approx H_{L-1}^{\text{res}} \cdots H_l^{\text{res}} X_l$

因此主路径梯度主要受到矩阵乘积 $H_{L-1}^{\text{res}} \cdots H_l^{\text{res}}$ 控制。无约束矩阵的连续乘积仍可能造成放大或收缩。

设有两条残差流 $X_l = \begin{bmatrix} 1 \\ 3 \end{bmatrix}$


读取权重为 $H_l^{\text{pre}} = [0.25 \ 0.75]$, 则 $u_l = 0.25 \times 1 + 0.75 \times 3 = 2.5$


假设 $F_l(u_l) = 1$, 并设 $H_l^{\text{res}} = I$, $H_l^{\text{post}} = [0.2 \ 0.8]$

则 $X_{l+1} = \begin{bmatrix} 1 \\ 3 \end{bmatrix} + \begin{bmatrix} 0.2 \\ 0.8 \end{bmatrix} \times 1$


所以 $X_{l+1} = \begin{bmatrix} 1.2 \\ 3.8 \end{bmatrix}$, 模块输出以不同强度写入两条残差流。

论文链接: <https://arxiv.org/pdf/2409.19606>







(a) Sequential Arrangement



(b) Parallel Arrangement



(b) Transformer with Residual Connections



(b) Transformer with Hyper-Connections

14. Frac-Connections

HC 使用 $n \geq 1$ 条完整残差流，状态宽度约为: nd

Frac-Connections 将扩展率推广到: $0 < n < 1$

令 $n = \frac{1}{m}$ ，并将原表示划分为 $x_i = [x_i^{(1)}; \dots; x_i^{(m)}]$ ，其中 $x_i^{(r)} \in \mathbb{R}^{d/m}$

因为 $\frac{d}{m} = nd$ ，并且 $\sum_{r=1}^m \dim x_i^{(r)} = m \frac{d}{m} = d$

所以 Frac-Connections 可以保留多路径路由能力，而不将整体状态宽度扩展到大于 d 。



设原始表示维数为 $d=4$ ，取 $n = \frac{1}{2}$

因此 $m=2$ ，若 $x_i = [1, 2, 3, 4]$ ，可以划分为 $x_i^{(1)} = [1, 2]$ ； $x_i^{(2)} = [3, 4]$

每个分区宽度为 $\frac{d}{m} = \frac{4}{2} = 2$ ，两个分区总宽度仍为 $2+2=4$

因此可以建立多路径结构，而不把总宽度扩展为 8。

论文链接: <https://arxiv.org/pdf/2503.14125>



15. Keel: 强化 Post-LN 主路径

Keel 使用 $x_{l+1} = \text{LN}(\alpha x_l + F_l(\text{LN}(x_l)))$

其中通常取 $\alpha = L$ ，令 $u_l = \alpha x_l + F_l(\text{LN}(x_l))$ ，则 $\frac{\partial x_{l+1}}{\partial x_l} = J_{\text{LN},\text{out}}(\alpha I + J_{F_l} J_{\text{LN},\text{in}})$

若 αx_l 主导 u_l ，归一化 Jacobian 的尺度近似为 $1/\alpha$ 。

此时主路径约为 $\frac{1}{\alpha} \alpha I \approx I$ ，而变换支路约为 $\frac{1}{\alpha} J_{F_l} J_{\text{LN},\text{in}}$

因此，Keel 通过强化主路径，使 Post-LN 的主梯度传播接近恒等映射。


设网络包含 $L=4$ ，因此 $\alpha = 4$ ，若主路径输入规模为 $x_l = 1$

残差支路输出规模为 $F_l(\text{LN}(x_l)) = 0.5$ ，则归一化前 $u_l = 4 \times 1 + 0.5 = 4.5$

其中主路径贡献为 4，残差支路贡献仅为 0.5。

在简化的尺度分析中，若外部归一化产生约 1/4 的缩放，则主路径梯度约为 $\frac{1}{4} \times 4 = 1$ ，因此主梯度接近恒等传播。

论文链接: <https://arxiv.org/pdf/2601.19895>



16. DeepSeek mHC

mHC 是对 Hyper-Connections 的稳定化扩展。

HC 的纯残差路由包含 $H_{L-1}^{\text{res}} \cdots H_l^{\text{res}}$

若矩阵不受约束，其奇异值可能在连续乘积中放大。

mHC 将残差混合矩阵限制为双随机矩阵：

$$\mathcal{B}_n = \{M \in \mathbb{R}^{n \times n} : M \geq 0, M\mathbf{1} = \mathbf{1}, \mathbf{1}^T M = \mathbf{1}^T\}$$

更新公式为 $X_{l+1} = M_l X_l + (H_l^{\text{post}})^T F_l(H_l^{\text{pre}} X_l)$

其中 $M_l \in \mathcal{B}_n$ ，由于每行元素和为 1， $|M_l|_\infty = 1$ ；由于每列元素和为 1， $|M_l|_1 = 1$

利用矩阵范数不等式 $|M_l|_2 \leq \sqrt{|M_l|_1 |M_l|_\infty}$ 得到 $|M_l|_2 \leq 1$ ，因此单层纯残差路由在谱范数意义下是非扩张的。

此外，双随机矩阵的乘积仍为双随机矩阵。

若 $A, B \in \mathcal{B}_n$ ，则 $(AB)\mathbf{1} = A(B\mathbf{1}) = A\mathbf{1} = \mathbf{1}$ ，并且 $\mathbf{1}^T AB = (\mathbf{1}^T A)B = \mathbf{1}^T B = \mathbf{1}^T$ 所以 $AB \in \mathcal{B}_n$

这意味着多层纯残差路由不会在谱范数意义下指数放大，但仍可能收缩某些与全一向量正交的方向。

设 $M_l = \begin{bmatrix} 0.7 & 0.3 \\ 0.3 & 0.7 \end{bmatrix}$ ，其每行和每列都为 1，因此是双随机矩阵。

设两条残差流为 $X_l = \begin{bmatrix} 1 \\ 3 \end{bmatrix}$ ，则 $M_l X_l = \begin{bmatrix} 0.7 \times 1 + 0.3 \times 3 \\ 0.3 \times 1 + 0.7 \times 3 \end{bmatrix}$

所以 $M_l X_l = \begin{bmatrix} 1.6 \\ 2.4 \end{bmatrix}$ ，混合前后的平均值均为 $\frac{1+3}{2} = \frac{1.6+2.4}{2} = 2$

同时 $|X_l|_2 = \sqrt{10} \approx 3.16$ ； $|M_l X_l|_2 = \sqrt{1.6^2 + 2.4^2} \approx 2.88$ ，说明该路由没有放大向量的欧几里得范数。

Sinkhorn 投影

mHC 从可学习矩阵参数开始 $M^{(0)} = \exp(\tilde{H}_l)$


随后交替进行行归一化 $M^{(t+\frac{1}{2})} = D_r^{-1} M^{(t)}$ ； $D_r = \text{Diag}(M^{(t)}\mathbf{1})$

以及列归一化 $M^{(t+1)} = M^{(t+\frac{1}{2})} D_c^{-1}$ ， $D_c = \text{Diag}(\mathbf{1}^T M^{(t+\frac{1}{2})})$

多次迭代后，可以得到近似双随机矩阵。

三种结构的关系可以概括为 ResNet：固定单流；HC：可学习多流；mHC：受约束的可学习多流。

论文链接：<https://arxiv.org/pdf/2512.24880>



17. Kimi Attention Residuals

普通 Pre-LN 残差可以展开为 $h_l = v_0 + \sum_{i=1}^{l-1} v_i$ ，其中 $v_0 = x_0$ ， $v_i = F_i(h_i)$ ，这相当于所有历史层都具有固定权重 1。

AttnRes 改为 $h_l = \sum_{i=0}^{l-1} \alpha_{i \rightarrow l} v_i$ ，注意力分数为 $s_{i \rightarrow l} = q_l^T \text{RMSNorm}(v_i)$

这里的 Attention 沿网络深度执行，而不是沿 Token 维度执行。

因为 $\alpha_i \geq 0$ ； $\sum_i \alpha_i = 1$ ，所以：

$$\sqrt{h_l^T h_l} = \sqrt{\left(\sum_i \alpha_i v_i\right)^T \left(\sum_i \alpha_i v_i\right)} \sqrt{h_l^T h_l} \leq \sum_i \alpha_i \sqrt{v_i^T v_i} \sum_i \alpha_i \sqrt{v_i^T v_i} \leq \max_i \sqrt{v_i^T v_i}$$

因此，AttnRes 不会仅因为历史层数量增加就必然放大残差流。

设两个历史层表示为 $v_0 = (1, 0)$ ； $v_1 = (0, 2)$

注意力权重为 $\alpha_0 = 0.25$ ， $\alpha_1 = 0.75$

则 $h = 0.25v_0 + 0.75v_1$ ； $h = 0.25(1, 0) + 0.75(0, 2)$

所以 $h=(0.25,1.5)$ ，其范数为 $|h|_2 = \sqrt{0.25^2 + 1.5^2} \approx 1.52$

而 $\max(|v_0|_2, |v_1|_2) = 2$

因此 $|h|_2 \leq 2$

梯度推导

简写为 $h = \sum_j \alpha_j$ ； $v_j \alpha_j = \text{softmax}(s_j)$

仅考虑 v_i 的变化： $dh = \alpha_i dv_i + \sum_j v_j d\alpha_j$

Softmax 导数为 $\frac{\partial \alpha_j}{\partial s_i} = \alpha_j (\delta_{ij} - \alpha_i)$

因此 $\sum_j v_j d\alpha_j = \alpha_i (v_i - h) ds_i$ ，又因为 $ds_i = (\nabla_{v_i} s_i)^T dv_i$

所以 $dh = [\alpha_i I + \alpha_i (v_i - h) (\nabla_{v_i} s_i)^T] dv_i$


最终 $\frac{\partial h}{\partial v_i} = \alpha_i I + \alpha_i (v_i - h) (\nabla_{v_i} s_i)^T$

其中 $\alpha_i I$ 表示历史层到当前层的直接梯度路径； $\alpha_i (v_i - h) (\nabla_{v_i} s_i)^T$ 表示通过改变深度注意力权重产生的路由梯度。

在上面的数值例子中， v_1 的直接梯度通路为 $\alpha_1 I = 0.75I$ ，说明当前表示对第二个历史层保留了权重为 0.75 的直接梯度路径。

完整 AttnRes 需要保存全部历史层表示，存储量约为 $O(Ld)$

若将网络划分为 N 个块，只保存块级表示，则长期状态变为 $O(Ld) \rightarrow O(Nd)$



总结:

方法	机制	主要作用
Highway	输入相关门控	学习是否使用恒等路径
ResNet	固定加法	建立恒等梯度通路
Pre-activation	非线性移入支路	保护外层恒等项
DenseNet	历史表示拼接	保留全部历史特征
Stochastic Depth	随机关闭支路	训练不同深度子网络
Fixup	深度相关初始化	无归一化稳定训练
ReZero	零初始化残差系数	初始网络严格恒等
LayerScale	逐通道残差缩放	控制通道级残差强度
Post-LN / Pre-LN	调整归一化位置	平衡梯度与表示
DeepNorm	强化主路径	稳定超深 Post-LN
DenseFormer	静态跨层加权	学习固定深度组合
Hyper-Connections	多残差流路由	学习残差拓扑
Frac-Connections	分数宽度路由	降低多流宽度开销
Keel	强化 Post-LN 主路径	稳定极深网络
DeepSeek mHC	双随机矩阵约束	稳定多流矩阵乘积
Kimi AttnRes	深度方向 Attention	按输入选择历史层