

Sigmoid 图文预训练模型 SigLIP

SigLIP 的论文全名是 *Sigmoid Loss for Language Image Pre-Training*，由 Xiaohua Zhai、Basil Mustafa、Alexander Kolesnikov 和 Lucas Beyer 在 2023 年提出。它延续 CLIP 的双编码器图文预训练框架，主要变化集中在训练损失：CLIP 使用基于 Softmax 的双向对比损失，SigLIP 把一个 batch 中的每一个图像-文本组合都看成独立的匹配判断，并使用 Sigmoid Loss 训练。原论文指出，这种损失不需要对整个 batch 的相似度进行全局 Softmax 归一化，因此在分布式训练和大 batch 扩展时更加方便，同时在较小 batch 下也能保持很强的效果。

<https://arxiv.org/abs/2303.15343>

为了理解 SigLIP，可以先从 CLIP 的训练问题开始。假设一个 batch 中有 N 对图文数据 $(I_1, T_1), (I_2, T_2), \dots, (I_N, T_N)$ ，其中 I_i 与 T_i 是正确配对。CLIP 会先构造一个 $N \times N$ 相似度矩阵，然后对每一行和每一列分别做 Softmax。对于第 i 张图片，它要在 N 段文本中选出正确文本；对于第 i 段文本，它又要在 N 张图片中选出正确图片。这样可以得到图像到文本和文本到图像两个方向的交叉熵损失。

SigLIP 仍然使用同样的图像编码器和文本编码器。设图像编码器为 f_θ ，文本编码器为 g_ϕ ，则第 i 张图片和第 j 段文本首先得到 $v_i = f_\theta(I_i)$ 与 $u_j = g_\phi(T_j)$ 。为了让内积主要反映方向上的语义相似程度，两个向量都进行 L_2 归一化：

$$x_i = \frac{v_i}{\|v_i\|_2}, \quad y_j = \frac{u_j}{\|u_j\|_2}.$$

归一化以后有 $\|x_i\|_2 = \|y_j\|_2 = 1$ ，因此 $x_i^\top y_j$ 就是两者的余弦相似度。

假设图像 I_1 是“一只狗在草地上奔跑”，文本分别为 $T_1 = \text{“a dog running on the grass”}$ 、 $T_2 = \text{“a car on the road”}$ 。图像和 T_1 的余弦相似度如果明显高于图像和 T_2 的余弦相似度，模型就已经在向正确的图文语义对齐方向学习。

一、从 CLIP 的 Softmax 到 SigLIP 的 Pairwise Sigmoid

CLIP 的训练可以理解成“在一组候选文本中找正确文本”。以图像到文本为例，第 i 张图片对应的相似度为 $s_{i1}, s_{i2}, \dots, s_{iN}$ ，Softmax 会把这一整行同时放进分母：

$$P(T_j | I_i) = \frac{\exp(s_{ij}/\tau)}{\sum_{k=1}^N \exp(s_{ik}/\tau)}.$$

因此第 (i, j) 个位置的概率会受到这一行其他所有相似度的影响。文本到图像方向同样需要沿列再做一次 Softmax。随着 batch 变大，训练过程需要处理更大的全局相似度集合；在多设备环境中，还需要让不同设备上的表示参与同一个归一化过程。

SigLIP 把这个问题改写成图文对的二元判断。对于任意一对 (I_i, T_j) ，只判断“这两个输入是否属于正确配对”。因此定义标签

$$z_{ij} = \begin{cases} +1, & i = j, \\ -1, & i \neq j. \end{cases}$$

对角线位置 (I_i, T_i) 是正样本，非对角线位置 $(I_i, T_j), j \neq i$ 是负样本。每一个 pair 都有自己的匹配分数和自己的 Sigmoid Loss。

假设 batch size 为 N ，那么总共有 N^2 个图文组合。其中正样本只有 N 个，负样本有 $N^2 - N = N(N - 1)$ 个。比如 $N = 4$ 时，一共得到 16 个 pair，其中 4 个是正样本，12 个是负样本。SigLIP 的训练就是让正样本分数增大，同时让大量负样本分数减小。

假设 batch 中有三对数据：

图片 I_1 ：猫，文本 T_1 ：a photo of a cat；

图片 I_2 ：狗，文本 T_2 ：a photo of a dog；

图片 I_3 ：汽车，文本 T_3 ：a photo of a car。

那么 (I_1, T_1) 、 (I_2, T_2) 、 (I_3, T_3) 的标签为 +1； (I_1, T_2) 、 (I_1, T_3) 、 (I_2, T_1) 等位置的标签都为 -1。

二、SigLIP 的 Logit

只有余弦相似度还不够。归一化后的内积 $x_i^\top y_j$ 落在 $[-1, 1]$ ，如果直接送进 Sigmoid，输出范围会比较集中，模型很难把“明显匹配”和“明显不匹配”拉得足够开。因此 SigLIP 引入一个可学习的正尺度 t ，用来放大相似度：

$$t = \exp(t'),$$

其中 t' 是真正参与优化的参数。使用指数参数化可以保证训练过程中始终有 $t > 0$ 。

同时，SigLIP 在每一个 pair 的 logit 中加入可学习偏置 b 。于是第 (i, j) 个 pair 的最终 logit 为

$$\ell_{ij} = t x_i^\top y_j + b.$$

这个式子可以直接拆成三个部分理解： $x_i^\top y_j$ 表示图文语义相似度； t 控制相似度差异被放大的程度； b 控制整体判定阈值。

偏置 b 与 SigLIP 中严重的正负样本数量差异有关。一个 batch 中负样本远多于正样本，训练初期模型还没有学会区分图文语义，此时所有相似度都接近一个较窄的范围。论文使用较大的负偏置初始化，使初始预测更符合“随机抽取的图文组合大多数属于负样本”这一先验。官方实现使用 $t' = \log 10$ 、 $b = -10$ 作为初始化，因此初始尺度为 $t = 10$ 。

例如某个 pair 的余弦相似度为 0.4，若当前 $t = 10$ 、 $b = -3$ ，则 logit 为 $\ell = 10 \times 0.4 - 3 = 1$ ；若另一个 pair 的相似度只有 0.05，则 $\ell = 10 \times 0.05 - 3 = -2.5$ 。同一个相似度经过尺度和偏置后，会被转换成更适合二元判别的数值范围。

三、Pairwise Sigmoid Loss

Sigmoid 函数定义为

$$\sigma(a) = \frac{1}{1 + \exp(-a)}.$$

对于正样本 $z_{ij} = +1$ ，希望 ℓ_{ij} 较大，这样 $\sigma(\ell_{ij})$ 接近 1；对于负样本 $z_{ij} = -1$ ，希望 ℓ_{ij} 较小，这样 $\sigma(\ell_{ij})$ 接近 0。

为了把正样本和负样本写成同一个公式，可以直接计算

$$\sigma(z_{ij}\ell_{ij}).$$

如果是正样本， $z_{ij} = +1$ ，这一项就是 $\sigma(\ell_{ij})$ ；如果是负样本， $z_{ij} = -1$ ，这一项变成 $\sigma(-\ell_{ij}) = 1 - \sigma(\ell_{ij})$ 。这样，一个公式同时表示“正样本预测为匹配”和“负样本预测为不匹配”的概率。

单个 pair 的损失写为

$$\mathcal{L}_{ij} = -\log \sigma(z_{ij}\ell_{ij}) = -\log \sigma(z_{ij}(t x_i^\top y_j + b)).$$

使用 $\log \sigma(a) = -\log(1 + \exp(-a))$ ，同一个损失也可以写成

$$\mathcal{L}_{ij} = \log(1 + \exp[-z_{ij}(t x_i^\top y_j + b)]).$$

整个 batch 的 SigLIP Loss 按照论文和官方实现的形式为

$$\mathcal{L}_{\text{SigLIP}} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^N \log \sigma(z_{ij}(t x_i^\top y_j + b)).$$

这里的归一化因子是 $1/N$ 。官方实现会对每一行中的所有 pair loss 求和，再对 N 个图像取平均。因此它和直接对 N^2 个矩阵元素做普通 mean 的数值尺度不同。

这个损失最重要的地方，是每一个 $\mathcal{L}_{ij}$ 都可以单独计算。计算 (I_i, T_j) 的损失只需要知道当前图像向量、当前文本向量、标签 z_{ij} 、尺度 t 和偏置 b 。它不需要知道同一行所有其他 pair 的 Softmax 分母。

四、为什么 Sigmoid Loss 会拉近正样本、推远负样本

可以直接看单个 pair 对 logit 的梯度。记 $a_{ij} = z_{ij}\ell_{ij}$ ，则

$$\mathcal{L}_{ij} = -\log \sigma(a_{ij}).$$

因为 $\frac{d}{da}[-\log \sigma(a)] = \sigma(a) - 1$ ，再乘上 $\frac{\partial a_{ij}}{\partial \ell_{ij}} = z_{ij}$ ，得到

$$\frac{\partial \mathcal{L}_{ij}}{\partial \ell_{ij}} = z_{ij} [\sigma(z_{ij} \ell_{ij}) - 1].$$

先看正样本。此时 $z_{ij} = +1$ ，所以

$$\frac{\partial \mathcal{L}_{ij}}{\partial \ell_{ij}} = \sigma(\ell_{ij}) - 1 < 0.$$

梯度下降会提高 ℓ_{ij} ，于是正样本的 logit 变大。因为 $\ell_{ij} = t x_i^\top y_j + b$ ，在 $t > 0$ 时，这会推动正确图文对的相似度 $x_i^\top y_j$ 增大。

再看负样本。此时 $z_{ij} = -1$ ，有

$$\frac{\partial \mathcal{L}_{ij}}{\partial \ell_{ij}} = 1 - \sigma(-\ell_{ij}) = \sigma(\ell_{ij}) > 0.$$

梯度下降会降低 ℓ_{ij} ，从而推动错误图文对的相似度减小。

因此，SigLIP 和 CLIP 都会形成“正确图文靠近、错误图文远离”的训练结果。二者的差异集中在损失如何组织这些 pair：CLIP 使用整行或整列的 Softmax 竞争关系，SigLIP 对每一个 pair 直接进行二元判别。

假设一个正样本 pair 当前 logit 为 $\ell = 0$ ，则 $\sigma(0) = 0.5$ ，其梯度为 $0.5 - 1 = -0.5$ ，梯度下降会提高这个 logit。

如果一个负样本 pair 当前 logit 同样为 $\ell = 0$ ，其梯度为 $\sigma(0) = 0.5$ ，梯度下降会降低这个 logit。

当正样本已经有很大的正 logit，或者负样本已经有很大的负 logit 时，对应 Sigmoid 会逐渐接近正确端点，梯度也会自然减小。

五、SigLIP 与 CLIP Loss 的区别

CLIP 与 SigLIP 都使用图像编码器和文本编码器，也都会计算 batch 内的图文相似度。最核心的区别可以从“一个训练样本在损失中依赖多少其他样本”来理解。

CLIP 的图像到文本损失中，第 i 张图片的正确文本概率为

$$P(T_i | I_i) = \frac{\exp(s_{ii}/\tau)}{\sum_{j=1}^N \exp(s_{ij}/\tau)}.$$

因此 s_{ii} 的概率由这一整行所有 N 个相似度共同决定。文本到图像方向还会沿列再计算一次。

SigLIP 对每个位置使用

$$P_{ij} = \sigma(t x_i^\top y_j + b),$$

然后根据 z_{ij} 判断该 pair 应该趋近于匹配还是不匹配。第 (i, j) 个位置的二元损失可以独立求出，不需要构造跨所有候选项的 Softmax 归一化项。

	CLIP	SigLIP
基本问题	在候选集合中选出正确配对	判断每一个 pair 是否匹配
概率函数	Softmax	Sigmoid
损失单位	一整行或一整列	单个图文 pair
归一化依赖	依赖同一集合中的其他样本	每个 pair 独立计算
正负关系	多候选竞争	二元正负判别
额外标量	温度参数	可学习尺度 t 与偏置 b

这种 pairwise 形式对分布式训练很重要。假设数据分布在多块设备上，Softmax 对比损失需要得到足够完整的候选集合来形成归一化分母；SigLIP 可以把跨设备的负样本分块处理，因为不同 pair 的损失可以独立累加。原论文据此设计了更节省内存的分块实现，并把 batch size 推到非常大的规模进行实验。

论文的实验还说明，大 batch 并不会无限带来收益。作者测试了最高约一百万的 batch size，收益随着 batch 继续增大很快趋于饱和；论文给出的结论是，大约 32k 的 batch 已经处于很有竞争力的范围。这说明 SigLIP 的价值并不只是追求极端大 batch，它还解除 Softmax 全局归一化对训练组织方式的限制。

六、偏置 b 为什么重要

SigLIP 一个 batch 中有 N 个正样本和 $N(N-1)$ 个负样本。随着 N 增大，负样本数量会远高于正样本。比如 $N = 1024$ 时，正样本有 1024 个，而负样本超过一百万个。

如果训练刚开始时所有 pair 的 logit 都接近 0，则 $\sigma(0) = 0.5$ 。这相当于模型给每一个图文组合都分配大约一半的匹配概率，与“绝大多数随机组合属于负样本”的真实比例差距很大。一个明显的负偏置会整体降低初始 logit，使模型在训练开始时对大多数 pair 给出较低匹配概率。

偏置仍然是可学习参数，所以训练过程中它会随着特征分布变化自动调整。尺度 t 也会一起学习，用来控制相似度的分离程度。两者配合后，模型可以逐渐形成适合当前数据分布的匹配边界。

从二分类角度看， $\ell_{ij} = t x_i^\top y_j + b$ 就像一个只有一个特征的线性分类器，其中 $x_i^\top y_j$ 是输入特征， t 是权重， b 是偏置。图像编码器和文本编码器负责把原始图像、文本变成越来越适合这个二元判别任务的表示。

七、Zero-shot 分类

SigLIP 训练完成以后，同样可以像 CLIP 一样做 zero-shot 图像分类。假设任务有 cat、dog、car 三个类别，可以把类别写成自然语言：

$$T_1 = \text{“a photo of a cat”}, \quad T_2 = \text{“a photo of a dog”}, \quad T_3 = \text{“a photo of a car”}.$$

先用文本编码器得到 y_1, y_2, y_3 ，再对输入图像得到 x 。每个类别对应的 logit 为

$$\ell_j = t x^\top y_j + b.$$

对应匹配分数可以写成 $p_j = \sigma(\ell_j)$ 。最后比较候选文本的分数，分数最大的类别就是模型的预测结果。

由于所有候选类别共享同一个 t 和 b ，在同一张图片内部做类别排序时，比较 ℓ_j 与比较余弦相似度 $x^\top y_j$ 的顺序是一致的。因此 SigLIP 依然保留了 CLIP 通过自然语言类别描述完成 zero-shot transfer 的基本能力。

八、SigLIP 的计算过程

把前面的过程连起来，SigLIP 一次训练迭代可以按下面的顺序理解。

给定一个 batch 的 N 对图文数据，图像编码器得到 $v_i = f_\theta(I_i)$ ，文本编码器得到 $u_i = g_\phi(T_i)$ 。对两类向量做 L_2 归一化以后得到 x_i 与 y_i 。任意图像 x_i 和任意文本 y_j 都形成一个 pair，并计算余弦相似度 $x_i^\top y_j$ 。随后加入可学习尺度和偏置，得到 $\ell_{ij} = t x_i^\top y_j + b$ 。

标签矩阵的对角线为 +1，其余位置为 -1，即 $z_{ii} = +1, z_{ij} = -1 (i \neq j)$ 。每个位置使用 $-\log \sigma(z_{ij} \ell_{ij})$ 计算自己的损失，最后把全部 pair 的损失求和并除以 batch size N 。反向传播会更新图像编码器参数 θ 、文本编码器参数 ϕ 、尺度参数 t' 和偏置 b 。

真正改变图像和文本表示的是编码器参数。因为 x_i 和 y_j 都来自深度网络，所以相似度损失通过链式法则不断向两个编码器内部传播。正样本产生的梯度让对应图文表示靠近，负样本产生的梯度让错误配对远离，最终得到共享的视觉-语言语义空间。

九、公式总结

综上，SigLIP 可以压缩成下面几步。

1. 图像和文本编码：

$$v_i = f_\theta(I_i), \quad u_j = g_\phi(T_j).$$

2. L_2 归一化：

$$x_i = \frac{v_i}{\|v_i\|_2}, \quad y_j = \frac{u_j}{\|u_j\|_2}.$$

3. 图文 pair 的 logit:

$$t = \exp(t'), \quad \ell_{ij} = t x_i^\top y_j + b.$$

4. 正负标签:

$$z_{ij} = \begin{cases} +1, & i = j, \\ -1, & i \neq j. \end{cases}$$

5. 单个 pair 的 Sigmoid Loss:

$$\mathcal{L}_{ij} = -\log \sigma(z_{ij} \ell_{ij}).$$

6. 整个 batch 的训练目标:

$$\mathcal{L}_{\text{SigLIP}} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^N \log \sigma(z_{ij} (t x_i^\top y_j + b)).$$

CLIP 与 SigLIP 学习的目标都可以概括成“正确图文语义靠近，错误图文语义远离”。SigLIP 用独立的 pairwise Sigmoid 二分类完成这个目标，使每一个图文 pair 都能单独贡献损失，并引入可学习尺度和偏置控制匹配边界。这一变化保留了双编码器结构与 zero-shot 能力，同时给大规模分布式图文预训练提供了更加灵活的损失组织方式。

主要资料:

Zhai, X., Mustafa, B., Kolesnikov, A., & Beyer, L. *Sigmoid Loss for Language Image Pre-Training*. 2023.

论文: <https://arxiv.org/abs/2303.15343>

官方代码: https://github.com/google-research/big_vision