

DINO: 无标签自蒸馏的数学原理

引言

1. DINO 的训练数据只有图像，没有人工类别标签。
2. 每张图像经过随机增强生成多个视图，学生网络需要预测教师网络对其他视图给出的概率分布。
3. 学生网络通过梯度下降更新，教师网络不进行反向传播，而通过学生参数的指数移动平均更新： $\theta_t \leftarrow m\theta_t + (1-m)\theta_s$
4. 学生和教师输出的不是人工类别，而是一个高维概率分布：

$$P_s(x), P_t(x) \in \Delta^{K-1}$$

5. DINO 的基本损失是教师分布与学生分布之间的交叉熵：

$$H(P_t, P_s) = - \sum_{k=1}^K P_t^{(k)} \log P_s^{(k)}$$

6. 交叉熵对学生输出 logits 的梯度是：

$$\frac{\partial H}{\partial z_s^{(k)}} = \frac{P_s^{(k)} - P_t^{(k)}}{\tau_s}$$

7. DINO 使用两种关键机制避免表征坍塌：**centering**：对教师 logits 做中心化；**sharpening**：使用较低的教师温度，使教师分布具有较低熵。
8. 教师只处理全局视图，学生处理全局视图和局部视图，这称为 **multi-crop training**。
9. DINO 没有显式使用负样本，也不需要构造正负样本对之间的对比损失。
10. DINO 在 ViT 中产生了明显的局部语义结构和物体区域注意力，但这种性质是实验观察到的涌现性质，而不是由损失函数直接保证的定理。

(<https://arxiv.org/pdf/2104.14294v2>)

设没有标签的图像数据集为 $\mathcal{D} = \{x_1, x_2, \dots, x_N\}$

我们希望训练一个视觉编码器 $f_\theta: \mathcal{X} \rightarrow \mathbb{R}^d$

使得它满足两个基本要求。

1. 同一图像不同视图的一致性

从图像增强分布 $\mathcal{T}$ 中独立采样两个变换： $t_1, t_2 \sim \mathcal{T}$ ，得到 $v_1 = t_1(x), v_2 = t_2(x)$

理想情况下，应有 $f_\theta(v_1) \approx f_\theta(v_2)$ ，表示表征应尽量保留两个视图共有的语义信息，而不是依赖裁剪位置、颜色扰动、模糊等变化。

2. 不同图像不能全部映射到同一点

仅要求视图一致性是不够的，因为下列函数同样满足一致性 $f_\theta(x) = c, \forall x \in \mathcal{X}$ 其中 c 是固定向量。

此时任意两张图像都有 $f_\theta(x_i) = f_\theta(x_j) = c$

这称为**表征坍塌**。模型虽然取得了完全的视图一致性，却没有保留任何图像信息。

在没有标签和显式负样本的情况下，如何获得跨视图一致、同时又不坍塌的视觉表征？

DINO 可以使用卷积网络，但它与 Vision Transformer 的结合尤其重要。原始论文发现，自监督训练后的 ViT 特征具有明显的局部语义结构。

设输入图像为 $x \in \mathbb{R}^{H \times W \times C}$ （对 RGB 图像通常有 $C = 3$ ），将图像划分为大小为 $P \times P$ 的图像块，则图像块数量为 $N_p = \frac{HW}{P^2}$ 。第 i 个图像块展开后为 $x_p^{(i)} \in \mathbb{R}^{P^2 C}$

利用可学习矩阵 $E \in \mathbb{R}^{P^2 C \times d}$ 将图像块映射到 d 维： $e_i = x_p^{(i)} E \in \mathbb{R}^d$

在序列最前面加入可学习的分类标记 x_{cls} ，再加入位置编码 E_{pos} ：

$$Z_0 = [x_{\text{cls}}; e_1; e_2; \dots; e_{N_p}] + E_{\text{pos}}$$

因此 $Z_0 \in \mathbb{R}^{(N_p+1) \times d}$ ，经过若干 Transformer 层后得到 $Z_L = \text{Transformer}(Z_0)$

通常取最终的 [CLS] 标记作为图像级表征： $h = Z_L^{[\text{CLS}]} \in \mathbb{R}^d$

对于某一层的输入 $Z \in \mathbb{R}^{n \times d}$ ，定义 $Q = ZW_Q$ $K = ZW_K$ $V = ZW_V$

其中 $W_Q, W_K, W_V \in \mathbb{R}^{d \times d_k}$ ，注意力矩阵为 $A = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)$

输出为 $\text{Attention}(Q, K, V) = AV$ ， A_{ij} 表示第 i 个 token 对第 j 个 token 分配的注意力权重。

DINO 包含两个结构相同的网络，学生网络参数 θ_s ，教师网络参数 θ_t

可以把编码器和投影头统一写为 $F_\theta = g_\theta \circ f_\theta$

其中 f_θ 是 ViT 主干网络； g_θ 是投影头； $F_\theta(x)$ 输出 K 维 logits。

学生网络输出 $z_s(v) = F_{\theta_s}(v) \in \mathbb{R}^K$

教师网络输出 $z_t(v) = F_{\theta_t}(v) \in \mathbb{R}^K$

设学生输出为 $z_s(v) = (z_s^{(1)}(v), \dots, z_s^{(K)}(v))$

学生概率分布定义为 $P_s^{(k)}(v) = \frac{\exp(z_s^{(k)}(v)/\tau_s)}{\sum_{j=1}^K \exp(z_s^{(j)}(v)/\tau_s)}$

向量形式为 $P_s(v) = \text{softmax}\left(\frac{z_s(v)}{\tau_s}\right)$

教师输出需要先减去中心向量 $c \in \mathbb{R}^K$ ，然后除以教师温度 τ_t 得到：

$$P_t^{(k)}(v) = \frac{\exp((z_t^{(k)}(v) - c^{(k)})/\tau_t)}{\sum_{j=1}^K \exp((z_t^{(j)}(v) - c^{(j)})/\tau_t)}$$

即 $P_t(v) = \text{softmax}\left(\frac{z_t(v) - c}{\tau_t}\right)$ ，在计算损失时，教师输出需要停止梯度

$\text{stopgrad}(P_t(v))$ ，因此教师不会通过交叉熵损失直接进行反向传播。

对于一张图像 x ，DINO 通常生成两个全局视图；多个局部视图。

记两个全局视图为 $\mathcal{G}(x) = \{v_1^g, v_2^g\}$ ，记 M 个局部视图为 $\mathcal{L}(x) = \{v_1^\ell, v_2^\ell, \dots, v_M^\ell\}$

所有视图组成 $\mathcal{V}(x) = \mathcal{G}(x) \cup \mathcal{L}(x)$ ，因此 $|\mathcal{V}(x)| = M + 2$

教师网络只处理两个全局视图 v_1^g, v_2^g

学生网络处理全部视图 $v_1^g, v_2^g, v_1^\ell, \dots, v_M^\ell$

设教师视图为 v ，学生视图为 v' ，教师目标分布为 $q = P_t(v)$ ，学生预测分布为 $p = P_s(v')$ ，交叉熵为 $H(q, p) = - \sum_{k=1}^K q_k \log p_k$ ，DINO 通过最小化该损失，使学生对视图 v' 的预测接近教师对另一个视图 v 的预测。

对于每个教师全局视图，学生需要使用其余所有视图进行预测：

$$\mathcal{L}_{\text{DINO}}(x) = \frac{1}{2(|\mathcal{V}| - 1)} \sum_{v \in \mathcal{G}(x)} \sum_{v' \in \mathcal{V}(x), v' \neq v} H(P_t(v), P_s(v'))$$

因为教师有两个全局视图，每个教师视图可以与学生的 $|\mathcal{V}| - 1$ 个不同视图配对，所以总配对数量为 $2(|\mathcal{V}| - 1) = 2(M + 1)$ ，排除 $v' = v$ 的原因是避免教师和学生处理完全相同的增强视图。训练重点是跨视图预测，而不是相同输入的直接复制。

对于固定教师分布 q 和学生分布 p ： $H(q, p) = - \sum_{k=1}^K q_k \log p_k$

教师分布的熵为 $H(q) = - \sum_{k=1}^K q_k \log q_k$

KL 散度为 $D_{\text{KL}}(q|p) = \sum_{k=1}^K q_k \log \frac{q_k}{p_k}$

展开 $D_{\text{KL}}(q|p) = \sum_{k=1}^K q_k \log q_k - \sum_{k=1}^K q_k \log p_k$

所以 $D_{\text{KL}}(q|p) = -H(q) + H(q, p)$

即 $H(q, p) = H(q) + D_{\text{KL}}(q|p)$

在更新学生网络时，教师分布 q 被停止梯度，因此 $H(q)$ 对学生参数来说是常数。于是 $\arg \min_{\theta_s} H(q, p) = \arg \min_{\theta_s} D_{\text{KL}}(q|p)$ ，所以 DINO 的交叉熵训练也可以理解为最小化教师跨视图分布到学生分布的 KL 散度。

设学生 logits 为 $z = (z_1, \dots, z_K)$

学生概率为 $p_k = \frac{\exp(z_k / \tau_s)}{\sum_{j=1}^K \exp(z_j / \tau_s)}$

损失为 $\mathcal{L} = - \sum_{k=1}^K q_k \log p_k$

首先写出 $\log p_k = \frac{z_k}{\tau_s} - \log \left(\sum_{j=1}^K \exp(z_j/\tau_s) \right)$

代入损失 $\mathcal{L} = - \sum_{k=1}^K q_k \frac{z_k}{\tau_s} + \sum_{k=1}^K q_k \log \left(\sum_{j=1}^K \exp(z_j/\tau_s) \right)$ ，因为 $\sum_{k=1}^K q_k = 1$ ，所以

$$\mathcal{L} = - \frac{1}{\tau_s} \sum_{k=1}^K q_k z_k + \log \left(\sum_{j=1}^K \exp(z_j/\tau_s) \right)$$


对第 r 个 logit 求偏导 $\frac{\partial \mathcal{L}}{\partial z_r} = - \frac{q_r}{\tau_s} + \frac{1}{\sum_j \exp(z_j/\tau_s)} \frac{\exp(z_r/\tau_s)}{\tau_s}$

第二项就是 $\frac{p_r}{\tau_s}$ ，因此 $\frac{\partial \mathcal{L}}{\partial z_r} = \frac{p_r - q_r}{\tau_s}$ ，向量形式为 $\nabla_z \mathcal{L} = \frac{1}{\tau_s} (p - q)$

假设投影头最后一层为 $z = Wh + b$

那么对图像表征 h 的梯度为 $\nabla_h \mathcal{L} = \frac{1}{\tau_s} W^\top (p - q)$

因此，教师概率分布通过投影头反向影响学生 ViT 的 [CLS] 表征和全部前置参数。




DINOv2 延续了 DINO 的无监督视觉表征学习方向，但不是简单地扩大原始 DINO。它在更大规模、经过筛选的数据上训练更大的 ViT，并结合 DINO 图像级自蒸馏目标和 iBOT 的 masked patch-level 目标，同时加入大规模训练稳定化方法。

(<https://arxiv.org/pdf/2304.07193>)

可以用示意形式表示为 $\mathcal{L}_{\text{DINOv2}} = \mathcal{L}_{\text{image}} + \lambda_{\text{patch}} \mathcal{L}_{\text{patch}} + \lambda_{\text{reg}} \mathcal{L}_{\text{reg}}$

其中 $\mathcal{L}_{\text{image}}$ 是类似 DINO 的 [CLS] 图像级自蒸馏损失； $\mathcal{L}_{\text{patch}}$ 是 masked patch token 预测损失； $\mathcal{L}_{\text{reg}}$ 是用于改善特征分布和训练稳定性的正则项。原始 DINO 主要

强调图像级跨视图自蒸馏；DINOv2 更加强调通用图像级和像素级视觉特征。



$$\text{学生分布 } P_s(v) = \text{softmax}\left(\frac{z_s(v)}{\tau_s}\right)$$

$$\text{教师分布 } P_t(v) = \text{softmax}\left(\frac{z_t(v) - c}{\tau_t}\right)$$

$$\text{学生梯度 } \frac{\partial H(P_t, P_s)}{\partial z_s^{(k)}} = \frac{P_s^{(k)} - P_t^{(k)}}{\tau_s}$$

$$\text{教师动量更新 } \theta_t \leftarrow m\theta_t + (1 - m)\theta_s$$