

Diffusion Model: 扩散模型

本章节建议掌握:

训练阶段: $x_0 \sim q_{\text{data}}$

随机选择: t

采样: $\epsilon \sim \mathcal{N}(0, I)$

生成噪声图: $x_t = \sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \epsilon$

神经网络预测: $\hat{\epsilon} = \epsilon_{\theta}(x_t, t)$

计算: $L = |\epsilon - \hat{\epsilon}|^2$

初始化: $x_T \sim \mathcal{N}(0, I)$

循环: $x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \alpha_t}} \epsilon_{\theta}(x_t, t) \right) + \sigma_t z$

最终: $x_T \rightarrow x_{T-1} \rightarrow \dots \rightarrow x_0$ 得到生成图像。

训练阶段, 把真实图像逐渐破坏成高斯噪声; 生成阶段, 学习如何把高斯噪声逐渐还原成真实图像。

早期扩散模型由 Sohl-Dickstein 等人从非平衡热力学的角度提出; DDPM (Denoising Diffusion Probabilistic Model) 进一步将训练过程简化为噪声预测, 使扩散模型成为主流生成模型。(<https://arxiv.org/pdf/1503.03585>)

为了便于理解, 我们先只研究最经典的 DDPM。

假设数据集中有很多真实图像 $x_0 \sim q_{\text{data}}(x)$, x_0 为真实图像; 下标 0 表示图像还没有被加噪; q_{data} 为真实数据分布。

实际上图像会被展开成一个高维向量 $x_0 \in \mathbb{R}^{H \times W \times C}$, 比如一张 $512 \times 512 \times 3$ 的 RGB 图像, 本质上是 $x_0 \in \mathbb{R}^{786432}$ 维的向量。

生成模型希望学习真实图像的概率分布 $p_{\theta}(x_0)$, 其中 θ 表示神经网络参数。训练完成以后, 我们希望 $x_0 \sim p_{\theta}(x_0)$ 生成的新图像看起来与真实数据具有相似的分布。

问题是 $q_{\text{data}}(x)$ 极其复杂, 我们无法直接写出它的概率密度。扩散模型采用了一种间接方法, 即通过复杂图像逐渐加噪声达到高斯噪声然后利用高斯噪声反过来学习逐渐去噪, 最后得到真实图像。

扩散模型包含 Forward Diffusion + Reverse Diffusion

前向扩散过程 (Forward Diffusion Process): $x_0 \rightarrow x_1 \rightarrow x_2 \rightarrow \dots \rightarrow x_T$, 即不断向图像加入高斯噪声。最终 $x_T \approx \mathcal{N}(0, I)$ 变成标准高斯噪声。

反向扩散过程 (Reverse Diffusion Process): $x_T \rightarrow x_{T-1} \rightarrow \dots \rightarrow x_1 \rightarrow x_0$, 即神经网络逐步预测并去除噪声。最终生成图像。

前向过程是人为规定的, 不需要训练。反向过程是未知的, 需要神经网络学习。

设扩散过程共有 T 个时间步。例如 $T = 1000$, 每一步只加入少量高斯噪声。

定义 β_t 表示第 t 步加入的噪声强度。

通常 $0 < \beta_1 < \beta_2 < \dots < \beta_T < 1$ ，例如 $\beta_1 = 0.0001$ 逐渐增加到 $\beta_T = 0.02$

定义前向概率

$$q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t I)$$

这表示已知上一时刻 x_{t-1} ，当前状态 x_t 服从高斯分布。均值是 $\sqrt{1 - \beta_t} x_{t-1}$ ，方差是 $\beta_t I$ 。

根据高斯分布的重参数化，可以直接采样 $x_t = \sqrt{1 - \beta_t} x_{t-1} + \sqrt{\beta_t} \epsilon_t$ ，其中 $\epsilon_t \sim \mathcal{N}(0, I)$ 表示标准高斯噪声。

[可能会产生疑问：

为什么不是 $x_t = (1 - \beta_t) x_{t-1} + \beta_t \epsilon$ ？而是 $x_t = \sqrt{1 - \beta_t} x_{t-1} + \sqrt{\beta_t} \epsilon$ ？

原因是需要控制方差。

假设 $\text{Var}(x_{t-1}) = 1$ 并且 $\text{Var}(\epsilon) = 1$ ，由于两个变量相互独立，因此：

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y)$$

因此 $\text{Var}(x_t) = (\sqrt{1 - \beta_t})^2 \text{Var}(x_{t-1}) + (\sqrt{\beta_t})^2 \text{Var}(\epsilon)$ ，代入 $\text{Var}(x_{t-1}) = 1$ 得到 $\text{Var}(x_t) = 1 - \beta_t + \beta_t$ ，因此 $\text{Var}(x_t) = 1$ ，使用平方根可以使数据整体方差保持稳定。]

为了简化公式，定义 $\alpha_t = 1 - \beta_t$ ，于是 $q(x_t | x_{t-1}) = \mathcal{N}(\sqrt{\alpha_t} x_{t-1}, (1 - \alpha_t) I)$ ，采样公式变为 $x_t = \sqrt{\alpha_t} x_{t-1} + \sqrt{1 - \alpha_t} \epsilon_t$ ，其中 $\epsilon_t \sim \mathcal{N}(0, I)$

逐步加噪存在一个问题，按照前面的公式 $x_1 = \sqrt{\alpha_1} x_0 + \sqrt{1 - \alpha_1} \epsilon_1$

然后 $x_2 = \sqrt{\alpha_2} x_1 + \sqrt{1 - \alpha_2} \epsilon_2$

如果需要计算 x_{500} ，难道必须执行： $x_0 \rightarrow x_1 \rightarrow x_2 \rightarrow \dots \rightarrow x_{500}$ ？

这样训练会非常慢。DDPM 有一个非常重要的性质：可以从 x_0 一步直接计算任意时间的 x_t 。

下面推导这个公式。

定义累积乘积 $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ ，例如 $\bar{\alpha}_3 = \alpha_1 \alpha_2 \alpha_3$

注意 α_t 只表示第 t 步保留多少信息。而 $\bar{\alpha}_t$ 表示经过前 t 步以后，总共保留多少原始信息。

第一步，根据 $x_t = \sqrt{\alpha_t} x_{t-1} + \sqrt{1 - \alpha_t} \epsilon_t$ ，当 $t=1$ 有 $x_1 = \sqrt{\alpha_1} x_0 + \sqrt{1 - \alpha_1} \epsilon_1$ ，由于 $\bar{\alpha}_1 = \alpha_1$ ，因此 $x_1 = \sqrt{\bar{\alpha}_1} x_0 + \sqrt{1 - \bar{\alpha}_1} \epsilon$ ；

第二步，当 $t=2$ ，有 $x_2 = \sqrt{\alpha_2} x_1 + \sqrt{1 - \alpha_2} \epsilon_2$ ，将 $x_1 = \sqrt{\alpha_1} x_0 + \sqrt{1 - \alpha_1} \epsilon_1$ 代入 $x_2 = \sqrt{\alpha_2} (\sqrt{\alpha_1} x_0 + \sqrt{1 - \alpha_1} \epsilon_1) + \sqrt{1 - \alpha_2} \epsilon_2$

展开：

$$x_2 = \sqrt{\alpha_1 \alpha_2} x_0 + \sqrt{\alpha_2 (1 - \alpha_1)} \epsilon_1 + \sqrt{1 - \alpha_2} \epsilon_2$$


前面的原图系数 $\sqrt{\alpha_1 \alpha_2} = \sqrt{\bar{\alpha}_2}$ ，后面两个噪声都是高斯噪声，它们组合以后仍然是高斯噪声。组合噪声的方差为 $\alpha_2 (1 - \alpha_1) + 1 - \alpha_2$ ，展开 $\alpha_2 - \alpha_1 \alpha_2 + 1 - \alpha_2$ ，得

到 $1 - \alpha_1 \alpha_2$ ，因为 $\bar{\alpha}_2 = \alpha_1 \alpha_2$ ，所以 $1 - \alpha_1 \alpha_2 = 1 - \bar{\alpha}_2$

最终 $x_2 = \sqrt{\bar{\alpha}_2} x_0 + \sqrt{1 - \bar{\alpha}_2} \epsilon$ ，推广到任意时间 $x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon$ ，其中 $\epsilon \sim \mathcal{N}(0, I)$ ，因此：

$$q(x_t | x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t) I)$$

(<https://arxiv.org/pdf/2006.11239>)



公式 $x_t = \underbrace{\sqrt{\bar{\alpha}_t} x_0}_{\text{原图部分}} + \underbrace{\sqrt{1 - \bar{\alpha}_t} \epsilon}_{\text{噪声部分}}$ ，可以拆成两部分。第一部分 $\sqrt{\bar{\alpha}_t} x_0$ 表示保留的原图信息；第二部分 $\sqrt{1 - \bar{\alpha}_t} \epsilon$ 表示加入的噪声。

当 $t = 0$ ，有 $\bar{\alpha}_0 \approx 1$ ，因此 $x_t \approx x_0$ 图像几乎没有噪声；

当 t 逐渐增大， $\bar{\alpha}_t \rightarrow 0$ ，于是 $\sqrt{\bar{\alpha}_t} x_0 \rightarrow 0$ ，同时 $\sqrt{1 - \bar{\alpha}_t} \rightarrow 1$ ，因此 $x_T \approx \epsilon$ ，最终 $x_T \sim \mathcal{N}(0, I)$ ，图像变成标准高斯噪声。

前向过程 $x_{t-1} \rightarrow x_t$ ，已知 $q(x_t | x_{t-1})$ ，生成过程需要反过来 $x_t \rightarrow x_{t-1}$ ，也就是 $p_\theta(x_{t-1} | x_t)$

定义 $p_\theta(x_{t-1} | x_t) = \mathcal{N}(\mu_\theta(x_t, t), \sigma_t^2 I)$ ，其中 $\mu_\theta(x_t, t)$ 由神经网络预测。

整个生成模型为 $p_\theta(x_{0:T}) = p(x_T) \prod_{t=1}^T p_\theta(x_{t-1} | x_t)$

其中 $p(x_T) = \mathcal{N}(0, I)$

我们真正希望知道 $q(x_{t-1} | x_t, x_0)$

根据贝叶斯公式 $q(x_{t-1} | x_t, x_0) = \frac{q(x_t | x_{t-1}, x_0) q(x_{t-1} | x_0)}{q(x_t | x_0)}$

由于马尔可夫性质 $q(x_t | x_{t-1}, x_0) = q(x_t | x_{t-1})$

因此 $q(x_{t-1} | x_t, x_0) \propto q(x_t | x_{t-1}) q(x_{t-1} | x_0)$

前面已经知道 $q(x_t | x_{t-1}) = \mathcal{N}(\sqrt{\alpha_t} x_{t-1}, \beta_t I)$

以及 $q(x_{t-1} | x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_{t-1}} x_0, (1 - \bar{\alpha}_{t-1}) I)$

两个高斯分布相乘仍然是高斯分布。

最终得到 $q(x_{t-1} | x_t, x_0) = \mathcal{N}(\tilde{\mu}_t, \tilde{\beta}_t I)$ ，其中 $\tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t$

均值为 $\tilde{\mu}_t = \frac{\sqrt{\bar{\alpha}_{t-1}} \beta_t}{1 - \bar{\alpha}_t} x_0 + \frac{\sqrt{\alpha_t} (1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} x_t$

观察可以发现，真实后验均值需要同时知道 x_t 和 x_0 ，但是生成图像时，我们只有

噪声 x_T ，并不知道真实图像 x_0 ，怎么办？让神经网络预测。

由 $x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon$ 可以解出 $\sqrt{\bar{\alpha}_t} x_0 = x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon$

$$\text{因此 } x_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon}{\sqrt{\bar{\alpha}_t}}$$

如果神经网络能够预测噪声 $\epsilon_\theta(x_t, t)$

那么就可以估计原图 $\hat{x}_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(x_t, t)}{\sqrt{\bar{\alpha}_t}}$ ，所以神经网络不一定需要直接

预测图像。只需要回答当前噪声图像 x_t 中包含什么噪声？

真实后验均值 $\tilde{\mu}_t = \frac{\sqrt{\bar{\alpha}_{t-1}} \beta_t}{1 - \bar{\alpha}_t} x_0 + \frac{\sqrt{\alpha_t} (1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} x_t$ ，将 $x_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon}{\sqrt{\bar{\alpha}_t}}$ 代入。

$$\text{经过化简可以得到 } \tilde{\mu}_t = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon \right)$$

真实噪声 ϵ 未知。

$$\text{使用神经网络 } \epsilon_\theta(x_t, t) \text{ 代替 } \mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right)$$

这就是 DDPM 反向采样的公式。

完整采样过程 $x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right) + \sigma_t z$ ，其中 $z \sim \mathcal{N}(0, I)$ ，第一部分 $\frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta \right)$ 负责去除预测噪声；第二部分 $\sigma_t z$ 重新加入适量随机性。

生成过程为 $x_T \rightarrow x_{T-1} \rightarrow x_{T-2} \rightarrow \dots \rightarrow x_0$

扩散模型希望最大化 $\log p_\theta(x_0)$ ，等价于最小化 $-\log p_\theta(x_0)$

但是 $p_\theta(x_0) = \int p_\theta(x_{0:T}) dx_{1:T}$ 存在大量隐变量 $x_1, x_2, \dots, x_T$ ，直接求积分非常困难，因此使用变分推断。

写成 $-\log p_\theta(x_0) = -\log \int p_\theta(x_{0:T}) dx_{1:T}$ ，乘除 $q(x_{1:T} | x_0)$ 得到：

$$-\log p_\theta(x_0) = -\log \int q(x_{1:T} | x_0) \frac{p_\theta(x_{0:T})}{q(x_{1:T} | x_0)} dx_{1:T}$$

使用 Jensen 不等式： $-\log \mathbb{E}[X] \leq \mathbb{E}[-\log X]$

得到 $-\log p_\theta(x_0) \leq \mathbb{E}_q \left[\log \frac{q(x_{1:T} | x_0)}{p_\theta(x_{0:T})} \right]$ ，右边称为 $\mathcal{L}_{\text{VLB}}$ ，即变分下界损失：

$$\mathcal{L}_{\text{VLB}} = \mathbb{E}_q \left[\log \frac{q(x_{1:T} | x_0)}{p_\theta(x_{0:T})} \right]$$

经过概率分解以后：

$$\mathcal{L}_{\text{VLB}} = D_{\text{KL}}(q(x_T | x_0) | p(x_T)) + \sum_{t=2}^T D_{\text{KL}}(q(x_{t-1} | x_t, x_0) | p_{\theta}(x_{t-1} | x_t)) - \mathbb{E}_q[\log p_{\theta}(x_0 | x_1)]$$

$$\text{可以写成 } \mathcal{L} = L_T + \sum_{t=2}^T L_{t-1} + L_0$$

其中 $L_T = D_{\text{KL}}(q(x_T | x_0) | p(x_T))$ 负责保证最终噪声接近 $\mathcal{N}(0, I)$

中间部分 $L_{t-1} = D_{\text{KL}}(q(x_{t-1} | x_t, x_0) | p_{\theta}(x_{t-1} | x_t))$ 负责让神经网络学习真实反向过程。

最后 $L_0 = -\mathbb{E}_q[\log p_{\theta}(x_0 | x_1)]$ 负责从 x_1 恢复 x_0 ，DDPM 使用这一变分目标，并进一步将主要训练部分简化成噪声预测误差。

真实后验为 $q(x_{t-1} | x_t, x_0) = \mathcal{N}(\tilde{\mu}_t, \tilde{\beta}_t I)$ ，模型预测 $p_{\theta}(x_{t-1} | x_t) = \mathcal{N}(\mu_{\theta}, \sigma_t^2 I)$

两个高斯分布的 KL 散度，在方差固定时可以写成 $D_{\text{KL}} = \frac{1}{2\sigma_t^2} |\tilde{\mu}_t - \mu_{\theta}|^2 + C$

其中 C 与神经网络参数无关。

因此优化均值即可 $\min_{\theta} |\tilde{\mu}_t - \mu_{\theta}|^2$

$$\text{真实均值: } \tilde{\mu}_t = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon \right); \text{ 预测均值: } \mu_{\theta} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_{\theta} \right)$$

$$\text{两者相减 } \tilde{\mu}_t - \mu_{\theta} = \frac{\beta_t}{\sqrt{\alpha_t(1 - \bar{\alpha}_t)}} (\epsilon_{\theta} - \epsilon)$$

$$\text{平方 } |\tilde{\mu}_t - \mu_{\theta}|^2 = \frac{\beta_t^2}{\alpha_t(1 - \bar{\alpha}_t)} |\epsilon - \epsilon_{\theta}|^2, \text{ 最终 } L_t = w_t |\epsilon - \epsilon_{\theta}(x_t, t)|^2$$

其中 $w_t = \frac{\beta_t^2}{2\sigma_t^2 \alpha_t(1 - \bar{\alpha}_t)}$ ，DDPM 发现，可以去掉复杂权重，直接使用：

$$\mathcal{L}_{\text{simple}} = \mathbb{E}_{x_0, t, \epsilon} \left[\left| \epsilon - \epsilon_{\theta}(\sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t) \right|_2^2 \right]$$

这就是经典扩散模型最常见的训练损失。

看起来非常简单，即真实噪声-预测噪声做均方误差。

扩散模型还有另一种理解：

神经网络实际上是在学习概率分布的梯度。定义概率分布的 **Score**： $s(x) = \nabla_x \log p(x)$ ，注意，这里的 **Score** 不是分类分数。它表示 $\log p(x)$ 关于 x 的梯度。

可以理解为当前样本应该向哪个方向移动，才能进入概率更高的数据区域？

$$\text{对于 } q(x_t | x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t) I) \text{ 有 } \log q(x_t | x_0) = -\frac{|x_t - \sqrt{\bar{\alpha}_t} x_0|^2}{2(1 - \bar{\alpha}_t)} + C$$

$$\text{对 } x_t \text{ 求梯度 } \nabla_{x_t} \log q(x_t | x_0) = -\frac{x_t - \sqrt{\bar{\alpha}_t} x_0}{1 - \bar{\alpha}_t}, \text{ 根据 } x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon$$

$$\text{代入 } \nabla_{x_t} \log q(x_t | x_0) = -\frac{\sqrt{1 - \bar{\alpha}_t} \epsilon}{1 - \bar{\alpha}_t} = -\frac{\epsilon}{\sqrt{1 - \bar{\alpha}_t}}, \text{ 所以 } s(x_t, t) = -\frac{\epsilon}{\sqrt{1 - \bar{\alpha}_t}}$$

反过来 $\epsilon = -\sqrt{1 - \bar{\alpha}_t} s(x_t, t)$ ，因此预测噪声等价于预测 Score，它们只相差一个时间相关的缩放系数。Score-based Model 使用随机微分方程统一描述连续扩散过程，反向生成依赖每个时间的概率 Score。

当时间步 $T \rightarrow \infty$ ，每一步 $\beta_t \rightarrow 0$ ，离散扩散过程可以写成连续随机微分方程：

$$dx = f(x, t)dt + g(t)dW_t$$

其中 $f(x, t)$ 是漂移项； $g(t)$ 控制噪声强度； W_t 是布朗运动。

DDPM 对应的 Variance Preserving SDE 可以写成： $dx = -\frac{1}{2}\beta(t)xdt + \sqrt{\beta(t)}dW_t$

反向时间 SDE 为 $dx = [f(x, t) - g(t)^2 \nabla_x \log p_t(x)]dt + g(t)d\bar{W}_t$

其中 $\nabla_x \log p_t(x)$ 就是 Score。

神经网络 $s_\theta(x, t)$ 负责估计 $\nabla_x \log p_t(x)$ ，所以连续扩散模型的仍然是学习每个噪声时刻的数据分布梯度。

经典 DDPM 可能设置 $T = 1000$ ，生成一张图需要 1000 次神经网络前向传播。过程 $x_{1000} \rightarrow x_{999} \rightarrow x_{998} \rightarrow \dots \rightarrow x_0$ 不能一次直接完成，因此速度较慢。DDIM 提出了一种非马尔可夫采样过程，可以使用与 DDPM 相同的训练目标，但是通过跳过部分时间步加速生成。

$$\text{首先预测原图 } \hat{x}_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(x_t, t)}{\sqrt{\bar{\alpha}_t}}$$

$$\text{然后 } x_{t-1} = \sqrt{\bar{\alpha}_{t-1}} \hat{x}_0 + \sqrt{1 - \bar{\alpha}_{t-1} - \sigma_t^2} \epsilon_\theta + \sigma_t z$$

$$\text{前面的原图系数 } \sigma_t = \eta \sqrt{\frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t}} \sqrt{1 - \frac{\bar{\alpha}_t}{\bar{\alpha}_{t-1}}}$$

参数 η 控制随机性，当 $\eta = 1$ ，采样具有较强随机性；当 $\eta = 0$ ，得到确定性采样 $x_{t-1} = \sqrt{\bar{\alpha}_{t-1}} \hat{x}_0 + \sqrt{1 - \bar{\alpha}_{t-1}} \epsilon_\theta$

此时相同初始噪声会产生相同图像。

传统 DDPM 直接在像素空间扩散。

假设图像 $x_0 \in \mathbb{R}^{512 \times 512 \times 3}$ 维度很高。Stable Diffusion 先使用编码器 $z_0 = E(x_0)$ 将图像压缩到潜在空间。例如 $512 \times 512 \times 3$ 压缩为 $64 \times 64 \times 4$ ，然后在 z 空间执行扩散 $z_0 \rightarrow z_1 \rightarrow \dots \rightarrow z_T$ ，生成完成后 $\hat{x}_0 = D(\hat{z}_0)$ ，其中 E 是编码器； D 是解码器。因此 Pixel Diffusion: x_t 变成 Latent Diffusion: z_t 。

Latent Diffusion 通过在预训练自动编码器的潜在空间中执行扩散，降低了高分辨率生成的计算量，并使用 Cross-Attention 加入文本条件。

文本：A cat sitting on a chair.

首先经过文本编码器 $c = \text{TextEncoder}(\text{prompt})$ 得到文本特征 $c \in \mathbb{R}^{L \times d}$ ，图像特征 h 和文本特征通过 Cross-Attention 交互。

$$\text{定义 } Q = hW_Q; K = cW_K; V = cW_V$$

计算 $CrossAttention(Q, K, V) = \text{operatorname{Softmax}}\left(\frac{QK^\top}{\sqrt{d}}\right)V$;

其中图像特征提供 Q ，文本特征提供 K, V ，因此图像区域可以关注文本中的不同词。例如 `cat` 控制猫的区域；`chair` 控制椅子的区域。

文本扩散模型通常会同时预测无条件噪声 $\epsilon_{\text{uncond}} = \epsilon_\theta(x_t, t, \emptyset)$ 和条件噪声 $\epsilon_{\text{cond}} = \epsilon_\theta(x_t, t, c)$ ，然后组合 $\epsilon_{\text{CFG}} = \epsilon_{\text{uncond}} + w(\epsilon_{\text{cond}} - \epsilon_{\text{uncond}})$ ，其中 w 是 **Guidance Scale**。当 $w = 1$ 有 $\epsilon_{\text{CFG}} = \epsilon_{\text{cond}}$ 正常使用文本条件。

当 $w > 1$ ，放大 $\epsilon_{\text{cond}} - \epsilon_{\text{uncond}}$ 模型会更加遵循文本。

Classifier-Free Guidance 通过联合训练有条件和无条件预测，并组合两者来控制条件一致性与生成多样性之间的平衡。