

Diffusion Transformer

DiT (Diffusion Transformer) 是由 William Peebles 和 Saining Xie 提出的一种生成模型架构 (<https://arxiv.org/pdf/2212.09748>)。它用 **Transformer** 替换掉传统扩散模型中一直使用的 **U-Net** 网络。

在深入 Transformer 之前,我们要明确 DiT 需要拟合的数学目标。扩散模型分为加噪 (Forward) 和去噪 (Reverse) 两个过程。

1. 前向加噪过程 (Forward Process)

给定初始状态 x_0 (在 DiT 中,这通常是经过 VAE 压缩后的潜在特征 **latent**,而不是直接的像素),我们在 T 个时间步内不断加入高斯噪声:

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1-\beta_t}x_{t-1}, \beta_t\mathbf{I})$$

利用高斯分布的叠加性质,我们可以直接从 x_0 推导出任意时刻 t 的状态 x_t 。令

$$\alpha_t = 1 - \beta_t, \text{ 且 } \bar{\alpha}_t = \prod_{i=1}^t \alpha_i:$$

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon$$

其中 $\epsilon \sim \mathcal{N}(0, \mathbf{I})$ 是注入的真实噪声。

2. 逆向去噪过程 (Reverse Process)

生成图像的过程,就是从纯噪声 $x_T \sim \mathcal{N}(0, \mathbf{I})$ 开始,逐步预测并减去噪声。模型需要学习的,正是逆向转移概率:

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

在实际训练中,DiT 的任务是预测在当前时间步 t 下,输入 x_t 中包含的噪声 ϵ 。其最简化的均方误差损失函数 (MSE Loss) 为:

$$L_{simple} = \mathbb{E}_{x_0, \epsilon, t} [\|\epsilon - \epsilon_\theta(x_t, c, t)\|^2]$$

其中 c 是条件 (如类别标签或文本提示)。

U-Net 天生适合处理具有空间结构的 2D 图像,但 Transformer 只能处理 1D 的序列 (Sequence)。因此,DiT 借用了 ViT (Vision Transformer) 的数学切片操作。

假设时间步 t 下的潜在特征表示为张量 $x_t \in \mathbb{R}^{C \times H \times W}$ (通道数、高、宽)。

后续操作可以参考 ViT 的论文。

我们将图像彻底变成了一个包含 N 个 Token 的序列,准备送入 Transformer。

普通的 Transformer 只有自注意力机制,但扩散模型在每一步去噪时,必须知道当前的时间步和类别条件 c 。U-Net 通常通过交叉注意力 (Cross-Attention) 或简单的加法来注入,而 DiT 采用了一种更为优雅的数学设计:自适应层归一化 (Adaptive Layer Normalization, adaLN)。

在标准的 Transformer 块中,LayerNorm 的公式为:

$$\text{LN}(h) = \gamma \frac{h - \mu}{\sigma} + \beta$$

这里的 γ (缩放) 和 β (平移) 通常是模型全局学习到的静态参数。

DiT 将时间步 t 和条件 c 映射为一个条件向量 c_{emb} 。接着,用一个多层感知机 (MLP)

网络，根据 c_{emb} 动态计算出上述的 γ 和 β 。

不仅如此，DiT 提出了 **adaLN-Zero**。它不仅仅预测 γ 和 β ，还预测了一个维度缩放因子 α （用于残差连接）：

$$(\gamma_1, \beta_1, \alpha_1, \gamma_2, \beta_2, \alpha_2) = \text{MLP}(c_{emb})$$

整个 DiT 的 Transformer Block 的数学前向传播可以表示为：

1. 注入条件到注意力层：

$$h_1 = h_0 + \alpha_1 \odot \text{Attention}(\gamma_1 \odot \text{LN}(h_0) + \beta_1)$$

2. 注入条件到前馈网络：

$$h_2 = h_1 + \alpha_2 \odot \text{FFN}(\gamma_2 \odot \text{LN}(h_1) + \beta_2)$$


为什么叫 Zero？

在模型初始化时，DiT 会强制让上述 MLP 最后一层的权重和偏置全为 0。


这意味着初始状态下： $\gamma = 1, \beta = 0, \alpha = 0$

代入公式你会发现，残差项 $\alpha \odot (\dots)$ 全局为 0，整个 Transformer Block 退化成了恒等映射 $h_2 = h_0$ 。这种初始化使得极其庞大的网络在训练早期像一个空壳，极大地降低了训练初期的梯度波动，加速了收敛。

经过 L 层这样的 DiT Block 处理后，我们得到最终的序列 $Z_L \in \mathbb{R}^{N \times d}$



1. **最后一次调制：** 再次使用 adaLN 对其进行归一化。
2. **线性解码：** 将维度为 d 的特征映射回像素空间的维度 $p \times p \times 2C$
3. **Unpatchify：** 也就是把长序列重新折叠还原成空间形状 $\mathbb{R}^{2C \times H \times W}$



因为在许多高级扩散模型（如改进的 DDPM）中，模型不仅需要预测噪声 $\epsilon_\theta \in \mathbb{R}^{C \times H \times W}$ ，还需要同时预测去噪方差 $\Sigma_\theta \in \mathbb{R}^{C \times H \times W}$ 。模型将这两个预测结果在通道维度上拼接，从而完成了整个单步去噪的数学闭环。