


自举式语言-图像预训练模型 BLIP

BLIP 是 Salesforce Research 在 ICML2022 提出的视觉-语言预训练框架，目标是让一个模型同时具备理解图像和文字是否匹配、根据图像生成文字、根据图像回答问题、进行图文检索、迁移到视频-语言任务。(https://proceedings.mlr.press/v162/li22n.html)

BLIP 原论文强调，BLIP 通过“生成 caption+过滤噪声 caption”的方式利用网页图文数据，在图文检索、图像描述、VQA 等任务上取得了提升。

在 BLIP 之前，很多视觉-语言模型有两个问题。第一类模型擅长理解任务，例如判断“这张图和这句话是否匹配”，但是不擅长生成完整自然语言；第二类模型擅长生成任务，例如图像描述，但是不一定擅长图文检索或图文匹配。

BLIP 的 Salesforce 官方介绍也明确指出，之前很多模型缺少灵活性：编码器模型不容易直接迁移到文本生成任务，而编码器-解码器模型又不一定适合图文检索任务；此外，网页采集的图文对经常有噪声，比如图片是蛋糕，网页文字却可能只是店名或无关广告。



BLIP 的主要模型结构叫做 MED (Multimodal Mixture of Encoder-Decoder)，中文为多模态编码器-解码器混合结构。整体可以写成：

$$I \rightarrow \text{ImageEncoder}$$

$$T \rightarrow \text{TextEncoder/TextDecoder}$$

其中， I 为输入图像； T 为输入文本； ImageEncoder 通常是 Vision Transformer，简称 ViT； TextEncoder 类似 BERT； TextDecoder 用于生成 caption 或答案。


BLIP 的图像编码器使用 Vision Transformer 思路。图像先被切成 patch。

假设输入图像为： $I \in \mathbb{R}^{H \times W \times C}$ ，其中， H 为图像高度； W 为图像宽度； C 为通道数，例如 RGB 图像中 $C = 3$ 。

如果每个 patch 大小是 $P \times P$ ，那么 patch 数量为 $N = \frac{H}{P} \cdot \frac{W}{P}$ ，每个 patch 展平成向量为 $x_i \in \mathbb{R}^{P^2 C}$ ，然后通过线性变换变成 embedding： $e_i = x_i W_E + b_E$ ，其中 $W_E \in \mathbb{R}^{P^2 C \times d}$ ，所以 $e_i \in \mathbb{R}^d$ ，再加入位置编码 $z_i^{(0)} = e_i + p_i$ ，最后输入 Transformer：

$$Z_I = \text{ViT}(z_1^{(0)}, z_2^{(0)}, \dots, z_N^{(0)})$$

BLIP 还会加入一个特殊的 [CLS] token，用来表示整张图像的全局语义。



BLIP 同时训练三个目标 $\mathcal{L} = \mathcal{L}_{ITC} + \mathcal{L}_{ITM} + \mathcal{L}_{LM}$

分别是图文对比学习损失 $\mathcal{L}_{ITC}$ ；图文匹配损失 $\mathcal{L}_{ITM}$ ； $\mathcal{L}_{LM}$ 语言建模损失。

损失	中文含义	对应能力
$\mathcal{L}_{ITC}$	Image-Text Contrastive Loss, 图文对比损失	图文检索
$\mathcal{L}_{ITM}$	Image-Text Matching Loss, 图文匹配损失	判断图片和文字是否匹配
$\mathcal{L}_{LM}$	Language Modeling Loss, 语言建模损失	看图生成文字

ITC 的思想和 CLIP 很接近。假设一个 batch 里有 B 对图文数据：

$$\{(I_1, T_1), (I_2, T_2), \dots, (I_B, T_B)\}$$

其中 I_i 是第 i 张图片； T_i 是第 i 张图片对应的文本。

图像经过图像编码器得到向量 $v_i = f_I(I_i)$

文本经过文本编码器得到向量 $t_i = f_T(T_i)$

为了计算相似度，通常会先做归一化 $\hat{v}_i = \frac{v_i}{\|v_i\|_2}$; $\hat{t}_i = \frac{t_i}{\|t_i\|_2}$ ，然后计算图像和文本的

余弦相似度 $s_{ij} = \frac{\hat{v}_i^\top \hat{t}_j}{\tau}$ ，其中 s_{ij} 代表第 i 张图和第 j 段文本的相似度； τ 温度参数，用来控制 Softmax 分布的尖锐程度。如果 $i = j$ ，说明图片和文字是正样本对；如果 $i \neq j$ ，说明图片和文字是不匹配的负样本对。

于是，对于图像 I_i ，它匹配正确文本 T_i 的概率为 $p_{i \rightarrow i} = \frac{\exp(s_{ii})}{\sum_{j=1}^B \exp(s_{ij})}$ ，对应的

image-to-text 损失是 $\mathcal{L}_{I2T} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(s_{ii})}{\sum_{j=1}^B \exp(s_{ij})}$ ，同理，对于文本 T_i ，它匹配正

确图像 I_i 的概率为 $p_{i \leftarrow i} = \frac{\exp(s_{ii})}{\sum_{j=1}^B \exp(s_{ji})}$ ，对应 text-to-image 损失是

$$\mathcal{L}_{T2I} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(s_{ii})}{\sum_{j=1}^B \exp(s_{ji})}, \text{ 最终 ITC 损失为 } \mathcal{L}_{ITC} = \frac{1}{2} (\mathcal{L}_{I2T} + \mathcal{L}_{T2I})$$

CLIP 的原始论文也使用“在一个 batch 中预测哪张图片和哪段文字匹配”的对比式训练思想；BLIP 保留了图文对齐能力，但进一步加入了图文匹配和语言生成目标。

ITC 只看全局向量相似度，速度快，但是粒度较粗。

例如图片是：

一只奶龙在草地上奔跑。

文本是：

一个 CST 在草地上奔跑。

这两句话和图片的整体语义很接近，但是“奶龙”和“CST”不同。ITC 可能觉得它们很相似。所以 BLIP 加入 ITM，即 Image – Text Matching

让文本 token 和图像 patch token 通过 cross-attention 深度交互。图像特征为 $Z_I = [z_1, z_2, \dots, z_N]$ ，文本特征为 $H_T = [h_1, h_2, \dots, h_M]$

在 cross-attention 中： $Q = H_T W_Q; K = Z_I W_K; V = Z_I W_V$

Query 来自文本，Key 和 Value 来自图像。cross-attention 为：

$$\text{CrossAttn}(H_T, Z_I) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$$

每个文本 token 都去图像 patch 里找和自己相关的视觉区域。比如文本 token 是“NaiLong”，它应该关注图像中的奶龙所在 patch。

最后得到图文融合表示 h_{multi} ，再送入二分类器 $p_{\text{match}} = \sigma(w^\top h_{\text{multi}} + b)$ ，其中 $\sigma(x) = \frac{1}{1 + \exp(-x)}$ ，如果图片和文字匹配，则标签为 $y = 1$ ；如果不匹配，则标签为 $y = 0$ 。ITM 损失是二元交叉熵 $\mathcal{L}_{ITM} = -[y \log p_{\text{match}} + (1 - y) \log(1 - p_{\text{match}})]$ 。

如果扩展到整个 batch： $\mathcal{L}_{ITM} = -\frac{1}{B} \sum_{i=1}^B [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$

BLIP 不仅要理解图片和文字，还要生成文字。

例如输入图片 I ，模型需要生成 $T = (w_1, w_2, \dots, w_M)$ ，例如 a dog running on the grass。

生成过程是自回归的 $P(T|I) = \prod_{m=1}^M P(w_m | w_1, w_2, \dots, w_{m-1}, I)$ ，也就是说，第 m 个词的生成依赖于前面已经生成的词和当前图片内容。语言建模损失是负对数似然：

$$\mathcal{L}_{LM} = -\sum_{m=1}^M \log P(w_m | w_{<m}, I)$$

其中 $w_{<m} = (w_1, w_2, \dots, w_{m-1})$ ，如果一个 batch 中有 B 个样本，则：

$$\mathcal{L}_{LM} = -\frac{1}{B} \sum_{i=1}^B \sum_{m=1}^{M_i} \log P(w_{i,m} | w_{i,<m}, I_i)$$

三个目标合起来: $\mathcal{L}_{BLIP} = \lambda_1 \mathcal{L}_{ITC} + \lambda_2 \mathcal{L}_{ITM} + \lambda_3 \mathcal{L}_{LM}$

BLIP 认为网页图文数据有很多噪声。比如某张图片是蛋糕,但是网页文字可能写的是店铺名称、促销信息、摄影师名字,而不是图片内容。BLIP 的解决方法是:先训练一个 captioner 给图片生成新的描述,再训练一个 filter 删除不匹配的原始 caption 或生成 caption。Salesforce 官方介绍中也将 CapFilt 描述为用 captioner 生成合成 caption,并用 filter 移除与图片不匹配的噪声 caption。


流程如下:

$$(I, T_{web}) \longrightarrow \text{Captioner} \longrightarrow T_{synthetic}$$

$$(I, T_{web}) \longrightarrow \text{Filter} \longrightarrow \text{keep or remove}$$

$$(I, T_{synthetic}) \longrightarrow \text{Filter} \longrightarrow \text{keep or remove}$$

最终得到更干净的数据集 $\mathcal{D}_{clean} = \{(I, T) \mid \text{Filter}(I, T) = 1\}$



[举例:

假设有一张图片: $I =$ 一只狗在草地上追飞盘

网页原始文字是: $T_{web} =$ Sunny day in Central Park

这句话可能来自网页标题,但它没有准确描述图片主体。BLIP 的 captioner 可能生成: $T_{syn} =$ A dog is running on the grass and catching a frisbee, 然后 filter 判断: $\text{Filter}(I, T_{web}) = 0; \text{Filter}(I, T_{syn}) = 1$, 于是原始 caption 被删除,合成 caption 被保留。

这样训练数据从 $(I, \text{Sunny day in Central Park})$ 变成:

$(I, \text{A dog is running on the grass and catching a frisbee})$

让模型学到更准确的图文对应关系。]

综上, BLIP 是一个统一的视觉-语言预训练框架。它把图像编码器、文本编码器、文本解码器结合起来,通过 ITC 学习图文全局对齐,通过 ITM 学习细粒度图文匹配,通过 LM 学习图像条件文本生成。同时, BLIP 使用 CapFilt 方法,让模型自己生成更好的 caption 并过滤网页噪声文本,从而提升训练数据质量。

用公式概括 $\text{BLIP} = \underbrace{\mathcal{L}_{ITC}}_{\text{图文对齐}} + \underbrace{\mathcal{L}_{ITM}}_{\text{图文匹配}} + \underbrace{\mathcal{L}_{LM}}_{\text{文本生成}} + \underbrace{\text{CapFilt}}_{\text{数据自举}}$