

CISPO：裁剪重要性采样权重策略优化

导论

CISPO 的一次训练过程可以概括为：

1. 旧策略对同一道题生成 G 条回答；
2. 验证器或奖励模型计算每条回答的奖励；
3. 根据组内奖励计算相对优势；
4. 计算每个词元的新旧策略概率比；
5. 对重要性采样权重进行裁剪；
6. 对裁剪后的权重执行 Stop-Gradient；
7. 使用全词元平均的策略梯度目标更新当前策略；
8. 配合 Dynamic Sampling 和 Length Penalty 继续下一轮 rollout。

CISPO 全称为 Clipped Importance Sampling-weight Policy Optimization, 由 MiniMax 团队在 MiniMax-M1 技术报告中提出。它主要处理 PPO、GRPO 一类方法中的 Token Clipping 问题。同一批 rollout 被重复用于多轮策略更新时，当前策略会逐渐偏离生成这批数据时的旧策略，一些词元的新旧策略概率比会迅速增大。PPO 式裁剪在这些词元越过边界后，会让对应方向的目标进入平坦区，随后该词元在这个方向上的策略梯度变为 0。

CISPO 将裁剪作用到 Importance Sampling Weight 上，并让梯度继续通过 $\log \pi_\theta$ 传播。这样可以继续利用概率变化较大的词元，同时限制单个词元由于重要性采样比过大而产生的梯度放大。MiniMax-M1 的实验继续采用 GRPO 的组内相对优势和 Token-Level Loss，并配合 Dynamic Sampling 与 Length Penalty。论文还明确说明，CISPO 的实验设置不使用 KL Penalty。

技术报告: MiniMax-M1: Scaling Test-Time Compute Efficiently with Lightning Attention (<https://arxiv.org/pdf/2506.13585>)

一、 CISPO 要解决什么问题

理解 CISPO 最方便的入口，是先看 PPO/GRPO 中的裁剪到底做了什么。强化学习阶段会先用旧策略 $\pi_{\theta_{\text{old}}}$ 生成回答，再用这些已经生成的回答更新当前策略 π_θ 。如果当前策略只更新一次，新旧策略通常还很接近；如果同一批 rollout 被连续用于多轮优化，新旧策略的差异会逐渐扩大。MiniMax-M1 的控制实验中，一个 generation batch 会进行多轮 off-policy 更新，因此这种差异非常明显。

设第 i 条回答中的第 t 个词元为 $o_{i,t}$ ，它前面的上下文为 $(q, o_{i,<t})$ 。新旧策略概

率比定义为

$$r_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})}.$$

$r_{i,t} = 1$ 表示当前策略和旧策略对该词元给出相同概率； $r_{i,t} > 1$ 表示当前策略提高了这个词元的概率； $r_{i,t} < 1$ 表示当前策略降低了这个词元的概率。比如旧概率为 0.10、新概率为 0.15 时， $r = 1.5$ ；旧概率为 0.10、新概率为 0.05 时， $r = 0.5$ 。

GRPO 使用 PPO 式裁剪目标。对一个词元，可以写为

$$L_{i,t}^{\text{GRPO}} = \min\left(r_{i,t}\hat{A}_{i,t}, \text{clip}(r_{i,t}, 1 - \epsilon_{\text{low}}, 1 + \epsilon_{\text{high}})\hat{A}_{i,t}\right).$$

其中 $\hat{A}_{i,t}$ 是优势。优势为正时，当前回答优于组内平均水平，模型希望提高相关词元的概率；优势为负时，当前回答低于组内平均水平，模型希望降低相关词元的概率。

先看正优势。若 $\hat{A}_{i,t} > 0$ 且 $r_{i,t}$ 仍在上界以内，目标随着 $r_{i,t}$ 增长；当 $r_{i,t} > 1 + \epsilon_{\text{high}}$ 后，目标固定为 $(1 + \epsilon_{\text{high}})\hat{A}_{i,t}$ 。这个结果已经不含 θ ，因此该方向上的梯度变成 0。负优势的情况对应下边界：若 $\hat{A}_{i,t} < 0$ 且 $r_{i,t} < 1 - \epsilon_{\text{low}}$ ，目标同样进入局部常数区域。

所以 GRPO 的梯度行为可以直接写成

$$\nabla_{\theta} L_{i,t}^{\text{GRPO}} = \begin{cases} 0, & \hat{A}_{i,t} > 0, r_{i,t} > 1 + \epsilon_{\text{high}}, \\ 0, & \hat{A}_{i,t} < 0, r_{i,t} < 1 - \epsilon_{\text{low}}, \\ r_{i,t}\hat{A}_{i,t}\nabla_{\theta} \log \pi_{\theta}(o_{i,t} \mid q, o_{i,<t}), & \text{其他情况.} \end{cases}$$

这个式子说明，PPO/GRPO 的裁剪同时承担两件事：一方面限制策略变化，另一方面会把特定越界词元从该方向的梯度计算中完全移除。CISPO 主要修改第二点，它希望继续保留这些词元的梯度，同时控制它们的权重大小。

二、为什么低概率词元更容易被裁剪

MiniMax-M1 的论文特别关注反思和推理调整词元，例如 However、Recheck、Wait、Aha。论文观察到，这类词元在基础模型中往往具有较低概率，但强化学习又可能快速提高它们的使用频率。概率比衡量的是相对变化，因此基础概率越低，同样大小的绝对概率变化越容易产生较大的 $r_{i,t}$ 。

为什么相同的概率增量会产生完全不同的概率比？

假设第一个词元的旧概率为 0.01，更新后变成 0.02，概率只增加 0.01，但重要性采样比已经达到 $r = 2$ 。第二个词元的旧概率为 0.40，同样增加 0.01 后变成 0.41，概率比只有 1.025。

两种情况的绝对变化完全相同，低概率词元的相对变化明显更大。如果上裁剪界为 1.2，第一个词元已经远远越过边界，第二个词元仍然处在正常更新区域。

这个现象在多轮 off-policy 更新中还会继续积累。第一次更新后，某个低概率反思词元可能从 0.01 提高到 0.015；继续使用同一批 rollout 更新时，它又可能提高到 0.02 或更高。旧策略概率仍然固定在 rollout 生成时的 0.01，因此 r 会持续增大。MiniMax-M1 报告，GRPO 会让这类词元在较早阶段进入裁剪区域，随后无法继续参与后续 off-policy 梯度更新。

DAPO 的 Clip-Higher 会提高上裁剪界，让正优势词元拥有更大的上升空间。这能推迟裁剪发生的时间。MiniMax-M1 的实验包含较多轮 off-policy 更新，论文发现只提高上界仍然不足以解决问题，因为当 $r_{i,t}$ 继续增大并超过新的上界后，词元仍然会进入零梯度区域。CISPO 因此改变了裁剪对象。

三、重要性采样权重从哪里来

CISPO 中最重要的量仍然是新旧策略概率比。它来自 Importance Sampling，用来处理“样本来自旧策略，优化目标却属于当前策略”这一情况。

假设希望计算当前策略 π_θ 下某个函数 $f(a)$ 的期望，直接形式是

$$\mathbb{E}_{a \sim \pi_\theta}[f(a)] = \sum_a \pi_\theta(a | s) f(a).$$

训练数据实际来自旧策略 $\pi_{\theta_{\text{old}}}$ 。在求和项中乘除旧策略概率，可以得到

$$\mathbb{E}_{a \sim \pi_\theta}[f(a)] = \mathbb{E}_{a \sim \pi_{\theta_{\text{old}}}} \left[\frac{\pi_\theta(a | s)}{\pi_{\theta_{\text{old}}}(a | s)} f(a) \right].$$

于是概率比

$$r(a, s) = \frac{\pi_\theta(a | s)}{\pi_{\theta_{\text{old}}}(a | s)}$$

就成为把旧策略样本修正到当前策略分布时需要的权重。

在语言模型中，状态 s_t 可以理解为问题和已经生成的前缀，动作 a_t 就是第 t 个生成词元。因此每一个词元都可以拥有自己的重要性采样比 $r_{i,t}$ 。这也是 GRPO、DAPO、CISPO 等方法都要计算词元级概率比的原因。

标准策略梯度的单步形式可以写成 $\hat{A}_t \nabla_\theta \log \pi_\theta(a_t | s_t)$ 。当数据来自旧策略时，

引入重要性采样以后，梯度变成

$$r_t \hat{A}_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t).$$

因此 r_t 的数值会直接放大或缩小当前词元的梯度。 $r_t = 2$ 时，这一部分梯度权重扩大为 2 倍； $r_t = 0.2$ 时，只保留约五分之一的权重。

四、 Stop-Gradient 为什么要放在 IS Weight 上

CISPO 的目标中出现了 Stop-Gradient，记为 $\text{sg}(\cdot)$ 。它的作用需要从求导过程看。

若使用

$$J_{\text{IS}}(\theta) = \mathbb{E} \left[\text{sg}(r_t) \hat{A}_t \log \pi_{\theta}(a_t | s_t) \right],$$

前向计算时 $\text{sg}(r_t)$ 的数值和 r_t 完全相同；反向传播时把它视为常数，即 $\nabla_{\theta} \text{sg}(r_t) = 0$ 。因此

$$\nabla_{\theta} J_{\text{IS}}(\theta) = \mathbb{E} \left[r_t \hat{A}_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right],$$

恰好得到重要性采样修正后的 policy gradient。

如果不使用 Stop-Gradient，直接优化 $r_t \hat{A}_t \log \pi_{\theta}$ ，根据乘法求导会出现两部分：

$$\nabla_{\theta} \left(r_t \hat{A}_t \log \pi_{\theta} \right) = \hat{A}_t [(\nabla_{\theta} r_t) \log \pi_{\theta} + r_t \nabla_{\theta} \log \pi_{\theta}].$$

由于 $\nabla_{\theta} r_t = r_t \nabla_{\theta} \log \pi_{\theta}$ ，第一项还会继续产生额外梯度。这样得到的结果已经偏离标准的 IS-weighted policy gradient。

所以 Stop-Gradient 让概率比只负责“给当前词元乘一个数值权重”，真正参与参数求导的是 $\log \pi_{\theta}$ 。CISPO 对 IS Weight 做裁剪以后，仍然保留这一结构。

五、 组内相对优势怎样得到

CISPO 继续使用 GRPO 的 group relative advantage。对于同一道问题 q ，旧策略一次生成 G 条回答 $o_1, \dots, o_G$ ，每条回答得到奖励 $R_1, \dots, R_G$ 。先计算组内平均奖励 $\mu_R = \frac{1}{G} \sum_{j=1}^G R_j$ ，再计算标准差

$$\sigma_R = \sqrt{\frac{1}{G} \sum_{j=1}^G (R_j - \mu_R)^2}.$$

第 i 条回答的相对优势为

$$\hat{A}_i = \frac{R_i - \mu_R}{\sigma_R + \epsilon_{\text{num}}}.$$

如果一条回答的奖励高于组内平均值，那么 $\hat{A}_i > 0$ ；如果奖励低于组内平均值，那么 $\hat{A}_i < 0$ 。标准差负责把不同问题组的奖励尺度归一化。对于只有 0/1 正确性奖

励的问题，一组回答中只要同时存在正确和错误样本，就可以形成正负不同的相对优势。

基本 CISPO 形式仍然使用回答级优势，所以同一条回答内通常有 $\hat{A}_{i,t} = \hat{A}_i$ 。这意味着一条回答中的不同词元可以拥有不同概率比和不同 IS Weight，但它们共享整条回答的相对好坏方向。后面会看到，这也是 CISPO 仍然存在信用分配限制的原因。

假设同一道题生成 4 条回答，奖励为 $[1, 1, 0, 0]$ 。组内平均奖励为 0.5，若采用总体标准差，则标准差也是 0.5，所以四条回答的优势分别为 $[1, 1, -1, -1]$ 。

两条正确回答中的词元整体获得正优势，更新方向倾向于提高对应生成概率；两条错误回答中的词元整体获得负优势，更新方向倾向于降低对应生成概率。词元之间具体更新多少，再由各自的概率比和裁剪后的 IS Weight 决定。

六、 CISPO 的完整目标函数

现在把组内优势、重要性采样和权重裁剪组合起来。对第 i 条回答的第 t 个词元，先计算

$$r_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})}.$$

然后把这个比值裁剪到规定范围：

$$\hat{r}_{i,t}(\theta) = \text{clip}(r_{i,t}(\theta), 1 - \epsilon_{\text{low}}^{\text{IS}}, 1 + \epsilon_{\text{high}}^{\text{IS}}).$$

CISPO 最终使用全词元平均，目标函数可以写成

$$\mathcal{J}_{\text{CISPO}}(\theta) = \mathbb{E} \left[\frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \text{sg}(\hat{r}_{i,t}(\theta)) \hat{A}_{i,t} \log \pi_{\theta}(o_{i,t} \mid q, o_{i,<t}) \right].$$

这个公式可以逐项理解。 $\log \pi_{\theta}$ 是真正承载策略梯度的部分； $\hat{A}_{i,t}$ 决定概率应该增加还是降低； $\hat{r}_{i,t}$ 根据新旧策略差异调整梯度大小； $\text{sg}(\cdot)$ 让裁剪权重只作为系数使用；分母 $\sum_i |o_i|$ 表示对整个组中的所有生成词元统一平均。

对目标函数求梯度后，单个词元的主要更新形式就是

$$g_{i,t}^{\text{CISPO}} = \hat{r}_{i,t} \hat{A}_{i,t} \nabla_{\theta} \log \pi_{\theta}(o_{i,t} \mid q, o_{i,<t}).$$

所以理解 CISPO 时只需要抓住两个量： $\hat{A}_{i,t}$ 决定方向， $\hat{r}_{i,t}$ 决定强度。

七、 为什么 CISPO 越过边界后仍有梯度

这是 CISPO 与 GRPO 最关键的数学区别。

先看一个正优势词元。假设 $\hat{A} > 0$ ，并且概率比已经超过上界 $u = 1 + \epsilon_{\text{high}}$ 。GRPO 在这个区域使用 $u\hat{A}$ ，它对 θ 是常数，因此梯度为 0。

CISPO 会把原始概率比裁成 $\hat{r} = u$ ，然后使用

$$L^{\text{CISPO}} = \text{sg}(u) \hat{A} \log \pi_{\theta}.$$

因为 u 只作为固定系数，求导得到

$$\nabla_{\theta} L^{\text{CISPO}} = u \hat{A} \nabla_{\theta} \log \pi_{\theta}.$$

只要优势不为 0，这个词元就仍然产生梯度。

负优势同样可以分析。若 $\hat{A} < 0$ 且原始概率比低于下界 $l = 1 - \epsilon_{\text{low}}^{\text{IS}}$ ，CISPO 只会把权重改成 l ，梯度仍然是 $l \hat{A} \nabla_{\theta} \log \pi_{\theta}$ 。MiniMax-M1 的实际实验没有启用有效的下界，主要调节上界，因此原论文重点控制的是过大的 IS Weight。

假设一个反思词元在旧策略中的概率为 0.01，当前策略已经把它提高到 0.03，所以 $r = 3$ 。设该词元优势为 1，示例上界取 $u = 1.2$ 。

GRPO 中，正优势词元已经超过上界，对应目标进入平坦区，梯度为 0。

CISPO 中，原始 $r = 3$ 被裁成 $\hat{r} = 1.2$ ，目标为 $1.2 \log \pi_{\theta}(o_t | s_t)$ ，因此梯度仍然是 $1.2 \nabla_{\theta} \log \pi_{\theta}(o_t | s_t)$ 。这个词元继续参与学习，单次更新强度受到上界限制。

这个差异解释了 CISPO 为什么能继续利用多轮 off-policy 更新中的越界词元。GRPO 的裁剪边界同时决定梯度是否存在；CISPO 的裁剪边界主要决定梯度权重最多有多大。

八、为什么裁剪 IS Weight 可以降低波动

重要性采样的一个常见问题是概率比可能很大。单个词元的梯度写成 $g_t = r_t \hat{A}_t \nabla_{\theta} \log \pi_{\theta}$ 。如果 $r_t = 10$ ，这个词元的梯度系数被放大到 10 倍；如果 $r_t = 30$ ，单个词元就可能对一个 minibatch 产生很强影响。

CISPO 使用 $\hat{r}_t = \text{clip}(r_t, l, u)$ 。若假设 $|\hat{A}_t| \leq A_{\max}$ ，并且 $\|\nabla_{\theta} \log \pi_{\theta}\| \leq G$ ，裁剪后的单词元梯度满足

$$\|\hat{g}_t\| \leq u A_{\max} G.$$

因此上界 u 给单个词元由 IS Weight 造成的梯度放大提供了明确限制。

从二阶矩也能看到相同结论。原始重要性采样梯度的方差会受到 r_t^2 影响，极端概率比会以平方形式进入二阶矩。裁剪后有 $\hat{r}_t^2 \leq u^2$ ，大权重对梯度波动的影响受到控制。MiniMax-M1 技术报告也明确指出，CISPO 在实验中有助于降低方差并稳定 RL 训练。

九、为什么权重裁剪会产生偏差

权重裁剪提高稳定性，同时会改变理想的重要性采样估计。标准 IS 满足

$$\mathbb{E}_{\pi_{\text{old}}}[r_t f_t] = \mathbb{E}_{\pi_{\theta}}[f_t].$$

CISPO 使用裁剪后的 $\hat{r}_t$ ，所以估计变成 $\mathbb{E}_{\pi_{\text{old}}}[\hat{r}_t f_t]$ 。两者的差可以写为

$$\text{Bias} = \mathbb{E}_{\pi_{\text{old}}}[(\hat{r}_t - r_t) f_t].$$

当所有样本都满足 $l \leq r_t \leq u$ 时， $\hat{r}_t = r_t$ ，这一部分额外偏差为 0。若出现 $r_t > u$ ，权重从 r_t 改成 u ；若启用下界并出现 $r_t < l$ ，权重从 r_t 改成 l 。这些被修改的区域会产生偏差。

因此 $\epsilon_{\text{high}}^{\text{IS}}$ 控制一个清楚的偏差与稳定性权衡。上界较小，极端权重被压得更明显，梯度波动较小，同时 IS 修正被改变得更多；上界较大，估计更接近原始 IS，但也允许更大的梯度权重。

MiniMax-M1 的实验没有设置有效的 IS Weight 下界。论文通过把 $\epsilon_{\text{low}}^{\text{IS}}$ 设为足够大的值，使下界约束基本失效，主要调节 $\epsilon_{\text{high}}^{\text{IS}}$ 。这说明原论文关注的主要问题是 大 IS Weight，而很小的 r_t 本身就会自然减小梯度贡献。

十、全词元平均为什么适合长 CoT

CISPO 使用 Token-Level Loss。它的归一化分母为 $\sum_i |o_i|$ ，也就是把当前问题组中的所有词元放到一起统一平均。

GRPO 常见写法会先对每条回答内部平均，再对回答平均：

$$\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} L_{i,t}.$$

这种写法让每条回答拥有相同总权重，因此回答越长，内部单个词元分到的基础权重越小。

例如只有两条回答，长度分别为 100 和 400。逐回答平均时，第一条回答每个词元的基础系数是 $1/200$ ，第二条回答每个词元是 $1/800$ ，短回答中的单个词元基础权重是长回答的 4 倍。全词元平均时，总长度为 500，两条回答中每个词元的基础系数都是 $1/500$ ，具体更新大小再由优势和 IS Weight 决定。

对于长 CoT，回答长度差异可能很大。全词元平均可以减少长回答中的单个推理词元由于回答更长而被额外稀释的问题。这个设计来自 DAPO 的 Token-Level Policy Gradient Loss，并被 CISPO 继续采用。

十一、统一 Mask 如何解释 PPO、GRPO 和 CISPO

MiniMax-M1 还给出一个统一形式，用 token-wise Mask 表示某个词元是否保留梯度。设 $M_{i,t} \in \{0, 1\}$ ，则可以写成

$$\mathcal{J}_{\text{unify}}(\theta) = \mathbb{E} \left[\frac{1}{\sum_i |o_i|} \sum_i \sum_t \text{sg}(\hat{r}_{i,t}) \hat{A}_{i,t} \log \pi_{\theta}(o_{i,t} \mid q, o_{i,<t}) M_{i,t} \right].$$

PPO/GRPO 对应的隐式 Mask 为

$$M_{i,t} = \begin{cases} 0, & \hat{A}_{i,t} > 0, r_{i,t} > 1 + \epsilon_{\text{high}}, \\ 0, & \hat{A}_{i,t} < 0, r_{i,t} < 1 - \epsilon_{\text{low}}, \\ 1, & \text{其他情况}. \end{cases}$$

也就是说，进入对应裁剪区域的词元等价于被 Mask 掉。

CISPO 的实验形式保持所有词元参与梯度，可以理解为 $M_{i,t} = 1$ ，再用 $\hat{r}_{i,t}$ 控制权重。这样“这个词元是否继续学习”和“这个词元用多大权重学习”被分成两个独立问题。原论文提出这一统一形式，就是为了说明不同 clipping 策略可以在同一个框架下理解和调节。

十二、CISPO 与 DAPO 的关系

DAPO 和 CISPO 都关注长推理强化学习中的 Token Clipping，但两者处理位置不同。

DAPO 的 Clip-Higher 会提高正优势方向的上裁剪界。例如原来允许的概率比上界较低时，低概率探索词元很容易越界；提高 ϵ_{high} 后，这些词元可以继续更新更长时间。它保留了 PPO 式 clipped objective，只是把上下裁剪范围解耦，并扩大正方向的空间。

CISPO 直接把裁剪移动到 IS Weight。原始概率比超过上界后， $\hat{r}$ 停止继续增加，但 $\log \pi_{\theta}$ 仍然产生梯度。因此 CISPO 对越界词元的处理更加持续。

可以把三种方法放在同一个词元梯度形式下比较。设

$$g_{i,t} = w_{i,t} \hat{A}_{i,t} \nabla_{\theta} \log \pi_{\theta}(o_{i,t} \mid q, o_{i,<t}),$$

那么 GRPO 在特定越界区域直接令 $w_{i,t} = 0$ ；DAPO 通过更宽的边界推迟 $w_{i,t} = 0$ 的发生；CISPO 使用裁剪后的 IS Weight，使 $w_{i,t}$ 保持为一个有界的非零值。

	GRPO	DAPO	CISPO
优势估计	组内相对优势	组内相对优势	组内相对优势
主要裁剪	PPO 式目标裁剪	非对称目标裁剪	IS Weight 裁剪
正优势越过上界	梯度变为 0	更晚进入零梯度区	梯度继续保留
负优势越过下界	梯度变为 0	受下界控制	梯度继续保留
损失归一化	常见逐回答平均	全词元平均	全词元平均
Dynamic Sampling	依实现而定	使用	使用
KL Penalty	依实现而定	原方案不依赖	MiniMax-M1 中不使用

十三、 Dynamic Sampling 与 CISPO 的配合

CISPO 负责解决词元裁剪和重要性采样权重问题，Dynamic Sampling 处理的是另一类无效训练数据。

GRPO 的组内优势依赖回答之间存在奖励差异。如果一道题生成 G 条回答，所有回答都正确，那么每条回答奖励都一样，组内归一化后优势接近 0；如果全部回答都错误，同样会得到接近 0 的优势。这样的组几乎不能提供有效的相对策略梯度。

Dynamic Sampling 会优先保留奖励存在差异的问题组，并继续采样直到有效组填满训练批次。这样可以提高一个 batch 中真正能够产生非零相对优势的数据比例。

CISPO 与 Dynamic Sampling 解决的是不同环节。Dynamic Sampling 保证“这个问题组有可学习的相对奖励信号”，CISPO 保证“已经拥有优势的词元在多轮更新中尽量继续提供梯度”。前者提高问题组层面的有效样本比例，后者提高词元层面的梯度利用率。

十四、 Length Penalty 与 KL Penalty

MiniMax-M1 技术报告说明，CISPO 训练还采用了 DAPO 中的 Length Penalty。长 CoT 训练中，模型可能通过不断延长回答获得更多推理步骤，但过长输出也可能包含重复、无效展开或截断风险。长度惩罚用于限制这种无效增长，使奖励不仅考虑任务结果，也对过长输出施加控制。

CISPO 的论文实验没有加入 KL Penalty。传统 RLHF 或部分 PPO 实现会使用参考模型 KL 项限制当前策略远离原模型，CISPO 在 MiniMax-M1 的设置中主要依靠 IS Weight Clipping、Dynamic Sampling、Length Penalty 以及整体训练配置维持稳定。

需要区分算法主体和配套训练策略。CISPO 这个名称主要对应“裁剪 Importance Sampling Weight，并保留所有词元梯度”的目标函数。Dynamic Sampling 和 Length Penalty 属于 MiniMax-M1 使用的配套 RL Recipe，它们和 CISPO 一起构成实际训练过程。

十五、完整数值例子

下面用一个小例子把优势、概率比、裁剪和梯度放在一起。

假设同一道题生成两条回答，奖励分别为 $R_1 = 1$ 和 $R_2 = 0$ 。组内平均奖励为 0.5，标准差为 0.5，因此两条回答的优势分别为 $\hat{A}_1 = 1$ 和 $\hat{A}_2 = -1$ 。

第一条正确回答包含三个词元。假设它们的新旧策略概率比分别为 3.0、1.1 和 0.8。为了便于演示，取 CISPO 上界 $u = 1.2$ 、下界 $l = 0.8$ ，那么裁剪后的 IS Weight 分别为 1.2、1.1 和 0.8。因为这条回答优势为 1，三个词元的梯度系数分别就是 1.2、1.1 和 0.8。

第一个词元原始概率比达到 3。GRPO 在正优势上裁剪区域会让它进入零梯度状态；CISPO 继续保留梯度，只把权重限制到 1.2。第二个词元位于正常区间，两种方法都会更新。第三个词元虽然 $r = 0.8$ ，但优势为正，它仍然需要提高概率，只是 CISPO 给它的梯度权重较小。

再看第二条错误回答中的一个词元。假设旧概率为 0.20，当前策略降到 0.10，那么 $r = 0.5$ ，同时 $\hat{A}_2 = -1$ 。如果演示性地下界取 0.8，CISPO 会使用权重 0.8，梯度系数为 -0.8 ，继续降低这个词元的概率。MiniMax-M1 原实验没有启用有效下界，所以实际设置中这个词元会以自身较小的 $r = 0.5$ 参与更新。

这个例子可以总结成一句话：优势决定更新方向，IS Weight 决定更新强度，CISPO 的裁剪只限制强度上限，越界词元仍然参与学习。

十六、多轮 off-policy 更新时发生什么

CISPO 的优势在多轮 off-policy 更新场景中更容易体现。设一批回答由旧策略 π_{θ_0} 生成。第一轮更新得到 π_{θ_1} ，第二轮得到 π_{θ_2} ，但概率比的分子仍然使用生成数据时的 π_{θ_0} 。随着更新继续进行，一部分词元的

$$r_{i,t}^{(k)} = \frac{\pi_{\theta_k}(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_0}(o_{i,t} \mid q, o_{i,<t})}$$

会逐渐远离 1。

如果一个正优势词元从 $r = 1.05$ 逐步增长到 1.15、1.30、1.80，GRPO 在超过上界后会让该词元停止提供对应方向的梯度。DAPO 提高上界以后，可以把这个时间点向后推。CISPO 则会在超过上界以后继续保留梯度，只把权重固定在上界。

因此，一批 rollout 被重复使用得越多，GRPO 的有效梯度词元数量可能越少。CISPO 试图让这些已经生成出来的 Token 在更多更新轮次中继续发挥作用，这也

是论文把它和训练效率联系起来的原因。

十七、 原论文中的实验结果

MiniMax 团队使用 Qwen2.5-32B-Base 做控制实验，在数学推理数据上分别采用 GRPO、DAPO 和 CISPO 进行 zero-RL 训练，并在 AIME 2024 上评测。技术报告显示，在相同训练步数下，CISPO 的表现高于 GRPO 和 DAPO；同时 CISPO 使用约 50% 的训练步数即可达到与 DAPO 接近的表现。

论文把这一结果解释为更高的梯度利用效率。GRPO 和 DAPO 在多层 off-policy 更新过程中会逐渐丢掉部分越界词元的梯度，CISPO 继续利用这些词元，同时限制 IS Weight 的最大值。因此同一批 rollout 可以提供更长时间的有效学习信号。

这项控制实验支持 CISPO 在论文配置中的训练效率优势，但它不意味着所有模型、数据、奖励函数和更新轮数下都一定得到相同收益。CISPO 的行为会受到 off-policy 程度、裁剪上界、回答长度、奖励分布和优化器设置等因素影响。

十八、 CISPO 的局限性

第一，IS Weight Clipping 会引入偏差。标准重要性采样希望使用完整的 r_t 修正新旧分布差异，CISPO 会把极端权重改成边界值，因此裁剪区域中的梯度估计和理想 IS 梯度存在差异。论文明确说明这种权重裁剪会带来轻微偏差。

第二，CISPO 需要选择合适的上界。上界过大时，少量极端词元仍可能获得较高梯度权重；上界过小时，大量词元会被压到同一权重边界，重要性采样对不同 off-policy 程度的区分会减弱。

第三，回答级优势限制了细粒度信用分配。同一条回答中的不同词元可以拥有不同 $\hat{r}_{i,t}$ ，但它们通常共享 $\hat{A}_i$ 。如果一条回答前半段推理正确、后半段出现错误，单纯依靠最终回答奖励很难判断具体哪一步造成了结果变化。

第四，CISPO 的收益与 off-policy 程度密切相关。当每批 rollout 只更新很少次数时，新旧策略差异较小，Token Clipping 问题本身也较弱；当同一批数据被重复更新很多轮时，CISPO 保留越界词元梯度的作用会更加明显，同时权重裁剪参数也更加重要。

第五，CISPO 只控制 IS Weight，并没有直接限制完整策略分布的距离。PPO 的 trust-region 风格裁剪会在特定方向形成零梯度区域，CISPO 保留所有词元梯度，因此稳定性更依赖权重上界、数据分布和其他训练策略的共同作用。

十九、 总结

CISPO 的数学起点是 off-policy policy gradient。旧策略负责生成 rollout，当前策略负责参数更新，因此需要重要性采样比

$$r_{i,t} = \frac{\pi_{\theta}(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})}$$

修正新旧策略之间的分布差异。

GRPO 把概率比放进 PPO 式 clipped objective。正优势词元越过上界、负优势词元越过下界以后，对应方向进入零梯度区域。CISPO 先把概率比裁剪成

$$\hat{r}_{i,t} = \text{clip}(r_{i,t}, 1 - \epsilon_{\text{low}}^{\text{IS}}, 1 + \epsilon_{\text{high}}^{\text{IS}}),$$

再把它作为 Stop-Gradient 权重乘到 $\hat{A}_{i,t} \log \pi_{\theta}$ 上。

最终的词元梯度可以写成

$$g_{i,t}^{\text{CISPO}} = \hat{r}_{i,t} \hat{A}_{i,t} \nabla_{\theta} \log \pi_{\theta}(o_{i,t} \mid q, o_{i,<t}).$$

$\hat{A}_{i,t}$ 决定更新方向， $\hat{r}_{i,t}$ 控制更新强度，裁剪限制极端权重，Stop-Gradient 保证权重只参与加权， $\log \pi_{\theta}$ 继续承担真正的参数梯度。

因此，CISPO 最重要的变化集中在一件事上：越过原有裁剪边界的词元仍然继续学习，重要性采样权重被限制在可控范围内。MiniMax-M1 的实验表明，这一修改在其长 CoT、多轮 off-policy 强化学习设置中提高了训练效率，并成为 MiniMax-M1 RL Recipe 的主要组成部分。