

DIVA-GRPO：难度自适应体优势优化

导论

DIVA-GRPO 的一次训练过程可以概括为：

1. 对每道训练问题维护一个随模型能力变化的难度系数；
2. 根据历史 rollout 的正确率更新当前问题难度；
3. 按照当前难度生成或采样不同难度的语义一致变体；
4. 对原问题及其变体分别执行多次 rollout，并计算奖励；
5. 在每个问题内部计算 Local Advantage；
6. 在原问题与全部变体组成的更大组内计算 Global Advantage；
7. 分别对 Local 与 Global Advantage 做归一化，并使用相对难度重新加权；
8. 根据实际奖励跨度执行 Reward-Range-Based Rescaling；
9. 将处理后的优势送入 GRPO 风格策略更新，持续训练当前多模态模型。

DIVA-GRPO 全称为 Difficulty-Adaptive Variant Advantage with GRPO，发表于 ICLR 2026。它关注多模态 GRPO 训练中的两个问题：Reward Sparsity 和 Advantage Vanishing。问题过难时，大量 rollout 都得到错误奖励，组内缺少正反馈；问题过易时，大量 rollout 全部正确，组内奖励几乎完全一致。GRPO 的优势来自组内奖励差异，所以这两种情况都会让有效优势明显减少。

DIVA-GRPO 从训练问题本身的难度分布入手。模型会持续估计“这道题对于当前模型到底有多难”，再为同一道题构造更难或更容易的变体，使一个问题及其变体能够持续产生有差异的奖励。论文进一步同时计算 Local Advantage 和 Global Advantage，用 batch-level normalization 平衡两类信号，再依据相对难度调整优势大小，并使用 Reward-Range-Based Rescaling 修正标准 z-score 可能放大的微小奖励差异。

论文：DIVA-GRPO: Enhancing Multimodal Reasoning through Difficulty-Adaptive Variant Advantage (<https://arxiv.org/pdf/2603.01106>)

一、GRPO 中的 Reward Sparsity 与 Advantage Vanishing

先回到标准 GRPO。对于一个问题 q ，策略 π_θ 生成 k 条回答 $\mathcal{Y}_q = \{y_1, \dots, y_k\}$ ，每条回答得到奖励 $r(y_i)$ 。GRPO 在这一组回答内部做 z-score 标准化，优势写为

$$A(y_i) = \frac{r(y_i) - \mu_r}{\sigma_r + \epsilon}, \quad \mu_r = \frac{1}{k} \sum_{j=1}^k r(y_j),$$

其中 σ_r 是组内奖励标准差， ϵ 用来保证数值稳定。策略梯度随后使用 $A(y_i)$ 对每条回答的对数概率梯度加权。

这套优势估计依赖一个条件：同一问题生成的回答需要有足够的奖励差异。如果奖励完全相同，就有 $\sigma_r = 0$ ，每个回答的 $r(y_i) - \mu_r$ 也为 0，所以组内无法形成有效的相对学习信号。

最简单的情况是二值奖励。设正确回答奖励为 1，错误回答奖励为 0。如果一题的 8 条 rollout 全部正确，奖励为 $[1, 1, 1, 1, 1, 1, 1, 1]$ ，每个回答都等于组内平均奖励，优势全部为 0。如果 8 条回答全部错误，奖励为 $[0, 0, 0, 0, 0, 0, 0, 0]$ ，结果同样如此。

对于困难问题，训练早期更容易出现全错或只有极少数正确回答，这对应 Reward Sparsity；对于已经被模型掌握的简单问题，训练后期更容易出现全对，组内优势逐渐消失。论文把后一现象称为 Advantage Vanishing。随着模型能力提高，原本有区分度的问题会逐渐变简单，因此晚期训练中非零优势样本比例还可能再次下降。

为什么“全对”和“全错”都会让 GRPO 失去学习信号？

GRPO 使用的是同一问题内部的相对奖励。假设奖励为 $[1, 1, 1, 1]$ ，平均值为 1，每个回答减去平均值都得到 0；奖励为 $[0, 0, 0, 0]$ 时，平均值为 0，每个回答减去平均值仍然得到 0。

真正有用的是组内同时出现较好和较差的回答。例如奖励为 $[1, 1, 0, 0]$ 时，正确与错误回答能够得到方向相反的优势，模型才知道哪些生成应该增加概率、哪些生成应该降低概率。

因此 DIVA-GRPO 更关注如何持续调整同一个问题附近的难度分布，使变体难度贴合当前模型能力，并让组内奖励长期保持足够的差异。

二、为什么训练问题需要动态难度

同一道题的难度会随着模型能力变化。训练初期，某道几何题可能只有少量 rollout 能够答对；经过若干轮强化学习以后，大部分 rollout 都可以正确完成，此时这道题对于当前模型已经变成简单样本。

DIVA-GRPO 为每道问题维护一个难度 $D_q \in [D_{\min}, D_{\max}]$ ，训练开始时统一初始化为中间值

$$D_{\text{mid}} = \frac{D_{\min} + D_{\max}}{2}.$$

设一个原问题当前有 m 个变体，每个变体执行 k 次 rollout。总共得到 mk 条回答，

用正确回答比例作为经验准确率

$$\alpha = \frac{1}{mk} \sum_{i=1}^m \sum_{j=1}^k \mathbb{I}[y_{i,j} \text{ 回答正确}].$$

随后按照

$$D^{\text{new}} = \text{clip}(D^{\text{old}} + \eta(0.5 - \alpha), D_{\min}, D_{\max})$$

更新难度，其中 $\eta > 0$ 控制每次难度调整幅度。

这个公式可以直接从 $0.5 - \alpha$ 理解。如果当前正确率 $\alpha > 0.5$ ，则 $0.5 - \alpha < 0$ ，难度系数会下降，说明当前模型已经较容易处理这道题；如果 $\alpha < 0.5$ ，难度系数会上升，说明这道题对于当前模型仍然偏难；如果 $\alpha \approx 0.5$ ，难度基本保持不变。

论文选择 0.5 作为平衡点，与后面的理论分析一致：当正确与错误样本比例接近 1 : 1 时，z-score 优势能够提供更强的有效更新信号。因此难度估计的目的，是持续追踪模型当前处在什么能力区间，再据此决定应该生成哪一类变体。

假设难度范围为 $[1, 9]$ ，中间值为 5，当前一道题的难度为 $D^{\text{old}} = 5$ ，并设 $\eta = 4$ 。

如果本轮 rollout 正确率为 $\alpha = 0.75$ ，新的难度为 $5 + 4(0.5 - 0.75) = 4$ ；如果正确率为 $\alpha = 0.25$ ，新的难度为 $5 + 4(0.5 - 0.25) = 6$ ；如果正确率刚好为 0.5，难度仍然保持在 5。

所以这个更新规则会随着模型真实表现平滑移动，不需要把一题永久标记为“简单”或“困难”。

论文的消融实验表明 η 过大时，单次 rollout 的随机性会使难度变化过快； η 过小时，模型能力已经变化，难度估计却更新得太慢。论文实验中 $\eta = 4$ 表现较好，并建议按照 $\eta = (D_{\max} - D_{\min})/2$ 选择调整幅度。

三、 Difficulty-Adaptive Variant Generation

得到当前难度以后，DIVA-GRPO 会为原问题生成语义一致的变体。设原问题为 $q = (I_q, T_q)$ ，其中 I_q 是图像， T_q 是文字描述和问题。变体集合记为 $\mathcal{V}_q = \{q^{(1)}, q^{(2)}, \dots\}$ 。所有变体都需要保持原题正确答案 y_q^* 不变，变化的只是题目呈现方式和求解难度。

DIVA-GRPO 的处理方向与当前难度有关。对于已经偏简单的问题，系统需要生成更有挑战性的版本；对于已经偏困难的问题，系统需要生成更容易获得部分正确反馈的版本；对于中等难度问题，主要保持难度并增加表达多样性。

3.1 简单问题：提高变体难度

当 $D_q < D_{\text{mid}}$ 时，说明当前模型已经比较容易答对原问题。继续大量重复原题容易出现全对，优势逐渐消失。论文因此对文本和图像做扰动。

文本变体会改变措辞、句子结构或表达方式，同时保持语义和答案一致。图像变体可以使用旋转、高斯噪声、椒盐噪声、散斑噪声、模糊等操作。扰动强度越大，视觉识别和后续推理通常越困难。

因此，简单问题的变体主要承担“重新制造区分度”的作用。模型可能继续答对一部分轻度扰动样本，同时在更强扰动上失败，这样同一问题附近重新产生正负奖励差异。

3.2 中等问题：保持难度并扩展表达

当 $D_q \approx D_{\text{mid}}$ 时，当前问题已经处在比较合适的训练区间。论文主要使用语义等价文本改写，保持原图和答案不变，同时用不同语言表达同一个问题。

这一类变体对难度的改变较小，主要增加表达多样性。模型因此可以在相近难度下接触不同问题表述，减少只适应固定措辞的情况。

3.3 困难问题：加入部分推理提示

当 $D_q > D_{\text{mid}}$ 时，原问题对于当前模型偏难，大量 rollout 可能全部失败。DIVA-GRPO 会加入部分中间推理步骤 $R_q^{(i)}$ ，构造 $q^{(i)} = (I_q, T_q \oplus R_q^{(i)})$ 。问题越困难，可以加入更多经过验证的中间步骤。

这样可以降低当前变体的实际求解难度，让原本几乎全部错误的组中出现一部分正确回答。论文的变体难度表从“强视觉扰动”一直排列到“增加 1、2、3 个 think steps”，形成由难到易的多个等级。

因此，Difficulty-Adaptive Variant Generation 的目标可以概括为：简单问题向更难方向采样，困难问题向更容易方向采样，中等问题主要做等难度改写，使问题组尽量停留在能够产生奖励差异的区域。

四、为什么 50% 左右的正确率更有利于 GRPO

论文在附录中给出了一个二值奖励下的分析。设一批 rollout 中共有 n 个样本，其中正确样本数量为 k ，定义正确比例 $\mu = k/n$ 。奖励只有 $\{0, R_{\text{max}}\}$ 两种取值。

平均奖励为 $\bar{r} = \mu R_{\text{max}}$ ，标准差为

$$\sigma_r = R_{\text{max}} \sqrt{\mu(1 - \mu)}.$$

经过 z-score 标准化后，正确样本的优势和错误样本的优势分别为

$$A_+ = \sqrt{\frac{1 - \mu}{\mu}}, \quad A_- = -\sqrt{\frac{\mu}{1 - \mu}}.$$

设正确样本和错误样本的平均 score gradient 在某个期望更新方向 v 上的投影分别为 s_+ 和 s_- 。论文在 class-mean approximation 下得到，整个 batch 更新在方向 v 上的投影幅度与

$$\sqrt{\mu(1 - \mu)} |s_+ - s_-|$$

成正比。

由于 $|s_+ - s_-|$ 与 μ 无关，只需要最大化 $\mu(1 - \mu)$ 。这个二次函数在 $\mu = 1/2$ 时达到最大值，所以正确与错误样本接近一半一半时，理论上的方向性更新信号最强。

为什么全对或全错时优势会消失，而一半对一半时最强？

当 μ 接近 0 或 1 时， $\mu(1 - \mu)$ 都接近 0，说明组内几乎只有一种奖励，缺少相对比较信息。当 $\mu = 0.5$ 时， $\mu(1 - \mu) = 0.25$ 达到最大，正负两类样本数量最平衡，GRPO 可以同时得到清楚的正向和负向更新信号。

这个结果也解释了难度更新公式为什么围绕 $0.5 - \alpha$ 调整：DIVA-GRPO 希望通过动态难度和变体采样，把训练数据持续拉回到具有较强优势差异的区域。

这个理论结论建立在二值奖励和类均值近似等假设上。真实训练中每个类别内部还存在梯度方差，奖励也可能不止两个取值，因此它提供的是一个清楚的分析基线。论文额外实验也显示，中等难度问题比随机抽取问题更有利于标准 GRPO 的快速优化。

五、 Local Advantage 与 Global Advantage

只有变体还不够。一个原问题及其多个变体会形成两种不同尺度的比较范围，DIVA-GRPO 分别计算 Local Advantage 和 Global Advantage。

设原问题生成 m 个变体，每个变体执行 k 次 rollout。对于第 j 个变体 $q^{(j)}$ ，Local Advantage 只使用这个变体自己的 k 条回答。若这些奖励为 $r_1^{(j)}, \dots, r_k^{(j)}$ ，则某条回答的 Local Advantage 与标准 GRPO 一样：

$$A_{\text{local}}(y_i^{(j)}) = \frac{r(y_i^{(j)}) - \mu_j}{\sigma_j + \epsilon},$$

其中 μ_j 和 σ_j 只在当前变体内部计算。

Local Advantage 回答的是：同一个具体问题版本下，这条回答相对于其他 rollout 表现如何。它保留了 GRPO 原本的组内比较结构。

Global Advantage 会把原问题相关的多个变体放到同一个更大范围里比较。整个 variant set 一共有大约 $m \times k$ 条回答，记全局奖励均值和标准差为 μ_q 、 σ_q ，则

$$A_{\text{global}}(y_i^{(j)}) = \frac{r(y_i^{(j)}) - \mu_q}{\sigma_q + \epsilon}.$$

Global Advantage 回答的是：这条回答放到同一原问题的所有难度变体中，整体处在什么位置。它可以把不同难度版本之间的奖励差异纳入优势估计。

假设一个原问题有三个难度变体, 每个变体各 rollout 4 次。第一个较难变体的奖励为 $[0, 0, 0, 1]$, 第二个中等变体为 $[0, 0, 1, 1]$, 第三个较易变体为 $[0, 1, 1, 1]$ 。

Local Advantage 会在三个 4 样本小组中分别做标准化, 所以每个回答主要和同难度版本比较。Global Advantage 会把 12 条奖励放在一起计算均值和标准差, 所以较难变体中唯一的正确回答会同时获得跨难度范围的相对信息。

两种优势关注的范围不同, 因此论文同时保留它们。

六、为什么 Local 和 Global 需要再次归一化

Local Advantage 和 Global Advantage 的统计范围不同。Local 使用 k 条 rollout, Global 使用大约 $m \times k$ 条回答。即使两者都已经在各自组内做过 z-score 标准化, 它们在一个训练 batch 中的整体分布范围仍然可能有明显差异。

论文观察到 Global Advantage 通常具有更高的稀疏性和方差。如果直接把两类信号共同用于优化, 数值范围更大的那一类更容易主导梯度, 另一类信号的贡献会被削弱。

因此 DIVA-GRPO 会在 batch 级别分别对 Local Advantage 和 Global Advantage 再做 z-score:

$$\tilde{A}_{\text{local}}(y) = \frac{A_{\text{local}}(y) - \mu_{\text{local}}}{\sigma_{\text{local}} + \epsilon}, \quad \tilde{A}_{\text{global}}(y) = \frac{A_{\text{global}}(y) - \mu_{\text{global}}}{\sigma_{\text{global}} + \epsilon}.$$

这里 $\mu_{\text{local}}, \sigma_{\text{local}}$ 来自当前 batch 中的 Local Advantage 分布, $\mu_{\text{global}}, \sigma_{\text{global}}$ 来自 Global Advantage 分布。两类优势被分别中心化并缩放以后, 整体尺度更加接近, 可以减少某一路优势长期压过另一条分支的情况。

论文附录进一步说明, 组内 z-score 只能保证每个局部组内部标准化; 不同组汇总到 batch 以后, Local 与 Global 的整体范围仍然可能不同, 所以 batch-level normalization 是额外需要的一步。

七、Difficulty-Weighted Scaling

完成归一化以后, DIVA-GRPO 还会根据变体的相对难度重新调整优势。设同一原问题的 N 个变体难度为 $D_q^{(1)}, \dots, D_q^{(N)}$, 组内平均难度为 $\bar{D}_q = \frac{1}{N} \sum_i D_q^{(i)}$ 。对于来自第 i 个变体的回答, 难度加权优势写为

$$\hat{A}(y_i | q^{(i)}) = \exp \left[k(D_q^{(i)} - \bar{D}_q) \text{sgn}(\tilde{A}(y_i)) \right] \tilde{A}(y_i),$$

其中 $k > 0$ 是敏感系数, $\tilde{A}$ 可以表示已经归一化的 Local 或 Global Advantage。

这个指数权重同时看两个量: 当前变体相对于同组平均值更难还是更容易, 以及当前回答的优势是正还是负。

如果 $D_q^{(i)} > \bar{D}_q$, 说明当前变体比同组平均更难。若 $\tilde{A} > 0$, 指数中的乘积为

正，权重大于 1，困难样本上的正确回答会被放大；若 $\tilde{A} < 0$ ， $\text{sgn}(\tilde{A}) = -1$ ，指数变成负值，权重小于 1，困难样本上的错误回答会被减弱。

如果 $D_q^{(i)} < \bar{D}_q$ ，说明当前变体更容易。正优势会被降低，错误回答的负优势绝对值会被增强。这样模型会更重视“难题答对”和“简单题答错”这两类更有信息量的情况。

假设同一问题组的平均难度为 $\bar{D} = 5$ ，敏感系数取 $k = 0.1$ 。某个困难变体难度为 $D = 7$ ，若归一化优势为 $\tilde{A} = 1$ ，权重为 $\exp(0.1 \times 2) \approx 1.22$ ，最终优势约为 1.22。

如果同一个困难变体得到 $\tilde{A} = -1$ ，权重变成 $\exp(-0.2) \approx 0.82$ ，最终优势约为 -0.82 。这表示困难问题答对时奖励信号增强，答错时惩罚信号减弱。

反过来，简单变体如果仍然答错，负优势会被放大，因为这种错误更值得模型修正。

论文选择相对难度 $D_q^{(i)} - \bar{D}_q$ ，没有直接使用绝对难度。不同原问题的“难”可能来自完全不同原因，例如一个问题逻辑本身复杂，另一个问题只是加入了图像噪声。跨问题直接比较绝对难度缺少统一含义。同一原问题的多个变体共享语义和答案，因此组内难度排序更加可靠。

消融实验中 $k \approx 0.1$ 表现较好。论文指出，当 $k = 0$ 时等价于关闭难度加权； k 过大时，不同难度之间的权重差异会过强，训练稳定性可能下降。

八、RRB-Rescaling 为什么还需要存在

Local/Global z-score 和 Difficulty Weighting 处理了优势尺度与难度关系，但标准 z-score 还存在另一个问题：它只关心相对位置，不关心原始奖励差异到底有多大。

论文给出两个例子。样本 A 的 5 次 rollout 奖励为 $[0, 0, 0, 0, 0.1]$ ，样本 B 为 $[0, 0, 0, 0, 1]$ 。两个组的形状完全一样，都是四个低值加一个高值。标准 z-score 只看相对结构，因此两组会得到相同的标准化优势：前四个样本大约都是 -0.45 ，最后一个样本大约都是 1.79。

问题在于，A 中最后一个 rollout 只比其他样本多得到 0.1，B 中最后一个 rollout 多得到整整 1.0。z-score 把两种差异压成完全相同的优势幅度，会让很小的奖励改善看起来和真正的完整正确一样重要。

DIVA-GRPO 因此提出 Reward-Range-Based Advantage Rescaling。设问题 q 的 rollout 奖励集合为 $\mathcal{R}_q$ ，任务允许的最大可能奖励跨度为 $R_{\max}$ ，定义

$$\Delta r_q = \frac{\max(\mathcal{R}_q) - \min(\mathcal{R}_q)}{R_{\max}}.$$

然后把标准化优势乘上这一系数：

$$\hat{A}_{\text{range}}(y_i) = \Delta r_q \tilde{A}(y_i).$$

如果一个组的实际奖励范围很小， Δr_q 也很小，标准 z-score 产生的优势会整体缩小；如果组内确实包含从低奖励到高奖励的大范围变化， Δr_q 接近 1，优势基本保留原有幅度。

仍然考虑奖励 $[0, 0, 0, 0, 0.1]$ 和 $[0, 0, 0, 0, 1]$ ，假设最大可能奖励跨度 $R_{\max} = 1$ 。

第一组的 $\Delta r = 0.1$ ，所以原本约 1.79 的正优势会缩小到约 0.179；第二组的 $\Delta r = 1$ ，对应正优势仍然约为 1.79。这样优势大小重新反映了真实奖励差异。

RRB-Rescaling 可以独立作用在 GRPO 风格优势上。论文把 RRB 单独加入标准 GRPO 后，在 MathVista、MathVerse、MMK12test 三个基准上的平均准确率从 60.23 提升到 62.17，说明这一组件的作用不依赖完整 DIVA-GRPO 框架。

九、把整个优势处理过程连起来

到这里，可以把 DIVA-GRPO 的优势处理分成四层。

第一层是在每个具体问题或变体内部计算 Local Advantage，得到同一版本内部的相对好坏。第二层是在原问题和全部变体形成的大组中计算 Global Advantage，得到跨变体的相对位置。第三层分别对 Local 与 Global 做 batch-level normalization，再依据变体相对难度进行指数加权。第四层使用 RRB 根据实际奖励跨度重新缩放优势幅度。

论文正文分别给出了这些步骤的公式，但没有在主文中把 Local 与 Global 两条分支压缩成一个唯一的单行闭式公式。因此讲义中也保留两类优势的独立含义：它们经过同样的归一化、难度加权和 RRB 处理后，共同为后续 GRPO 风格策略更新提供训练信号。

DIVA-GRPO 主要修改的是“优势怎样产生和怎样缩放”，策略优化仍然建立在 GRPO 风格的 policy gradient 上。设处理后的优势记为 $\hat{A}(y)$ ，单条回答的策略梯度仍然可以抽象写成

$$g(\theta) = \hat{A}(y) \nabla_{\theta} \log \pi_{\theta}(y | q).$$

因此，DIVA-GRPO 的重点是让 $\hat{A}(y)$ 在不同问题难度和不同训练阶段都保持稳定、具有区分度，并尽量减少无效的零优势样本。

十、为什么归一化与难度加权能够改善稳定性

论文附录从梯度方差角度分析这一设计。设随机策略梯度估计为

$$g(\theta) = \sum_{t=1}^T A_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t).$$

在常见随机优化分析中，参数到最优点的期望平方距离包含一个与梯度估计方差相关的项。论文给出的形式为

$$\mathbb{E}[\|\theta_{t+1} - \theta^*\|^2] \leq \mathbb{E}[\|\theta_t - \theta^*\|^2] - \eta \|\nabla J(\theta_t)\|^2 + \eta^2 \text{Var}[\tilde{g}(\theta_t)].$$

前两部分描述当前参数距离和有效下降，最后一项表示随机梯度噪声带来的影响。在其他条件接近时， $\text{Var}[\tilde{g}]$ 越小，参数更新越稳定。

DIVA-GRPO 的 batch normalization 先让 Local 和 Global 优势处于可比较尺度，难度加权再重新分配不同难度样本的贡献。论文附录给出的结论是，在其假设下调整后的梯度满足 $\text{Var}[\tilde{g}(\theta)] \leq \text{Var}[g(\theta)]$ ，从而有利于更稳定的优化。

这里需要注意，这一结论依赖论文给出的理论假设。实际大模型训练中的梯度分布更加复杂，但消融实验显示去掉 Global-Local Balance、Difficulty Weighting 或 RRB 都会降低最终性能，说明这些组件在实验设置中具有互补作用。

十一、完整数值例子

下面用一个小例子把动态难度、Local Advantage、Global Advantage、Difficulty Weighting 和 RRB 放到同一条计算过程中。

假设一个原问题当前有三个变体，难度分别为 $D = [4, 5, 6]$ ，所以组内平均难度为 $\bar{D} = 5$ 。每个变体执行 4 次 rollout，奖励分别为

$$[0, 0, 0, 1], \quad [0, 0, 1, 1], \quad [0, 1, 1, 1].$$

三个变体的正确率分别为 25%、50% 和 75%，整个 12 条回答的总正确率刚好为 50%。

先看 Local Advantage。每个变体分别在自己的 4 条 rollout 中计算均值和标准差，所以第一个变体唯一的正确回答会获得较高正优势，第二个变体形成比较对称的正负优势，第三个变体唯一的错误回答会获得较大的负优势。

Global Advantage 则把 12 个奖励一起计算。因为总共有 6 个正确、6 个错误，全局奖励分布最平衡，正确回答获得统一正优势，错误回答获得统一负优势。它反映的是跨三个难度版本的整体相对位置。

接着考虑 Difficulty Weighting。设 $k = 0.1$ 。难度 6 的变体比平均难度高 1，因此其中正优势会乘 $\exp(0.1) \approx 1.105$ ，负优势会乘 $\exp(-0.1) \approx 0.905$ ；难度 4 的变体刚好相反，正优势会减弱，负优势绝对值会增强；难度 5 的变体保持原尺度。

最后，如果奖励本身只有 0 和 1，那么每个同时包含正确与错误结果的组都有完整奖励跨度，RRB 的 Δr 接近 1，优势基本不缩小。若某个任务还包含很小的格式奖励，例如奖励只从 0 变化到 0.1，RRB 会把这一组优势整体缩小到原来的约 0.1。

这几个步骤分别处理不同问题：Local/Global 提供不同尺度的相对比较，batch normalization 平衡两类信号，Difficulty Weighting 根据相对难度调整训练重点，RRB 保证优势幅度能够反映真实奖励差异。

十二、 实验设置与主要结果

论文主要在六个多模态推理基准上评估 DIVA-GRPO，包括 MathVista、MathVerse、MathVision、OlympiadBench、WeMath 和 MMK12-test。主要 7B 模型以 Qwen2.5-VL-7B 为 backbone。

DIVA-GRPO-7B 在六个基准上的结果分别为 74.2、57.6、32.1、23.1、69.3 和 70.2，平均准确率为 54.58。论文报告其在 7B 规模上取得较强的整体表现，并在多个基准上超过其他开源推理模型。

消融实验在 MathVista、MathVerse 和 MMK12test 上分别去掉 Variant Generation、Difficulty Weighting、RRB-Rescaling 和 Global-Local Balance。完整模型三项平均为 66.1；去掉 Variant Generation 后平均为 61.6，去掉 Difficulty Weighting 后为 64.0，去掉 RRB 后为 63.8，去掉 Global-Local Balance 后为 64.1。各组件都对最终性能有贡献。

论文还在 Qwen3-VL-4B-Instruct 和 Qwen3-VL-8B-Instruct 上验证了方法。相对于对应 GRPO，DIVA-GRPO 的平均结果分别进一步提高约 2.5 和 4.2 个百分点，说明这种难度自适应优势方法可以应用到不同模型规模。

十三、 训练效率为什么会提高

DIVA-GRPO 每一步需要生成和处理变体，因此单步计算并不会自动更便宜。它的效率优势来自更少的无效训练步骤和更持续的非零优势信号。

标准 GRPO 在训练早期会快速提升正确率，但随着模型变强，大量原问题逐渐变得过易，非零优势样本比例会明显下降。DIVA-GRPO 会持续提高简单问题的变体难度，并降低困难问题的变体难度，因此更多问题组能够继续维持正负奖励混合。

论文在训练效率实验中报告，在不同数据控制方式下，DIVA-GRPO 达到最优表现所需步数最高可减少超过 $2.55\times$ ；在考虑变体和 think-step 生成成本以后，端到端墙钟时间仍可获得超过 $1.76\times$ 的加速。这个结果说明额外的数据变体处理开销可以被更快的收敛速度抵消。

十四、 外部模型与变体质量

DIVA-GRPO 的部分困难变体需要生成经过验证的中间推理步骤，论文实验使用外部模型完成这一过程。为了检查外部模型质量是否会强烈影响最终训练，作者分别使用 Qwen-Plus 和 GPT-o3 生成变体及 think steps。

在相同训练条件下，两种外部模型最终平均结果只相差约 0.3 个百分点。论文解释，这与结果监督和数据筛选有关：训练使用的是能够得到正确最终答案的有效样本，生成模型本身的差异经过验证和筛选以后被明显减弱。

论文还随机抽取 1000 个问题变体检查与原问题的一致性，报告约 98.8% 的变体保持语义和答案一致。这一点很重要，因为 Difficulty-Adaptive Variant Generation 只有在“难度变化、任务语义不变”的条件下才成立。如果变体修改了真正要解决的问题，Local/Global Advantage 就会混入错误监督。

十五、 DIVA-GRPO 的局限性

第一，变体生成增加了训练流程复杂度。文本改写、图像扰动和 think-step 生成都需要额外数据处理，困难样本的 reasoning hints 还依赖外部模型。虽然论文报告整体墙钟时间仍然更快，但工程实现比标准 GRPO 更复杂。

第二，难度估计来自历史 rollout 正确率，因此会受到模型采样随机性影响。 η 过大时，少量偶然正确或错误回答可能快速改变难度； η 过小时，难度更新跟不上模型能力变化。论文通过消融选择合适的调整速度。

第三，变体必须严格保持原答案和原任务语义。图像噪声过强、文本改写错误或提示信息不可靠都会破坏训练样本一致性。论文使用验证流程提高变体可靠性，但这种质量控制仍然是方法的重要前提。

第四，Local Advantage 和 Global Advantage 来自不同统计范围，归一化能够减少尺度不平衡，但真实训练中的两类梯度仍可能具有复杂相关性。论文通过 batch z-score 和消融实验验证了实际效果，完整的最优融合方式仍然可以继续研究。

第五，难度加权依赖相对难度的可靠排序。论文选择组内相对难度，是因为跨原问题的绝对难度缺少统一可比性。即使在同一问题内部，视觉扰动强度、语言复杂度和 reasoning hint 数量也只能近似表示真实求解难度。

第六，论文关于 50% 正确率最有利的理论分析采用二值奖励和类均值近似。实际多模态强化学习可以包含连续奖励、格式奖励以及更复杂的梯度分布，所以这一结论更适合作为动态难度设计的理论依据和趋势解释。

十六、 总结

DIVA-GRPO 处理的是 GRPO 中奖励分布缺少区分度的问题。困难问题容易产生全错和奖励稀疏，简单问题容易产生全对和优势消失。随着模型能力变化，一

道题的有效训练难度也会不断变化，因此固定问题分布无法长期保证稳定优势。

DIVA-GRPO 首先根据历史 rollout 正确率动态更新问题难度，再按难度选择不同类型的语义一致变体。简单问题通过文本和视觉扰动提高难度，困难问题通过部分推理步骤降低难度，中等问题主要使用等价改写保持难度。整个机制希望让正确率长期维持在具有较强区分度的区域。

优势估计同时使用 Local 与 Global 两个尺度。Local Advantage 描述同一具体问题版本内部的相对表现，Global Advantage 描述原问题和多个变体之间的整体相对表现。两类优势经过 batch-level normalization 后，再利用

$$\exp\left[k(D_q^{(i)} - \bar{D}_q) \text{sgn}(\tilde{A})\right]$$

进行相对难度加权，使困难变体中的正确回答获得更强信号，简单变体中的错误回答获得更强惩罚。

RRB-Rescaling 进一步利用真实奖励范围修正 z-score 的尺度。它用 $\Delta r_q = (\max \mathcal{R}_q - \min \mathcal{R}_q)/R_{\max}$ 乘到标准化优势上，使很小的奖励差异不会被标准化成和大幅奖励改善相同的优势幅度。

因此 DIVA-GRPO 的整体思路可以概括为：动态调整问题难度，让组内持续存在有区分度的奖励；同时从局部、全局、相对难度和真实奖励跨度四个角度修正优势，使策略梯度在不同训练阶段都保持更加稳定和有效的学习信号。