

Qwen-VL

导论

Qwen 是阿里云通义团队推出的大语言模型系列，也是目前国内发展最完整的开源大模型体系之一。它持续围绕模型架构、长上下文、多模态理解、推理能力、代码能力、工具调用和 Agent 等方向进行迭代。从早期的 Qwen、Qwen1.5，到 Qwen2、Qwen2.5、Qwen3，再到后续更加统一的原生多模态模型，Qwen 的整体路线逐渐从“通用文本大模型”发展为能够同时处理文本、图像、视频、音频、代码和工具调用任务的通用基础模型。

在模型架构方面，Qwen 系列经历了从传统 Decoder-only Transformer 到 GQA、MoE、长上下文机制以及混合序列架构的持续演进；在视觉方向，又形成了独立而完整的 Qwen-VL 技术路线，从最初的 ViT 与视觉语言适配器，逐渐发展到动态分辨率、M-RoPE、Window Attention、DeepStack 和原生视觉语言联合训练。与此同时，Qwen 还发展出了 Qwen-Coder、Qwen-VL、Qwen-Omni、Qwen-Image 等多个分支，使同一技术体系能够覆盖代码生成、视觉理解、视频理解、语音交互和图像生成等不同任务。

随着模型版本不断更新，Qwen 的研究重点也逐渐从“让模型拥有更多能力”转向“让不同能力在同一个模型中协同工作”。文本理解、视觉感知、复杂推理、代码生成、工具调用和 Agent 不再被视为完全独立的模块，而开始在统一的基础模型中共同训练和使用。因此，Qwen 系列的发展过程实际上很好地体现了近年来大模型技术的发展方向：从单一语言模型走向多模态基础模型，再进一步走向能够感知、推理、调用工具并完成复杂任务的通用智能体。

一、Qwen-VL

技术报告：Qwen-VL: A Versatile Vision-Language Model for Understanding, Localization, Text Reading, and Beyond (<https://arxiv.org/pdf/2308.12966>)

Qwen-VL 是 Qwen 系列第一代正式的视觉语言模型，也是后面所有 Qwen-VL 架构的起点。这个时期的基本问题非常直接：Qwen 原本只能接收文本 Token，而图片是由像素组成的，因此必须先设计一个视觉模块，把图片转换成一串能够被语言模型处理的向量。

Qwen-VL 因此采用了非常明确的三部分结构：**Vision Encoder**、**Vision-Language Adapter** 和 **Qwen Language Model**。其中语言部分使用 Qwen-7B，视觉部分使用一个大型 Vision Transformer，也就是 ViT，并使用 OpenCLIP 的 ViT-bigG 权重初始化。图片首先进入 ViT，ViT 会把图片分割成很多固定大小的 Patch，每个 Patch 被转换成一个视觉向量，然后经过多层 Transformer 计算，最终得到一组视觉特征。到这里为止，这些特征仍然属于视觉特征空间，不能直接当作普通文本 Token 交给 Qwen，因此还需要中间的 Vision-Language Adapter 完成视觉和语言空间之间的连接。


Qwen-VL 的 Adapter 是一个带有 **Cross-Attention**，也就是交叉注意力机制的模块。这个模块内部维护一组可以训练的 Query，这些 Query 会主动读取 ViT 输出的大量 Patch 特征，然后把整张图片的信息压缩到固定数量的视觉 Token 中。第一代 Qwen-VL 最终把一张图片压缩为 **256 个视觉 Token**。这意味着无论输入图片原本有多少视觉 Patch，最终进入 Qwen 的视觉序列长度基本固定。这种设计的优点是很容易控制计算成本，因为语言模型永远只需要额外处理大约 256 个视觉 Token；但缺

点也很明显，一张信息非常简单的图片和一张拥有大量文字、表格和细节的高分辨率图片最终都得到相同数量的 Token，因此视觉信息的压缩程度并不会根据图片复杂程度变化。这个问题后来直接成为 Qwen2-VL 改架构的重要原因。

第一代 Qwen-VL 同时非常重视图片内部的二维空间位置。普通文本是一维序列，只需要知道某个 Token 在前还是在后，但图片中的物体具有上下、左右关系。因此 Qwen-VL 在视觉 Adapter 中加入位置相关设计，让模型在压缩图片时尽量保留 Patch 原本所在的二维位置。这一点对 OCR、表格和目标定位特别重要，因为模型不仅要知道图片里出现了什么，还要知道它出现在哪里。例如一张表格中的数字，如果只识别出数字本身而不知道它位于哪一行、哪一列，那么模型仍然无法正确理解表格。Qwen-VL 因此从第一代开始就没有把图片仅仅当成“分类输入”，而是要求视觉特征保留尽可能多的空间结构。


Qwen-VL 另一个后来一直延续下来的重要设计是 **Visual Grounding**。所谓 Grounding，可以简单理解成模型不仅输出“图片中有一个目标”，还能够输出这个目标在图片中的位置。Qwen-VL 没有额外安装一个传统目标检测网络，而是把 Bounding Box，也就是目标框的位置，直接转换成语言模型能够生成的 Token。它首先把坐标归一化到统一范围，然后使用专门的 <box> 和 <ref> 等 Token，把文字和图片中的区域对应起来。因此模型可以生成“某个物体位于某个坐标范围”这样的结果。这样以后，图像描述、视觉问答、OCR 和目标定位全部可以通过同一个自回归语言模型输出，而不需要为每个任务设计一个独立的输出头。这种“把视觉任务统一成语言生成”的思路后来一直延续到了 Qwen2-VL、Qwen2.5-VL 和 Qwen3-VL。

Qwen-VL 的训练采用三个比较清楚的阶段。第一阶段主要进行视觉和语言对齐，核心目标是让视觉 Encoder 输出的特征能够对应正确的文字描述；第二阶段加入更加复杂的多模态任务，包括图像描述、视觉问答、OCR、Grounding、多图输入、图文交错数据等，使模型不仅能够描述图片，还能理解图片中的文字、区域和关系；第三阶段进行多模态 Instruction Tuning，使模型学习按照用户指令围绕图片进行对话，最终形成 Qwen-VL-Chat。Qwen-VL 技术报告把视觉感知、语言理解、文字阅读和定位能力作为这一代模型的主要目标。



所以如果要用一句比较准确的话概括 Qwen-VL：它完成了“ViT 提取图片特征 → Cross-Attention Adapter 压缩并完成视觉语言对齐 → 固定数量视觉 Token 输入 Qwen”的第一代视觉语言架构。

它最大的局限是：固定分辨率、固定视觉 Token 数，以及图片和视频还没有真正使用统一的表示方式。




二、Qwen-VL-Plus / Qwen-VL-Max

Qwen-VL-Plus 和 Qwen-VL-Max 更适合认为是第一代 Qwen-VL 的能力增强版本。官方在这一阶段重点展示了更强的高分辨率图片理解、文字识别、文档分析、图表理解和复杂视觉推理能力，尤其是对于图片中的小文字和复杂页面，能力相比早期 Qwen-VL 明显增强。官方还强调了高分辨率识别以及文档理解等方向。

但是需要特别注意，Qwen 团队没有像后来的 Qwen2-VL 那样为 Qwen-VL-Plus 和 Qwen-VL-Max 单独发布完整的技术报告，因此更准确的说法应该是：这一时期证明了高分辨率、OCR、文档和复杂视觉输入的重要性，并为 Qwen2-VL 的 **Dynamic Resolution** 架构铺垫了需求。

三、Qwen2-VL

技术报告：Qwen2-VL: Enhancing Vision-Language Model's Perception of the World at Any Resolution (<https://arxiv.org/pdf/2409.12191>)



Qwen2-VL 是整个 Qwen 图片多模态发展史中非常重要的一代。Qwen-VL 最大的问题之一是输入图片通常需要经过比较固定的 **Resize**，并且最终会压缩成固定数量视觉 **Token**。对于普通照片，这个问题可能不明显，但对于网页截图、论文页面、表格、地图、手机长截图等输入，**Resize** 很容易造成文字缩小、形状改变或者大量细节丢失。Qwen2-VL 因此从最前面的图片处理阶段就进行了修改，提出了 **Naive Dynamic Resolution**，也就是**动态分辨率机制**。允许不同大小、不同比例的图片产生不同数量的视觉 **Token**。小图片产生较少 **Token**，大图片产生较多 **Token**，长图可以继续保持长图结构，而不必全部被强制变成固定尺寸的正方形。官方把 **Dynamic Resolution** 和 **M-RoPE** 列为 Qwen2-VL 最重要的架构创新。

这次变化意味着 Qwen 的视觉表示从 **固定长度视觉序列**变成了**可变长度视觉序列**。例如，如果一张图片内部只有比较少的 **Patch**，那么进入语言模型的视觉 **Token** 数量也比较少；如果一张图片非常大，模型就允许它产生更多 **Patch**，从而为更多细节分配更多 **Token**。这对于 **OCR** 和文档理解非常关键，因为文字较多的图片本身就需要更高的信息容量。Qwen2-VL 由此不再要求“所有图片使用相同的信息预算”，而是让视觉计算量开始跟随图片尺寸变化。

但是 **Dynamic Resolution** 会带来一个新的问题：以前图片尺寸基本固定，因此视觉 **Transformer** 可以使用固定的位置编码；现在图片可能形成不同高度、不同宽度的 **Patch** 网格，原来的固定二维位置编码就不够方便。因此 Qwen2-VL 在视觉 **Encoder** 中使用了 **2D-RoPE**，也就是二维 **Rotary Position Embedding**。这里可以简单理解成，每一个视觉 **Patch** 不仅拥有自己的内容特征，同时还需要知道自己位于图片的哪个横向位置和哪个纵向位置。这样即使图片尺寸发生变化，模型仍然可以正确理解上、下、左、右等位置关系。对于文本，位置关系主要是一维前后顺序；对于图片，则必须保存二维空间结构。这也是 Qwen2-VL 开始更加明确地区分文本位置和视觉位置的重要一步。

Qwen2-VL 同时彻底改变了第一代的 **Visual Adapter**。Qwen-VL 使用 **Cross-Attention Query**，把图片统一压缩成固定数量视觉 **Token**；Qwen2-VL 则使用一个更加简单的 **Vision-Language Merger**。它会把空间上相邻的视觉 **Patch** 进行合并，再通过 **MLP** 映射到语言模型需要的 **Hidden Dimension**。最典型的是把邻近的 2×2 **Patch** 合并，也就是说原本四个相邻视觉特征最后形成一个输入语言模型的视觉 **Token**。这会


显著减少视觉 Token 数量，但不会像 Qwen-VL 那样强制所有图片都压缩成完全一样的长度。因此 Qwen2-VL 的视觉 Token 数仍然会随着图片面积变化，只是经过 Merger 后数量大约进一步减少。

Qwen 的视觉前端从：ViT → Cross-Attention Query → 固定长度

变成：Dynamic Resolution ViT → Spatial Merge → 可变长度视觉 Token。

这套结构后来一直延续到了 Qwen2.5-VL 和 Qwen3-VL。

Qwen2-VL 第二项架构创新是 **M-RoPE**，也就是 **Multimodal Rotary Position Embedding**。它解决的问题是：文字、图片和视频的位置结构并不相同。文字只有一维顺序；图片拥有高度和宽度两个维度；视频除了高度和宽度之外，还有时间维度。因此 Qwen2-VL 把位置关系拆成三个部分：**Temporal、Height、Width**，也就是**时间、高度、宽度**。对于文本，这三个位置值保持相同，因此整体效果接近普通语言模型的一维 RoPE；对于图片，时间位置基本保持不变，而 Height 和 Width 随视觉 Patch 在图片中的位置改变；对于视频，则三个维度都会发挥作用，Temporal 描述帧之间的时间关系，Height 和 Width 描述每一帧内部的二维空间关系。



这使 Qwen2-VL 第一次真正建立了一套统一的文字—图片—视频位置系统。图片不再只是特殊的文字 Token，视频也不需要完全独立的位置编码，而是都可以通过同一个多模态位置编码框架进入 Transformer。M-RoPE 实际上解决的是不同模态在同一 **Transformer** 中如何拥有各自正确的位置关系。

Qwen2-VL 同时进一步统一了图片和视频的视觉处理。图片是二维 Patch，而视频还多一个时间维度，因此 Qwen2-VL 在视频中引入 **Temporal Patch**，把连续的视频帧组织成时空视觉单元，再交给 Vision Transformer。这样图像和视频可以尽量共享同一套视觉 Encoder、Merger 和语言模型，而不是维护完全独立的 Image Model 与 Video Model。官方技术报告明确强调 Qwen2-VL 使用统一范式处理图片和视频。



固定图片 → 动态图片
 固定视觉 Token → 可变视觉 Token
 Cross-Attention 压缩 → Spatial Merge
 普通位置编码 → 2D-RoPE + M-RoPE
 图片模型 → 图片与视频统一模型
 这可以认为是 Qwen 多模态架构历史上的第一次换代。


四、QVQ-72B-Preview

QVQ-72B-Preview 并不是 Qwen2-VL 之后的新一代 Vision Encoder，而是建立在 **Qwen2-VL-72B** 基础上的视觉推理模型。官方明确把它定位为一个实验性的 Multimodal Reasoning Model，重点研究视觉任务中的复杂推理，而不是重新设计 Dynamic Resolution、Visual Merger 或 M-RoPE。

因此 QVQ 最大的变化发生在后训练和模型行为上。传统 Qwen2-VL 更倾向于“输入视觉内容 → 理解 → 回答”，而 QVQ 开始让模型在视觉数学、科学、图形推理等问题上生成更长的思考过程。这条路线后来继续发展成 Qwen3-VL 的 Thinking 模型。

五、Qwen2.5-VL

技术报告：Qwen2.5-VL Technical Report (<https://arxiv.org/abs/2502.13923>)




Qwen2.5-VL 仍然保持 **Vision Encoder → Vision-Language Merger → Language Model** 的形式，但它重新设计了 Vision Transformer 本身，使 Dynamic Resolution 真正可以应用到更高分辨率、更复杂、更长的现实输入。官方明确指出 Qwen2.5-VL 从头训练了一个 **Native Dynamic-Resolution Vision Transformer**。视觉 Encoder 内部也开始采用与现代大语言模型更加接近的组件，例如 RMSNorm 和 SwiGLU。

Qwen2.5-VL 在 Vision Transformer 中最值得关注的改变是 **Window Attention**。Qwen2-VL 的 Dynamic Resolution 有一个自然的问题：图片越大，产生的视觉 Token 越多。如果每一层 ViT 都让所有视觉 Token 相互进行 Attention，那么高分辨率图片的计算量会非常高。Qwen2.5-VL 因此让大多数视觉 Transformer 层只在局部窗口内部进行 Attention，而周期性地安排少数 Global Attention 层进行整张图片的信息交换。这样做的结果是，模型在绝大多数层主要处理局部细节，例如局部文字、边缘、纹理和小区域结构；经过若干层以后，再通过 Global Attention 把不同区域的信息结合起来。官方技术报告将 Native Dynamic-Resolution ViT 和 Window Attention 明确列为这一代降低视觉计算开销的关键技术。因此 Qwen2.5-VL 才第一次比较完整地把“原生高分辨率输入”从一个表示方法变成一个具有实际计算可行性的视觉架构。

Vision-Language Merger 这一部分则延续 Qwen2-VL 的主要思路，即把相邻视觉 Patch 合并，再通过 MLP 映射到 LLM 的 Hidden Dimension。这说明 Qwen 团队已经认为 2x2 Spatial Merge 是一个比较成熟的视觉 Token 压缩方案，没有必要重新使用 Qwen-VL 第一代的 Cross-Attention Query。这样模型既能保持动态视觉 Token 数量，又可以显著降低进入语言模型的视觉序列长度。

Qwen2-VL 已经拥有 Temporal、Height、Width 三维 M-RoPE，但视频采样通常仍然比较固定。例如同样取 100 帧，如果一个视频是 10FPS，另一个视频是 60FPS，那么这 100 帧代表的真实时间长度完全不同。Qwen2.5-VL 因此引入 **Dynamic FPS Training**，让训练中的视频使用不同帧率进行采样，同时把 Temporal Position 与真实时间建立更直接的对应。这样模型不再只知道“这是视频中的第几个采样位置”，而开始能够理解“这个画面大约发生在视频的第几秒”。模型不仅需要回答视频里出现了什么，还要回答“什么时候出现”“事件持续多久”“某个动作发生在什么时间段”。如果时间位置只表示帧序号，模型很难稳定理解真实时间；加入 Absolute Time 后，时间 Grounding 就可以变得更加明确。因此 Qwen2.5-VL 开始支持小时级视频理解，并能

进行秒级事件定位。



Qwen2.5-VL 在空间坐标上也发生了一个非常重要的变化。早期 Qwen-VL 往往把坐标归一化到统一范围，这样语言模型不需要考虑图片究竟是 800×600 还是 2000×1500。但 Qwen2.5-VL 开始使用图片本身尺寸对应的实际坐标体系。这意味着模型输出坐标时，需要理解当前图片的实际宽度和高度。这样 Grounding 与 Native Resolution 就更加统一：模型看到的是图片真实尺度，输出的位置也对应这一尺度。对于目标定位、Pointing、GUI 点击和 Computer Use，这种设计更加自然。

Qwen2.5-VL 的另一个重大变化是 **Document Parsing**。以前所谓 OCR 主要意味着“识别图片中的文字”，但真实文档还有标题、段落、表格、公式、图片、图注和布局。Qwen2.5-VL 因此训练模型直接恢复文档的结构，而不只输出文字内容。这让模型能够处理论文页面、票据、表单、报表、网页和复杂图表，并把视觉区域和对应文字结构联系起来。官方技术报告特别强调 Qwen2.5-VL 在 Document Parsing、Invoice、Form、Table、Chart、Diagram 等任务上的能力。

对于 GUI Agent，模型需要连续完成几个步骤：读取当前截图、识别界面元素、确定需要操作的目标、输出点击位置或其他动作、获得新的截图，再继续推理。Qwen2.5-VL 在训练中加入了大量 Computer、Phone 和 GUI Interaction 数据，因此 Bounding Box 和 Pointing 能力不再只是视觉 Benchmark，而开始成为真正的 Agent Action Interface。官方技术报告明确将其描述为能够进行 reasoning、tool usage 和真实电脑、手机任务执行的 Interactive Visual Agent。

Dynamic Resolution 保留，Vision Transformer 本身重新设计；

全局视觉 Attention → Window Attention 为主、Global Attention 为辅；

固定视频采样 → Dynamic FPS；

帧位置 → 真实时间；


归一化坐标 → Native Coordinate；

普通 OCR → Document Parsing；


六、Qwen2.5-Omni

技术报告：Qwen2.5-Omni Technical Report (<https://arxiv.org/abs/2503.20215>)

Qwen2.5-Omni 是另一条非常重要的扩展路线。Qwen2.5-VL 主要处理 Text、Image 和 Video，而 Qwen2.5-Omni 开始同时处理 Text、Image、Video 和 Audio，并且能够生成文本和实时语音。也就是说，图片不再是唯一的非文本输入，视觉系统开始和音频系统共同进入一个统一模型。




这一代最重要的架构设计是 **Thinker-Talker**。Thinker 主要负责理解输入、进行多模态推理并生成文字，而 Talker 使用 Thinker 提供的高层表示生成语音 Token。这样模型既可以理解图片、视频和声音，又可以直接进行流式语音回答。为了让视频和音频在时间上正确对应，Qwen2.5-Omni 又提出 **TMRoPE**，也就是 **Time-aligned Multimodal RoPE**，将音频和视频按照时间进行对齐。




七、Qwen3-VL

技术报告：Qwen3-VL Technical Report (<https://arxiv.org/abs/2511.21631>)



Qwen3-VL 仍然保留 Qwen2-VL 和 Qwen2.5-VL 建立起来的总体结构，即 **Vision Encoder → Vision-Language Merger → Language Model**，但是视觉 Encoder、位置编码以及视觉和语言之间的融合方式都进行了重要升级。官方把 Qwen3-VL 的三项关键架构创新明确总结为：**Interleaved-MRoPE**、**DeepStack** 和 **Text-based Time Alignment**。模型同时提供 Dense 和 MoE 两类架构，并原生支持最高 256K 的图文视频交错上下文。



首先是 Vision Encoder。Qwen3-VL 开始采用 **SigLIP-2** 系列视觉 Encoder 作为重要初始化基础。SigLIP-2 本身已经经过大规模图片和文本对齐训练，因此它提供了比较成熟的视觉语义表示。Qwen3-VL 在此基础上继续进行 **Dynamic Resolution Training**，并继续使用适合二维图片位置的设计。这说明 Qwen 并没有放弃从 Qwen2-VL 开始建立的 **Dynamic Resolution** 路线，而是在更强的视觉基础模型上继续进行动

态视觉建模。

Vision-Language Merger 的总体思想也没有推翻。模型仍然会压缩相邻视觉特征，并把视觉 Hidden Dimension 映射成 Qwen3 LLM 所需要的维度。真正发生重大变化的是：**Qwen3-VL 不再只使用 Vision Transformer 最后一层的视觉结果。**

DeepStack

Vision Transformer 不同深度提取到的信息并不完全相同。前面的视觉层会保留更多局部细节，例如边缘、细小文字、局部形状和纹理；经过更多 Transformer Layer 后，表示逐渐变得更加抽象，更适合表达整个物体、场景以及高级语义。过去如果只拿 ViT 最后输出的视觉特征交给语言模型，一部分早期视觉细节可能已经被高层抽象过程弱化。对于普通图片描述问题影响不一定很大，但对于 OCR、表格、Chart、GUI 和复杂空间关系，这些细节可能非常重要。

Qwen3-VL 的 DeepStack 因此从 Vision Transformer 的**多个不同深度**提取视觉特征，然后分别通过对应的 Vision-Language Merger 转换成语言模型能够接收的 Hidden State，并把这些视觉信息注入语言模型前部的多个层。这样，LLM 在早期计算过程中就可以同时获得不同层级的视觉表示，而不是只在输入时看到一次已经高度处理过的最终视觉 Token。官方技术报告将 DeepStack 描述为利用 Multi-level ViT Features 来增强 Vision-Language Alignment。

Qwen-VL: 视觉特征 → Cross-Attention Adapter → LLM

Qwen2-VL / Qwen2.5-VL: 视觉特征 → MLP Merger → Visual Tokens → LLM 输入


Qwen3-VL: 不同 ViT 深度的视觉特征 → 多级 Merger → 注入 LLM 多个层级

因此 Qwen3-VL 的多模态融合开始从主要的**输入级融合**向更加明显的**层级融合**发展。

第二个创新是 **Interleaved-MRoPE**。Qwen2-VL 已经拥有 Temporal、Height、Width 三部分 M-RoPE，但原本不同维度在 RoPE 的不同频率区域中分配并不完全均衡。Qwen3-VL 因此重新排列 Temporal、Height 和 Width 在位置编码维度中的分布，让三个维度更加交错地使用不同频率的位置表示。这样时间、高度和宽度都能够同时利用不同尺度的位置信息，对长视频、复杂空间关系和长距离视觉关系更加友好。

第三个变化是视频中的 **Text-based Time Alignment**。这里实际上是一次很有意思的技术调整。Qwen2.5-VL 尝试把视频真实时间直接编码进 Temporal Position，但 Qwen3-VL 进一步发现，对于特别长的视频，这可能让时间位置变得非常大，而且模型需要适应大量不同 FPS。于是 Qwen3-VL 开始直接把时间戳以文本形式放进上下文，例如告诉语言模型当前视觉片段对应视频中的某个具体时间。这样模型可以直接利用自身语言理解能力处理时间，而不必完全依赖隐式的位置编码。官方把它描述为从 T-RoPE 演进到 Explicit Textual Timestamp Alignment。

Qwen3-VL 还有一个很重要的扩展是 **256K 原生多模态上下文**。这意味着一个上下文里面可以连续出现长文本、多张图片、文档页面和视频，而模型需要跨很远的位置继续查找、比较和引用视觉内容。因此视觉模型开始真正面向多页 PDF、长视频、多图片分析和持续 Agent Interaction，而不再局限于“单张图片 + 一个问题”。官方技术报告明确说明 Qwen3-VL 原生支持最高 256K 的 Interleaved Text-Image-Video Context。



与此同时，Qwen3-VL 正式把 **Thinking** 引入主系列。它同时发布 **Instruct** 和 **Thinking** 版本，视觉数学、STEM、空间推理和复杂视频任务开始使用更加系统的多步推理训练。这意味着 QVQ 时期作为独立实验存在的视觉 Reasoning 路线已经被合并进正式 Qwen-VL 主干。

所以 Qwen3-VL 的变化可以概括为：

更强 Vision Encoder；Dynamic Resolution 继续保留；

视觉最后一层 → 多层视觉特征；

Visual Tokens 只在入口出现 → DeepStack 多层注入；

M-RoPE → Interleaved-MRoPE；


隐式视频时间 → 显式 Text Timestamp；

短多模态上下文 → 256K 原生图文视频上下文；


普通 Instruct → Instruct + Thinking

八、Qwen3-Omni

技术报告：Qwen3-Omni Technical Report (<https://arxiv.org/abs/2509.17765>)




Qwen3-Omni 延续 Qwen2.5-Omni 的 Thinker-Talker 架构,但是将系统进一步扩展到 MoE, 并加强 Audio、Video、Vision 与 Reasoning 的统一。Thinker 负责多模态理解和文本推理, Talker 负责实时语音输出。相比 Qwen2.5-Omni, Qwen3-Omni 的 Thinker 和 Talker 都开始采用 MoE, 并重新设计音频 Encoder 和多 Codebook 语音生成系统。官方技术报告同时强调 Qwen3-Omni 能在保持视觉能力的情况下加入更强的音频能力。



对于图片主线而言, Qwen3-Omni 的重点是让视觉成为一个更大的 Omni System 中的组成部分。模型能够同时根据图像、视频和声音进行推理, 而且 Thinking 模型可以跨音频和视觉信息进行联合推理。

Qwen2.5-VL / Qwen3-VL: 视觉语言主线

Qwen2.5-Omni / Qwen3-Omni: 在视觉语言基础上增加完整音频感知和语音生成两条路线互相影响, 但并不是完全相同的架构发展线。



九、Qwen3.5

Qwen3.5 则开始强调 **Unified Vision-Language Foundation**。官方明确写到使用 **Early Fusion Training on Multimodal Tokens**。这里的重点在于，从基础模型训练比较早的阶段，就让视觉和文本数据共同参与模型训练，而不是先得到一个几乎完全成熟的纯文本 LLM，再单独进行视觉适配。因此视觉理解、语言推理、Coding、Agent 等能力开始更早共享同一个基础模型训练过程。

Qwen3.5 的另一个非常重要的变化发生在语言主干。它采用 **Hybrid Architecture**，把 **Gated DeltaNet** 和传统的 **Full Attention** 混合使用。以公开的 397B-A17B 模型为例，共有 60 层，整体按照“连续 3 层 Gated DeltaNet + 1 层 Gated Attention”的模式重复 15 次。Gated DeltaNet 属于更加适合长序列高效计算的序列建模结构，而周期性 **Full Attention** 则继续提供全局 Token 之间的直接交互。

因为多模态输入天然非常长，一张高清图片可能产生大量视觉 Token，多张文档页面会进一步增加长度，视频还会产生更长的视觉序列。如果每一层全部采用 **Full Attention**，计算压力会越来越大。Qwen3.5 因此不只是在继续优化 **Vision Encoder**，而开始优化整个视觉—文本联合长序列的主干计算方式。这说明 Qwen 多模态架构的关注重点正在从“图片怎么 Token 化”扩展到“几十万多模态 Token 怎么高效计算”。官方模型卡显示 Qwen3.5 原生 **Context Length** 为 262,144，并可扩展到约 1,010,000 Token。

Qwen3.5 同时大规模使用 **MoE**。例如 397B-A17B 拥有约 397B 总参数，但每个 Token 实际激活约 17B 参数；模型拥有 512 个 **Experts**，其中每次激活一部分

Routed Experts，并额外使用 Shared Expert。MoE 的意义主要是让模型拥有非常大的总知识容量，同时避免每个 Token 都经过全部模型参数。对于同时处理视觉、语言、代码、数学、Agent 等大量类型数据的 Foundation Model，这种架构可以在模型容量和单次计算成本之间取得更好的平衡。

Qwen-VL：给 Qwen 增加视觉能力。

Qwen2-VL / Qwen2.5-VL / Qwen3-VL：构建越来越强的专用 Vision-Language Foundation Model。


Qwen3.5：基础 Qwen 模型本身开始被训练成原生 Vision-Language Foundation。因此从 Qwen3.5 开始，“VL”越来越不必作为一个完全独立的模型分支存在。

十、Qwen3.5-Omni

技术报告：Qwen3.5-Omni Technical Report (<https://arxiv.org/abs/2604.15804>)



Qwen3.5-Omni 延续 Omni 路线，但进一步扩大规模，并让 Thinker 和 Talker 都使用 **Hybrid Attention MoE**。官方技术报告显示，这一代模型使用大规模 Text-Vision 数据以及超过一亿小时 Audio-Visual 数据，并支持 256K Context。



Qwen3.5 的 Hybrid Architecture 开始进入 Omni 模型：也就是说，Gated DeltaNet、Full Attention、MoE 不只服务纯文本和视觉语言，也开始负责 Audio-Visual 长序列。Qwen 的整体方向已经越来越明确：统一不同模态之后，问题变成怎样高效处理非常长的多模态序列。

十一、Qwen3.6

语言模型总参数约 35B，每次约激活 3B；拥有 40 层，内部继续采用：3 个 Gated DeltaNet 层 + 1 个 Gated Attention 层，组成一个重复单元，同时使用 MoE。原生 Context Length 为 262,144，并可以扩展到约 1,010,000 Token。

因此从底层方向看，Qwen3.6 并没有公开宣布像 Qwen3-VL 的 DeepStack 那样一个新的视觉融合机制。它主要继续强化 Qwen3.5 已经建立的 **Unified Vision-Language + Hybrid Architecture**，并把模型重点转向 Agentic Coding、Frontend、Repository Reasoning、Visual Understanding 和真实 Agent 工作流。官方 Qwen3.6-27B 同样明确说明它是 Natively Multimodal，可以同时处理图片、视频和文本，并支持视觉语言的 Thinking 与 Non-Thinking。

十二、Qwen3.7 / Qwen3.7-Plus

Qwen3.7 尤其是 Qwen3.7-Plus 的重点已经明显从传统 Vision-Language Benchmark 转向 **Multimodal Agent Intelligence**。官方将 Qwen3.7-Plus 描述为一个将 Vision 和 Language 统一到 Agent Foundation 中的多模态模型，并强化视觉输入、代码生成、GUI、工具调用和复杂工作流。

早期 Qwen-VL 中，一张图片主要是一个需要回答问题的输入；到了 GUI Agent

场景，图片可能是每一步操作后的屏幕状态。模型需要不断读取新截图，判断页面变化，然后决定下一步动作。因此视觉系统不只是“理解一个静态输入”，而是成为 Agent 持续获取环境状态的输入通道。Qwen3.7-Plus 特别强调了 Multimodal Agent 和 Visual Coding，也就是模型可以直接根据图片、UI、视频等视觉输入完成代码和交互任务。

十三、Qwen3.8-Max

Qwen3.8-Max 是目前 Qwen 官方主线中最新的重要版本之一。官方表示 Qwen3.8-Max 建立在 Qwen3.5 架构基础之上，并将规模扩大到约 **2.4T 参数**，重点强化 Coding、Cowork、Research、Long-Horizon Tasks 和多模态 Agent。官方对这一代的视觉描述已经明显不是传统的“图片问答”，而是强调 Multimodal Agent 通过视觉持续理解、行动和完成工作。

Qwen3.8-Max 继续使用原生多模态 Agent 路线，并建立在 Qwen3.5 之后的 Hybrid Architecture 基础上。