

VisualGLM

导论

GLM (General Language Model) 是由清华大学知识工程实验室 (KEG) 与智谱 AI 团队持续研发的大语言模型体系, 也是国内较早形成完整技术路线的大模型系列之一。GLM 最初提出的核心目标, 是在一个统一的 Transformer 框架中同时兼顾自然语言理解与文本生成能力。早期 GLM 通过自回归空白填充等预训练方式探索统一语言建模, 随后逐步发展出 GLM-130B、ChatGLM、ChatGLM2、ChatGLM3 和 GLM-4 等语言模型, 并在此基础上继续向代码生成、工具调用、视觉理解、复杂推理和智能体等方向扩展。

GLM 系列的发展是持续对模型架构、注意力机制、位置编码、训练数据和后训练方法进行调整。早期 GLM 更关注统一预训练范式, ChatGLM 阶段开始重点解决大模型对话能力和低成本部署问题, 随后又不断引入更长上下文、更高效的注意力结构、更完善的指令微调和人类偏好对齐方法。进入 GLM-4 之后, 整个模型体系逐渐从单纯的语言模型发展为能够完成推理、代码生成、搜索、工具调用和 Agent 任务的通用基础模型。GLM-4.5 等后续模型进一步采用 MoE 等架构, 使模型可以在扩大总体模型容量的同时控制单次推理所需要激活的参数量, 从而兼顾模型能力与计算效率。

视觉多模态是 GLM 技术体系中非常重要的一条发展路线。早期 VisualGLM-6B 通过视觉编码器和 Q-Former 将图像信息连接到 ChatGLM, 使语言模型首次获得图像理解和视觉问答能力。随后 CogVLM 提出了 Visual Expert, 在 Transformer 内部为视觉 Token 引入专门的注意力和前馈网络参数, 使视觉与语言从简单的输入层连接发展为更深层次的特征融合。CogAgent 和 CogVLM2 又进一步解决高分辨率图像、GUI、OCR 和视频理解问题。到了 GLM-4V、GLM-4.1V、GLM-4.5V 等阶段, GLM 的视觉模型逐渐形成以视觉编码器、视觉投影模块和大语言模型 Decoder 为核心的统一架构, 同时加入原生分辨率处理、二维和三维位置编码、视频时序建模以及大规模多模态强化学习, 使模型从基本的“看图回答问题”发展到复杂视觉推理、文档理解、GUI 操作和视频分析。


在训练方法方面, GLM 系列也逐渐从传统的“预训练 + 指令微调”发展为更加完整的大模型训练体系。预训练阶段使用大规模文本、代码以及多模态数据建立基础知识和生成能力; 监督微调阶段让模型学习遵循人类指令; 随后再利用偏好优化和强化学习改善复杂推理、工具调用以及答案质量。特别是在较新的多模态模型中, 强化学习已经不仅用于改善语言回答, 还被扩展到数学、科学、视觉问答、OCR、Grounding、GUI、视频和 Agent 等不同任务, 使模型能够在统一框架中学习感知、推理和行动。

GLM 已经从最初解决自然语言统一建模问题的语言模型, 逐渐发展为覆盖文本、图像、视频、代码和工具调用的通用多模态模型体系。其技术重点也经历了从语言预训练、对话能力、长上下文和模型效率, 到视觉语言融合、复杂推理、强化学习以及智能体能力的连续变化。特别是近年来, GLM 的目标已经不再局限于让模型生成高质量文本, 而是让模型能够理解复杂环境中的多种信息, 在此基础上进行推理、规划、调用工具并完成实际任务。

一、GLM

技术报告：GLM: General Language Model Pretraining with Autoregressive Blank Infilling (<https://arxiv.org/pdf/2103.10360>); ChatGLM: A Family of Large Language Models from GLM-130B to GLM-4 All Tools (<https://arxiv.org/pdf/2406.12793>)

GLM 最初并不是多模态模型。2021 年提出的 GLM，目标是建立一种既能完成语言理解、又能完成语言生成的统一 Transformer 预训练框架。早期 GLM 使用自回归空白填充训练方式，并设计了二维位置编码等机制；随后 GLM-130B、ChatGLM-6B、ChatGLM2、ChatGLM3 一路发展，逐渐形成智谱和清华 THUDM 后续模型使用的语言基础设施。后面的 VisualGLM 首先选择“不重新训练一个视觉语言 Transformer”，而是在已经具有语言能力的 ChatGLM 前面增加视觉模块，让图像最终变成 ChatGLM 能够处理的信息。也就是说，GLM 多模态路线最开始就是典型的“保留成熟 LLM，再给它增加视觉接口”。



这种思路决定了之后几年 GLM-V 的基本结构。无论是 VisualGLM 的 Q-

Former，还是后来 GLM-4V、GLM-4.1V、GLM-4.5V 的视觉编码器和 Projector，本质上都需要解决同一个问题：图像首先由一个视觉网络理解，但视觉网络输出的是视觉特征，而语言模型处理的是语言 Token 表示，因此必须设计某种机制把视觉特征转换到语言模型能够处理的表示空间。真正发生巨大变化的地方，是这个“视觉—语言接口”到底应该只放在输入端，还是应该深入语言模型内部。这个问题直接催生了后来的 CogVLM。

二、VisualGLM-6B

VisualGLM-6B 可以看作 GLM 视觉路线真正意义上的第一代。它直接采用已经训练好的 **ChatGLM-6B** 作为语言模型，再增加视觉编码和视觉语言对齐部分。ChatGLM-6B 本身约有 62 亿参数，而 VisualGLM 加入视觉部分后整体约为 78 亿参数。它的总体处理路径可以概括为：**图像 → 视觉编码器 → BLIP-2 Q-Former → ChatGLM-6B → 文本回答**。其中 Q-Former 负责读取视觉编码器生成的大量图像特征，再提取出语言模型比较容易接收的一组视觉表示，从而建立图像空间和 ChatGLM 语言空间之间的连接。官方明确说明 VisualGLM 的图像部分采用训练 BLIP-2 Q-Former 的方式建立视觉模型和语言模型之间的桥梁。

这一代方案属于当时非常典型的“视觉编码器 + Connector + LLM”架构。图像并不会从 ChatGLM 第一层开始就在所有 Transformer 层里拥有自己独立的视觉计算路径，而是首先被视觉网络提取，再由 Q-Former 压缩和转换，最后送进语言模型。它的优势非常明显：不需要破坏已经训练好的 ChatGLM，可以利用大量现成语言能力，训练成本相对可控，并且能够快速让 ChatGLM 获得图片描述、视觉问答以及多轮图文对话能力。但它的瓶颈也同样明显：**视觉信息在进入语言模型之前已经经过一次较强压缩，视觉和语言之间主要依赖一个连接模块完成对齐**。当任务需要细粒度目标识别、OCR、复杂空间关系或者非常密集的视觉信息时，这种结构就容易受到限制。VisualGLM 官方也承认当时模型存在图像细节捕捉不足、事实性和视觉幻觉等问题。

VisualGLM 在数据层面也确立了后来 GLM-V 非常重要的一个特点：**中英文视觉语言共同训练**。官方披露，其预训练使用来自 CogView 的约 3000 万高质量中文图文对，以及约 3 亿经过筛选的英文图文对，并让中英文数据在训练时保持相同权重。预训练首先解决“图片内容如何映射到语言语义空间”的问题，之后再使用较长的视觉问答数据进行微调，使模型能够按照人类对话习惯回答图片相关问题。因此这一阶段 GLM 多模态技术的重点不是复杂推理，而是三个基础问题：让模型“看到图片”、让视觉信息和中文/英文语言语义对齐，以及让模型能够以对话形式回答视觉问题。

VisualGLM 最大的历史意义验证了 ChatGLM 可以通过一个相对独立的视觉桥接模块迅速转变成 VLM。但它也暴露了“只在输入端做视觉语言对齐”的上限。后来的 CogVLM 研究正是直接针对这个问题提出：只把视觉特征映射到 LLM 输入空间属于相对浅层的融合，如果视觉 Token 在进入语言模型以后仍然完全沿用为文本设计的参数，那么模型没有真正针对视觉表示建立足够强的内部处理能力。于是 GLM 视觉路线进入了第二阶段——**从视觉接口转向视觉专家**。

三、CogVLM

技术报告：CogVLM: Visual Expert for Pretrained Language Models

(<https://arxiv.org/pdf/2311.03079>)

CogVLM 是整个 GLM 视觉技术路线中第一次非常重要的架构转折。严格来说，CogVLM 的语言骨干并不是 ChatGLM，而是使用了 7B 级语言模型，因此它不能简单理解成“某一代 GLM-V”；但是 CogVLM、CogAgent、CogVLM2 与后来的 GLM-4V 是同一支 THU DM / 智谱视觉语言研究路线，而且 CogVLM2 官方论文直接把 VisualGLM、CogVLM、CogVLM2 和 GLM-4V 描述为连续发展的 VLM 系列，所以如果研究 GLM 图片多模态架构，CogVLM 是不能跳过的。CogVLM-17B 大约由 70 亿语言参数与约 100 亿视觉相关参数组成，使用 EVA2-CLIP-E 视觉编码器、MLP Adapter、预训练语言模型以及最重要的 **Visual Expert**。

CogVLM 最核心的创新，就是不再认为“把视觉特征转换成语言模型输入维度”就足够了。它在 Transformer 的每一层都增加了专门处理视觉 Token 的参数。在注意力模块中加入视觉专用的 Q、K、V 投影，在 FFN 中也加入视觉专用的前馈网络；文字 Token 继续使用原来的语言模型参数，视觉 Token 则进入 Visual Expert 参数。这样，文本和视觉信息仍然可以通过统一的自注意力互相交互，但是视觉信息在每一层都有一套更适合自身特征分布的变换。官方把这种设计概括为 **deep visual-language feature alignment**，也就是视觉与语言不是只在模型入口对齐一次，而是在 Transformer 网络深层持续进行融合。

OCR-Free Reasoning




Q1: What did Musk say?

CogVLM: Elon Musk in the tweet said: "Fight Recap: I joked on X about fighting Zack, Zack then said, 'Send ME LOCATION.' Italy graciously offered a Colosseum, but Zack declined. I suggested his home as a 'safe space.' Tragically, he was slain 'traveling.' Is there anywhere he will fight?"

Q2: Do you think Zack is really traveling?

CogVLM: Based on the content of the tweet, it seems that Zack is not really traveling, but rather pretending to be traveling in order to avoid the conflict.

Meme Understanding



Q: Can you explain this meme?

CogVLM: This meme is a humorous take on the idea that certain drugs, like cocaine, are believed to have no side effects. The meme uses a fictional meeting of various mythical creatures, each with a unique and exaggerated appearance, to represent the different effects of cocaine. The text at the top of the image, 'Publicly, we are not saying there are no side effects,' is a statement often made by pharmaceutical companies or health organizations about certain drugs. The creatures in the meeting, with their various and often comical expressions and postures, humorously represent the different 'side effects' of cocaine, suggesting that the drug has a wide range of unintended effects.

World Knowledge



Q: How many goals did the person in the picture score in the 2018 World Cup?

CogVLM: The person in the picture is Cristiano Ronaldo. He is the captain of the Portuguese team and has participated in the 2018 World Cup. In the 2018 World Cup, Cristiano Ronaldo scored 4 goals.

Detailed Description



Q: Describe this image in detail.

CogVLM: The image showcases a railway platform labeled 'Platform 2'. A green train is approaching, with steam emanating from its engine. On the platform, there are several people, including a woman in a pink shirt, a child with a backpack, and a man in a green shirt. There's a chalkboard sign on the platform that reads: 'Please Use The Footbridge To Cross The Line If You Require Assistance. Please Ask The Station Staff.' In the background, there's a signal post and some trees.

Visual Reasoning



Q: From the perspective of a photographer, analyze why this picture was taken well?

CogVLM: From a photographer's perspective, several elements contribute to the quality of this image. The composition is balanced, with the hot air balloon taking up a significant portion of the frame, yet still allowing the surrounding environment to be visible. The use of lighting, especially the soft glow from the balloon and the car's headlights, creates a warm and inviting atmosphere. The depth of field is shallow, focusing on the subjects in the foreground while softly blurring the background, drawing attention to the main elements of the scene.

Grounding with Caption

Q: Can you provide a description of the image and include the coordinates [x0,y0,x1,y1] for each mentioned object?

CogVLM: A piggy bank [302,198,694,857] with a smile [400,520,582,643] on it is surrounded by coins [1028,820,986,997], toy houses [1052,697,174,892; 526,763,636,952; 168,697,286,883; 738,697,852,895], and greenery.






Chart Understanding & Reasoning



Q: What is the difference of largest and smallest bar? Answer it step by step.

CogVLM: The largest bar represents Iceland with a percentage of 100%. The smallest bar represents Cambodia with a percentage of 52.4%. To find the difference, subtract the smallest percentage from the largest: $100\% - 52.4\% = 47.6\%$.

Referring Expression Comprehension



Grounding Visual Question Answering

Q1: What color are the clothes of the girl whose hands are holding flowers? Let's think step by step.

CogVLM: Find the flowers [328,519,436,780]. Check the girl holding it, got the girl [116,069,450,927]. Check the clothes of it, got the clothes [1134,309,418,852]. The clothes [1134,309,418,852] are blue. So the answer is blue.




Q2: What color are the jeans of the girl whose hands are not holding flowers? Let's think step by step.

CogVLM: Find the not(flowers) hands [654,637,710,728]. Check the girl with it, got the girl [526,109,880,946]. Check the jeans of it, got the jeans [530,613,880,871]. The jeans [530,613,880,871] are gray. So the answer is gray.



这一设计还有一个非常重要的目的：保护语言模型已有能力。如果简单地为了图像任务对整个 LLM 大规模微调，原来的纯文本能力可能下降。CogVLM 通过保留文本 Token 原来的语言参数，同时让视觉 Token 使用新增 Visual Expert，使语言能力与视觉能力在参数层面得到一定程度的分工。因此 CogVLM 的意义第一次系统性回答了一个架构问题：视觉 Token 和文字 Token 是否真的应该完全共享同一套 Transformer 参数？CogVLM 的答案是否定的。



VisualGLM 的视觉语言连接主要集中在视觉编码器和语言模型之间，而 CogVLM 把视觉专用计算扩展到了语言模型的 Attention 和 FFN 内部。因此，如果把两者放在一起看，VisualGLM 是“视觉表示转换之后交给语言模型”，CogVLM 则是“视觉表示进入语言模型后仍持续由视觉专家处理”。这使 CogVLM 在目标识别、视觉问答、Visual Grounding 等任务上获得明显提升，也为后来的 CogVLM2 建立了基础。第一代 CogVLM 支持约 490×490 的图像输入，相比早期 224 级别图像已经有所提升，但对于文档、网页截图、GUI 等需要识别小字体和密集元素的任务仍然存在明显限制。

四、CogAgent

技术报告：CogAgent: A Visual Language Model for GUI Agents

(<https://arxiv.org/pdf/2312.08914>)

CogAgent 可以理解为 CogVLM 架构向高分辨率视觉和 GUI Agent 方向的一次专门扩展。CogVLM 虽然已经具有很强的通用视觉理解能力，但计算机屏幕、网页和手机 GUI 的问题与普通自然图片不同：大量重要信息可能只占几十个像素，例如按钮文字、菜单、输入框、小图标和状态栏。如果把一张 1080p 屏幕直接缩小到 224 或 490 分辨率，很多这些信息会直接丢失。因此 CogAgent 没有简单把 CogVLM 的输入尺寸暴力扩大，而是引入了 **低分辨率视觉编码器 + 高分辨率视觉编码器 + High-Resolution Cross-Module** 的结构，并把最高输入提升到约 1120×1120。

它保留 CogVLM 作为基础 VLM：低分辨率图像经过 EVA2-CLIP-E 和 Adapter 进入带有 Visual Expert 的语言 Decoder。同时增加另一套处理高分辨率图像的视觉路径。高分辨率特征并不是直接全部塞进语言模型，因为那样视觉 Token 数量会非常庞大，而是通过额外的 Cross-Attention 模块让语言模型中的表示去读取高分辨率视觉特征。这样模型既保留低分辨率全局视觉结构，也可以访问高分辨率局部信息。这一点使 CogAgent 能够识别 GUI 中小尺寸文字和控件，并进一步输出界面位置或操作。


CogAgent 的创新重点已经从普通“看图问答”开始转向“视觉理解之后进行操作”。这一步后来对 GLM-V 的影响非常深。GLM-4.1V、GLM-4.5V、GLM-4.6V 和 GLM-5V-Turbo 都把 GUI Grounding、GUI Agent、视觉工具调用作为重要能力，而这一研

究方向在 CogAgent 时期已经成型。更重要的是，CogAgent 暴露了高分辨率多模态模型的一个核心工程矛盾：增加图像分辨率可以看到更多细节，但会导致视觉 Token 数量快速增加。因此接下来的 CogVLM2 和 GLM-4V 开始更加重视**高分辨率条件下的视觉 Token 压缩和计算效率**。


五、CogVLM2

技术报告：CogVLM2: Visual Language Models for Image and Video Understanding
(<https://arxiv.org/pdf/2408.16500>)


CogVLM2 是 CogVLM 的直接后继者。它继续保留 **Visual Expert** 结构，也就是视觉 Token 在语言 Transformer 内仍然拥有视觉专用 Attention 和 FFN 参数，但视觉前端和连接结构进行了明显升级。CogVLM2 使用 EVA2-CLIP-E 作为主要视觉编码器，并将输入图像能力提升到最高约 **1344×1344**。同时使用卷积和 SwiGLU 等结构对视觉特征进行压缩，使高分辨率图像产生的视觉 Token 数量保持在可控制范围内。语言模型一侧则切换到更新的 Llama 3 8B 级语言骨干，从而形成约 19B 规模的 CogVLM2。官方明确指出 CogVLM2 继承了第一代 CogVLM 的 Visual Expert，同时主要改进了高分辨率架构以及预训练和后训练方案。



这一代还有一个非常重要的扩展——**CogVLM2-Video**。以前如果处理视频，常见做法是把视频抽成若干图片然后当作多图输入，但这样模型并不知道两张图片实际相隔多少秒。CogVLM2-Video 在多帧图像之外显式加入时间戳，使模型能够知道每一帧对应的视频时间，并专门构造 **temporal grounding** 数据。官方构建了约 3 万条时间相关视频问答数据，使模型不仅回答“视频里发生了什么”，还可以回答“某个事件什么时候发生”“动作持续多久”等问题。由此 GLM 视觉路线第一次从静态图片明确扩展到了统一的**图像—多图—视频理解**。




CogVLM2 在验证 Visual Expert 有效的基础上解决三个现实问题：第一，输入图像从数百像素提高到千像素级别；第二，通过视觉下采样减少高分辨率带来的 Token 爆炸；第三，把同一套视觉语言结构扩展到视频，并显式加入真实时间信息。




六、GLM-4V / GLM-4V-9B

技术报告：ChatGLM: A Family of Large Language Models from GLM-130B to GLM-4 All Tools (<https://arxiv.org/pdf/2406.12793>)

GLM-4V-9B 和 CogVLM2 使用大量相同的数据及训练方案，但语言骨干换成了 **GLM-4-9B**。更关键的是，它没有继续照搬 CogVLM2 那套规模很大的 Visual Expert。CogVLM2 官方仓库明确说明，GLM-4V-9B 使用与 CogVLM2 相同的数据和训练 recipe，但**移除了 Visual Experts**，从而明显降低整体模型规模。换句话说，在 CogVLM 阶段，研究团队认为需要在 LLM 每一层加入视觉专家才能实现深层对齐；到了 GLM-4V，他们又证明了如果视觉编码器、视觉压缩以及多模态训练足够好，一个更简单的结构也能取得很高的性能。




GLM-4V 的基本结构因此重新变得相对简洁: 高分辨率视觉编码器 → 视觉特征压缩/投影 → GLM-4 Decoder。其视觉编码部分基于 EVA 系视觉模型, 高分辨率版本支持约 1120×1120 输入; 转换后的视觉表示作为视觉 Token 与文字 Token 一起送入 GLM-4。官方开源模型主要强调中英文多轮视觉对话、OCR、图表、视觉推理等能力。这种结构实际上非常重要, 因为后来 GLM-4.1V 并没有重新回到复杂的逐层 Visual Expert, 而是继续沿着“强视觉编码器 + Projector + 强 LLM”的方向发展。



因此 GLM-4V 可以看成 GLM 多模态路线的一次架构收敛。VisualGLM 认为 Connector 足够, CogVLM 认为 Connector 不够, 于是加入大量 Visual Expert; GLM-4V 则发现随着视觉编码器、数据和语言骨干增强, 可以再次简化融合模块, 而不是无限增加视觉专用参数。这个决定后来事实证明非常关键, 因为 GLM-4.1V、4.5V、


4.6V 都继续采用“三段式”基本架构：**Vision Encoder + MLP Projector + LLM Decoder**。真正的大规模能力提升开始更多来自视觉编码器本身、位置编码、多模态数据以及后训练，而不再依赖在每个 Transformer 层部署一套视觉专家。



七、GLM-4.1V-9B

GLM-4.5V and GLM-4.1V-Thinking: Towards Versatile Multimodal Reasoning with Scalable Reinforcement Learning (<https://arxiv.org/pdf/2507.01006>)


GLM-4.1V 的关键词是 **Native Resolution + Spatio-temporal Position + Multimodal Reasoning**。这一代正式确定了后来 GLM-V 系列共享的三组件结构：**ViT Vision Encoder → MLP Projector → GLM Language Decoder**。视觉编码器不再沿用 CogVLM 的 EVA2-CLIP，而是使用 **AIMv2-Huge** 进行初始化；语言 Decoder 使用 GLM-4-9B-0414。MLP Projector 负责把视觉编码器输出转换成语言模型的隐藏表示，然后视觉 Token 与文字 Token 一起由 GLM Decoder 处理。



最大的视觉架构改进是原生分辨率和任意宽高比支持。早期 VisualGLM、CogVLM、GLM-4V 基本仍围绕预先规定的输入尺寸运行，而 GLM-4.1V 对 ViT 位置系统进行了重新设计。首先在视觉 Transformer 中加入二维 RoPE，使模型能够理解 Patch 在图片横向和纵向上的相对位置；与此同时并没有完全删除 AIMv2 原来的可学习绝对位置编码，而是通过插值让它适应不同图像尺寸。这样做的结果是模型可以处理极端宽高比和超过 4K 的高分辨率图像，而不是必须把所有图片强行缩放到统一的正方形。官方报告甚至指出该设计能够处理宽高比超过 200:1 的图像。

GLM-4.1V 还把视频处理真正融入同一套视觉编码器。在视觉输入的 Patch Embedding 阶段，原有二维卷积被三维卷积替代，因此不仅可以处理图像的宽和高，还可以处理时间维度。对于视频，可以在时间方向进行二倍下采样，减少视觉 Token；对于单张图片，则复制图像来兼容同样的数据路径。每个视频帧后还加入对应的时间索引 Token，让模型明确知道这张图位于视频的哪个时间点。与此同时，语言模型侧把位置编码进一步扩展成 3D-RoPE，使视觉 Token 的水平、垂直以及时间信息能够进入语言推理过程。

真正让 GLM-4.1V 与 GLM-4V 拉开差距的其实还是数据和后训练。其预训练数据不仅有普通图片 Caption，还包含大规模网页图文、超过一亿本数字化书籍中提取的学术图文、多达约 2.2 亿张 OCR 图像、自然图像 Grounding、GUI Grounding、视频等数据。官方从超过 100 亿候选图文对开始筛选，同时专门保留学术图、工程图、地图、示意图等高知识密度图片；Grounding 数据中还包含约 4000 万自然图片定位标注，并构造了超过 1.4 亿 GUI 相关问答对。这使 GLM-V 从普通视觉内容识别进入了文档、学术图表、OCR、GUI、空间关系等更加复杂的视觉环境。



GLM-4.1V-9B-Thinking 不再只训练模型“直接给答案”，而是使用长链条视觉推理

数据进行 SFT，然后进一步使用强化学习提升视觉推理能力。训练数据覆盖 STEM、数学、GUI、Grounding、OCR、视频、文档等不同领域，使模型学习先分析图片、再进行多步推理、最后给出答案。因此 GLM-4.1V 的真正创新是第一次把大规模多领域视觉推理强化学习确立为 GLM-V 的核心训练路线。

八、GLM-4.5V

GLM-4.5V and GLM-4.1V-Thinking: Towards Versatile Multimodal Reasoning with Scalable Reinforcement Learning (<https://arxiv.org/pdf/2507.01006>)

GLM-4.5V 是与 GLM-4.1V 共用同一代 GLM-V 基本架构：AIMv2-Huge 初始化的 ViT、支持图像和视频的 3D Patch Embedding、二维视觉 RoPE、保留并插值绝对位置编码、MLP Projector，以及语言端的 3D-RoPE。发生变化的是语言 Decoder。GLM-4.1V 使用约 9B 的 Dense GLM-4-9B-0414，而 GLM-4.5V 使用 **GLM-4.5-Air** 作为语言骨干，也就是一个 **106B 总参数、每次约激活 12B 参数的 MoE 模型**。这样视觉部分基本保持成熟稳定，但语言推理容量大幅增加。

这个变化说明 GLM-V 的研究重点已经发生转移。2023 年时主要问题还是“图片怎么接到 LLM 上”；2025 年 GLM-4.5V 时，视觉接入方案已经相对稳定，真正的瓶颈开始变成“看到视觉信息之后，模型能进行多强的推理”。因此 GLM-4.5V 的核心投入转向多模态预训练、长 CoT、Reward System 和大规模强化学习。它继续使用图片、视频、文档、GUI、Grounding、数学、科学等大量数据，并把不同领域放在统一强化学习框架中优化。

RLCS

GLM-4.5V 提出的关键训练创新之一是 **Reinforcement Learning with Curriculum Sampling, RLCS**。其出发点是：如果同时对数学、GUI、OCR、视频、视觉问答、Grounding 等大量任务做 RL，不同训练样本难度差异极大。过于简单的问题无法提供有效学习信号，过于困难的问题又可能让模型一直失败。因此 RLCS 根据模型当前能力动态选择更有训练价值的问题，并随着能力提高不断调整训练数据难度。与此同时，GLM-V 团队发现，多领域强化学习不一定像传统 SFT 那样产生严重的任务间冲突，反而可能产生跨任务的推理迁移，例如某一领域学习到的检查、验证和回溯方式可以帮助其他视觉任务。

GLM-4.5V 还有一个很实际的变化：它同时支持 **Thinking** 和 **Non-Thinking**。这意味着同一模型既可以在高难度图片推理问题中生成较长推理过程，也可以在普通 OCR、识别、简单问答中直接回答，从而在推理效果和计算成本之间进行选择。这后来也成为 GLM-4.6V 的基本设计。

九、GLM-4.6V / GLM-4.6V-Flash

GLM-4.6V 继续沿用 GLM-4.5V 的总体视觉架构，大版本没有重新更换视觉编码方案。完整版依旧采用约 **106B-A12B** 的 MoE 语言骨干路线，而 GLM-4.6V-Flash 则采用约 9B 级 Dense 模型，面向本地部署和低延迟场景。因此这一代的重点已经不再是设计新的 Image Encoder，而是扩大上下文、加强多模态推理并加入 Agent 所需要的原生行动接口。

最直接的改进是上下文被扩展到 **128K Token**。在 GLM-4.1V/4.5V 的长上下文训

练基础上, GLM-4.6V 又进行额外长序列训练,把上下文进一步扩展到 131072 Token。对于纯文本模型,这主要意味着更长文档;但对于 VLM 意义更大,因为视频帧、多个高分辨率图片、几十页 PDF 和网页截图本身都会消耗大量 Token。因此 128K 多模态上下文实际上是在为长视频、长文档、多页图片以及复杂 Agent 交互提供基础。

GLM-4.6V 最大的新能力是**原生多模态 Function Calling**。此前的 VLM 可以看图片,也可以输出坐标,但是“视觉感知 → 决策 → 调用工具”往往还需要外部 Agent 框架包装。GLM-4.6V 则在训练中直接加入结构化工具调用格式,让模型根据视觉输入生成明确的函数名称和参数。比如看到网页截图以后,不只是回答“按钮在哪里”,而是可以生成下一步应该调用什么工具以及对应参数。这意味着 GLM-V 的目标从“理解视觉世界”进一步转变成“根据视觉世界采取操作”。


十、GLM-5V-Turbo

技术报告: GLM-5V-Turbo: Toward a Native Foundation Model for Multimodal Agents
(<https://arxiv.org/pdf/2604.26752>)

截至 2026 年 8 月 14 日, GLM-5V-Turbo 是这条 GLM 视觉多模态主线公开技术报告中最新的重要一代。官方不再把视觉理解看成语言模型旁边的附加输入,而是明确提出: **multimodal perception 应当成为 reasoning、planning、tool use 和 execution 的组成部分**。换句话说,模型不只是“接受一张图片然后回答问题”,而是要持续读取图片、视频、网页、PDF、GUI,再根据这些视觉信息制定计划、调用工具、检查执行结果并继续下一步操作。

MMTP

GLM-5V-Turbo 还第一次系统提出 **Multimodal Multi-Token Prediction, MMTP**。传统自回归 LLM 通常根据前面 Token 预测下一个 Token,而 MTP 会让模型在训练时同时预测后面多个 Token,从而提高训练效率并帮助模型学习更丰富的未来信息。但把 MTP 直接搬到多模态模型会出现一个问题:视觉 Token 并不是词表中的普通 Token,而是视觉编码器产生的连续向量。如果直接把这些大规模视觉表示不断传入额外预测头,会明显增加流水线并行时的通信成本。



GLM-5V-Turbo 团队测试了多种方案，最后采用了一种非常工程化但很有效的处理方式：在 MTP 分支中不直接传递完整视觉向量，而是保留视觉位置，同时把视觉内容表示替换成共享的特殊 `<|image|>` Token。主要语言模型仍然能够读取真正的视觉特征，只是额外 MTP Head 不需要在多台设备之间传递庞大的视觉 embedding。这减少了分布式训练通信负担，同时保持视觉位置结构。GLM 多模态架构已经不再只考虑“模型理论上能不能看图”，而是在模型设计阶段直接考虑几百亿甚至更大规模多模态训练时的**系统通信、并行和推理效率**。

GLM-5V-Turbo 的另一个重大变化，是更加明确地强调从预训练阶段就同时混合纯文本和多模态数据，而不是先得到一个几乎完整的 LLM，再通过较小规模 VLM 数据“补视觉”。它的多模态预训练数据包含普通世界知识、图文交错内容、OCR、代码、GUI、视频、多模态工具使用、空间感知、Grounding、学术问题等大量类型。特别值得注意的是 **multimodal coding** 数据被专门加强，因为如果模型未来要根据网页截图生成 HTML、根据 UI 设计生成应用或者修改现有界面，仅仅“识别图片内容”是不够的，它需要建立视觉布局与代码结构之间直接的对应关系。

在后训练阶段，GLM-5V-Turbo 又把多模态强化学习扩大到 **30 多类任务**，同时训练视觉感知、OCR、2D/3D Grounding、视频、STEM、GUI Agent、Coding Agent 和工具调用。GLM 团队继续沿用并扩展在 GLM-4.1V 和 4.5V 中发现的结论：多任务 RL 不一定导致所有任务相互干扰，恰当设计的数据和奖励可以让不同领域共同提升，而且某些推理策略能够跨任务迁移。

VisualGLM 中，一张图片基本是一次性的静态输入；模型读取图片然后生成答案。到了 GLM-5V-Turbo，图片可以成为工具操作的一部分。例如模型可以先查看整张图片，然后进行 Crop；再对局部区域进行识别；再使用以图搜图；再读取网页；再根据搜索结果重新判断原图片中的对象。对于 GUI，则可以读取截图、定位元素、执行操作、获取新的截图，再继续决策。视觉信息因此不再只是“Prompt 的附件”，而进入了 Agent 的连续状态和行动循环。官方把这一流程概括成完整的 **perception-planning-execution loop**。

为了实现这一点，GLM-5V-Turbo 的工具体系已经包括视觉识别、图片搜索、网页读取、图片裁剪、Bounding Box 标注、点标注、几何标记、三维框、视频目标追踪以及网页和 PPT 创建等能力。特别是在 Multimodal Deep Research 中，模型可以读取网页中的图片和图表，而不是只读取抽取出来的网页纯文本；它还可以主动选择视觉证据，并在最终报告中重新组织这些视觉材料。