

马尔可夫决策

“未来只取决于现在，与过去无关。”只要我掌握了现在的全部信息，我怎么走到这一步的历史记录就不重要了。

[举例：

想象你在看一盘下到一半的国际象棋。为了决定下一步怎么走，你只需要看一眼当前棋盘上各个棋子的位置（现在的状态）。你**不需要**知道前 20 步对手是怎么移动的（过去的历史）。这就叫满足马尔可夫性质。]

即 $P(S_{t+1}|S_t) = P(S_{t+1}|S_1, S_2, \dots, S_t)$ ，右边那一长串历史状态，可以被左边仅仅一个当前状态 S_t 替代。

定义：

$\mathcal{S}$ (状态 State): 环境所有可能情况的集合。

$\mathcal{A}$ (动作 Action): 智能体在某个状态下可以采取的所有行为。

$\mathcal{P}$ (状态转移概率 Transition): 在状态 s 下执行动作 a 后，变成状态 s' 的概率。

$\mathcal{R}$ (奖励 Reward): 执行动作后，环境给你的即时打分。

γ (折扣因子 Discount Factor): 一个 0 到 1 之间的数字，用来衡量“未来的奖励在今天值多少得分”。

π (策略 Policy): 规定了在状态 s 下，应该采取什么动作 a ：

$$\pi(a|s) = P(A_t = a | S_t = s)$$

G (回报 Return): 玩一局游戏下来，拿到的总分：

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots$$

目标：找到一个最优策略 π^* ，让期望的长期回报最大化。

[$\pi(a|s) = P(A_t = a | S_t = s)$ 表示在状态 s 下选择动作 a 的概率。如果策略是确定性的，则可以写成： $a = \pi(s)$ ；如果策略是随机性的，则写成： $\pi(a|s)$]

假设智能体从初始状态 s_0 出发，按照策略 π 与环境交互，产生一条轨迹：

$$\tau = (s_0, a_0, r_1, s_1, a_1, r_2, \dots, s_T)$$

根据概率链式法则，这条轨迹的概率可以写成：

$$P(\tau) = P(s_0) \prod_{t=0}^{T-1} P(a_t | s_t) P(s_{t+1} | s_t, a_t)$$

[假设有两个事件 A 和 B 。根据条件概率的定义，在事件 A 已经发生的前提下，事件 B 发生的概率是 $P(B|A) = \frac{P(A,B)}{P(A)}$ ，稍微变一下形，就得到了链式法则：

$$P(A,B) = P(A)P(B|A)。$$

如果现在有三个事件 A, B, C 依次发生，我们可以先把 (A, B) 捆绑在一起看作一个整体事件： $P(A, B, C) = P(A, B)P(C|A, B)$ ，然后再把刚刚推导过的链式法则代进去： $P(A, B, C) = P(A)P(B|A)P(C|A, B)$ 。

以此类推，对于任意 n 个随机变量 $X_1, X_2, \dots, X_n$ ，它们的联合概率分布可以写成： $P(X_1, X_2, \dots, X_n) = P(X_1)P(X_2 | X_1)P(X_3 | X_1, X_2) \dots P(X_n | X_1, \dots, X_{n-1})$ ，可以极其优雅地写成： $P(X_1, X_2, \dots, X_n) = \prod_{i=1}^n P(X_i | X_1, \dots, X_{i-1})$

假设智能体经历了一条轨迹 $\tau = (S_0, A_0, S_1, A_1, S_2)$ ，按照最原始的链式法则： $P(\tau) = P(S_0) \times P(A_0 | S_0) \times P(S_1 | S_0, A_0) \times P(A_1 | S_0, A_0, S_1) \times P(S_2 | S_0, A_0, S_1, A_1)$
动作只取决于当前状态，所以 $P(A_1 | S_0, A_0, S_1)$ 被剪成了 $\pi(A_1 | S_1)$ 。
下一个状态只取决于当前状态和当前动作。所以 $P(S_2 | S_0, A_0, S_1, A_1)$ 被剪成了 $P(S_2 | S_1, A_1)$ 。]

因为 $P(a_t | s_t) = \pi(a_t | s_t)$ ，所以 $P(\tau) = \rho_0(s_0) \prod_{t=0}^{T-1} \pi(a_t | s_t) P(s_{t+1} | s_t, a_t)$ ，其中 $\rho_0(s_0)$ 表示初始状态分布。一条轨迹由两部分共同决定：策略 $\pi(a_t | s_t)$ 和环境转移 $P(s_{t+1} | s_t, a_t)$

智能体不是只关心当前奖励，而是关心从当前时刻开始的长期累计奖励。

定义从时刻 t 开始的回报为： $G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots$

写成求和形式 $G_t = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$

现在对这个式子进行递推变形： $G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \gamma^3 R_{t+4} + \dots$

把后面的部分提取出一个 γ ： $G_t = R_{t+1} + \gamma(R_{t+2} + \gamma R_{t+3} + \gamma^2 R_{t+4} + \dots)$

括号里面正好是： G_{t+1}

因此 $G_t = R_{t+1} + \gamma G_{t+1}$

在策略 π 下，状态 s 的价值定义为： $V^\pi(s) = \mathbb{E}_\pi[G_t | S_t = s]$ ，表示如果当前处于状态 s ，并且以后一直按照策略 π 行动，那么从现在开始能获得的期望长期回报是多少。因为 $G_t = R_{t+1} + \gamma G_{t+1}$ ，所以 $V^\pi(s) = \mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1} | S_t = s]$ ，利用期望的线性性 $V^\pi(s) = \mathbb{E}_\pi[R_{t+1} | S_t = s] + \gamma \mathbb{E}_\pi[G_{t+1} | S_t = s]$ ，但是下一步会先选择动作 a ，再转移到状态 s' 。所以需要对所有动作和所有下一状态求和。

在状态 s 下，按照策略 π 选择动作 a 的概率为： $\pi(a | s)$ 。因此要先对动作求和： $\sum_{a \in \mathcal{A}} \pi(a | s) (\dots)$

在状态 s 下采取动作 a 后，转移到状态 s' 的概率为： $P(s' | s, a)$ ，所以再对下一状态求和： $\sum_{s' \in \mathcal{S}} P(s' | s, a) (\dots)$

转移到状态 s' 后，得到即时奖励 $R(s, a, s')$ ，未来价值为 $V^\pi(s')$ ，因此：

$$V^\pi(s) = \sum_{a \in \mathcal{A}} \pi(a | s) \sum_{s' \in \mathcal{S}} P(s' | s, a) [R(s, a, s') + \gamma V^\pi(s')]$$

这是状态价值函数的贝尔曼期望方程。

动作价值函数表示在状态 s 下先采取动作 a ，之后按照策略 π 行动，能够获得的期望长期回报。记为 $Q^\pi(s, a) = \mathbb{E}_\pi[G_t | S_t = s, A_t = a]$ ，因为 $G_t = R_{t+1} + \gamma G_{t+1}$ ，所以 $Q^\pi(s, a) = \mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1} | S_t = s, A_t = a]$ ，在当前已经固定状态 s 和动作 a 的情况下，只需要考虑下一状态 s' 。于是：

$$Q^\pi(s, a) = \sum_{s' \in \mathcal{S}} P(s' | s, a) [R(s, a, s') + \gamma V^\pi(s')]$$

而

$$V^\pi(s') = \sum_{a' \in \mathcal{A}} \pi(a' | s') Q^\pi(s', a')$$

代入可得：

$$Q^\pi(s, a) = \sum_{s' \in \mathcal{S}} P(s' | s, a) \left[R(s, a, s') + \gamma \sum_{a' \in \mathcal{A}} \pi(a' | s') Q^\pi(s', a') \right]$$

这是动作价值函数的贝尔曼期望方程。

所有策略中，能让状态 s 获得最大价值的那个价值，称为最优状态价值函数： $V^*(s) = \max_{\pi} V^\pi(s)$ ，我们希望找到最优策略 π^* ，使得 $V^{\pi^*}(s) = V^*(s)$ 。

普通策略下 $V^\pi(s) = \sum_a \pi(a | s) \sum_{s'} P(s' | s, a) [R(s, a, s') + \gamma V^\pi(s')]$ ，如果我们追求最优策略，那么在状态 s 下，不应该再按照固定概率选择动作，而应该选择能让价值最大的动作。因此，把对策略的期望选择变成对动作的最大选择，即：

$$V^*(s) = \max_{a \in \mathcal{A}} \sum_{s' \in \mathcal{S}} P(s' | s, a) [R(s, a, s') + \gamma V^*(s')]$$

这是贝尔曼最优方程。

最优动作价值函数定义为 $Q^*(s, a) = \max_{\pi} Q^\pi(s, a)$ ，对应贝尔曼最优方程为：

$$Q^*(s, a) = \sum_{s' \in \mathcal{S}} P(s' | s, a) \left[R(s, a, s') + \gamma \max_{a' \in \mathcal{A}} Q^*(s', a') \right]$$

最优策略可以由最优动作价值函数得到 $\pi^*(s) = \arg \max_{a \in \mathcal{A}} Q^*(s, a)$

对于固定策略 π ，可以把贝尔曼期望方程写成矩阵形式。

定义 V^π 为所有状态价值组成的列向量。定义 R^π 为策略 π 下每个状态的期望即时奖励。定义 P^π 为策略 π 下的状态转移矩阵。

贝尔曼期望方程可以写成 $V^\pi = R^\pi + \gamma P^\pi V^\pi$

移项 $V^\pi - \gamma P^\pi V^\pi = R^\pi$ ，提取 V^π 得 $(I - \gamma P^\pi) V^\pi = R^\pi$ ，如果矩阵可逆，则：

$$V^\pi = (I - \gamma P^\pi)^{-1} R^\pi$$

对于一个固定策略，如果我们知道环境转移概率和奖励函数，就可以直接解出该策略下所有状态的价值。

贝尔曼最优方程为 $V^*(s) = \max_a \sum_{s'} P(s' | s, a) [R(s, a, s') + \gamma V^*(s')]$ ，由于

$V^*(s)$ 同时出现在等式左右两边，所以一般不能直接得到答案。于是可以采用迭代方式。初始化 $V_0(s) = 0$ ，然后反复更新：

$$V_{k+1}(s) = \max_a \sum_{s'} P(s' | s, a) [R(s, a, s') + \gamma V_k(s')]$$

当 k 足够大时： $V_k(s) \rightarrow V^*(s)$ ，这是**价值迭代**。

定义贝尔曼最优算子： $(TV)(s) = \max_a \sum_{s'} P(s' | s, a) [R(s, a, s') + \gamma V(s')]$

价值迭代为 $V_{k+1} = TV_k$ ，对于任意两个价值函数 U 和 V ，有：

$$|TU - TV|_\infty \leq \gamma |U - V|_\infty$$

因为 $0 \leq \gamma < 1$ 所以每次更新都会把两个价值函数之间的差距缩小到原来的 γ 倍以内。这说明贝尔曼最优算子是一个压缩映射，因此价值迭代会逐渐收敛到唯一的不动点 $V^* = TV^*$ ，这个不动点就是最优价值函数。

[假设我们的马尔科夫决策过程包含有限个状态，状态总数为 n ，我们可以将任意

一个状态价值函数 $V(s)$ 视为一个 n 维列向量 $V = \begin{bmatrix} V(s_1) \\ V(s_2) \\ \vdots \\ V(s_n) \end{bmatrix}$ ，为了衡量两次迭代之间价

值函数的“差异”或“距离”，我们需要在线性空间中引入**范数**。在这里，我们使用**无穷范数** $|\cdot|_\infty$ 。

[无穷范数通常也称为**最大值范数**或**一致范数**。在向量空间或函数空间中，用来衡量向量“长度”或函数“大小”的一种极其常用的距离度量方式。

在有限维向量空间中对于一个 n 维向量 $x = [x_1, x_2, \dots, x_n]^T$ ，它的无穷范数定义为该向量所有元素绝对值中的**最大值** $|x|_\infty = \max_{1 \leq i \leq n} |x_i|$ 。

如果 V 是一个定义在离散状态空间 $\mathcal{S}$ 上的函数，那么 V 的无穷范数定义为它在所有状态上取值的绝对值的最大值 $|V|_\infty = \max_{s \in \mathcal{S}} |V(s)|$

无穷范数实际上是更通用的 L_p 范数的极限情况，对于向量 x ，它的 L_p 范数定义为：

$$|x|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}。$$

当 $p=1$ 时，是所有元素绝对值之和（即曼哈顿距离）。

当 $p=2$ 时，是平方和开根号（即最常见的欧几里得空间直线距离）。

当 $p \rightarrow \infty$ 时，在这个公式的求和过程中，绝对值**最大**的那个元素会被指数 p 无限放大，从而完全主导整个求和结果。其他较小的元素相较于最大元素会变得微不足道。经过微积分极限证明，可以得出： $\lim_{p \rightarrow \infty} |x|_p = \max_i |x_i|$

对于任意两个价值向量 U 和 V ，它们之间的无穷范数距离定义为所有状态中最大的那个差值的绝对值 $|V - U|_\infty = \max_{s \in \mathcal{S}} |V(s) - U(s)|$

我们将价值迭代中的更新规则抽象为一个数学算子，记作 T 。

算子 T 作用于某一个价值向量 V 后，会输出一个新的价值向量 TV 。根据贝尔曼最优方程，算子 T 在任意状态 s 上的具体运算定义为：

$$(TV)(s) = \max_{a \in \mathcal{A}} \left(\sum_{s' \in \mathcal{S}} P(s' | s, a) [R(s, a, s') + \gamma V(s')] \right)$$

价值迭代的过程，在数学上就是对初始向量 V_0 不断重复应用算子 T ，即 $V_{k+1} = T(V_k)$ 。

[为了继续推导，我们需要证明一个基础的绝对值不等式：对于定义域相同的任意两个实值函数 $f(a)$ 和 $g(a)$ ，下式成立：

$$|\max_a f(a) - \max_a g(a)| \leq \max_a |f(a) - g(a)|$$

假设 a_1 是使得 $f(a)$ 取得最大值的自变量，即 $f(a_1) = \max_a f(a)$ 。

假设 a_2 是使得 $g(a)$ 取得最大值的自变量，即 $g(a_2) = \max_a g(a)$ 。

不失一般性，假设 $\max_a f(a) \geq \max_a g(a)$ 。那么：

$$|\max_a f(a) - \max_a g(a)| = f(a_1) - g(a_2)$$

因为 $g(a_2)$ 是 $g(a)$ 的最大值，所以对于任意 a ，必然有 $g(a_2) \geq g(a_1)$ 。即可以得到 $-g(a_2) \leq -g(a_1)$ ，将这个不等式代入刚刚的差值中 $f(a_1) - g(a_2) \leq f(a_1) - g(a_1)$ ，显然， $f(a_1) - g(a_1) \leq |f(a_1) - g(a_1)|$ 。而 $|f(a_1) - g(a_1)|$ 必定小于或等于所有 a 中差值绝对值的最大值： $|f(a_1) - g(a_1)| \leq \max_a |f(a) - g(a)|$ 。

引理得证。]

对于任意两个价值向量 U 和 V ，算子 T 作用于它们之后，它们之间的距离会严格缩小。即证明： $|TV - TU|_\infty \leq \gamma |V - U|_\infty$

对于任意给定的状态 s ，计算 $(TV)(s)$ 和 $(TU)(s)$ 的差值的绝对值：

$$|(TV)(s) - (TU)(s)| =$$

$$\left| \max_a \sum_{s'} P(s' | s, a) [R(s, a, s') + \gamma V(s')] - \max_a \sum_{s'} P(s' | s, a) [R(s, a, s') + \gamma U(s')] \right|$$

应用引理，将外层的绝对值和最大值符号交换位置：

$$|(TV)(s) - (TU)(s)| \leq$$

$$\max_a \left| \sum_{s'} P(s' | s, a) [R(s, a, s') + \gamma V(s')] - \sum_{s'} P(s' | s, a) [R(s, a, s') + \gamma U(s')] \right|$$

观察括号内部，即时奖励 $R(s, a, s')$ 被直接相减抵消。提取公因数 γ ，得到：

$$\begin{aligned} \max_a \left| \sum_{s'} P(s' | s, a) [R(s, a, s') + \gamma V(s')] - \sum_{s'} P(s' | s, a) [R(s, a, s') + \gamma U(s')] \right| = \\ \max_a \left| \gamma \sum_{s'} P(s' | s, a) [V(s') - U(s')] \right| \end{aligned}$$

根据微积分中的绝对值三角不等式（和的绝对值小于等于绝对值的和，即： $|\sum x_i| \leq \sum |x_i|$ ），以及 γ 和 P 都是非负数可以得到：

$$\max_a \left| \gamma \sum_{s'} P(s' | s, a) [V(s') - U(s')] \right| \leq \max_a \gamma \sum_{s'} P(s' | s, a) |V(s') - U(s')|$$

根据我们在**第一步**定义的无穷范数，对于任意 s' ，都有 $|V(s') - U(s')| \leq |V - U|_\infty$ 。将其代入替换：

$$\max_a \gamma \sum_{s'} P(s' | s, a) |V(s') - U(s')| = \max_a \left(\gamma |V - U|_\infty \sum_{s'} P(s' | s, a) \right)$$

根据概率论的公理，从状态 s 采取动作 a 转移到所有可能状态 s' 的概率之和必须为1，即 $\sum_{s'} P(s' | s, a) = 1$ 。因此：

$$\max_a \left(\gamma |V - U|_\infty \sum_{s'} P(s' | s, a) \right) = \gamma |V - U|_\infty$$

因此，对于**任意**特定的状态 s ，都有 $|(TV)(s) - (TU)(s)| \leq \gamma |V - U|_\infty$ 。既然这对所有状态都成立，那么左侧取所有状态中的最大值（即无穷范数定义）也必然成立：

$$|TV - TU|_\infty \leq \gamma |V - U|_\infty$$

因为折扣因子 $\gamma \in [0, 1)$ ，这证明了 T 严格缩小了 U 和 V 之间的距离。 T 是一个压缩映射。

根据贝尔曼最优方程的定义，最优价值函数 V^* 是算子 T 的不动点，即满足方程：

$$V^* = T(V^*)$$

在价值迭代中，第 k 次迭代的值为 $V_k = T(V_{k-1})$ 。我们计算第 k 次迭代值 V_k 与最优值 V^* 之间的无穷范数距离 $|V_k - V^*|_\infty = |T(V_{k-1}) - T(V^*)|_\infty$ ，根据我们在**第四步**证明的压缩映射性质，上式满足 $|T(V_{k-1}) - T(V^*)|_\infty \leq \gamma |V_{k-1} - V^*|_\infty$ ，将其不断向下递推展开：

$$|V_k - V^*|_\infty \leq \gamma |V_{k-1} - V^*|_\infty \leq \gamma^2 |V_{k-2} - V^*|_\infty \leq \dots \leq \gamma^k |V_0 - V^*|_\infty$$

现在，我们在等式两边对 k 求趋于无穷的极限：

$$\lim_{k \rightarrow \infty} |V_k - V^*|_\infty \leq \lim_{k \rightarrow \infty} \gamma^k |V_0 - V^*|_\infty$$

因为给定的初始向量 V_0 与最优解 V^* 之间的距离 $|V_0 - V^*|_\infty$ 是一个有限的常数，且已知 $0 \leq \gamma < 1$ 。由于 $\lim_{k \rightarrow \infty} \gamma^k = 0$ ，因此等式右侧为0。而范数（距离）不可能为负数，所以 $\lim_{k \rightarrow \infty} |V_k - V^*|_\infty = 0$ 。

从数学上严格证明了：当迭代次数 k 趋向于无穷大时，价值迭代得到的序列 V_k 会严格收敛于最优价值函数 V^* 。]

1. 策略评估

给定策略 π_k ，求它的价值函数：

$$V^{\pi_k}(s) = \sum_a \pi_k(a|s) \sum_{s'} P(s'|s, a) [R(s, a, s') + \gamma V^{\pi_k}(s')]$$

2. 策略改进

有了 V^{π_k} 之后，对每个状态选择更好的动作：

$$\pi_{k+1}(s) = \arg \max_a \sum_{s'} P(s'|s, a) [R(s, a, s') + \gamma V^{\pi_k}(s')]$$

流程为 $\pi_0 \rightarrow V^{\pi_0} \rightarrow \pi_1 \rightarrow V^{\pi_1} \rightarrow \pi_2 \rightarrow \dots \rightarrow \pi^*$ ，当策略不再变化时 $\pi_{k+1} = \pi_k$ ，说明已经得到最优策略。

价值迭代更新公式： $V_{k+1}(s) = \max_a \sum_{s'} P(s'|s, a) [R(s, a, s') + \gamma V_k(s')]$

策略迭代先做策略评估： $V^{\pi_k} = R^{\pi_k} + \gamma P^{\pi_k} V^{\pi_k}$ ；

再做策略改进： $\pi_{k+1}(s) = \arg \max_a Q^{\pi_k}(s, a)$ 。