

## Policy Entropy: 策略熵

### 导论

在强化学习中，模型需要不断根据奖励调整自己的行为策略。但如果模型过早地认定某一种选择是最优的，就可能迅速减少对其他可能性的尝试，最终陷入局部最优。

策略熵（Policy Entropy）是用来衡量策略具有多少不确定性和探索性的指标。策略熵越高，说明模型愿意尝试更多不同的动作；策略熵越低，说明模型的选择越来越集中，策略也越来越确定。

策略熵主要用在强化学习里，用来衡量模型当前的策略有多“随机”。

策略熵的公式为  $H(\pi) = - \sum_a \pi(a|s) \log \pi(a|s)$

其中  $\pi(a|s)$  表示模型在状态  $s$  下选择动作  $a$  的概率； $H(\pi)$  表示策略  $\pi$  的熵。

如果模型对不同动作给出的概率比较接近，例如  $\pi = (0.34, 0.33, 0.33)$

那么  $H(\pi)$  比较大，说明模型会尝试更多不同的动作，**探索性比较强**。

如果模型的概率高度集中，例如  $\pi = (0.98, 0.01, 0.01)$

那么  $H(\pi)$  很小，说明模型几乎固定选择某一个动作，**探索性比较弱**。

因此，在强化学习中经常加入一个**熵奖励（Entropy Bonus）**：

$$J = J_{\text{reward}} + \beta H(\pi)$$

如果按照最小化损失函数来写，则是  $L = L_{\text{RL}} - \beta H(\pi)$

其中  $L_{\text{RL}}$ ：原来的强化学习损失； $H(\pi)$ ：策略熵； $\beta$ ：控制熵奖励强度的超参数。

它作用是防止模型过早把所有概率集中到某一种动作上，保持一定的探索能力，避免策略过早坍缩。即让模型不要太早认定“某一种回答方式一定最好”，而是保留一定的输出多样性。