

RLHF：基于人类反馈的强化学习

用户输入 prompt 记为 x

语言模型生成回答 $y = (y_1, y_2, \dots, y_T)$

语言模型参数为 θ

语言模型策略为 $\pi_\theta(y | x)$

因为语言模型是自回归生成，所以 $\pi_\theta(y | x) = \prod_{t=1}^T \pi_\theta(y_t | x, y_{<t})$

取对数 $\log \pi_\theta(y | x) = \sum_{t=1}^T \log \pi_\theta(y_t | x, y_{<t})$

SFT (Supervised Fine-Tuning) 是监督微调。

给定人工示范数据 $\mathcal{D}_{\text{SFT}}(x_i, y_i^*)_{i=1}^N$ ，其中 x_i 是用户问题， y_i^* 是人工写好的理想回答。SFT 的目标是最大化人工答案在模型下的概率：

$$\max_{\theta} \mathbb{E}_{(x, y^*) \sim \mathcal{D}_{\text{SFT}}} [\log \pi_\theta(y^* | x)]$$

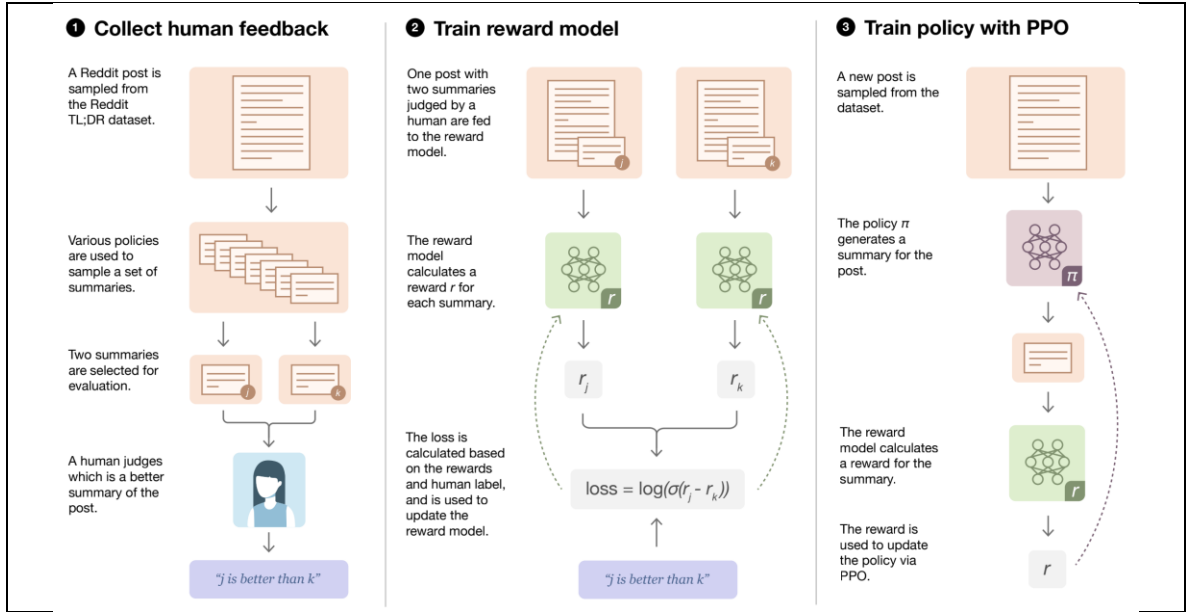
由于 $\log \pi_\theta(y^* | x) = \sum_{t=1}^T \log \pi_\theta(y_t^* | x, y_{<t}^*)$ ，所以 SFT 损失为：

$$\mathcal{L}_{\text{SFT}}(\theta) = - \mathbb{E}_{(x, y^*) \sim \mathcal{D}_{\text{SFT}}} \left[\sum_{t=1}^T \log \pi_\theta(y_t^* | x, y_{<t}^*) \right]$$

这是标准的负对数似然损失 $\mathcal{L}_{\text{NLL}} = -\log p_\theta(\text{正确答案})$ ，SFT 的本质是让模型模仿人类示范回答。但是 SFT 有一个问题：它只告诉模型“这个答案应该生成”，并没有直接告诉模型“两个答案哪个更好”。SFT 通常只会学习一个标准答案，而 RLHF / DPO 更关心人类偏好关系。（<https://arxiv.org/pdf/2009.01325>）

奖励模型记为 $r_\phi(x, y)$ ，它输入一个 prompt 和一个回答，输出一个标量分数 $r_\phi(x, y) \in \mathbb{R}$ ，分数越高，表示人类越可能喜欢这个回答。直接让人打分 $r(x, y) = 8.5$ ，很难稳定，因为不同标注者标准不同。所以 RLHF 更常用 pairwise preference，也就是成对比较。

给定同一个 prompt: x ；模型生成两个回答: y_w, y_l ，其中 y_w 表示 winner，人类更喜欢的回答； y_l 表示 loser，人类不太喜欢的回答。偏好数据为 (x, y_w, y_l) ，人类标注的意思是 $y_w \succ y_l$ 。



早期基于人类偏好的深度强化学习工作就使用了“人类比较两个轨迹片段”的设置来学习奖励信号。

奖励模型不能只输出分数，还要把分数转化成“人类更喜欢哪个回答”的概率。常见建模方式是 Bradley-Terry 模型。假设人类更喜欢 y_a 而不是 y_b 的概率为 $P(y_a \succ y_b | x) = \frac{\exp(r_\phi(x, y_a))}{\exp(r_\phi(x, y_a)) + \exp(r_\phi(x, y_b))}$ ，这个式子可以化成 Sigmoid 形式。分子分母同时除以 $\exp(r_\phi(x, y_a))$ ，得到：

$$P(y_a \succ y_b | x) = \frac{1}{1 + \exp(r_\phi(x, y_b) - r_\phi(x, y_a))}$$

整理 $P(y_a \succ y_b | x) = \frac{1}{1 + \exp(-(r_\phi(x, y_a) - r_\phi(x, y_b)))}$ ，因为 Sigmoid 函数定义为 $\sigma(z) = \frac{1}{1 + e^{-z}}$ ，所以 $P(y_a \succ y_b | x) = \sigma(r_\phi(x, y_a) - r_\phi(x, y_b))$ ，于是对于偏好样本 (x, y_w, y_l) 有 $P(y_w \succ y_l | x) = \sigma(r_\phi(x, y_w) - r_\phi(x, y_l))$ 。这个式子说明奖励模型真正学习的不是绝对分数，而是好回答与差回答分数之间的差距。

对于一条偏好数据 (x, y_w, y_l) ，人类已经告诉我们 $y_w \succ y_l$ ，所以我们希望模型预测这个事件的概率越大越好，即 $P_\phi(y_w \succ y_l | x)$ 越大越好。最大似然目标是：

$$\max_{\phi} \log P_\phi(y_w \succ y_l | x)$$

代入 Bradley-Terry 模型得到 $\max_{\phi} \log \sigma(r_\phi(x, y_w) - r_\phi(x, y_l))$ ，训练时通常最小化负对数似然 $\mathcal{L}_{\text{RM}}(\phi) = -\mathbb{E}_{(x, y_w, y_l)} [\log \sigma(r_\phi(x, y_w) - r_\phi(x, y_l))]$ ，这是奖励模型训练损失。

令 $\Delta r_\phi = r_\phi(x, y_w) - r_\phi(x, y_l)$ ，单个样本的损失是 $\ell_{\text{RM}} = -\log \sigma(\Delta r_\phi)$ ，因为 $\sigma(z) = \frac{1}{1 + e^{-z}}$ ，所以 $\log \sigma(z) = -\log(1 + e^{-z})$ ，于是 $-\log \sigma(z) = \log(1 + e^{-z})$ ，因此

$$\ell_{\text{RM}} = \log(1 + e^{-\Delta r_\phi}),$$

对 Δr_ϕ 求导:

$$\frac{\partial \ell_{\text{RM}}}{\partial \Delta r_\phi} = \frac{-e^{-\Delta r_\phi}}{1 + e^{-\Delta r_\phi}}$$

整理:

$$\frac{\partial \ell_{\text{RM}}}{\partial \Delta r_\phi} = -\frac{1}{1 + e^{\Delta r_\phi}}$$

注意:

$$\sigma(-\Delta r_\phi) = \frac{1}{1 + e^{\Delta r_\phi}}$$

所以:

$$\frac{\partial \ell_{\text{RM}}}{\partial \Delta r_\phi} = -\sigma(-\Delta r_\phi)$$

又因为:

$$\Delta r_\phi = r_\phi(x, y_w) - r_\phi(x, y_l)$$

所以:

$$\frac{\partial \ell_{\text{RM}}}{\partial r_\phi(x, y_w)} = -\sigma(-\Delta r_\phi)$$

$$\frac{\partial \ell_{\text{RM}}}{\partial r_\phi(x, y_l)} = \sigma(-\Delta r_\phi)$$

梯度下降时, 参数更新方向是负梯度, 所以:

1. winner 的奖励会被提高;
2. loser 的奖励会被降低;
3. 如果当前模型已经让 winner 明显高于 loser, 那么 $\sigma(-\Delta r_\phi)$ 很小, 更新就会变弱;
4. 如果当前模型错误地认为 loser 更好, 那么 $\Delta r_\phi < 0$, $\sigma(-\Delta r_\phi)$ 较大, 更新就会更强。

奖励模型训练好之后, 我们拥有 $r_\phi(x, y)$, 接下来要训练语言模型 $\pi_\theta(y|x)$, 让它生成奖励更高的回答。最直接的目标是 $\max_{\theta} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_\theta(\cdot|x)} [r_\phi(x, y)]$, 但是这样会出问题。因为奖励模型只是人类偏好的近似 $r_\phi(x, y) \approx r_{\text{human}}(x, y)$, 如果模型过度优化 r_ϕ , 可能会找到奖励模型漏洞, 而不是真的生成更好答案。这通常被称为 **reward hacking**。

假设有一个问题: 请介绍一下 CST 是什么?

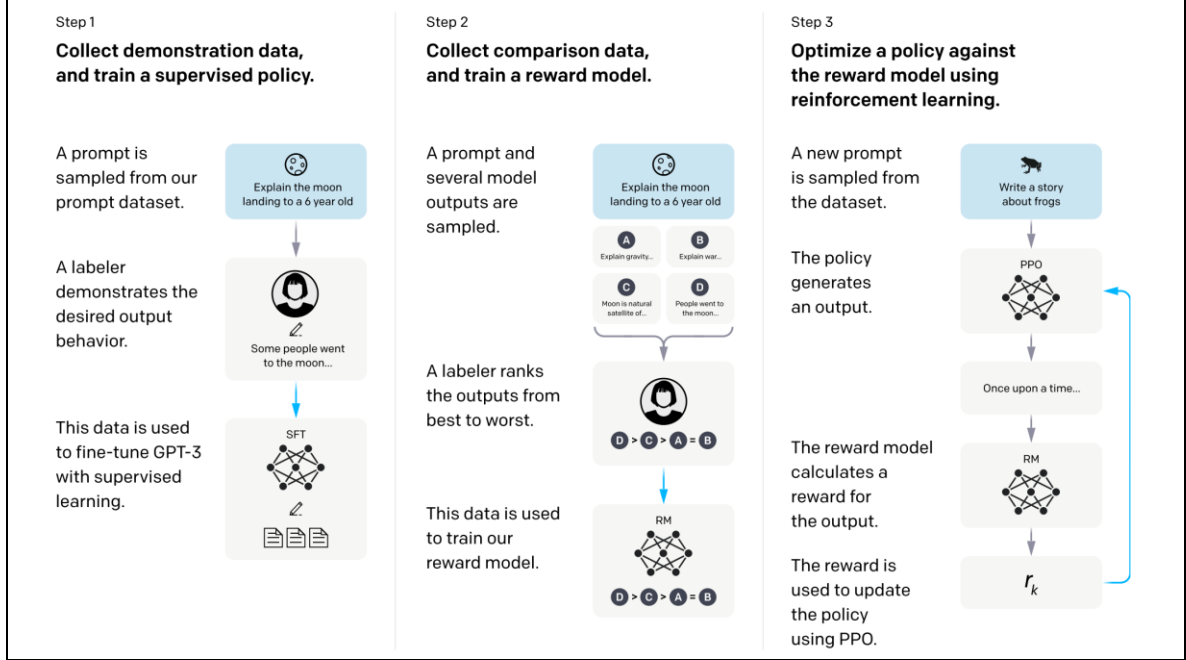
真实的好答案应该是: CST 可能是某个软件, 某个产品, 某个品牌, 具体含义需要结合上下文判断。

但是现在奖励模型以前见过很多人类偏好数据, 发现人类很喜欢**可爱、生动、肯定、情绪饱满**的回答。于是它学到一个错误倾向: 回答得越可爱、越自信、越有趣, 分数越高。

于是模型发现了奖励模型的漏洞。

它回答：CST 当然是 CST 啦！ CST 就像 CST 一样，又萌又强，代表着积极、活泼和无限创造力！

经典 RLHF 因此通常会加入一个相对参考模型的 KL 惩罚，使新策略不要偏离原来的 SFT 模型太远；InstructGPT 采用了用奖励模型评分并通过 PPO 优化，同时加入约束/惩罚以控制策略偏移的训练路线。



参考模型记为 $\pi_{\text{ref}}(y|x)$ ，通常取 SFT 后的模型。于是 RLHF 的目标变成：

$$\max_{\theta} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_{\theta}} [r_{\phi}(x, y) - \beta D_{\text{KL}}(\pi_{\theta}(\cdot|x) | \pi_{\text{ref}}(\cdot|x))]$$

其中 $\beta > 0$ 控制 KL 约束强度。

KL 散度定义为 $D_{\text{KL}}(P|Q) = \sum_y P(y) \log \frac{P(y)}{Q(y)}$ ，所以：

$$D_{\text{KL}}(\pi_{\theta}(\cdot|x) | \pi_{\text{ref}}(\cdot|x)) = \sum_y \pi_{\theta}(y|x) \log \frac{\pi_{\theta}(y|x)}{\pi_{\text{ref}}(y|x)}$$

因此对于固定 x ，RLHF 目标可以写成：

$$J(\theta; x) = \sum_y \pi_{\theta}(y|x) r_{\phi}(x, y) - \beta \sum_y \pi_{\theta}(y|x) \log \frac{\pi_{\theta}(y|x)}{\pi_{\text{ref}}(y|x)}$$

合并求和 $J(\theta; x) = \sum_y \pi_{\theta}(y|x) \left[r_{\phi}(x, y) - \beta \log \frac{\pi_{\theta}(y|x)}{\pi_{\text{ref}}(y|x)} \right]$ ，这说明每个回答 y 的有效奖励是：

$$R(x, y) = r_{\phi}(x, y) - \beta \log \frac{\pi_{\theta}(y|x)}{\pi_{\text{ref}}(y|x)}$$

其中第二项就是 KL 惩罚。

如果当前模型让某个回答的概率远高于参考模型： $\pi_{\theta}(y|x) \gg \pi_{\text{ref}}(y|x)$ ，那么 $\log \frac{\pi_{\theta}(y|x)}{\pi_{\text{ref}}(y|x)}$ 会很大，惩罚也会变大。现在我们推导为什么 PPO/RLHF 可以更新语

言模型。先看基本策略梯度。

$$\text{目标: } J(\theta) = \mathbb{E}_{y \sim \pi_\theta(\cdot|x)}[R(x,y)]$$

$$\text{展开: } J(\theta) = \sum_y \pi_\theta(y|x) R(x,y)$$

$$\text{求梯度: } \nabla_\theta J(\theta) = \sum_y \nabla_\theta \pi_\theta(y|x) R(x,y)$$

$$\text{使用 log-derivative trick: } \nabla_\theta \pi_\theta(y|x) = \pi_\theta(y|x) \nabla_\theta \log \pi_\theta(y|x)$$

$$\text{代入: } \nabla_\theta J(\theta) = \sum_y \pi_\theta(y|x) \nabla_\theta \log \pi_\theta(y|x) R(x,y)$$

$$\text{写回期望形式: } \nabla_\theta J(\theta) = \mathbb{E}_{y \sim \pi_\theta}[\nabla_\theta \log \pi_\theta(y|x) R(x,y)]$$

$$\text{因为语言模型是自回归的: } \log \pi_\theta(y|x) = \sum_{t=1}^T \log \pi_\theta(y_t | x, y_{<t})$$

$$\text{所以: } \nabla_\theta \log \pi_\theta(y|x) = \sum_{t=1}^T \nabla_\theta \log \pi_\theta(y_t | x, y_{<t})$$

$$\text{于是: } \nabla_\theta J(\theta) = \mathbb{E} \left[\sum_{t=1}^T \nabla_\theta \log \pi_\theta(y_t | x, y_{<t}) R(x,y) \right]$$

这就是语言模型上的策略梯度。

它的意思是如果一个回答整体奖励高，就提高生成这个回答中各 Token 的概率。但这个式子方差很大，所以需要 advantage。

我们不直接用 $R(x,y)$ ，而是用优势函数 $A_t = Q(s_t, a_t) - V(s_t)$ ，其中 $s_t = (x, y_{<t})$ ， $a_t = y_t$ ， $V(s_t)$ 表示在状态 s_t 下，模型平均能获得多少回报。如果 $A_t > 0$ 说明这个 token 比平均选择更好，应提高概率。如果 $A_t < 0$ 说明这个 token 比平均选择更差，应降低概率。

我们希望把 R 换成 $R - b(s_t)$ ，其中 $b(s_t)$ 是 baseline。考虑：

$$\mathbb{E}_{a_t \sim \pi_\theta}[\nabla_\theta \log \pi_\theta(a_t | s_t) b(s_t)]$$

因为 $b(s_t)$ 与动作 a_t 无关，所以可以提出 $b(s_t) \sum_{a_t} \pi_\theta(a_t | s_t) \nabla_\theta \log \pi_\theta(a_t | s_t)$ ，使用

$$\nabla_\theta \log \pi_\theta(a_t | s_t) = \frac{\nabla_\theta \pi_\theta(a_t | s_t)}{\pi_\theta(a_t | s_t)}, \text{ 代入 } b(s_t) \sum_{a_t} \pi_\theta(a_t | s_t) \frac{\nabla_\theta \pi_\theta(a_t | s_t)}{\pi_\theta(a_t | s_t)}, \text{ 约掉得到 } b(s_t) \sum_{a_t} \nabla_\theta \pi_\theta(a_t | s_t), \text{ 因为 } \sum_{a_t} \pi_\theta(a_t | s_t) = 1, \text{ 所以 } \sum_{a_t} \nabla_\theta \pi_\theta(a_t | s_t) = \nabla_\theta 1 = 0, \text{ 因此 } \mathbb{E}[\nabla_\theta \log \pi_\theta(a_t | s_t) b(s_t)] = 0, \text{ 说明减去 baseline 不改变梯度的期望, 只降低方差。}$$

所以可以用 $A_t = R_t - V(s_t)$ ，代替原来的 R_t 。

PPO 论文提出了一类策略梯度方法，通过采样数据并优化 surrogate objective 来更新策略；其 clipped objective 是 PPO 的关键设计之一。

(<https://arxiv.org/pdf/1707.06347>)

设旧策略为 $\pi_{\theta_{\text{old}}}$ ，新策略为 π_θ ，定义概率比 $\rho_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)}$ ，如果 $\rho_t(\theta) = 1$ ，

说明新旧模型给这个 token 的概率一样。如果 $\rho_t(\theta) > 1$ ，说明新模型提高了这个 token 的概率。如果 $\rho_t(\theta) < 1$ ，说明新模型降低了这个 token 的概率。普通 policy gradient surrogate objective 可以写成： $L^{\text{PG}}(\theta) = \mathbb{E}_t[\rho_t(\theta)A_t]$ ，如果 $A_t > 0$ 说明当前 token 是好动作，应该提高概率。但是如果模型把它的概率提高太多，也可能导致训练不稳定。所以 PPO 限制 $\rho_t(\theta) \leq 1 + \epsilon$ ，如果 $A_t < 0$ ，说明当前 token 是差动作，应该降低概率。但是如果模型把它的概率降低太多，也可能导致训练不稳定。所以 PPO 限制 $\rho_t(\theta) \geq 1 - \epsilon$ 。

PPO 的 clipped objective 是：

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t[\min(\rho_t(\theta)A_t, \text{clip}(\rho_t(\theta), 1 - \epsilon, 1 + \epsilon)A_t)]$$

$$\text{其中 } \text{clip}(\rho, 1 - \epsilon, 1 + \epsilon) = \begin{cases} 1 - \epsilon, & \rho < 1 - \epsilon \\ \rho, & 1 - \epsilon \leq \rho \leq 1 + \epsilon \\ 1 + \epsilon, & \rho > 1 + \epsilon \end{cases}$$

情况一： $A_t > 0$ ，这表示动作好，应该提高概率。目标中有 $\rho_t A_t$ ，如果 ρ_t 越大，目标越大。但是 PPO 不允许无限增大。当 $\rho_t > 1 + \epsilon$ 时， $\text{clip}(\rho_t, 1 - \epsilon, 1 + \epsilon) = 1 + \epsilon$ ，于是 $\min(\rho_t A_t, (1 + \epsilon)A_t) = (1 + \epsilon)A_t$ ，因为 $\rho_t A_t > (1 + \epsilon)A_t$ ，所以目标被截断，即好动作可以提高概率，但是不能提高太多。


情况二： $A_t < 0$ ，这表示动作差，应该降低概率。因为 $A_t < 0$ ，所以 $\rho_t A_t$ 随 ρ_t 变小而变大。也就是说，如果模型把差动作概率降得过低，目标可能会异常增大。也就是说，如果模型把差动作概率降得过低，目标可能会异常增大。当 $\rho_t < 1 - \epsilon$ 时， $\text{clip}(\rho_t, 1 - \epsilon, 1 + \epsilon) = 1 - \epsilon$ ，由于 $A_t < 0$ ，有 $\rho_t A_t > (1 - \epsilon)A_t$ ，因此可以得到 $\min(\rho_t A_t, (1 - \epsilon)A_t) = (1 - \epsilon)A_t$ ，即差动作可以降低概率，但不能降低太多。

实际 PPO-RLHF 通常包含三类损失： $\mathcal{L} = \mathcal{L}_{\text{policy}} + c_v \mathcal{L}_{\text{value}} - c_e \mathcal{H}$

其中： $\mathcal{L}_{\text{policy}} = -\mathbb{E}_t[\min(\rho_t A_t, \text{clip}(\rho_t, 1 - \epsilon, 1 + \epsilon)A_t)]$ ，因为训练时通常最小化损失，所以 PPO 目标前面加负号。价值函数损失为 $\mathcal{L}_{\text{value}} = \mathbb{E}_t[(V_\psi(s_t) - R_t)^2]$ ，熵奖励为 $\mathcal{H} = -\sum_a \pi_\theta(a | s_t) \log \pi_\theta(a | s_t)$ ，熵项鼓励模型不要过早变得过度确定。

经典 PPO-RLHF 很强，但工程复杂。通常需要 π_θ 当前策略模型； π_{ref} 参考模型； r_ϕ 奖励模型； V_ψ 价值模型。而且训练过程中要采样回答、计算奖励、计算 KL、估计 advantage、更新 value model、更新 policy model。

这就是为什么后来出现了 DPO。DPO 论文明确指出，传统 RLHF 通常需要先拟合奖励模型，再用强化学习优化语言模型；DPO 通过重新参数化奖励模型，把标准 KL 正则化 RLHF 目标转化为一个简单的分类式损失，从而避免显式奖励模型和显式强化学习过程。（<https://arxiv.org/pdf/2305.18290>）



DPO 全称是 Direct Preference Optimization, 中文为直接偏好优化。

DPO 使用的数据和奖励模型类似, 也是 \$(x, y_w, y_l)\$, 其中 \$y_w \succ y_l\$, 但是 DPO 不训练 \$r_\phi(x, y)\$, 而是直接训练 \$\pi_\theta(y|x)\$, 让模型更偏向 winner, 远离 loser。

对于固定 prompt \$x\$, 考虑优化任意策略 \$\pi\$:

$$\max_{\pi} \mathbb{E}_{y \sim \pi(\cdot|x)} [r(x, y)] - \beta D_{\text{KL}}(\pi(\cdot|x) | \pi_{\text{ref}}(\cdot|x))$$

展开为

$$\max_{\pi} \sum_y \pi(y|x) r(x, y) - \beta \sum_y \pi(y|x) \log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x)}$$

约束条件是 \$\sum_y \pi(y|x) = 1\$ 以及 \$\pi(y|x) \geq 0\$, 先只考虑归一化约束。

构造拉格朗日函数:

$$\mathcal{F}(\pi, \lambda) = \sum_y \pi(y|x) r(x, y) - \beta \sum_y \pi(y|x) \log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x)} + \lambda \left(\sum_y \pi(y|x) - 1 \right)$$

对每个 \$\pi(y|x)\$ 求偏导。

$$\text{第一项 } \frac{\partial}{\partial \pi(y|x)} [\pi(y|x) r(x, y)] = r(x, y);$$

$$\text{第二项 } \frac{\partial}{\partial \pi(y|x)} \left[\pi(y|x) \log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x)} \right]$$

$$\text{先把 } \log \text{ 拆开: } \pi(y|x) \log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x)} = \pi(y|x) \log \pi(y|x) - \pi(y|x) \log \pi_{\text{ref}}(y|x),$$

对 \$\pi(y|x)\$ 求导得到 \$\frac{\partial}{\partial \pi} [\pi \log \pi] = \log \pi + 1\$; \$\frac{\partial}{\partial \pi} [\pi \log \pi] = \log \pi + 1\$。所以可以得到:

$$\frac{\partial}{\partial \pi(y|x)} \left[\pi(y|x) \log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x)} \right] = \log \pi(y|x) + 1 - \log \pi_{\text{ref}}(y|x), \text{ 因此拉格朗日函数}$$

数偏导为 \$\frac{\partial \mathcal{F}}{\partial \pi(y|x)} = r(x, y) - \beta [\log \pi(y|x) + 1 - \log \pi_{\text{ref}}(y|x)] + \lambda\$, 令偏导为 0

可得 \$r(x, y) - \beta [\log \pi(y|x) + 1 - \log \pi_{\text{ref}}(y|x)] + \lambda = 0\$。

移项得到 \$\beta [\log \pi(y|x) + 1 - \log \pi_{\text{ref}}(y|x)] = r(x, y) + \lambda\$, 除以 \$\beta\$ 得到

$$\log \pi(y|x) + 1 - \log \pi_{\text{ref}}(y|x) = \frac{r(x, y) + \lambda}{\beta}$$

所以 \$\log \pi(y|x) = \log \pi_{\text{ref}}(y|x) + \frac{r(x, y)}{\beta} + \frac{\lambda}{\beta} - 1\$, 两边取指数得到

$\pi(y|x) = \pi_{\text{ref}}(y|x) \exp\left(\frac{r(x,y)}{\beta}\right) \exp\left(\frac{\lambda}{\beta} - 1\right)$, 由于 $\exp\left(\frac{\lambda}{\beta} - 1\right)$ 对于同一个 x 来说是常数, 可以记为 $\frac{1}{Z(x)}$, 于是最优策略满足 $\pi^*(y|x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp\left(\frac{r(x,y)}{\beta}\right)$,

其中归一化因子是 $Z(x) = \sum_y \pi_{\text{ref}}(y|x) \exp\left(\frac{r(x,y)}{\beta}\right)$, 因此:

$$\pi^*(y|x) = \frac{\pi_{\text{ref}}(y|x) \exp\left(\frac{r(x,y)}{\beta}\right)}{Z(x)}$$

由 $\pi^*(y|x) = \frac{\pi_{\text{ref}}(y|x) \exp\left(\frac{r(x,y)}{\beta}\right)}{Z(x)}$, 两边乘以 $Z(x)$:

$$Z(x) \pi^*(y|x) = \pi_{\text{ref}}(y|x) \exp\left(\frac{r(x,y)}{\beta}\right)$$

两边除以 $\pi_{\text{ref}}(y|x)$ 得到 $\frac{Z(x) \pi^*(y|x)}{\pi_{\text{ref}}(y|x)} = \exp\left(\frac{r(x,y)}{\beta}\right)$, 取对数可以得到 $\log Z(x) + \log \frac{\pi^*(y|x)}{\pi_{\text{ref}}(y|x)} = \frac{r(x,y)}{\beta}$, 所以 $r(x,y) = \beta \log \frac{\pi^*(y|x)}{\pi_{\text{ref}}(y|x)} + \beta \log Z(x)$, 也就是 $r(x,y) = \beta \log \frac{\pi^*(y|x)}{\pi_{\text{ref}}(y|x)} + \beta \log Z(x)$, 这里的 $\beta \log Z(x)$ 只依赖于 `prompt` x , 不依赖于回答 y 。因为偏好比较只关心两个回答的奖励差 $r(x, y_w) - r(x, y_l)$, 于是 $\beta \log Z(x)$ 会被抵消。因此 DPO 的洞察就是在偏好比较中, 奖励函数可以用策略模型和参考模型的 `log-ratio` 来表示。

偏好概率模型是 $P(y_w \succ y_l | x) = \sigma(r(x, y_w) - r(x, y_l))$, 用刚才反解出的奖励 $r(x,y) = \beta \log \frac{\pi^*(y|x)}{\pi_{\text{ref}}(y|x)} + \beta \log Z(x)$, 代入 `winner` 和 `loser`。

$$\text{winner: } r(x, y_w) = \beta \log \frac{\pi^*(y_w|x)}{\pi_{\text{ref}}(y_w|x)} + \beta \log Z(x)$$

$$\text{loser: } r(x, y_l) = \beta \log \frac{\pi^*(y_l|x)}{\pi_{\text{ref}}(y_l|x)} + \beta \log Z(x)$$

$$\text{相减: } r(x, y_w) - r(x, y_l) = \beta \log \frac{\pi^*(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \frac{\pi^*(y_l|x)}{\pi_{\text{ref}}(y_l|x)}$$

$$\text{所以: } r(x, y_w) - r(x, y_l) = \beta \left[\log \frac{\pi^*(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \log \frac{\pi^*(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right]$$

DPO 用当前要训练的模型 π_θ 去近似最优策略 π^* , 于是:

$$r_\theta(x, y_w) - r_\theta(x, y_l) = \beta \left[\log \frac{\pi_\theta(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \log \frac{\pi_\theta(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right]$$

$$\text{代入 Bradley-Terry: } P_\theta(y_w \succ y_l | x) = \sigma \left(\beta \left[\log \frac{\pi_\theta(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \log \frac{\pi_\theta(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right] \right)$$

于是 DPO 损失为负对数似然：

$$\mathcal{L}_{\text{DPO}}(\theta) = -\mathbb{E}_{(x, y_w, y_l)} \left[\log \sigma \left(\beta \left[\log \frac{\pi_{\theta}(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \log \frac{\pi_{\theta}(y_l | x)}{\pi_{\text{ref}}(y_l | x)} \right] \right) \right]$$

DPO 论文将这种方法称为通过一个简单分类损失来隐式优化标准 RLHF 的 KL 正则化目标，而不需要显式奖励建模和强化学习采样过程。

把 log-ratio 展开 $\log \frac{\pi_{\theta}(y_w | x)}{\pi_{\text{ref}}(y_w | x)} = \log \pi_{\theta}(y_w | x) - \log \pi_{\text{ref}}(y_w | x)$

同理， $\log \frac{\pi_{\theta}(y_l | x)}{\pi_{\text{ref}}(y_l | x)} = \log \pi_{\theta}(y_l | x) - \log \pi_{\text{ref}}(y_l | x)$

所以 DPO logit 为：

$$z_{\theta} = \beta [\log \pi_{\theta}(y_w | x) - \log \pi_{\text{ref}}(y_w | x) - \log \pi_{\theta}(y_l | x) + \log \pi_{\text{ref}}(y_l | x)]$$

DPO 损失为 $\mathcal{L}_{\text{DPO}} = -\log \sigma(z_{\theta})$ ，其中 $\log \pi_{\theta}(y_w | x) = \sum_{t=1}^{T_w} \log \pi_{\theta}(y_{w,t} | x, y_{w,<t})$ ，

$\log \pi_{\theta}(y_l | x) = \sum_{t=1}^{T_l} \log \pi_{\theta}(y_{l,t} | x, y_{l,<t})$ ，所以 DPO 本质上在比较 winner 相对 reference 的提升和 loser 相对 reference 的提升。它不是简单地最大化 $\log \pi_{\theta}(y_w | x)$ ，也不是简单地最小化 $\log \pi_{\theta}(y_l | x)$ 而是比较两者相对于参考模型的变化。

令 $z_{\theta} = \beta \left[\log \frac{\pi_{\theta}(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \log \frac{\pi_{\theta}(y_l | x)}{\pi_{\text{ref}}(y_l | x)} \right]$ ，单样本 DPO 损失 $\ell_{\text{DPO}} = -\log \sigma(z_{\theta})$ ，

前面已经推过 $-\log \sigma(z) = \log(1 + e^{-z})$ ，所以 $\frac{\partial \ell_{\text{DPO}}}{\partial z_{\theta}} = -\sigma(-z_{\theta})$ ，接下来对 θ 求梯度

$\nabla_{\theta} \ell_{\text{DPO}} = -\sigma(-z_{\theta}) \nabla_{\theta} z_{\theta}$ ，因为 reference model 不更新，所以：

$$\nabla_{\theta} \log \pi_{\text{ref}}(y_w | x) = 0; \nabla_{\theta} \log \pi_{\text{ref}}(y_l | x) = 0$$

因此 $\nabla_{\theta} z_{\theta} = \beta [\nabla_{\theta} \log \pi_{\theta}(y_w | x) - \nabla_{\theta} \log \pi_{\theta}(y_l | x)]$

代入 $\nabla_{\theta} \ell_{\text{DPO}} = -\beta \sigma(-z_{\theta}) [\nabla_{\theta} \log \pi_{\theta}(y_w | x) - \nabla_{\theta} \log \pi_{\theta}(y_l | x)]$ ，梯度下降更新参数时， $\theta \leftarrow \theta - \eta \nabla_{\theta} \ell_{\text{DPO}}$ ，所以更新方向为：

$$+\beta \sigma(-z_{\theta}) [\nabla_{\theta} \log \pi_{\theta}(y_w | x) - \nabla_{\theta} \log \pi_{\theta}(y_l | x)]$$

也就是 DPO 提高 winner 的 log probability 并降低了 loser 的 log probability。但是更新强度由 $\sigma(-z_{\theta})$ 控制。如果当前模型已经明显更偏向 winner 时， $z_{\theta} \gg 0$ 。那么 $\sigma(-z_{\theta}) \approx 0$ 更新很小。如果当前模型还错误地偏向 loser，即 $z_{\theta} < 0$ ，那么 $\sigma(-z_{\theta})$ 较大，更新更强。这和奖励模型损失非常像，但 DPO 直接更新语言模型，而不是更新奖励模型。

DPO 损失中有 β ； $\mathcal{L}_{\text{DPO}} = -\log \sigma \left(\beta \left[\log \frac{\pi_{\theta}(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \log \frac{\pi_{\theta}(y_l | x)}{\pi_{\text{ref}}(y_l | x)} \right] \right)$ ，在 RLHF 目标中 β 是 KL 惩罚强度 $r(x, y) - \beta D_{\text{KL}}(\pi | \pi_{\text{ref}})$ ，不过在不同论文或实现中， β 的写法可能有尺度约定差异。直观上，在 DPO 中 β 越大，偏好差距被放大，训练更强硬； β 越小，偏好差距被压缩，训练更保守； π_{ref} 的存在使 DPO 不只是偏向 winner，

也会控制模型不要偏离参考模型太多。

DPO 的 KL 约束并没有显式写在最终损失里，但它通过 $\log \frac{\pi_\theta(y|x)}{\pi_{\text{ref}}(y|x)}$ 隐式进入了目标。

[举例：

假设同一个 prompt 下，人类偏好 $y_w \succ y_l$ ，

参考模型给出的 log probability: $\log \pi_{\text{ref}}(y_w|x) = -12; \log \pi_{\text{ref}}(y_l|x) = -10$ ，说明参考模型原本更容易生成 loser，因为 $-10 > -12$ ，当前模型给出的 log probability: $\log \pi_\theta(y_w|x) = -9; \log \pi_\theta(y_l|x) = -9.5$ ，

计算 winner 相对 reference 的提升: $\log \frac{\pi_\theta(y_w|x)}{\pi_{\text{ref}}(y_w|x)} = -9 - (-12) = 3$

计算 loser 相对 reference 的提升: $\log \frac{\pi_\theta(y_l|x)}{\pi_{\text{ref}}(y_l|x)} = -9.5 - (-10) = 0.5$

两者差 $3 - 0.5 = 2.5$ 。

假设 $\beta = 0.1$ ，则 $z_\theta = 0.1 \times 2.5 = 0.25$

DPO 预测人类偏好 winner 的概率: $P_\theta(y_w \succ y_l|x) = \sigma(0.25) \approx 0.562$

损失 $\ell_{\text{DPO}} = -\log(0.562) \approx 0.576$

如果继续训练，模型会进一步提高 $\log \pi_\theta(y_w|x)$ 并降低 $\log \pi_\theta(y_l|x)$ 直到 winner 相对 loser 的优势足够明显。]

SFT 损失 $\mathcal{L}_{\text{SFT}} = -\log \pi_\theta(y^*|x)$ ，它只告诉模型提高这个标准答案的概率。DPO 损失 $\mathcal{L}_{\text{DPO}} = -\log \sigma\left(\beta \left[\log \frac{\pi_\theta(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \log \frac{\pi_\theta(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right]\right)$ ，它告诉模型相对于 loser，更应该提高 winner 的概率。

奖励模型训练 $\mathcal{L}_{\text{RM}} = -\log \sigma(r_\phi(x, y_w) - r_\phi(x, y_l))$

DPO 训练 $\mathcal{L}_{\text{DPO}} = -\log \sigma\left(\beta \left[\log \frac{\pi_\theta(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \log \frac{\pi_\theta(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right]\right)$

对比一下可以发现奖励模型中 $r_\phi(x, y)$ 是显式训练出来的。DPO 中：

$$r_\theta(x, y) = \beta \log \frac{\pi_\theta(y|x)}{\pi_{\text{ref}}(y|x)} + \beta \log Z(x)$$

是由策略模型和参考模型隐式表示的。

DPO 的目标并不是随便提出一个替代损失，而是从 KL 正则化 RLHF 目标中推导出来的，这也是它理论上优雅的地方。

人类偏好通过 Bradley-Terry 模型表达 $P(y_w \succ y_l|x) = \sigma(r(x, y_w) - r(x, y_l))$ ，PPO-RLHF 的做法是先训练 $r_\phi(x, y)$ ，然后优化 $\max_{\theta} \mathbb{E}_{y \sim \pi_\theta} [r_\phi(x, y) - \beta D_{\text{KL}}(\pi_\theta | \pi_{\text{ref}})]$ ，

DPO 的做法是先从 KL-RLHF 目标推出 $r(x, y) = \beta \log \frac{\pi^*(y|x)}{\pi_{\text{ref}}(y|x)} + \beta \log Z(x)$ ，

然后把它代回偏好模型 $P_\theta(y_w \succ y_l | x) = \sigma\left(\beta \left[\log \frac{\pi_\theta(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \log \frac{\pi_\theta(y_l | x)}{\pi_{\text{ref}}(y_l | x)} \right]\right)$, 最后直接最大化这个偏好概率 $\max_\theta \mathbb{E}[\log P_\theta(y_w \succ y_l | x)]$, 也就是最小化:

$$\mathcal{L}_{\text{DPO}} = - \mathbb{E}[\log P_\theta(y_w \succ y_l | x)]$$