

# DAPO: 解耦裁剪与动态采样策略优化

## 导论

给定一批数学问题，DAPO 的训练流程可以概括为：

1. 旧策略对每道题生成  $G$  条回答
2. 使用规则验证器计算正确性奖励
3. 删除全部正确或全部错误的问题组
4. 继续采样，直到有效问题组填满批次
5. 计算组内归一化相对优势
6. 加入软长度惩罚
7. 计算非对称裁剪的词元级策略梯度目标
8. 反向传播并更新策略参数

原始实验使用规则化正确性奖励  $R(\hat{y}, y) = \begin{cases} 1, & \hat{y} \text{ 与 } y \text{ 等价,} \\ -1, & \text{否则.} \end{cases}$

也就是说，DAPO 主要依靠答案是否正确，而不是额外训练一个神经网络奖励模型。

DAPO 可以理解为一套针对大语言模型长思维链强化学习的改进方案。它仍然使用 GRPO 的“问题多回答、组内相对优势”思想，但重点修复了 GRPO 在大规模长推理训练中的四个问题：

| GRPO 中的问题              | DAPO 的改进                         |
|------------------------|----------------------------------|
| 对上下方向使用相同裁剪范围          | Clip-Higher 非对称裁剪                |
| 全对或全错的问题没有梯度           | Dynamic Sampling                 |
| 每条回答权重相同，长回答中的单个词元权重过低 | Token-Level Policy Gradient Loss |
| 超长回答被简单截断和惩罚，产生奖励噪声    | Overlong Reward Shaping          |

DAPO 论文由字节跳动 Seed 与清华 AIR 等团队在 2025 年提出。论文报告其从 Qwen2.5-32B Base 出发，在 AIME 2024 上达到 50 的 avg@32，并公开了代码、数据和训练方案。（<https://arxiv.org/pdf/2503.14476v2>）

GRPO 对同一个问题  $q$  生成  $G$  条回答  $\{o_1, o_2, \dots, o_G\}$   
分别获得奖励  $\{R_1, R_2, \dots, R_G\}$

然后使用组内奖励归一化计算优势  $\hat{A}_i = \frac{R_i - \text{mean}(R_1, \dots, R_G)}{\text{std}(R_1, \dots, R_G)}$

DAPO 保留了这个基本设计：对于第  $i$  条回答的第  $t$  个词元，策略概率比仍然是  $\rho_{i,t}(\theta) = \frac{\pi_\theta(o_{i,t} | q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} | q, o_{i,<t})}$ ，因此，DAPO 并没有放弃 GRPO，而是在 GRPO 式优势估计基础上修改裁剪、采样、损失归一化和长度奖励。

## DAPO 的目标函数

使用  $\rho_{i,t}$  表示策略概率比后，DAPO 的核心目标可以写为：

$$\mathcal{J}_{\text{DAPO}}(\theta) = \mathbb{E} \left[ \frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \min(\rho_{i,t}(\theta) \hat{A}_{i,t}, \text{clip}(\rho_{i,t}(\theta), 1 - \varepsilon_{\text{low}}, 1 + \varepsilon_{\text{high}}) \hat{A}_{i,t}) \right]$$

同时，动态采样要求保留的组满足  $0 < |\{o_i \mid o_i \text{ 的答案正确}\}| < G$

这个目标函数与 GRPO 有两个非常明显的公式差异：

第一，裁剪范围从对称的  $[1 - \varepsilon, 1 + \varepsilon]$  改成非对称的  $[1 - \varepsilon_{\text{low}}, 1 + \varepsilon_{\text{high}}]$ ，第二，归一化项从逐回答平均  $\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|}$  改成所有词元统一平均  $\frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|}$

这两个变化分别对应 Clip-Higher 和 Token-Level Policy Gradient Loss。

### 改进一：Clip-Higher

DAPO 将上下裁剪范围解耦。例如论文训练配置使用  $\varepsilon_{\text{low}} = 0.2$ ； $\varepsilon_{\text{high}} = 0.28$ ，此时上界变为  $1 + \varepsilon_{\text{high}} = 1.28$ ，该探索词元对应的上界变为  $0.01 \times 1.28 = 0.0128$ ，这样便为低概率但有正优势的词元保留了更大的上升空间。

论文认为这种设计有助于缓解策略熵快速下降和回答趋同的问题。

为什么只提高上界？

DAPO 通常满足  $\varepsilon_{\text{high}} > \varepsilon_{\text{low}}$ ，它提高正优势词元的概率增长空间，但不相应放宽负方向。

原因是：如果把下界也降得太低，某些词元的概率可能被快速压向 0。一旦大量词元几乎不再被采样，策略的探索空间就可能坍塌。

因此，Clip-Higher 给有价值的低概率探索词元更大的上升空间，同时保持对概率下降的谨慎限制。

需要注意，裁剪的是目标函数中的概率比贡献，并不是把模型输出概率直接强制截断在某个区间。

### 改进二：Dynamic Sampling

GRPO 的零梯度问题：

假设对一道题生成  $G=4$  条回答

并且四条回答全部正确： $[R_1, R_2, R_3, R_4] = [1, 1, 1, 1]$ ，组内平均奖励为  $\mu_R = 1$ ，每条回答与平均值之差都是  $R_i - \mu_R = 0$ ，因此所有优势都是  $\hat{A}_i = 0$ ，最终策略梯度也近似为 0；类似地，如果四条回答全部错误： $[-1, -1, -1, -1]$ ，它们的相对优势仍然全部为 0。

这两种问题都无法告诉模型：同组回答中，哪一条比其他回答更好？

DAPO 只保留同时包含正确回答和错误回答的问题组，即： $0 < N_{\text{correct}} < G$

其中  $N_{\text{correct}}$  表示组内正确回答数量。当  $G=4$  时：

| 奖励情况          | 是否保留 |
|---------------|------|
| [1,1,1,1]     | 不保留  |
| [-1,-1,-1,-1] | 不保留  |
| [1,1,-1,-1]   | 保留   |
| [1,-1,-1,-1]  | 保留   |

如果当前批次过滤后数量不足，DAPO 就继续抽取新问题并生成回答，直到动态采样缓冲区中装满足够多的有效问题组。这就是“Dynamic Sampling”中的“动态”：每次为了填满一个有效训练批次，需要生成的问题数量不是固定的。

为什么这样更有效？

假设一个批次原本有 100 道题，其中：

40 道题全部回答正确；

20 道题全部回答错误；

40 道题有对有错。

那么真正产生组内相对优势的只有 40 道题。

普通 GRPO 仍然可能对全部 100 道题进行后续训练计算，但其中 60 道题几乎不提供策略梯度。

DAPO 会继续采样，直到得到规定数量的“有对有错”问题组，从而使训练批次中的大部分数据都能提供非零学习信号。论文报告，虽然这种方法会生成更多样本，但可能因为减少了无效更新而更快收敛。

### 改进三：Token-Level Policy

GRPO 的逐回答平均

$$\text{GRPO 的归一化方式是 } \frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \mathcal{L}_{i,t}$$

它先计算每条回答内部的词元平均，再对回答取平均。因此，无论回答长度是多少，每条回答的总权重都相同。

假设只有两条回答  $G=2$

第一条回答长度为  $|o_1|=3$ ；第二条回答长度为  $|o_2|=9$ ，在 GRPO 中，每条回答的总权重都是  $\frac{1}{2}$ ，所以第一条回答中每个词元的权重是  $\frac{1}{2} \times \frac{1}{3} = \frac{1}{6}$ ，第二条回答中每个词元的权重是  $\frac{1}{2} \times \frac{1}{9} = \frac{1}{18}$

因此，九词元回答中的每个词元，权重只有三词元回答中每个词元的三分之一。

DAPO 的全词元平均

$$\text{DAPO 改成 } \frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \mathcal{L}_{i,t}$$

在刚才的例子中，词元总数为  $3+9=12$ ，所以每个词元的权重都是  $\frac{1}{12}$

第一条回答的总权重为  $3 \times \frac{1}{12} = \frac{1}{4}$ ；第二条回答的总权重为  $9 \times \frac{1}{12} = \frac{3}{4}$

DAPO 不再保证每条回答权重相等，而是保证每个词元权重相等。

为什么适合长思维链？

在长推理回答中，某些重要推理模式可能分布在大量词元中。如果先对每条回答取平均，那么长回答中的每个词元都会被赋予较小权重：

1. 优质长推理中的有效步骤不容易被充分强化；
2. 低质量长回答中的重复、乱码和无效循环也不容易被充分惩罚。

DAPO 的全词元平均使相同类型的词元模式获得更接近的优化权重，不再仅仅因为它位于较长回答中就被大幅稀释。代价是长回答会对总体梯度产生更大影响，因此还需要配合超长奖励塑形来控制无意义的长度增长。

#### 改进四：Overlong Reward Shaping

为什么直接惩罚截断回答有问题？

训练长推理模型时，通常会设置最大生成长度  $L_{\max}$ ，当模型生成超过这个长度时，回答会被截断。

但被截断并不一定表示推理完全错误。例如：

1. 前面的推理过程可能基本正确；
2. 模型只是没有来得及输出最终答案；
3. 生成长度只比上限多了一点。

如果对所有截断回答直接赋予强烈负奖励，就会把“推理错误”和“推理过长”混为一谈，产生奖励噪声。

DAPO 先实验了 Overlong Filtering，即让截断样本不参与策略损失；随后进一步设计了 Soft Overlong Punishment，以连续方式惩罚接近最大长度的回答。

#### 软长度惩罚公式

DAPO 的长度奖励可以写为：

$$R_{\text{length}}(y) = \begin{cases} 0, & |y| \leq L_{\max} - L_{\text{cache}}, \\ \frac{(L_{\max} - L_{\text{cache}}) - |y|}{L_{\text{cache}}}, & L_{\max} - L_{\text{cache}} < |y| \leq L_{\max}, \\ -1, & L_{\max} < |y|. \end{cases}$$

其中  $|y|$  是回答长度； $L_{\max}$  是最大长度； $L_{\text{cache}}$  是软惩罚区间长度。

假设  $L_{\max} = 100$  ;  $L_{\text{cache}} = 20$  , 那么不惩罚区域是  $|y| \leq 80$  , 软惩罚区域是  $80 < |y| \leq 100$

回答长度为 70, 因为  $70 \leq 80$  , 所以  $R_{\text{length}} = 0$  , 不进行长度惩罚。

回答长度为 90, 因为  $80 < 90 \leq 100$  , 所以  $R_{\text{length}} = \frac{80 - 90}{20} = -0.5$  , 获得中等程度的长度惩罚。

回答长度为 98,  $R_{\text{length}} = \frac{80 - 98}{20} = -0.9$  , 越接近最大长度, 惩罚越强。

回答长度为 105, 因为超过  $L_{\max} = 100$  , 所以  $R_{\text{length}} = -1$

这种设计不会在某个长度位置突然从“完全不惩罚”跳到“强烈惩罚”, 从而减少长度边界附近的奖励突变。

GRPO 完整目标中包含  $-\beta D_{\text{KL}}(\pi_{\theta}|\pi_{\text{ref}})$  , 但原始 DAPO 论文的训练方案移除了 KL 惩罚项。

论文的解释是: 在偏好对齐任务中, KL 约束用于防止策略过度偏离初始模型; 但长思维链强化学习本身可能要求策略显著偏离基础模型, 因此作者没有在 DAPO 目标中保留该限制。

因此, 原论文中的 DAPO 目标主要是:

$$\mathcal{J}_{\text{DAPO}} = \mathcal{J}_{\text{asymmetric clip}}$$

而不是  $\mathcal{J}_{\text{DAPO}} = \mathcal{J}_{\text{asymmetric clip}} - \beta D_{\text{KL}}$  , 这并不表示所有后来名为 DAPO 的实现都必须移除 KL, 而是原始论文所公开训练方案的选择。