

VAPO: 基于价值模型增强的近端策略优化

导论

VAPO 的训练过程可以概括为:

1. 固定策略生成数据
2. 使用完整回报预训练价值模型
3. 当前策略对每个问题重复生成多条回答
4. 验证器判断最终答案是否正确
5. 价值模型预测每个中间状态的价值
6. 使用解耦且长度自适应的 GAE 计算词元优势
7. 计算 Clip-Higher 和 Token-Level PPO 损失
8. 对正确回答加入额外 NLL 损失
9. 更新 Actor 和 Critic:

更新 Actor: $\theta \leftarrow \theta - \eta_{\pi} \nabla_{\theta} (\mathcal{L}_{\text{PPO}} + \mu \mathcal{L}_{\text{NLL}})$

更新 Critic: $\phi \leftarrow \phi - \eta_V \nabla_{\phi} \mathcal{L}_V$

VAPO 是在 PPO 基础上设计的长思维链强化学习框架。价值模型虽然难以训练, 但一旦解决长序列中的偏差和不稳定问题, 它能够提供更比“整条回答共享一个优势”更精细的词元级信用分配。(<https://arxiv.org/pdf/2504.05118v3>)

为什么 VAPO 又把 Critic 加回来了?

假设模型生成一条三词元回答 $o_i = (o_{i,1}, o_{i,2}, o_{i,3})$

GRPO 和 DAPO 通常先根据最终答案计算整条回答的优势 $\hat{A}_i$

然后将它分配给所有词元 $\hat{A}_{i,1} = \hat{A}_{i,2} = \hat{A}_{i,3} = \hat{A}_i$

例如, 回答最终正确 $\hat{A}_i = 1$, 那么三个词元都会得到 [1,1,1]

但实际情况可能是:

1. 第一个词元引入了有效思路;
2. 第二个词元进行了关键推导;
3. 第三个词元只是输出最终答案。

也可能是前面出现了错误, 后面又偶然修正。仅使用最终奖励时, 很难判断究竟是哪一步产生了贡献。

VAPO 使用价值模型 $V_{\phi}(s_t)$, 估计在当前推理状态 s_t 下, 模型最终得到正确答案的期望回报, 从而为每个词元计算不同的优势。

VAPO 包含两个需要训练的网络。

1. 策略模型 Actor

策略模型为 $\pi_{\theta}(a_t | s_t)$, 它负责根据当前上下文 s_t 生成下一个词元 a_t , 参数为 θ

2. 价值模型 Critic

价值模型为 $V_{\phi}(s_t)$, 它负责预测从当前状态继续生成, 最终能够获得多少回报? 参数为 ϕ

因此，VAPO 的训练包含两个更新过程：

$$\theta \leftarrow \theta - \eta_{\pi} \nabla_{\theta} \mathcal{L}_{\text{policy}} \text{ 和 } \phi \leftarrow \phi - \eta_V \nabla_{\phi} \mathcal{L}_{\text{value}}$$

其中 η_{π} 是策略模型学习率； η_V 是价值模型学习率。

VAPO 继承 PPO 中的广义优势估计，即 GAE。

$$\text{首先计算时间差分误差 } \delta_t = R_t + \gamma V_{\phi}(s_{t+1}) - V_{\phi}(s_t)$$

其中 R_t 是第 t 步获得的奖励； $V_{\phi}(s_t)$ 是当前状态价值； $V_{\phi}(s_{t+1})$ 是下一个状态价值； γ 是回报折扣因子。

$$\text{然后计算第 } t \text{ 个词元的优势 } \hat{A}_t = \sum_{k=0}^{T-t-1} (\gamma\lambda)^k \delta_{t+k}, \text{ 其中 } \lambda \text{ 控制优势估计中的偏差与方差权衡。}$$

VAPO 的重要改进之一是根据序列长度动态调整策略模型使用的 λ 。

假设一条回答包含三个词元，最终答案正确。设置 $\gamma = 1$ ； $\lambda = 0.8$

奖励只在最后一步出现 $R_1 = 0$ ， $R_2 = 0$ ， $R_3 = 1$

价值模型预测 $V(s_1) = 0.2$ ； $V(s_2) = 0.4$ ； $V(s_3) = 0.8$

生成结束后的终止状态价值为 $V(s_4) = 0$

第一步的时间差分误差： $\delta_1 = R_1 + V(s_2) - V(s_1)$ ； $\delta_1 = 0 + 0.4 - 0.2 = 0.2$

第二步的时间差分误差： $\delta_2 = R_2 + V(s_3) - V(s_2)$ ； $\delta_2 = 0 + 0.8 - 0.4 = 0.4$

第三步的时间差分误差： $\delta_3 = R_3 + V(s_4) - V(s_3)$ ； $\delta_3 = 1 + 0 - 0.8 = 0.2$

于是三个词元的优势分别为：

$$\hat{A}_3 = \delta_3 = 0.2$$

$$\hat{A}_2 = \delta_2 + \lambda \delta_3；\hat{A}_2 = 0.4 + 0.8 \times 0.2 = 0.56$$

$$\hat{A}_1 = \delta_1 + \lambda \delta_2 + \lambda^2 \delta_3；\hat{A}_1 = 0.2 + 0.8 \times 0.4 + 0.8^2 \times 0.2 = 0.648$$

$$\text{最终得到 } [\hat{A}_1, \hat{A}_2, \hat{A}_3] = [0.648, 0.560, 0.200]$$

这与 GRPO 的不同。VAPO 可以让三个位置获得不同的训练强度，这是价值模型带来的词元级信用分配。

VAPO 认为，长思维链中的价值模型方法主要面临三个问题：

1. 长序列中的价值模型偏差；
2. 回答长度差异过大；
3. 可验证奖励过于稀疏。

为此，VAPO 组合了七项技术：

问题	VAPO 的解决方法
价值模型初始化偏差	Value Pretraining
长序列中奖励传播衰减	Decoupled GAE
长短回答需要不同的 λ	Length-Adaptive GAE
低概率探索词元不易提高	Clip-Higher
长回答中单个词元权重过低	Token-Level Loss
正确样本过于稀少	Positive Example LM Loss
同一问题缺少对比样本	Group Sampling

这些技术中，Clip-Higher 和 Token-Level Loss 继承自 DAPO；Value Pretraining 和 Decoupled GAE 借鉴了 VC-PPO；VAPO 新提出的关键部分是 Length-Adaptive GAE，并将这些技术整合为一个价值模型框架。

改进一：Value Pretrainin

价值模型为什么会有初始化偏差？

传统 PPO 有时会使用奖励模型初始化价值模型。但二者的任务并不相同：奖励模型主要对完整回答进行评分；价值模型需要对回答中每一个中间状态估计未来回报。

例如，奖励模型看到不完整的推理： $x^2 - 5x + 6 = 0$ ，因此可能给出很低的分数，因为回答尚未完成。但价值模型应该判断从这个中间状态继续生成，最终正确的概率有多大？

如果直接用奖励模型初始化 Critic，中间词元的价值预测可能存在系统性偏差，并在长序列的 GAE 递推中不断累积。

VAPO 在正式更新 Actor 之前：

1. 固定一个策略模型；
2. 使用该策略不断生成回答；
3. 根据最终奖励计算 Monte Carlo 回报；
4. 单独训练价值模型拟合这些回报；
5. 当价值损失和解释方差等指标达到合适水平后，再开始策略训练。

可以将价值预训练目标简化写成 $\mathcal{L}_V(\phi) = \frac{1}{N} \sum_{t=1}^N (V_\phi(s_t) - \hat{R}_t)^2$

$$\text{其中 } \hat{R}_t = \sum_{k=t}^T \gamma^{k-t} R_k$$

VAPO 论文的实验配置先对价值网络进行 50 个更新步骤的预热，再开始更新策略模型。

改进二：Decoupled GAE

普通 PPO 通常用同一个 λ 同时服务于 Actor 的优势估计和 Critic 的训练目标。

VAPO 将二者分开，Critic 使用 $\lambda_{\text{critic}} = 1$ ，当 $\lambda = 1$ 时，价值模型更接近学习完整的 Monte Carlo 回报，减少长序列中奖励信号指数衰减造成的偏差；Actor 使用 $\lambda_{\text{policy}} < 1$ ，策略模型使用较小或自适应的 λ ，以降低优势估计方差并加快策略收敛。

因此 $\lambda_{\text{critic}} \neq \lambda_{\text{policy}}$ ，这就是“Decoupled GAE”，即解耦的广义优势估计。

改进三：Length-Adaptive GAE

这是 VAPO 最有代表性的改进。

假设固定 $\lambda = 0.95$ ，距离最终奖励 100 个词元的位置，其奖励传播系数为 $0.95^{100} \approx 0.006$ ，也就是说，最终奖励传回前面词元时，信号已经几乎消失。

但是，如果把 λ 固定得非常接近 1，对较短回答又可能产生较高方差。

所以短回答和长回答不适合使用完全相同的 λ 。

VAPO 根据回答长度 l 设置 $\lambda_{\text{policy}} = 1 - \frac{1}{\alpha l}$ ，其中 l 是当前回答长度； α 是控制偏差与方差平衡的超参数。

论文实验设置 $\alpha = 0.05$ ，例如，当 $l=100$ 得到 $\lambda_{\text{policy}} = 1 - \frac{1}{0.05 \times 100} = 0.8$ ；
 当 $l=500$ 得到 $\lambda_{\text{policy}} = 1 - \frac{1}{0.05 \times 500} = 0.96$ ；当 $l=1000$ 得到
 $\lambda_{\text{policy}} = 1 - \frac{1}{0.05 \times 1000} = 0.98$
 因此：
 回答较短时，使用较小的 λ ；
 回答较长时，使用更接近 1 的 λ ；
 长回答中的最终奖励能够传播到更前面的词元。

改进四：Positive Example LM Loss

在困难推理问题中，正确回答可能非常稀少。

假设同一道题生成 16 条回答，只有一条正确。普通策略梯度虽然会提高这条正确回答的概率，但 VAPO 认为还应进一步充分利用这个珍贵样本。

因此，VAPO 对正确回答额外加入语言模型负对数似然损失：

$$\mathcal{L}_{\text{NLL}}(\theta) = - \sum_{o_i \in \mathcal{T}} \frac{1}{|o_i|} \sum_{o_i \in \mathcal{T}} \sum_{t=1}^{|o_i|} \log \pi_{\theta}(o_{i,t} | s_{i,t})$$

其中 $\mathcal{T}$ 表示当前批次中所有正确回答组成的集合。最终策略损失为：

$$\mathcal{L}(\theta) = \mathcal{L}_{\text{PPO}}(\theta) + \mu \mathcal{L}_{\text{NLL}}(\theta)$$

论文中采用 $\mu = 0.1$

相当于对在线采样得到的正确推理轨迹进行额外的自模仿学习。

改进五：Group Sampling

VAPO 不把全部生成预算分配给大量不同的问题，而是对同一问题重复采样多次。

论文中的基础 PPO 配置近似为 8192 个问题 $\times$ 1 条回答

VAPO 改为 512 个问题 $\times$ 16 条回答

总回答数仍然是 $512 \times 16 = 8192$

但后一种方式能够让同一道题同时产生正确回答；错误回答；不同的推理路径。从而提供更丰富的对比信号。需要注意，VAPO 的 Group Sampling 与 DAPO 的 Dynamic Sampling 并不完全相同：前者强调对同一提示重复生成，后者还特别过滤全对或全错的零方差回答组。

VAPO 论文使用 Qwen2.5-32B 基础模型进行实验，并报告在其特定训练和评测设置下，AIME 2024 的 avg@32 达到 60.4；论文中的 DAPO 对照结果为 50。作者还报告 VAPO 在约 5000 个梯度更新步骤内达到该结果，并在多次独立训练中保持稳定。