

GMPO: 几何平均策略优化

导论

GMPO 的一次训练过程可以概括为:

1. 旧策略对同一道题生成多条回答
2. 验证器计算每条回答的奖励
3. 计算组内相对优势 $\hat{A}_i$
4. 计算每个词元的新旧策略概率比 $\rho_{i,t}$
5. 根据优势符号对每个词元进行裁剪
6. 对裁剪后的词元贡献取几何平均
7. 反向传播并更新当前策略

GMPO 不需要额外的 Critic, 其优势计算方式与 GRPO 基本一致。

GRPO 存在的问题

对于第 i 条回答中的第 t 个词元, 定义重要性采样概率比:

$$\rho_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t} | q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} | q, o_{i,<t})}$$

忽略裁剪时, GRPO 对第 i 条回答的目标为 $\mathcal{J}_{i,\text{GRPO}} = \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \rho_{i,t}(\theta) \hat{A}_i$, 这实际上是各词元重要性加权奖励的**算术平均**。

如果一条回答包含三个词元, 概率比分别为 $\rho_{i,1}=1.0, \rho_{i,2}=1.1, \rho_{i,3}=10$, 并且 $\hat{A}_i=1$, 那么 GRPO 的回答贡献为 $\mathcal{J}_{i,\text{GRPO}} = \frac{1.0 + 1.1 + 10}{3}$


得到 $\mathcal{J}_{i,\text{GRPO}} \approx 4.033$, 虽然前两个词元的概率比都接近 1, 但第三个词元的概率比是 10, 于是整个平均值被这个极端词元显著拉高。

这会让该词元产生非常大的梯度权重, 造成较激进的策略更新。GMPO 论文将这种极端重要性采样比视为 GRPO 不稳定性的一个主要来源。

GMPO 不再计算算术平均 $\frac{x_1 + x_2 + \dots + x_T}{T}$, 而是计算几何平均 $(x_1 x_2 \dots x_T)^{\frac{1}{T}}$

对于刚才的三个数 1.0, 1.1, 10, 其几何平均为 $(1.0 \times 1.1 \times 10)^{\frac{1}{3}}$

即 $11^{\frac{1}{3}} \approx 2.224$, 对比可得算术平均 ≈ 4.033 ; 几何平均 ≈ 2.224 , 因此, 极端值 10 对几何平均的影响小于对算术平均的影响。GMPO 利用这一性质来抑制异常词元的重要性采样比。(<https://arxiv.org/pdf/2507.20673v2>)



暂时忽略裁剪，GMPO 的目标函数为：

$$\mathcal{J}_{\text{GMPO}}^*(\theta) = \frac{1}{G} \sum_{i=1}^G \left(\prod_{t=1}^{|o_i|} |\rho_{i,t}(\theta) \hat{A}_i| \right)^{\frac{1}{|o_i|}} \text{sgn}(\hat{A}_i)$$

其中 $\text{sgn}(\hat{A}_i)$ 表示优势的符号。符号函数满足 $\text{sgn}(\hat{A}_i) = \begin{cases} 1, & \hat{A}_i > 0, \\ -1, & \hat{A}_i < 0. \end{cases}$

需要绝对值和符号函数，是因为几何平均通常要求参与乘积的数为非负数，但优势可能为负。先对绝对值取几何平均，再通过 $\text{sgn}(\hat{A}_i)$ 恢复正确的优化方向。

由于同一条回答中的所有词元共享同一个优势 $\hat{A}_i$ ，所以 $\left(\prod_{t=1}^{|o_i|} |\rho_{i,t} \hat{A}_i| \right)^{\frac{1}{|o_i|}}$ ，可以拆成 $\left(\prod_{t=1}^{|o_i|} \rho_{i,t} \right)^{\frac{1}{|o_i|}} \left(\prod_{t=1}^{|o_i|} |\hat{A}_i| \right)^{\frac{1}{|o_i|}}$ ，因为共有 $|o_i|$ 个相同的 $|\hat{A}_i|$ ，所以 $\left(\prod_{t=1}^{|o_i|} |\hat{A}_i| \right)^{\frac{1}{|o_i|}} = |\hat{A}_i|$ ，再利用 $|\hat{A}_i| \text{sgn}(\hat{A}_i) = \hat{A}_i$ ，得到 $\mathcal{J}_{i,\text{GMPO}}^* = s_i(\theta) \hat{A}_i$ ，其中 $s_i(\theta) = \left(\prod_{t=1}^{|o_i|} \rho_{i,t}(\theta) \right)^{\frac{1}{|o_i|}}$ ，也可以写成数值更稳定的对数形式 $s_i(\theta) = \exp\left(\frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \log \rho_{i,t}(\theta)\right)$

所以，在不考虑裁剪时，GMPO 对一条回答使用的是所有词元概率比的几何平均。

完整 GMPO 不会先计算序列几何平均，再对整个序列统一裁剪。它首先对**每个词元**进行 PPO 式裁剪，然后对裁剪结果取几何平均：

$$\mathcal{J}_{\text{GMPO}}(\theta) = \frac{1}{G} \sum_{i=1}^G \left\{ \prod_{t=1}^{|o_i|} \left[\min[\rho_{i,t}(\theta) \hat{A}_i, \text{clip}(\rho_{i,t}(\theta), \epsilon_{\text{low}}, \epsilon_{\text{high}}) \hat{A}_i] \right] \right\}^{\frac{1}{|o_i|}} \text{sgn}(\hat{A}_i)$$

论文强调 GMPO 使用**词元级裁剪**，因为序列级裁剪一旦触发，可能使整条回答的所有词元都失去梯度；词元级裁剪只抑制异常位置，不会丢弃整条回答。

GMPO 的梯度为什么更稳定？

忽略裁剪，GRPO 对第 i 条回答的梯度为：

$$\nabla_{\theta} \mathcal{J}_{i,\text{GRPO}}^* = \frac{\hat{A}_i}{|o_i|} \sum_{t=1}^{|o_i|} \rho_{i,t}(\theta) \nabla_{\theta} \log \pi_{\theta}(o_{i,t} | q, o_{i,<t})$$

可以看到，第 t 个词元的梯度权重是 $\rho_{i,t}(\theta) \hat{A}_i$ ，因此，如果某个词元出现 $\rho_{i,t} = 100$ ，这个词元的梯度就可能被放大很多。

GMPO 的梯度为：

$$\nabla_{\theta} \mathcal{J}_{i,\text{GMPO}}^* = \frac{s_i(\theta) \hat{A}_i}{|o_i|} \sum_{t=1}^{|o_i|} \nabla_{\theta} \log \pi_{\theta}(o_{i,t} | q, o_{i,<t})$$

其中 $s_i(\theta) = \left(\prod_{k=1}^{|o_i|} \rho_{i,k}(\theta) \right)^{\frac{1}{|o_i|}}$ ，因此，同一条回答中的所有词元共享同一个几何

平均权重 $s_i(\theta) \hat{A}_i$

对比：

GRPO：每个词元由自己的 $\rho_{i,t}$ 加权；

GMPO：每个词元由整条回答的几何平均 s_i 加权

例如三个概率比为[1, 1, 100]

GRPO 的三个权重为[1, 1, 100]

GMPO 的共享权重为 $s_i = (1 \times 1 \times 100)^{\frac{1}{3}} \approx 4.642$

所以极端词元不再以 100 倍权重单独支配参数更新。论文的理论分析正是基于这种梯度权重差异。

为什么 GMPO 可以使用更宽的裁剪范围？

传统 GRPO 常使用类似[0.8,1.2] 或 DAPO 的[0.8,1.28]，GMPO 论文使用对数空间的对称范围[-0.4,0.4]，对应概率比空间为 $[e^{-0.4}, e^{0.4}]$ ，近似为[0.670,1.492]，这个范围明显比 [0.8,1.2] 更宽。

之所以能够放宽，是因为几何平均本身已经抑制了单个异常词元的影响，所以可以给策略更大的探索空间，而不至于像 GRPO 那样容易出现极端梯度。论文实验发现，GMPO 在较宽裁剪范围下仍保持了更稳定的重要性采样比。

需要注意，实际实现通常在**对数概率空间**中完成裁剪和几何平均，避免大量小概率直接相乘产生数值下溢。

GMPO 的局限性

1. 几何平均可能掩盖局部差异。

例如：[2, 1, 0.5]，其几何平均为 $(2 \times 1 \times 0.5)^{\frac{1}{3}} = 1$ ，从整体看似乎没有变化，但实际上第一个词元概率翻倍，第三个词元概率减半。

2. 同一回答中的所有词元仍共享回答级优势 $\hat{A}_i$

因此 GMPO 没有直接解决词元级信用分配问题。

3. 第三，几何平均对非常小的值较敏感。若某个未被正确处理的词元贡献接近 0，乘积可能显著下降，所以实际实现必须配合裁剪、掩码和对数空间计算。

4. 第四，GMPO 目前的收益主要来自论文报告的特定数学与多模态推理配置，不能保证在所有模型、数据和奖励设计中都优于 GRPO。

论文报告 GMPO-7B 在五个数学推理基准上的平均 Pass@1 相对应 GRPO 提高 4.1 个百分点，在 Geometry3K 多模态推理任务上提高 1.4 个百分点。

总结

GMPO 的思想是不让某一个极端词元的概率比单独支配梯度，而是用整条回答所有词元概率比的几何平均，为各词元提供更平衡的更新权重。