

DeepSeek LLM 67B


导论

DeepSeek LLM 是 DeepSeek 在早期代码模型之后推出的通用大语言模型系列，其目标从代码生成进一步扩展到自然语言理解、知识问答、数学、代码和复杂推理等通用任务。与 DeepSeek-Coder 主要依赖代码数据不同，DeepSeek LLM 从约 2T Token 的中英文通用语料上进行预训练，并系统研究了模型规模、数据规模、学习率和 Batch Size 之间的 Scaling Law。

本文重点介绍其中规模更大的 DeepSeek LLM 67B。该模型仍采用 Decoder-only Transformer，但规模显著扩大：共有 95 个 Decoder Block，隐藏维度达到 8192，包含 64 个 Query Head，每个 Head 维度为 128，SwiGLU 中间维度为 22016，模型词表空间为 102400，上下文长度为 4096。与前面的 DeepSeek-Coder-1.3B 最大的结构区别在于，67B 不再使用传统 MHA，而采用 Grouped-Query Attention (GQA)，将 64 个 Query Head 与仅 8 个 Key/Value Head 组合，从而显著降低 KV Cache 和推理带宽开销。

因此，DeepSeek LLM 67B 可以看作 DeepSeek 从早期稠密代码模型向大规模通用语言模型演进的重要阶段。它还没有后来 DeepSeek-V2/V3 的 MLA 和 MoE，但已经开始在注意力结构、模型深度、训练规模以及后训练方法上进行更系统的优化。

论文链接: <https://arxiv.org/pdf/2401.02954>



参数	DeepSeek LLM 67B
模型结构	Decoder-only Transformer
Transformer 层数	95
隐藏维度	8192
Query Head 数量	64
KV Head 数量	8
单个 Head 维度	128
GQA 分组比例	8 : 1
FFN 中间维度	22016
模型词表大小	102400
普通 Token 数	100000
特殊 Token 数	15
最大上下文	4096 Token
位置编码	RoPE
RoPE 基频	10000
归一化	RMSNorm
FFN	SwiGLU
激活函数	SiLU
注意力	GQA
权重共享	Embedding 与 LM Head 不共享
权重精度	BF16
KV Cache	支持
预训练数据量	2T Token

其中 $d_{\text{head}} = \frac{8192}{64} = 128$ ，而每个 KV Head 对应 $\frac{64}{8} = 8$ 个 Query Head。


首先可以直接比较：

结构	DeepSeek-Coder-1.3B	DeepSeek LLM 67B
参数量	约 1.346B	约 67.425B
Decoder 层	24	95
隐藏维度	2048	8192
Query Heads	16	64
KV Heads	16	8
注意力	MHA	GQA
Head Dim	128	128
FFN	5504	22016
词表	32256	102400
上下文	16K	4K
主要定位	代码	通用语言模型
SFT	Instruct	Chat
偏好优化	无	DPO
MoE	无	无
MLA	无	无

可以看到一个很有意思的现象：67B 虽然模型大了约 50 倍，但单个 Attention Head 的维度仍然保持 128。

它主要通过增加隐藏维度；增加 Head 数量；大幅增加网络深度；扩大 FFN；扩大词表来提升模型规模。

完整前向传播流程图：




模型真正最复杂的部分就是中间的 Decoder Block $\times 95$ ，所以接下来重点拆开它。

第 1 个 Decoder Block 输入 $H^{(l)} \in \mathbb{R}^{B \times T \times 8192}$

首先进入注意力子层 $U^{(l)} = H^{(l)} + \text{GQA}_l(\text{RMSNorm}_{l,1}(H^{(l)}))$

然后进入 SwiGLU 子层 $H^{(l+1)} = U^{(l)} + \text{FFN}_l(\text{RMSNorm}_{l,2}(U^{(l)}))$

流程为：



与 DeepSeek-Coder-1.3B 相比，这里的最大变化就是 MHA $\rightarrow$ GQA

RMSNorm

设一个 Token 的隐藏向量为 $x \in \mathbb{R}^{8192}$

计算均方根 $\text{RMS}(x) = \sqrt{\frac{1}{8192} \sum_{i=1}^{8192} x_i^2 + \epsilon}$ ，其中 $\epsilon = 10^{-6}$

最终 $\text{RMSNorm}(x) = g \odot \frac{x}{\text{RMS}(x)}$ ，其中 $g \in \mathbb{R}^{8192}$ 是可训练缩放参数。

于是 $H^{(l)} \rightarrow \bar{H}^{(l)}$ ，且 $\bar{H}^{(l)} \in \mathbb{R}^{B \times T \times 8192}$

官方论文明确说明 DeepSeek LLM 使用 **Pre-Norm + RMSNorm**。

GQA 的 Q、K、V 投影

Query 有 64 个 Head: $64 \times 128 = 8192$

因此 $Q = \bar{H}W_Q^T$ ，其中 $W_Q \in \mathbb{R}^{8192 \times 8192}$ ，得到 $Q \in \mathbb{R}^{B \times T \times 8192}$

拆 Head $Q \rightarrow \mathbb{R}^{B \times 64 \times T \times 128}$

模型只有 8 个 KV Head。因此 Key 的总维度只有 $8 \times 128 = 1024$

所以 $W_K \in \mathbb{R}^{1024 \times 8192}$ ，并得到 $K \in \mathbb{R}^{B \times 8 \times T \times 128}$

Value 同理 $W_V \in \mathbb{R}^{1024 \times 8192}$ ， $V \in \mathbb{R}^{B \times 8 \times T \times 128}$


因此

Query:
64 Heads $\times$ 128

Key:
8 Heads $\times$ 128

Value:
8 Heads $\times$ 128

因为 $\frac{64}{8} = 8$ ，所以每一个 KV Head 服务 8 个 Query Head。可以表示为：



数学上，可以定义 Query Head h 所属 KV 组 $g(h) = \left\lfloor \frac{h}{8} \right\rfloor$ ，其中 $h = 0, 1, \dots, 63$ 于是 $g(h) \in \{0, 1, \dots, 7\}$ ，第 h 个 Query Head 使用 $K_{g(h)}$ 和 $V_{g(h)}$ 计算注意力。

为什么不让所有 Query 都有自己的 K/V

如果采用传统 MHA: Q = 64 Heads; K = 64 Heads; V = 64 Heads

那么 $K, V \in \mathbb{R}^{B \times 64 \times T \times 128}$ ，而 GQA: Q = 64 Heads; K = 8 Heads; V = 8 Heads

因此 K/V 数量降低为原来的 $\frac{8}{64} = \frac{1}{8}$ ，即 KV Cache 理论主体大小降低约 8 倍。

但 Query 仍然有 64 个 Head，因此模型能够保持较强的多头查询表达能力。

这是 DeepSeek 官方给 67B 使用 GQA 的原因之一：降低大型模型的推理成本。

GQA 的完整过程

对于第 h 个 Query Head: $Q_h \in \mathbb{R}^{B \times T \times 128}$

它对应的 KV Head: $g = g(h)$ ，于是 $K_g, V_g \in \mathbb{R}^{B \times T \times 128}$

应用 RoPE: $\tilde{Q}_h = \text{RoPE}(Q_h)$; $\tilde{K}_g = \text{RoPE}(K_g)$ ，注意力分数 $S_h = \frac{\tilde{Q}_h \tilde{K}_g^T}{\sqrt{128}} + M$ ，

其中 M 是因果掩码。

然后 $A_h = \text{Softmax}(S_h)$ ，最后 $O_h = A_h V_g$ ，因此第 h 个 Query Head 与其所属 KV Group 共享同一份 Key 和 Value。

完整 GQA 可以写为 $O_h = \text{Softmax}\left(\frac{\tilde{Q}_h \tilde{K}_{g(h)}^T}{\sqrt{128}} + M\right) V_{g(h)}$

RoPE

DeepSeek LLM 67B 使用 $\text{rope_theta} = 10000$ 且 $\text{rope_scaling} = \text{null}$

也就是说它没有像 DeepSeek-Coder-1.3B 那样使用 $\text{factor}=4$ 的线性位置缩放。公开配置给出的最大位置数为 4096。

对于 Head Dim: $d_h = 128$ ，可以组成 64 组二维坐标。

第 r 组频率 $\omega_r = 10000^{-2r/128}$ ；位置 p 的旋转角 $\theta_{p,r} = p\omega_r$

查询和键执行 $\begin{bmatrix} q'_{2r} \\ q'_{2r+1} \end{bmatrix} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} \begin{bmatrix} q_{2r} \\ q_{2r+1} \end{bmatrix}$ ，Key 同理，Value 不进行 RoPE。

GQA 输出

得到 64 个 Query Head 的输出 $O_1, O_2, \dots, O_{64}$

每个 $O_h \in \mathbb{R}^{B \times T \times 128}$ ；拼接 $O = \text{Concat}(O_1, \dots, O_{64})$ ，所以 $O \in \mathbb{R}^{B \times T \times 8192}$

再执行 $Y_{\text{attn}} = O W_O^T$ ，其中 $W_O \in \mathbb{R}^{8192 \times 8192}$

第一次残差连接

得到 $U^{(l)} = H^{(l)} + Y_{\text{attn}}$ ，或者 $U^{(l)} = H^{(l)} + \text{GQA}(\text{RMSNorm}(H^{(l)}))$

两边维度都是 $B \times T \times 8192$ ，因此可以直接逐元素相加。

SwiGLU FFN

注意力计算完成以后，再执行第二次 RMSNorm: $\bar{U}^{(l)} = \text{RMSNorm}(U^{(l)})$ ，然后进入 SwiGLU。

DeepSeek LLM 67B 的中间维度 $d_{\text{ff}} = 22016$ ，因此有三组矩阵。

1. Gate Projection

$$W_{\text{gate}} \in \mathbb{R}^{22016 \times 8192}; G = \bar{U} W_{\text{gate}}^T$$

2. Up Projection

$$W_{\text{up}} \in \mathbb{R}^{22016 \times 8192}; A = \bar{U} W_{\text{up}}^T$$

3. SiLU

$$\text{SiLU}(x) = \frac{x}{1 + e^{-x}}, \text{ 然后 } C = \text{SiLU}(G) \odot A$$

4. Down Projection

$$W_{\text{down}} \in \mathbb{R}^{8192 \times 22016} \text{ 得到 } Y_{\text{FFN}} = C W_{\text{down}}^T, \text{ 最终 } Y_{\text{FFN}} \in \mathbb{R}^{B \times T \times 8192}$$

官方论文明确采用 RMSNorm、SwiGLU 和 RoPE，并说明 FFN 的设计大体延续 LLaMA。

第二次残差连接

$$\text{得到 } H^{(l+1)} = U^{(l)} + Y_{\text{FFN}}$$

所以一个完整 DeepSeek LLM 67B Decoder Block 可以压缩为两个公式：

$$U^{(l)} = H^{(l)} + \text{GQA}_l(\text{RMSNorm}_{l,1}(H^{(l)}))$$

$$H^{(l+1)} = U^{(l)} + \text{SwiGLU}_l(\text{RMSNorm}_{l,2}(U^{(l)}))$$

整个模型连续执行 95 次，即 $H^{(0)} \rightarrow H^{(1)} \rightarrow \dots \rightarrow H^{(95)}$

为什么是 95 层？

这是 DeepSeek LLM 一个比较特别的设计。

官方论文明确指出，67B 使用 95 层，并且与很多采用 GQA 后扩大 FFN 宽度的模型不同，DeepSeek 选择把更多参数投入到网络深度，而不是单纯继续扩大 FFN 宽度。

DeepSeek 还指出，这样的层数设计有利于 Pipeline Parallelism 的划分。这是 DeepSeek LLM 67B 的一个比较值得注意的宏观架构选择。

Final RMSNorm

$$\text{最后得到 } H^{(95)} \in \mathbb{R}^{B \times T \times 8192}, \text{ 执行 } H^{\text{final}} = \text{RMSNorm}(H^{(95)})$$

$$\text{维度不变 } H^{\text{final}} \in \mathbb{R}^{B \times T \times 8192}$$

LM Head

输出头 $W_{lm} \in \mathbb{R}^{102400 \times 8192}$ ，执行 $Z = H^{final} W_{lm}^T$ ，于是 $Z \in \mathbb{R}^{B \times T \times 102400}$

其中每个位置都有 102400 个 Logit。

配置 `tie\word\_embeddings=false`，故 Token Embedding 与 LM Head 不共享参数。

Tokenizer 也发生了很大的变化

DeepSeek LLM 官方论文明确说明其使用 **Byte-level BPE**。

普通词表包含 100000 个 Token。随后增加 15 个特殊 Token。所以真实 tokenizer vocabulary 为 100015，但为了 GPU 计算效率；张量维度对齐；为未来特殊 Token 预留空间，模型配置最终使用 102400 作为词表维度。

因此 Tokenizer 实际已有 Token 100015 到模型 Embedding 空间 102400，并不代表其中 102400 个位置全部都是普通文本 Token。

GQA 对 KV Cache 的影响

这是这个模型特别值得学习的地方。

如果采用普通 MHA: $K, V \in \mathbb{R}^{B \times 64 \times T \times 128}$

但实际 GQA: $K, V \in \mathbb{R}^{B \times 8 \times T \times 128}$ ，单层 KV Cache 的元素数量 $2 \times 8 \times T \times 128$

假设 $T=4096$ ，BF16 每个元素 2 Byte。

那么 95 层 KV Cache 约为 $2 \times 95 \times 8 \times 4096 \times 128 \times 2$ Byte，约 1.48 GiB

如果同样使用 64 个 KV Head 的 MHA，则大约需要 11.88 GiB

因此仅从理论 KV 张量本身计算：GQA 将 67B 模型的 KV Cache 由约 11.9 GiB 降到了约 1.5 GiB。这就是 GQA 在大模型推理中的巨大价值。

DeepSeek LLM 不仅发布 Base，还发布 Chat 模型。

也就是说 Base $\rightarrow$ SFT $\rightarrow$ DPO $\rightarrow$ Chat，官方论文报告，其 SFT 数据超过 1 百万条，并进一步使用 DPO 改善对话偏好。这也是相对于前面 DeepSeek-Coder 更完整的一套通用聊天模型训练流程。

DeepSeek LLM 67B 在约 2T Token 上预训练。

官方超参数包括 AdamW; $\beta_1 = 0.9$; $\beta_2 = 0.95$; *weight decay* = 0.1; 峰值学习率 3.2×10^{-4} ; 2000 Warmup Steps; Multi-step Learning Rate Scheduler; Gradient Clipping 1.0; BF16 前向/反向; FP32 梯度累积。

训练系统则使用 DeepSeek 自研的：HAI-LLM

包括 Data Parallelism; Tensor Parallelism; Sequence Parallelism; Pipeline Parallelism; ZeRO-1; FlashAttention; 通信与计算重叠。