

Qwen3.6-27B

导论

Qwen3.6-27B 可以看作 Qwen 系列从“传统 Transformer 大语言模型”进一步走向“原生多模态、高效长上下文与 Agent 模型”的重要代表。早期的 Qwen2.5、Qwen3 等模型，其语言主干仍然主要建立在标准 Transformer Attention 体系之上；尤其是 Qwen3，虽然已经在 Thinking / Non-Thinking 双模式、推理能力、工具调用和 Agent 能力方面进行了大幅增强，但其 Dense 模型整体仍然采用传统 Attention Decoder。

到了 Qwen3.5/3.6 这一代，一个非常明显的变化是模型不再简单地把大量 Full Self-Attention 层连续堆叠，而是采用 Hybrid Decoder。以 Qwen3.6-27B 为例，整个语言主干包含 64 层，并按照 $3 \times \text{Gated DeltaNet} + 1 \times \text{Gated Attention}$ 的比例组成一个四层周期，再重复 16 次。也就是说，64 层中只有 16 层使用完整的 Gated Attention，而另外 48 层使用 Gated DeltaNet。这样做的目的是在保留 Full Attention 全局信息交互能力的同时，利用递归状态结构降低长序列处理过程中对传统 KV Cache 和两两 Token Attention 的依赖。

其中最值得关注的创新模块就是 Gated DeltaNet。传统 Self-Attention 需要让当前 Token 与大量历史 Token 进行显式相关性计算，而 Gated DeltaNet 更接近一种可学习的递归记忆系统：它通过 Q、K、V 与门控信号不断读取、修正和更新一个固定尺寸的状态矩阵。因此，模型不必在每一层都维护不断随序列长度增长的完整注意力历史。这也是为什么理解 Qwen3.6 时，不能再简单地把它描述成“64 层 Transformer”，而应该把它理解为 线性递归记忆与全局 Attention 相结合的混合序列模型。

第二个非常重要的变化，是 语言与视觉进一步走向统一。Qwen3.6-27B 官方模型类型已经不是单纯的 Causal Language Model，而是 Causal Language Model with Vision Encoder。图片和视频首先经过 Vision Encoder，被转换成与文本隐藏状态维度一致的视觉 Token，随后与文本 Token 一起进入同一套 Hybrid Decoder。换句话说，视觉信息并不是模型外部额外挂接的辅助特征，而是被转换成统一 Token 序列参与后续推理，这体现了这一代 Qwen 更明显的 原生 Vision-Language Foundation 思路。

在 Attention 本身的设计上，Qwen3.6 也没有简单采用传统 Multi-Head Attention。Full Attention 层采用 Gated Attention + GQA：24 个 Query Heads 共享 4 个 KV Heads，同时在 Attention 输出端加入 Gate；此外，位置编码只作用于 Head 中的一部分维度，即 Partial Rotary Position Encoding。这样一来，模型同时从 KV Cache、Attention 参数化以及位置编码三个角度控制长上下文计算成本。Qwen3.6-27B 原生支持 262,144 Token 上下文，并可进一步扩展到约 101 万 Token。

除此之外，这一代模型还进一步强化了 局部建模与全局建模的结合。Gated DeltaNet 在进入递归状态更新之前加入了短程的因果卷积，用局部卷积提取相邻 Token 的局部模式，再由 Delta Rule 负责更长距离的状态记忆；每隔几层又插入一次 Full Attention，用于重新建立全局 Token 之间的直接联系。因此它不是单纯用一种模块替换 Attention，而是在“局部卷积、递归状态、全局 Attention”三种信息传播方式之间进行组合。

不过，如果只比较 Qwen3.6-27B 与 Qwen3.5-27B，官方给出的两者架构配置

基本相同。Qwen3.6 本身更强调的是在已有架构基础上进一步提高真实应用能力，特别是 Agentic Coding 和 Thinking Preservation：前者加强了前端开发、代码仓库级推理和复杂 Coding Agent 任务，后者允许模型保留历史消息中的 reasoning context，从而减少多轮复杂任务中反复重建推理过程的开销。

Qwen3.6-27B 不是传统意义上连续堆叠 64 个标准 Transformer Self-Attention Block 的模型。它采用的结构是

$$16 \times [3 \times (\text{Gated DeltaNet} \rightarrow \text{FFN}) + 1 \times (\text{Gated Attention} \rightarrow \text{FFN})]$$

也就是说，每 4 层形成一个周期


第 1 层: Gated DeltaNet + SwiGLU
 $\downarrow$
 第 2 层: Gated DeltaNet + SwiGLU
 $\downarrow$
 第 3 层: Gated DeltaNet + SwiGLU
 $\downarrow$
 第 4 层: Gated Full Attention + SwiGLU

然后这个四层单元重复 16 次 $4 \times 16 = 64$

因此 $L_{\text{GDN}} = 48$ ； $L_{\text{Attention}} = 16$ ； $L = 48 + 16 = 64$

语言模型参数如下：

总参数规模	27B
隐藏维度	$d = 5120$
Decoder 层数	$L = 64$
词表维度	$V = 248320$
FFN 中间维度	$d_{\text{ff}} = 17408$
Gated DeltaNet 层	48
Full Attention 层	16
Full Attention Query Heads	$H_Q = 24$
Full Attention KV Heads	$H_{KV} = 4$
Attention Head Dimension	$d_h = 256$
RoPE Dimension	$d_{\text{rope}} = 64$
DeltaNet QK Heads	$H_{QK} = 16$
DeltaNet Value Heads	$H_V = 48$
DeltaNet Head Dimension	$d_k = d_v = 128$
DeltaNet Conv Kernel	$k = 4$
RMSNorm epsilon	$\epsilon = 10^{-6}$
原生上下文	262144
官方扩展能力	1010000 Token



假设用户输入文本为

请用一句话解释什么是递归。

经过 Chat Template 后得到完整模型输入字符串。

再经过 Tokenizer: $X_{\text{text}} \xrightarrow{\text{Tokenizer}} (x_1, x_2, \dots, x_T)$

其中每一个 Token ID 满足 $x_t \in \{0, 1, \dots, 248319\}$

批量输入 $X_{\text{id}} \in \mathbb{N}^{B \times T}$, 其中 $B = \text{Batch Size}$; $T = \text{Sequence Length}$

Token Embedding

Embedding 矩阵 $E \in \mathbb{R}^{248320 \times 5120}$, 第 t 个 Token 为 $h_t^{(0)} = E_{x_t}$, 其中 $h_t^{(0)} \in \mathbb{R}^{5120}$

全部 Token 为 $H^{(0)} = E[X_{\text{id}}]$, 得到 $H^{(0)} \in \mathbb{R}^{B \times T \times 5120}$, 之后的全部语言模型 Decoder Layer 都保持最后一个维度为 $d=5120$

Qwen3.6-27B 自带 Vision Encoder。

视觉编码器主要参数包括 $L_v = 27$; $d_v = 1152$; $H_v = 16$; $d_{\text{ff},v} = 4304$

视觉 Patch: $p_t = 2$; $p_h = p_w = 16$, 因此源码中的视觉 Patch Embedding 使用三维卷积 $2 \times 16 \times 16$, 并映射为 1152

Vision Encoder 中一个 Block 可以写为:

$$U_v^{(l)} = X_v^{(l)} + \text{VisionAttention}_l(\text{LayerNorm}_{l,1}(X_v^{(l)}))$$

然后

$$X_v^{(l+1)} = U_v^{(l)} + \text{VisionMLP}_l(\text{LayerNorm}_{l,2}(U_v^{(l)}))$$

视觉 MLP 的尺寸 $1152 \rightarrow 4304 \rightarrow 1152$


Vision Patch Merger

视觉 Encoder 的输出维度为 1152, 语言模型维度却是 5120, 因此必须进行 Patch Merge。空间合并尺寸为 $s=2$, 即每 $2 \times 2 = 4$ 个视觉 Patch 合并。所以合并后的输入宽度 $4 \times 1152 = 4608$, 随后通过视觉 Merger 投影到 5120

因此最终视觉 Token 与文字 Token 一样 $v_i \in \mathbb{R}^{5120}$

真正送进语言模型的是统一 Token 序列

例如最终形成 $H^{(0)} = [h_1, h_2, \dots, v_1, v_2, \dots, v_m, \dots, h_T]$ ，其中无论 h_i 还是 v_i ，都满足 $h_i, v_i \in \mathbb{R}^{5120}$ ，之后视觉 Token 与文本 Token 不再进入两套独立语言模型，而是一起送入相同的 64 层 Hybrid Decoder。



第 l 层输入 $H^{(l)} \in \mathbb{R}^{B \times T \times 5120}$

第一次 RMSNorm: $\bar{H}^{(l)} = \text{RMSNorm}_{l,1}(H^{(l)})$

Token Mixer: $M^{(l)} = F_l(\bar{H}^{(l)})$

其中 $F_l = \text{GatedDeltaNet}_l$ 或者 $F_l = \text{GatedAttention}_l$

第一次残差 $U^{(l)} = H^{(l)} + M^{(l)}$

第二次 RMSNorm: $\bar{U}^{(l)} = \text{RMSNorm}_{l,2}(U^{(l)})$

FFN: $Y_{\text{ffn}}^{(l)} = \text{SwiGLU}_l(\bar{U}^{(l)})$

第二次残差: $H^{(l+1)} = U^{(l)} + Y_{\text{ffn}}^{(l)}$

源码中的普通 RMSNorm 不是直接学习缩放参数 g ，而使用以 1 为中心的参数化。先计算 $r(x) = \sqrt{\frac{1}{d} \sum_{i=1}^d x_i^2 + \epsilon}$ ，然后 $\text{RMSNorm}(x) = (1 + w) \odot \frac{x}{r(x)}$ ，其中 $w \in \mathbb{R}^d$ 并初始化 $w=0$ ，因此初始化时 $1+w=1$ ，同时 $\epsilon = 10^{-6}$

第一种 Token Mixer: Gated DeltaNet

这是 Qwen3.6 与传统 LLaMA 最大的区别之一。

传统 Attention 是 QK^T ，然后形成 $T \times T$ 注意力矩阵。而 Gated DeltaNet 不保存完整历史 Attention Matrix，而维护一个递归状态 S_t ，可以粗略理解为：



源码在 Prefill 时使用 Chunk Gated Delta Rule，在单 Token Decode 时使用 Recurrent Gated Delta Rule。

Gated DeltaNet 的 QKV 投影

DeltaNet 参数 $H_{QK}=16$ ； $H_V=48$ ； $d_k=d_v=128$

因此 Query 总维度 $d_Q=16 \times 128 = 2048$ ；Key 为 $d_K=16 \times 128 = 2048$ ，Value 为 $d_V=48 \times 128 = 6144$ ，联合 $d_{QKV}=2048 + 2048 + 6144 = 10240$

输入 $X \in \mathbb{R}^{B \times T \times 5120}$ ，联合投影 $M_{QKV} = XW_{QKV}^T$ ，其中 $W_{QKV} \in \mathbb{R}^{10240 \times 5120}$ ，因此 $M_{QKV} \in \mathbb{R}^{B \times T \times 10240}$

QKV 后先经过 Depthwise Causal Conv1D。

首先 $M' = \text{SiLU}(\text{CausalConv1D}(M_{QKV}))$ ，卷积核 $k=4$ ，通道 $C=10240$ ，并且 $G=C=10240$ ，所以它是 Depthwise Conv1D，即每个通道分别进行短程因果卷积。源码中 groups 就设置为整个 QKV 通道维度。

拆分 Q、K、V

卷积后 $M' \rightarrow Q, K, V$ ，尺寸分别是：

$$Q \in \mathbb{R}^{B \times T \times 16 \times 128}；K \in \mathbb{R}^{B \times T \times 16 \times 128}；V \in \mathbb{R}^{B \times T \times 48 \times 128}$$

因为实际 Delta Rule 使用 48 个 Value / State Heads，所以 Q 和 K 会重复 $r = \frac{48}{16} = 3$ ，得到 $Q' \in \mathbb{R}^{B \times T \times 48 \times 128}$ ； $K' \in \mathbb{R}^{B \times T \times 48 \times 128}$

Gated DeltaNet 还有三条门控支路

除了 QKV，还计算 $Z = XW_Z^T$ ，其中 $W_Z \in \mathbb{R}^{6144 \times 5120}$ ，所以 $Z \in \mathbb{R}^{B \times T \times 6144}$ ，还计算 $a = XW_a^T$ ； $b = XW_b^T$ ，其中 $W_a, W_b \in \mathbb{R}^{48 \times 5120}$ ，所以 $a, b \in \mathbb{R}^{B \times T \times 48}$

DeltaNet 的递归状态

每一个 State Head 保存 $S_{t,h} \in \mathbb{R}^{128 \times 128}$

因此整层状态 $S_t \in \mathbb{R}^{B \times 48 \times 128 \times 128}$ ，这与传统 KV Cache 最大的区别是这个状态本身不会因为上下文从 1K 变成 100K 就增加一个新的 Token 维度。

Q、K 归一化

首先 $\hat{q}_t = \frac{q_t}{\sqrt{\sum_{i=1}^{128} q_{t,i}^2 + \epsilon}}$ ， $\hat{k}_t = \frac{k_t}{\sqrt{\sum_{i=1}^{128} k_{t,i}^2 + \epsilon}}$ ，然后 Query 进行缩放 $\bar{q}_t = \frac{\hat{q}_t}{\sqrt{128}}$

状态衰减与更新门

Beta Gate: $\beta_t = \sigma(b_t)$ ，其中 $\sigma(x) = \frac{1}{1 + \exp(-x)}$

状态衰减参数 $g_t = -\exp(A_{\log})\text{Softplus}(a_t + d_t)$

进一步 $\lambda_t = \exp(g_t)$

由于 g_t 通常为负，因此 λ_t 控制旧记忆保留比例。

Delta Rule

旧状态先衰减 $S_t^- = \lambda_t S_{t-1}$

利用当前 Key 从旧记忆读取 $m_t = \hat{k}_t^T S_t^-$

比较真实 Value 与旧记忆预测： $\Delta_t = \beta_t (v_t - m_t)$

写入新的信息 $S_t = S_t^- + \hat{k}_t \Delta_t^T$


最后 Query 读取更新后的记忆： $o_t = \bar{q}_t^T S_t$

Gated RMSNorm

得到 o_t ，以后，先 RMSNorm： $r_t = w \odot \frac{o_t}{\sqrt{\frac{1}{128} \sum_{i=1}^{128} o_{t,i}^2 + \epsilon}}$

然后与 Z 门相乘： $y_t = r_t \odot \text{SiLU}(z_t)$ ，48 个头拼接： $48 \times 128 = 6144$

再经过 $W_O^{\text{GDN}} \in \mathbb{R}^{5120 \times 6144}$ ，得到 $Y_{\text{GDN}} \in \mathbb{R}^{B \times T \times 5120}$



第二种 Token Mixer: Gated Full Attention

每 4 层中的第四层仍然是真正的 Full Causal Attention。

其参数 $H_Q = 24$; $H_{KV} = 4$; $d_h = 256$, 所以属于 GQA , 即 Grouped-Query Attention。官方模型卡和源码都给出了 24 个 Query Heads、4 个 KV Heads。

Q Projection

普通 Query 总维度 $24 \times 256 = 6144$ ，但源码的 Q Projection 同时生成 Query 和 Output Gate。

因此 $[Q, G] = XW_Q^T$ ，其中 $W_Q \in \mathbb{R}^{12288 \times 5120}$ ，因为 $12288 = 2 \times 24 \times 256$

拆分后 $Q \in \mathbb{R}^{B \times T \times 24 \times 256}$ ； $G \in \mathbb{R}^{B \times T \times 24 \times 256}$

K 和 V Projection

Key: $K = XW_K^T$; Value: $V = XW_V^T$ ，因为只有 $H_{KV} = 4$ ，所以 $4 \times 256 = 1024$ ，因此 $W_K, W_V \in \mathbb{R}^{1024 \times 5120}$ ，得到 $K, V \in \mathbb{R}^{B \times T \times 4 \times 256}$

QK Norm

Attention 之前先 $Q' = \text{RMSNorm}_Q(Q)$ ； $K' = \text{RMSNorm}_K(K)$

这里 RMSNorm 的维度为每一个 Head: $d_h = 256$

而不是完整的隐藏状态 $d=5120$

Partial MRoPE

一个 Attention Head: $h=256$

配置 $f_{\text{rope}} = 0.25$ ，因此旋转维度 $d_{\text{rope}} = 256 \times 0.25 = 64$

所以 $Q' = [Q_{\text{rope}}, Q_{\text{pass}}]$ ，其中 $Q_{\text{rope}} \in \mathbb{R}^{64}$ ； $Q_{\text{pass}} \in \mathbb{R}^{192}$ ，Key 同理。

只有前 64 维进入 MRoPE。

GQA 的 KV 共享

有 $H_Q = 24$ ，但 $H_{KV} = 4$ ，因此每一个 KV Head 服务 $n_g = \frac{24}{4} = 6$ 个 Query Heads。

所以在计算 Attention 时 $K \rightarrow K_{\text{repeat}}$ ； $V \rightarrow V_{\text{repeat}}$ ，最后 $K_{\text{repeat}}, V_{\text{repeat}} \in \mathbb{R}^{B \times 24 \times T \times 256}$

缩放点积注意力

第 h 个 Query Head: $S_h = \frac{Q_h K_h^T}{\sqrt{256}}$ ，因为 $\sqrt{256} = 16$ ，所以也可以写 $S_h = \frac{Q_h K_h^T}{16}$

因果 Mask: $M_{ij} = 0 \quad j \leq i$ 以及 $M_{ij} = -\infty \quad j > i$ ，加入 Mask: $S_h' = S_h + M$

Softmax: $A_{h,i,j} = \frac{\exp(S_{h,i,j}')}{\sum_{r=1}^T \exp(S_{h,i,r'})}$ ，然后 $O_h = A_h V_h$

Attention Output Gate

24 个头拼接 $24 \times 256 = 6144$


因此 $O \in \mathbb{R}^{B \times T \times 6144}$ ，然后利用 Q Projection 同时生成的 Gate: $\tilde{O} = O \odot \sigma(G)$

最后 $Y_{\text{attn}} = \tilde{O} W_O^T$ ，其中 $W_O \in \mathbb{R}^{5120 \times 6144}$ ，所以 $Y_{\text{attn}} \in \mathbb{R}^{B \times T \times 5120}$

SwiGLU FFN

无论是 Gated DeltaNet Layer 还是 Full Attention Layer，后面的 FFN 都相同。输

入 $X \in \mathbb{R}^{B \times T \times 5120}$, Gate Projection: $G = XW_g^T$; Up Projection: $U = XW_u^T$, 其中 $W_g, W_u \in \mathbb{R}^{17408 \times 5120}$, 因此 $G, U \in \mathbb{R}^{B \times T \times 17408}$, SiLU: $\text{SiLU}(x) = \frac{x}{1 + \exp(-x)}$
 门控乘法 $C = \text{SiLU}(G) \odot U$, Down Projection: $Y_{\text{ffn}} = CW_d^T$, 其中 $W_d \in \mathbb{R}^{5120 \times 17408}$, 因此 $Y_{\text{ffn}} \in \mathbb{R}^{B \times T \times 5120}$



Qwen3.6-27B 最重要的结构可以直接写成：

$$H^{(0)} \xrightarrow{\text{GDN}} H^{(1)} \xrightarrow{\text{GDN}} H^{(2)} \xrightarrow{\text{GDN}} H^{(3)} \xrightarrow{\text{GatedAttention}} H^{(4)}$$

第二组 $H^{(4)} \xrightarrow{\text{GDN}} H^{(5)} \xrightarrow{\text{GDN}} H^{(6)} \xrightarrow{\text{GDN}} H^{(7)} \xrightarrow{\text{GatedAttention}} H^{(8)}$ ，一直重复 16 次，最终 $H^{(64)} \in \mathbb{R}^{B \times T \times 5120}$ ，全部 64 层以后 $H^{\text{final}} = \text{RMSNorm}_{\text{final}}(H^{(64)})$ ，尺寸不变：
 $H^{\text{final}} \in \mathbb{R}^{B \times T \times 5120}$

LM Head

词表维度 $V = 248320$ ，LM Head: $W_{\text{lm}} \in \mathbb{R}^{248320 \times 5120}$ ，计算 $Z = H^{\text{final}} W_{\text{lm}}^T$ ，因此 $Z \in \mathbb{R}^{B \times T \times 248320}$

Logits

推理只需要最后一个位置 $z = Z_{:,T-1,:}$ ，因此 $z \in \mathbb{R}^{B \times 248320}$ ，温度 $\tilde{z}_i = \frac{z_i}{\tau}$ ，Softmax：

$$p_i = \frac{\exp(\tilde{z}_i)}{\sum_{j=1}^{248320} \exp(\tilde{z}_j)}，贪心 y_s = \arg\max_i p_i；随机采样 y_s \sim \text{Categorical}(p_1, p_2, \dots, p_{248320})，$$

然后 $X^{(s+1)} = [X^{(s)}, y_s]$